

AI Infra 行业深度：行业概述、市场现状及空间、产业链及相关公司深度梳理

作为支撑大模型全生命周期的核心脊梁，AI Infra 已成为全球科技大国与企业博弈的战略高地。它不仅承载着巨大的算力洪流，更是决定 AI 应用能否落地生根的关键土壤。面对这一万亿级赛道，国际巨头加速跑马圈地，不断加码全球 AI 基础设施的布局；而中国科技力量也不遑多让，阿里、腾讯、百度等厂商正全力推进全栈自研战略，旨在打破技术壁垒，构建自主可控的 AI 生态闭环。随着全球数字化进程的深化，AI 基础设施行业正处于爆发前夜，即将迎来新一轮的黄金增长期。

本报告旨在系统梳理 AI Infra 的全景图，我们将首先解读其核心内涵与必然性，接着分析市场现状与空间，继而深入产业链上下游，详细剖析硬件革新与软件进化的关键路径，并盘点国内外核心厂商的布局与能力。希望通过这份梳理，为理解 AI 时代的底层支撑力量提供清晰的框架。

目录

一、行业概述	1
二、行业现状及市场空间.....	4
三、产业链分析.....	7
四、AI Infra 硬件	11
五、AI Infra 软件	27
六、AI 基础设施厂商	40
七、参考研报	47

一、行业概述

1、AI Infra 概念

AI Infra (AI Infrastructure, AI 基础设施) 指的是专门为 AI 工作负载的设计、构建、管理和优化的底层硬件与软件系统。它的核心目标是高效、大规模地完成 AI 模型的训练和推理任务。如果将开发大模型比做是“造房子”，那 AI Infra 就是“工具箱”，包括构建、部署和维护人工智能系统所需的**硬件、软件和服务**的组合。一个完整的 AI 基础设施通常包含：

- 1) 算力层：GPU、TPU、AI ASIC、推理芯片等；
- 2) 存储层：高性能分布式存储、对象存储、NVM SSD；
- 3) 网络层：高带宽低延迟互连（InfiniBand、NVLink、RoCE）；

- 4) 软件与中间件层：分布式训练框架（PyTorch DDP、DeepSpeed、Horovod）、MLOps 工具链（Kubeflow、MLflow）；
- 5) 运维与管理层：Kubernetes 集群调度、资源监控、自动扩缩容。

图 1：AI infra 包含哪些核心环节



资料来源：Coting（技术博客），申万宏源研究

当前基础设施硬件层已经得到了充分的认知，包括算力芯片、服务器、交换机及网络设计以及存储等，AI 编译和计算架构主要由底层硬件层厂商开发，AI 训推框架玩家也已相对固定，包括 Pytorch、Tensorflow、vLLM 等，且常为开源。但再向上层，AI 应用大规模渗透所需要的 Infra 软件，价值仍未被完全发掘。

2、AI 基础设施和传统 IT 基础设施的区别

以 AI 大模型训练为例，在资源占用模式上与传统 IT 任务存在根本性差异：

- （1）**计算密集与高并发**：AI 训练依赖庞大的浮点运算量，例如 GPT-3 的训练计算需求高达数百 PetaFLOPs 天。这要求多 GPU 能够进行高带宽、低延迟的协同，这区别于传统 CPU 服务器以 IO 为主的任务特性。
- （2）**海量数据吞吐**：训练过程涉及 TB 至 PB 级数据集的加载，因此存储系统必须提供极高的 IOPS 和顺序吞吐能力，并支持高效的数据预取机制。

（3）调度复杂与弹性需求：AI 训练任务通常耗时较长（可持续数天乃至数周），一旦中断将造成严重损失。此外，分布式训练对 GPU、网络结构及节点位置高度敏感，必须采用针对性的调度策略。

（4）异构计算与优化需求：AI 硬件不再是单一架构（GPU、TPU、FPGA、ASIC 并存）。软件栈需要适配不同硬件的特性，最大化性能利用率。

总结来看，AI 任务计算密集、数据吞吐巨大、调度复杂且依赖异构硬件，传统 IT 基础设施无法满足性能和稳定性要求。

	传统IT基础设施	AI基础设施
计算单元	CPU为主	GPU/TPU/AI ASIC为主，支持CPU协同
计算模式	多任务并发、IO密集	浮点运算密集、长时间批量计算
网络需求	千兆以太网足够	高速互连（InfiniBand、NVLink）低延迟通信
存储模式	磁盘阵列、低频访问	高IOPS、高吞吐分布式存储
调度策略	通用任务调度	大规模分布式训练优化调度
容错与恢复	短任务容错容易	长任务断点恢复关键
软件栈	通用应用和数据库	深度学习框架、分布式训练工具链、MLOps平台

3、AI Infra 应具备六大核心能力

异构算力调度能力：针对当前算力多元化的发展趋势，AI Infra 通过算力调度技术和平台，实现对异构算力芯片的深度适配和统一纳管，能够根据不同业务场景进行高效的算力选型、编排和分发。

智能应用支撑能力：基于云原生调度编排、微服务框架和高性能应用服务，AI Infra 针对智能应用提供开发、部署、运维的全生命周期管理，具备支撑复杂多业务场景智能应用的能力。

全链路数据管理能力：基于湖仓一体对数据采集、清洗和预处理流程的支撑能力，以及向量数据库对向量数据检索的支撑能力，AI Infra 具备针对 AI 模型开发和部署的全链路数据管理能力。

训推一体化和加速能力：AI 训推平台针对 AI 模型训练/微调和推理框架的支撑能力，以及对于 AI 训推流程的加速能力，成为 AI Infra 在 AI 模型开发层面的核心技术平台。


安全体系构建能力：基于隐私计算和联邦学习的核心安全能力，AI Infra 融合基础云安全能力，构建适配 AI 模型和应用的智算安全体系，保障 AI 模型和用户敏感数据的安全。

全流程场景化服务能力：针对智能体（Agent）在各行业领域加速应用的趋势，AI Infra 具备支撑智能体开发与应用全流程的场景化服务能力，为 MCP 等智能体相关技术提供了稳定的运行环境。

二、行业现状及市场空间

1、AI 基础设施正式步入稳定与革新并存的应用期

伴随着移动互联网和大数据技术的普及以及近年来 AI 能力的爆发式提升，AI 技术在各行各业得到广泛应用，对高性能计算、大规模存储、高效算法库等基础设施需求不断增长。AI 基础设施正式步入稳定与革新并存的应用期。



雏形期（2010 年以前）：该时期，AI 基础设施处于探索与发现阶段，人工智能领域处于低谷时期，AI 项目多数处于实验性阶段。因此，AI 基础设施生态系统在该阶段尚不清晰，专业的人才与资源缺失，主导 AI 项目的玩家主要集中于科研机构。

完善期（2010-2019 年）：随着机器学习和深度学习等一系列 AI 技术的关键突破，AI 基础设施行业开始迈入爆发与增长阶段。一方面，AI 技术的进步，互联网发展带来的大数据时代以及 AI 开源社区的建立，均为 AI 技术的发展与传播提供了有力的支撑条件，进而对底层基础设施的技术发展产生积极性影响。另一方面，AI 基础设施的商业模式逐渐清晰，头部互联网企业与部分 AI 创业企业逐步认知到 AI 的潜力，纷纷加入该赛道，加大了对 AI 基础设施的资源投入。


应用期（2020 年-至今）：2020 年后，各行各业开始大规模应用深度学习技术实施创新应用，加快产业转型和升级。随着 AI 与各场景的深度融合与发展，计算能力、分布式系统和大规模数据处理能力等

新能力反向助推了 AI 基础设施的创新与优化。此外，随着 5G 与 AI 的融合发展趋势，运营商也在该阶段进入赛道，开始积极布局包含 AI 基础设施新基建、平台能力新基建与云网新基建等。

2、AI 焦点转向“推理”驱动，国内外厂商加码 AI 基建投入


AI 产业焦点从“训练”转向“推理”，带来 AI Infra 需求增量。在过去两年，AI 产业聚焦于大模型的训练阶段，各大厂商着力于扩大大模型的参数规模，增加预训练的数据量。这是产业的“投入期”。目前，产业焦点已经逐步转向大模型的推理阶段。根据量子位援引谷歌数据，2025 年 10 月谷歌月处理 Tokens 量达到 1,300 万亿，是 2025 年 5 月数据的 2 倍多。根据未尽研究援引字节跳动数据，2025 年 9 月字节跳动月处理 Tokens 量达到 900 万亿，是 2025 年 3 月的 2 倍多。根据虎嗅网报道，黄仁勋在 GTC2025 大会上指出，AI 正在从生成式向代理式（Agentic AI）和物理式（Physical AI）升级，预计 2028 年全球 AI 数据中心基础设施建设支出将达到 1 万亿美元。能够认为主流大模型的能力已经达到“可用性”门槛，可以满足大多数场景的商业化需求。随着大模型在商业场景的落地，推理对 Tokens 消耗量的需求快速增长，亦对 AI 基础设施建设（AI Infrastructure）提出了更高的要求。

图表 1. 谷歌月处理 Tokens 量



资料来源：Google，量子位，中银证券


图表 2. 字节跳动月处理 Tokens 量



资料来源：字节跳动，未尽研究，中银证券


国内和海外云厂商积极提高资本开支以应对 AI Infra 扩张趋势。根据 ifind 数据，阿里巴巴 2022~2024 年资本开支合计达到 1,206 亿元；根据华尔街见闻报道，阿里预期未来三年资本开支合计达到 3,800 亿元。根据 ifind 数据，腾讯 2022~2024 年资本开支合计达到 1,943 亿元；根据华尔街见闻援引高盛数据，腾讯预期未来三年（2025~2027 年）资本开支合计达到 3,500 亿元。根据 Bloomberg 数据，2025 年北美四大云厂商 Amazon、Meta、Microsoft、Google 资本开支合计将达到 3,496 亿美元，YoY+53%；预计 2026/2027 年该资本开支数据将进一步增长至 4,243/4,632 亿美元。

图表 3. 阿里巴巴资本开支变化趋势




资料来源：ifind，华尔街见闻，中银证券

图表 4. 腾讯资本开支变化趋势



资料来源：ifind，华尔街见闻，高盛，中银证券

图表 5. 北美四大云厂商 Amazon、Meta、Microsoft、Google 资本开支变化趋势




资料来源：Bloomberg，中银证券

注：Amazon、Meta、Google 财年和自然年数据一致，Microsoft 财年和自然年数据不一致，这里取自然年数据。

3、全球 AI 基础设施市场规模预测

据 Business Research Insights 数据，全球 AI 基础设施市场规模在 2024 年为 279.4 亿美元，预计将在 2025 年上升至 329.8 亿美元，预计到 2033 年将达到 12403 亿美元，在 2025-2033 期间的复合年增长率为 18.01%。

图：全球AI基础设施市场规模



资料来源：Business research Onsights，国信证券经济研究所整理


三、产业链分析

AI 基础设施行业产业链上游为各类硬件原材料供应商、数据集供应商以及网络服务等；中游包括服务于各行业场景企业用户与消费级终端用户的云计算厂商、AI 原生厂商、硬件系统厂商以及运营商；下游各行业应用中，互联网等数字原生行业为应用进展先行者。



1、产业链上游：AI 芯片国产替代进程加速

AI 芯片作为 AI 产业链的基础层，直接决定了 AI 系统的计算能力与效率，是上游的核心领域。随着 2025 年美国对于 AI 芯片限制的进一步加强与一系列国产芯片支持的政策推出，AI 芯片国产替代进程加速，中国芯片自给率稳步提升，但仍亟待提高。



中美科技博弈持续演绎的背景下，作为核心基础层的 AI 芯片政策战略地位高，积极导向的政策颁布与有力的资金支持，助推芯片国产化率提升。长期看，一方面，中国企业将加大对芯片制造技术的研发投入，努力提升自身的制造能力和技术水平，减少对海外代工厂的依赖；另一方面，国内的芯片制造设备和材料供应商也将获得更多的发展机会，推动整个芯片制造产业链的国产化进程。根据 Techsights 数据，中国芯片自给率呈现稳定增长态势，从 2015 年的 16% 增长至 2023 年的 23%。此外，在 2020 年国务院颁布的《新时期促进集成电路产业和软件产业高质量发展的若干政策》中，明确提出 2025 年芯片自给率目标为 70%，国产芯片未来增长空间可观。

然而，高端芯片的技术壁垒急需攻破，英伟达等国外厂商在高端芯片技术上仍保持领先地位。将国产主流 AI 芯片与英伟达产品对比，可发现部分运算性能仍存在较大差距，例如 H100 芯片采用的 4nm 工艺国内尚未实现。国产芯片在运算性能、市场份额与生态建设仍需逐步提升。

2、产业链中游：AI 基础设施厂商类型与商业模式

(1) 厂商类型

AI 基础设施厂商指为 AI 技术开发、训练和部署等提供底层硬件、软件以及平台的企业，目前主流 AI 基础设施厂商可分为云厂商、AI 原生、硬件系统厂商以及运营商。云计算、AI 原生、硬件系统与运营商四类主要厂商塑造 AI 基础设施市场格局，提供全栈服务能力的云计算、提供垂直一体化解决方案的


AI 原生、提供高效硬件支持的硬件系统厂商与整合网络资源的运营商共同推动 AI 基础设施行业生态完善与技术演进。

云计算厂商：头部云厂商具备完善的全栈服务能力、庞大的开发者生态与客户基础以及丰富的 C 端产品经验与技术。以阿里云、腾讯云为例的该类厂商在技术创新、算法研发与平台支持层面起到关键作用。

AI 原生厂商：较早开始布局 AI 技术与产品，具备深厚的 AI 算法沉淀。以商汤科技为例的该类厂商在端到端的垂直一体化解决方案以及长尾场景下的定制化能力具备优势。

硬件系统厂商：专注于开发和提供以 GPU、服务器等处理 AI 任务的硬件设备以提升 AI 任务处理效率。以华为等为例的该类厂商具备领先的硬件设计能力，在为各类 AI 任务提供高效计算能力层面至关重要。

运营商：覆盖广泛的网络资源与政企相关渠道，提供符合最高标准的安全合规性产品。以中国移动等为例的该类厂商通过与 AI 产业链其他玩家合作共同服务企业客户，提供“AI+DICT”解决方案。



(2) 商业模式

AI 基础设施商业模式根据资产所有权与控制权可分为重资产、轻资产以及混合模式三种主要模式。其中混合模式凭借“核心自控+外部弹性扩展”的灵活性优势，符合大多数企业和场景的现实选择，愈发成为明显的未来趋势。

重资产：该模式的核心为规模化的硬件投入和基础设施建设，为企业客户提供稳定且高性能的算力资源。然后完全自建算力中心对多数企业而言经济负担大且具备较高的技术迭代风险和运维难度。

轻资产：该模式的核心在于通过软件、平台等自身不持有大量物理资产，更聚焦于软件的敏捷开发和生态构建。然而对于企业用户的数据控制和管理能力相对较弱且对厂商具备较高的依赖性。

混合模式：核心在于结合前两种模式的优势，既拥有部分核心资产以保证关键服务的可控性，又通过合作、租赁等轻量合作模式保持其灵活性，加强了企业用户对复杂场景需求的适应性。


AI 基础设施厂商商业模式				
商业模式	主要覆盖厂商	主要覆盖客群	优势	挑战
重资产： 企业用户从硬件到软件系统均由企业用户自建	- 头部云计算厂商 - 运营商 - 算力硬件厂商	- 互联网大厂 - 科研机构与高校 ...	- 用户自主掌控 - 深度定制化 - 安全隐私防护能力 - 高性能、大规模的算力输出	- 初始投资成本高 - 技术迭代风险 - 能耗与运维成本高
轻资产： 企业用户通过与第三方合作建设 AI 基础设施，或租赁、购买第三方提供的 AI 算力服务	- Maas 供应商 ...	- 中小型创业企业 - 数字化转型传统企业 ...	- 更快的部署速度 - 灵活性高 - 运维负担小	- 不适用于算力需求庞大的企业用户 - 定制化程度受限 - 迁移与兼容挑战 - 底层硬件依赖性
 混合模式： 企业用户灵活利用云服务或合作方资源进行补充和扩展	- 云计算厂商 - AI 原生厂商 ...	- 中小微商业体 ...	可在安全合规、成本控制与定制化需求中取得最佳平衡点	- 成本控制的精确计算和预测 - 不同环境下的数据安全 - 对企业用户的技术能力与资源正能力要求较高

3、产业链下游：应用情况

在面向行业的具体落地过程中，AI 基础设施结合不同行业的业务特性，提供适配的部署模式、资源配置和技术能力，满足从算力管理到 AI 应用落地的全流程需求。AI 基础设施基于行业性 AI 业务和应用需求视角，具备云边一体的算力池化、调度与管理能力，云原生的应用开发、运维，全链路的湖仓一体、向量数据检索能力，一体化的训推框架、训推加速能力，以及体系化的基础云安全、模型安全和数据安全。在交通出行行业，AI 基础设施通过云边端协同架构，实现车路协同、多模态感知等关键能力，推动智能出行与交通管理革新；在工业制造领域，依托实时数据处理与分布式算力，优化生产全流程，实现柔性制造与供应链智能决策；教育行业则借助训练加速、向量数据库等技术，构建个性化学习与智能教学新范式；泛互联网与 IT 服务依赖其高并发支撑与敏捷扩展能力，保障业务快速迭代；具身智能通过多模态融合与云边端协同，赋予机器人精准感知与实时决策能力；而医疗行业则基于高性能算力与隐私计算，推动 AI 诊疗、精准药物研发等场景落地。

应用行业考量因素：在渗透率较高的行业中，安全隐私性成为了诸多用户的首要考虑条件，尤其在金融与医疗等监管严格的行业，大量的数据（包括交易数据、病患信息等）需得到妥善的保护，因此该类行

业用户对于 AI 基础设施的风险实时监测能力有较大需求。而互联网与制造业由于场景复杂，对于高性能与可扩展性有着迫切需求。此外，不同的解决方案部署方式以及 AI 应用成熟度也对各行业优先考量条件产生一定影响。




四、AI Infra 硬件

1、计算效率和互联带宽是 AI 芯片升级的重要方向

GPU/ASIC 的计算效率和 Switch 的互联带宽是两大重要升级方向。根据英伟达在 GTC2025 大会上披露的产品规划，英伟达将在 2025/2026/2027/2028 年推出 Blackwell Ultra 8S HBM3e/Rubin8S HBM4/Rubin Ultra 16S HBM4e/FeymanNext-Gen HBM 解决方案。其中 Blackwell Ultra NVL72 算力达到 1.1EF Dense FP4 Inference/0.36EF FP8 Training，整体是 GB200 NVL72 的 1.5 倍；Vera Rubin NVL144 算力达到 3.6EFP4 Inference/1.2EF FP8 Training，整体是 GB300 NVL72 的 3.3 倍；Rubin Ultra NVL576 算力达到 15EF FP4 Inference/5EF FP8 Training，整体是 GB300 NVL72 的 14 倍。同时 6th Gen NVSwitch 和 7th Gen NVSwitch 速率也将达到 3,600GB/s，是 5th Gen NVSwitch 速率的 2 倍。随着链式推理（Chain of Thought）生成的 Tokens 快速增长，为了提高结果的准确性，英伟达积极推动 GPU 计算效率和 Switch 互联带宽的升级。

图表 6. 英伟达 Blackwell NVL72 解决方案



资料来源: Nvidia GTC 2025, 中银证券

图表 7. 英伟达 Vera Rubin NVL144 解决方案



资料来源: Nvidia GTC 2025, 中银证券

根据财联社 2025 年 9 月 10 日报道, 英伟达宣布推出专为长上下文工作负载设计的专用 GPU Rubin CPX, 对应的 AI 服务器 Vera Rubin NVL144CPX 共集成 36 颗 VeraCPU、144 颗 Rubin GPU 和 144 颗 Rubin CPX GPU。英伟达计划以两种形式提供 Rubin CPX, 第一种是和 Vera Rubin 装配在同一个 Compute Tray 上, 第二种是独立以整个机架的 CPX 解决方案提供给客户, 数量正好匹配 Rubin 机架。英伟达分析称, 推理过程包括上下文阶段和生成阶段, Rubin CPX 针对“数百万 tokens”级别的长上下文性能进行优化, 具备 30PFlops 的 NVFP4 算力和 128GB GDDR7 内存。Vera Rubin NVL144CPX 机架处理长上下文的性能相较于 GB300 NVL72 高出最多 6.5 倍。

图表 8. 英伟达 Rubin Ultra NVL576 解决方案



资料来源: Nvidia GTC 2025, 中银证券


图表 9. 英伟达 Vera Rubin NVL144 CPX 解决方案



资料来源: Nvidia, 中银证券

根据华尔街见闻和新浪财经报道, 在 2025 年第二次 GTC 大会上, 英伟达宣布 Hopper 芯片在其生命周期内共出货了 400 万颗, 预计 Blackwell 芯片出货量将达到 2,000 万颗, 预计 Rubin GPU 将在 2026 年 10 月量产。英伟达预计 Blackwell 和 Rubin 芯片将带来五个季度共计 5,000 亿美元的营收。

图表 10. 英伟达 AI GPU 产品规划路线图



资料来源: Nvidia GTC 2025, 中银证券

GPU/ASIC 厂商均在积极提高芯片算力效率。根据 IT 之家报道，AMD 在其 2025 年年度人工智能直播活动 Advancing AI 2025 上正式发布 MI350X 和 MI355X 的解决方案。根据 Bloomberg 信息，AMD 预计将在 2026 年推出 MI400 及其相关的“Helios”72GPU Rack 级解决方案，以应对英伟达的竞争。Amazon、Google、Microsoft、Meta、OpenAI 等云厂商亦在积极联合第三方设计公司推出自研 AI ASIC 以应对英伟达的竞争。根据半导体行业观察报道，谷歌在 Google Cloud Next25 大会上推出第七代张量处理单元（TPU）Ironwood，Ironwood 提供 256 颗芯片和 9,216 颗芯片两种配置，后者总算力达 42.5EFlops，单芯片峰值算力 4.614EFlops，功率效率是 Trillium 的 1.5 倍，每瓦性能翻倍，较首代 TPU 提升 30 倍。


ASIC 厂商或迎来第三方市场加速发展机遇。根据智东西 2025 年 10 月 24 日报道，谷歌宣布将向 Anthropic 供应 100 多万颗 TPU 芯片以及附加的谷歌云服务，交易价值数百亿美元。谷歌在声明中称，这是 Anthropic 迄今为止规模最大的 TPU 扩容计划。至此，Anthropic 已经和英伟达、谷歌、亚马逊三大芯片供应商达成合作。根据财联社 2025 年 11 月 25 日报道，Meta Platforms 正在考虑斥资数十亿美元采购谷歌 TPU 芯片，包括用于 Meta 的数据中心建设。

图表 12. 第三方 AI ASIC 解决方案

Semi Designer	Company	Type	Volume Ramp
Marvell / Alchip / Annapurna	Amazon AWS	AI Training Accelerator (5nm, 3nm)	CY25/CY26
Marvell	Google	ARM Server CPU	CY24
Marvell	Microsoft	AI Accelerator	CY26/CY27
Broadcom	Google	XPU (3nm)	CY25
Broadcom	Meta	XPU (3nm)	CY25
Broadcom	OpenAI	AI Inference Accelerator	CY26/CY27


资料来源: Bloomberg, 中银证券

图表 11. 英伟达和 AMD AI GPU 技术路线对比




资料来源: Company Filings, Bloomberg, 中银证券

图表 13. 谷歌 AI ASIC 性能对比



资料来源: Google, 半导体行业观察, 中银证券

图表 14. 谷歌 AI ASIC 能效对比




资料来源: Google, 半导体行业观察, 中银证券

机架级互连（**Rack Level Interconnects**）对 AI 性能有重要影响。根据 Nilesh Shah Zero Point Technologies&Rohit Mittal Auradine 《Optimizing Foundational Models: Hardware-Accelerated Memory Compression&Interconnects》数据分析，英伟达 B200 芯片性能是 H100 的 2 倍左右，而 GB200 NVL72Rack 性能是 DGX H100 Rack 的 30 倍左右。互联技术和纵向扩展网络（**Scale-up Networking**）是实现这种性能增益的关键因素。能够认为目前 AI Infra 升级方向不仅仅局限于 AI 芯片计算性能的提升，也对高带宽的互连技术提出了更高的要求。


综合来看，AI GPU 和 AI ASIC 的发展趋势都是向更大的 **diesize**、更高的计算效率、更大的互联带宽升级。这也对 PCB 及其相关材料提出了更高的要求。

图表 15. 机柜级解决方案对 AI 性能的影响



资料来源: Semianalysis, Industry Source, Nilesh Shah ZeroPoint Technologies & Rohit Mittal Auradine 《Optimizing Foundational Models: Hardware-Accelerated Memory Compression & Interconnects》，中银证券

图表 16. 英伟达 GB200 NVL72 Scale Up 级互连



资料来源: Semianalysis, Industry Source, Nilesh Shah ZeroPoint Technologies & Rohit Mittal Auradine 《Optimizing Foundational Models: Hardware-Accelerated Memory Compression & Interconnects》，中银证券

2、PCB 技术迭代对层数、线宽/线距、制造工艺提出了更高的要求

PCB（Printed Circuit Board，印制电路板）是为电子元器件提供机械支撑和电气连接的重要部件。随着行业对算力的极致追求，PCB 也在向着更多的层数、更小的线宽/线距、更高的制造工艺升级。

图表 17. 英特尔和 AMD 服务器 CPU 平台对 PCB 层数要求在 8~22 层

Intel	Platform	Purley		Whitley	Eagle Stream		Birch Stream
	CPU	Skylake	Cascade Lake	Ice lake	Sapphire Rapids	Emerald Rapids	Granite Rapids
	Nano Process	14 nm	14 nm+	10 nm	Intel 7	Intel 7	Intel 3
	PCIe Gen	PCIe 3.0	PCIe 3.0	PCIe 4.0	PCIe 5.0	PCIe 5.0	PCIe 5.0
	MP Time	2017 Q3	2019 Q3	2021 Q1	2023 H1	2023 H2	2024
	CCL Material	Mid Loss	Mid Loss	Low Loss	Very Low Loss	Very Low Loss	VLL/ Ultra Low Loss
	Layer count	8 to 12	8 to 12	12 to 16	16 to 20	16 to 20	18 to 22

AMD	Architecture	Zen	Zen2	Zen3	Zen4		Zen5
	CPU	Naples	Rome	Milan	Genoa	Bergamo	Turin
	Nano Process	14 nm (Global Foundries)	7 nm (TSMC)	7 nm (TSMC)	5 nm (TSMC)	5 nm (TSMC)	4 nm / 3 nm (TSMC)
	PCIe Gen	PCIe 3.0	PCIe 4.0	PCIe 4.0	PCIe 5.0	PCIe 5.0	PCIe 5.0
	MP Time	2017 Q3	2019 Q3	2020 Q4	2022 Q4	2023	2024
	CCL Material	Mid Loss	Low Loss	Low Loss	Very Low Loss	Very Low Loss	VLL/ Ultra Low Loss
	Layer count	8 to 12	12 to 16	12 to 16	16 to 20	16 to 20	18 to 22



资料来源：联茂电子 ITEQ，中银证券

AI 服务器的 PCB 层数相较于传统服务器有显著升级。相较于传统服务器，AI 服务器新增了 GPU 板组，而 GPU 对连接带宽要求更高，进而对 PCB 提出了更高的要求。同时交换机所承载的总带宽大小也是影响 PCB 性能的关键。传统服务器 CPU 平台对 PCB 层数要求通常在 8~22 层。根据联茂电子 ITEQ 数据，英特尔服务器 CPU 平台从 Skylake 升级到 Granite Rapids，其对应的 PCB 层数亦从 8~12 层升级到 18~22 层；AMD 服务器 CPU 平台从 Naples 升级到 Turin，其对应的 PCB 层数亦从 8~12 层升级到 18~22 层。根据爱彼电路数据，AI 服务器在面向云端 AI 计算等场景对 PCB 层数要求通常在 20~30 层。

图表 18. AI 服务器 PCB 和普通 PCB 的技术差异

应用场景	传统应用场景	AI 服务器场景
PCB 类别	普通 PCB	AI PCB
数据传输速率	≤10Gbps	≥112Gbps
功率密度	≤5W/cm2	20~30W/cm2
树脂	FR-4 环氧树脂	PTFE、罗杰斯 RO4350B 等
布线密度	100~200 点/平方英寸	500~800 点/平方英寸
布线层数	4~8 层	云端 AI 计算 20~30 层，边缘 AI 计算 8~12 层

资料来源：爱彼电路 iPCB，中银证券

根据福邦投顾数据，OAI-OAM（主板）承担搭载 GPU/ASIC 模组的功能，通常采用四阶及以上的 HDI，其 PCB 层数约为 20~30 层；OAI-UBB（主板）承担搭载 8 颗加速卡模组和连接网络拓扑的功能，通常采用多层板或一阶 HDI，其 PCB 层数约为 20~40 层及以上；OAI-HIB（副板）承担连接 GPU、CPU、DPU 等芯片的功能，通常采用多层板，其 PCB 层数约为 20~30 层；MotherBoard（副板）承担搭载 CPU、存储等元件的功能，通常采用多层板，其 PCB 层数约为 16~26 层。

图表 19. AI 服务器架构中各 PCB 类型及参数

PCB 类型	OAI-OAM (主板)	OAI-UBB (主板)	OAI-HIB (副板)	MotherBoard (副板)
层数	20~30L (NV: 16~22L)	20~40L+	20~30L	16~26L
CCL 等级	M7~M8	M7~M9 及以上	M7~M8	M6
制程工艺	四阶+HDI	多层板~一阶 HDI	多层板	多层板
功能	搭载 GPU/ASIC 模组	搭载 8 颗加速卡模组和连接网络拓扑	连接 GPU、CPU、DPU 等	搭载 CPU、存储等元件

资料来源：福邦投顾《PCB 产业 2025Q3 更新》，中银证券

英伟达 AI 服务器 PCB 层数持续增长。根据 Goldman Sachs Global Investment Researchs 数据，英伟达 AI 服务器从 Hopper 向 Balckwell 再向 Rubin 架构升级的过程中，其 OAM 保持五阶 HDI 的参数配置，UBB 从 24~26 层多层板向 34 层及以上多层板升级，Switch board 从 20~22 层多层板向六阶 HDI 升级，整体 PCB 层数呈现增长趋势。

图表 20. 英伟达 AI 服务器架构中各 PCB 参数

类型	DGX H100	DGX B200	GB200 NVL72	GB300 NVL72	VR200 NVL72	VR300 NVL72
OAM	5+N+5 HDI	5+N+5 HDI	5+N+5 HDI	5+N+5 HDI	5+N+5 HDI	5+N+5 HDI
UBB	24~26 layers RPCB	26~28 layers RPCB			34 layers RPCB	34+ layers RPCB
Mainboard	16~18 layers RPCB	16~20 layers RPCB				
Switch board	20~22 layers RPCB	22~24 layers RPCB	22 layers RPCB	22 layers RPCB	6+N+6 HDI	6+N+6 HDI
Others			4+N+4 HDI	4+N+4 HDI	4+N+4 HDI	4+N+4 HDI

资料来源：Goldman Sachs Global Investment Research《Rubin CCL upgrade is in-line with our expectation, where EMC should benefit the most》，中银证券

相较于标准 PCB，AI 服务器 PCB 线宽/线距更小。根据 Kingbrother《AI Server PCB:How to Choose the Right Manufacturer for Data Centers》数据，标准 PCB 的线宽/线距通常在 100μm 及以上，AI 服务器要求 PCB 的线宽/线距达到 40μm 及以下，需要以最小钻孔直径为 0.06mm 的激光钻孔为原型制作，通孔深宽比达到 25:1。

英伟达 RubinNVL576 或采用正交背板。根据 Serve The Home 报道，英伟达在 GTC2025 大会上首次展示其 Rubin NVL576 机架（名为 Kyber），其中计算节点和交换节点均采用竖插的方式，两者通过 Midplane 形成连接。根据福邦投顾数据，英伟达 RubinNVL576 后续有望采用正交背板（Midplane 的变形）的解决方案，预计是 78 层（3×26L）或 104 层（4×26L）的设计+铜浆烧结或 80+层的设计。

根据华为 IP 知识百科，正交架构是一种硬件结构。采用正交架构的设备背板无需走线，传输效率高，突破了传统背板架构的线路速率瓶颈。正交架构在可扩展性强、交换容量大的同时，保持了较小的信号衰减。

图表 21. 英伟达 Kyber Rubin NVL576 计算节点



资料来源：ServeTheHome，中银证券

图表 22. 英伟达 Kyber Rubin NVL576 交换节点






资料来源：ServeTheHome，中银证券

CoWoP 技术有望成为 AI 服务器 PCB 的升级方向。根据 SemiVision 数据，英伟达在其最新的芯片封装技术路线图中引入 CoWoP（Chip-on-Wafer-on-PCB，芯片-晶圆-印制电路板）概念。CoWoP 技术去除了传统的 ABF 载板，将芯片和硅中介层模块直接贴装在高精度印制电路板（通常是类载板，即 SLP，或 Substrate-LikePCB）上，形成从芯片级到系统板级的直接连接。

CoWoP 技术在降低信号传输损耗和热力学表现上有突出优势。CoWoP 技术在理论上拥有两个关键优势：1）更短的信号路径和更低的插入损耗。这对于 NVLink、PCIeGen6/7 和 HBM3/4 等高速互联至关重要。2）更高的热学和力学灵活性。因为芯片裸片直接贴装在 PCB 上，这有助于直接接触式冷板或液冷解决方案的实施，尤其适合于解决千瓦级人工智能 GPU 的散热问题。

CoWoP 技术对 PCB 的加工工艺提出了极高的要求。相较于现有的 CoWoS 和 CoPoS 技术，CoWoP 面临的技术挑战包括：1）印制电路板精度要求较高。系统板必须承担封装载板的高密度布线功能，其线宽/线距（L/S）必须达到 15~20μm 甚至更低，同时保持严格的平整度和尺寸稳定性。2）热机械可靠性要求较高。由于热循环和热膨胀系数（CTE）不匹配，直接贴装在 PCB 表面的裸芯片和硅中介层可能面临更高的焊点疲劳和翘曲风险。3）制造和良率挑战。传统 PCB 工厂需升级至接近先进封装标准，配备 ISO1~5 级洁净室，且组装后的良率必须极高，缺陷容忍度极低。

图表 23. CoWoP 和 CoWoS、CoPoS 技术对比


Item/ By SemiVision	CoWoS (Chip-on-Wafer-on-Substrate)	CoPoS (Chip-on-Panel-on-Substrate)	CoWoP (Chip-on-Wafer-on-PCB)
Structure			
Core Concept	Chips and silicon interposers are first integrated, then mounted on an ABF package substrate	Chip modules are packaged on square or panel-level substrates to improve production efficiency and reduce cost	Removes the ABF substrate; chip + interposer module is mounted directly on a high-precision SLP (Substrate-Like PCB)
Substrate Type	ABF substrate (Conventional packaging substrate)	Panel-level ABF substrate	High-precision SLP (Substrate-Like PCB)
Line / Space (L/S)	5-8 μm (CoWoS-L) 8-12 μm (CoWoS-R) 10-15 μm (CoWoS-S)	8-15 μm (Panel-level)	15-20 μm; <10 μm required for full-scale production
Advantages	Mature technology; supports HBM stacking and high-speed interconnects	Higher production efficiency, lower unit cost, suitable for large-area designs	Simplified structure, shortest signal path, better thermal design flexibility, theoretically lowest cost
Challenges	Substrate size limit; warpage risk	Panel-level equipment still in development; production line conversion required	Extremely high PCB precision, thermal-mechanical reliability issues, high yield risk
Mass Production Timeline	Already in mass production (H100/H200, AI/HPC)	Earliest RD Stage and plan to adopted by Nvidia	Earliest RD Stage and plan to adopted by Nvidia
Primary Applications	AI accelerators, high-performance computing (HPC), HBM stacked modules	Next-gen GPUs, AI servers, panel-level SoCs	Future Rubin Ultra or next-gen GPU/AI systems
Supply Chain Impact	Dependent on ABF substrates; TSMC CoWoS capacity is the key bottleneck	Drives panel-level packaging equipment and material upgrades	Requires high-precision PCB, ultra-thin copper foil, SLP, and mSAP as key enablers

资料来源：SemiVision 《From Glass Fiber to CCL：The Material Backbone Powering the New Era of CoWoP Packaging》，中银证券

SAP 和 mSAP 工艺可以实现较细的线宽/线距。类载板（SLP，Substrate-Like PCB）采用改良型半加成法（mSAP，Modified Semi-Additive Process），和传统减成蚀刻法相比，能够实现更细的线宽/线距。1）减成蚀刻法使用厚铜箔覆盖整个 PCB 表面，然后通过光刻胶、曝光和蚀刻等方式来制作线路。受蚀刻精度限制，该方法制作的 PCB 容易出现边缘粗糙问题。2）加成法是从 PCB 的绝缘基底开始，仅在需要的地方选择性镀铜或沉积铜。该方法制作的 PCB 可以实现极细的线路，但是生产成本较高，大规模生产效率较低。3）半加成法工艺（SAP/mSAP）从一层薄铜基底开始，确定图案，电镀线路，蚀刻掉多余的基底铜。该方法制作的 PCB 可以实现 10μm 级别的线宽/线距，且生产效率比全加成法更高。

SLP 工艺在模块中已有成熟应用，但是 CoWoP 技术实现大规模商业化节点仍待观察。目前 SLP 工艺已经在英伟达的 800G 和 1.6T 光模块中有成熟应用，光模块的小尺寸外形和可控的翘曲度使 SLP 工艺落地切实可行。考虑到 SLP 工艺在大型 GPU 板卡的应用上面临显著的翘曲风险，CoWoP 技术的成熟度还需要长期鉴定。从应用和时间线的角度来看，短期内 CoWoP 不太可能在人工智能加速器或图形处理器中实现大规模量产。虽然英伟达已经将 CoWoP 技术纳入 Rubin Ultra 平台的内部技术路线图中，以应对散热和翘曲问题，但是 Rubin Ultra 的大规模量产仍将依赖于 CoPoS 或其他成熟的过渡解决方案。CoPoS 采用和 CoWoS 类似的工艺，但是方形面板级封装所需设备可能要到 2026 年底才能准备就绪。

图表 24. PCB 走线工艺技术路线对比



资料来源：SemiVision 《From Glass Fiber to CCL: The Material Backbone Powering the New Era of CoWoP Packaging》，中银证券

AI 服务器 PCB 有望成为增长最快的子赛道。根据 PCB 网城 ISPCAIGPCA 援引 Prismark 数据，2024 年全球电子产业增长略高于长期平均水平，预估整体规模达到 2.54 万亿美元，同比增长 4.6%，这主要得益于服务器市场前所未有的强劲表现。由于 AI 服务器和相关的高速网络基础设施的需求攀升，2024 年用于服务器和存储的 PCB 和封装基板产值达到 109.16 亿美元，同比增长 33.1%。

图表 25. 全球 PCB 和封装基板产值（按应用划分）

时间	2020	2023	2024	2024 YoY(%)	2029E	2024~2029E CAGR(%)
服务器/存储	58.76	82.01	109.16	33.1	189.21	11.6
手机	141.50	130.85	138.86	6.1	173.29	4.5
汽车电子	64.57	91.53	91.95	0.5	112.05	4.0
计算机	112.10	93.91	94.29	0.4	106.79	2.5
消费电子	93.66	91.29	89.72	(1.7)	103.77	3.0
有线基础设施	49.58	59.55	61.53	3.3	79.90	5.4
航空航天	28.24	35.14	37.70	7.3	48.64	5.2
无线基础设施	27.71	31.18	31.77	1.9	39.73	4.6
其他计算机	38.01	36.61	36.49	(0.3)	39.59	1.6
工控	25.43	28.71	29.18	1.6	35.56	4.0
医疗	12.63	14.40	15.00	4.2	18.07	3.8
总计	652.18	695.17	735.65	5.8	946.61	5.2

资料来源：Prismark 2025.3, PCB 网城 ISPCAIGPCA，中银证券

18 层及以上多层板、HDI、封装基板有望成为增长前三快的 PCB 细分板块。根据深南电路 2025 年半年报援引 Prismark 数据，2024~2029 年 PCB 各细分产品预计将实现不同幅度的增长。2025 年 18 层及以上多层板产值预计将达到 34.31 亿美元，同比增长 41.7%；2024~2029 年 18 层及以上多层板产值预计将从 24.21 亿美元增长至 50.20 亿美元，CAGR 达到约 15.7%，是增长最快的 PCB 细分产品。2025 年封装基板产值预计将达到 135.66 亿美元，同比增长 7.6%；2024~2029 年封装基板产值预计将从 126.02 亿美元增长至 179.85 亿美元，CAGR 达到约 7.4%，是增长第二快的 PCB 细分产品。2025 年 HDI 板产值预计将达到 141.34 亿美元，同比增长 12.9%；2024~2029 年 HDI 板产值预计将从 125.18 亿美元增长至 170.37 亿美元，CAGR 达到约 6.4%，是增长第三快的 PCB 细分产品。

尽管 18 层及以上多层板市场规模绝对值在 PCB 细分产品中较小，但是 AI 服务器和数据中心网络对 18 层及以上多层板有较强需求，推动该领域市场规模增速较快。HDI 面向智能手机领域的需求增长并不大，但是面向 AI 服务器、数据中心网络、卫星通信、汽车电子的需求增长较快，亦驱动 HDI 市场规模增速较快。封装基板市场主要受益于 AI 高阶算力和存储需求的增长。


图表 26. 全球 PCB 和封装基板产值（按产品划分）

时间 类型	2024 产值（亿美元）	2025E 产值（亿美元）	YoY(%)	2029E 产值（亿美元）	2024~2029E CAGR(%)
纸基板/单面/双面板	79.47	82.81	4.2	91.49	2.9
4~6 层板	157.36	163.60	4.0	176.61	2.3
8~16 层板	98.37	104.32	6.1	121.92	4.4
18 层板及以上	24.21	34.31	41.7	50.20	15.7
HDI	125.18	141.34	12.9	170.37	6.4
封装基板	126.02	135.66	7.6	179.85	7.4
柔性板	125.04	129.24	3.4	156.17	4.5
合计	735.65	791.28	7.6	946.61	5.2

资料来源：Prismark，深南电路 2025 年半年度报告，中银证券

中国大陆深度参与全球 PCB 供应链，亦有望深度受益于 AI Infra 带动的 PCB 升级浪潮。根据 PCB 网城 ISPCAIGPCA 援引 Prismark 数据，2024 年全球 PCB 产值预计达到 735.65 亿美元，其中中国大陆 PCB 产值达到 412.13 亿美元，占全球比例约 56.0%；中国台湾 PCB 产值达到 86.69 亿美元，占全球比例约 11.8%；韩国 PCB 产值达到 66.31 亿美元，占全球比例约 9.0%；东南亚和亚洲其他地区 PCB 产值达到 60.81 亿美元，占全球比例约 8.3%。综合来看，中国大陆贡献全球 PCB 产值超过一半以上，预计中国大陆的 PCB 厂商亦会深度受益于 AI Infra 带动的 PCB 升级浪潮。

图表 27. 2024 年全球各地区 PCB 产值分布



资料来源：Prismark，PCB 网城 ISPCAIGPCA，中银证券

3、AI INFRA 聚焦低介电性能，PCB 材料全面升级


Dk 值和 Df 值是衡量 PCB 及相关材料电性能的关键指标。AI Infra 通常需要配备高阶 HDI 和 18 层及以上的高多层 PCB，通常这些 PCB 产品层数较多且单层厚度较薄、线宽线距较小。PCB 层数厚度较薄且线宽线距较小会导致信号干扰、电气性能损失和散热性能下降等问题。在这种情况下，系统设计更强调选用具有低介电常数（Low-Dk）和低介电损耗（Low-Df）的 PCB 材料，这对于降低信道损耗和保持信号完整性至关重要。因为高速传输损耗的来源主要是介质损耗和导体损耗，所以基板材料的特性直接决定了数据能否在极高频率下可靠传输。

印制电路板产业链较长，上游主要为原材料环节，包括电解铜箔、电子级玻纤布、合成树脂、木浆纸等；中游为制造环节，包括覆铜板、半固化片、油墨、刻蚀液、镀铜液等原材料以及印制电路板 PCB 的生产制造；下游为应用环节，包括通信设备、半导体、消费电子、航空航天、计算机等各个领域的应用。

（1）覆铜板

覆铜板（Copper Clad Laminate, CCL）是电子工业中用于制造印制电路板的核心基材，其基本结构由铜箔和粘合剂构成，其中基板采用高分子合成树脂和增强材料（玻纤布）复合而成，表面覆盖有导电性能的铜箔。覆铜板是电子元器件安装焊接的载体，通过层压工艺将导电层和绝缘基材结合，广泛应用于通讯设备、计算机、汽车电子等领域。

根据 Df 数值大小，覆铜板分为 M1-M9 等不同等级。**M8 及以上级别覆铜板更适合作为高性能芯片的基材。**根据思瀚产业研究院信息，英伟达 GB 系列超级芯片拥有高速数据传输能力，这对覆铜板的电性能有较高要求。覆铜板必须具有极低的介电常数和介电损耗因子才能保证 GB 系列芯片的高性能使用。目前在覆铜板行业内，松下电工的 MEGTRON 系列是高频高速覆铜板领域的分级标杆。松下电工历年发布的不同代 MEGTRON 高速覆铜板都会成为覆铜板行业内其他厂商发布基本技术等级处于同一水平的对标产品。松下电工最新的覆铜板产品是 MEGTRON8 和 MEGTRON8S，其介电损耗因子 Df 基本都小于 0.002。其中 MEGTRON8S 系列覆铜板在 28GHz 的条件下，传输损耗相比于 M7 减少了 30%，更适合作为高性能芯片的覆铜板硬件材料。



资料来源：松下，中银证券

台系占据高端覆铜板主要份额，陆系企业积极突破有望迎发展机遇。2024 年全球特殊覆铜板市场份额前三均为台系企业，分别为台光电子、联茂电子、台耀科技，市场份额约为 17.9%、17.5%和 13.1%。内

资企业生益科技、南亚新材、华正新材则积极突破，市场份额分别为 8.9%、2.0%和 1.1%。其中生益科技方面，根据《生益科技：2025 年半年度业绩说明会》，公司有全系列高速覆铜板，有不同等级高速覆铜板应用在不同传输速率的产品，可以满足服务器、数据中心、交换机、光模块等应用领域的需求，极低损耗产品已通过多家国内及海外终端客户的材料认证，并已有产品在批量供应。南亚新材方面，公司 M8 材料已获得国内多家重要终端认证，现已实现小订单批量生产，在高阶产品上如 AI 服务器、交换机、光模块等领域得到应用；M9 材料目前正在多家 PCB 客户测试中，积极向多家国内外终端推广认证。

图 38：2024 年全球特殊覆铜板市场份额



数据来源：联茂电子官网，东莞证券研究所

图 39：南亚新材 NYP5 产品参数



数据来源：南亚新材官网，东莞证券研究所

(2) 铜箔


HVLP4 需求有望快速释放，2026 年供需缺口或加大。覆铜板主要由铜箔、树脂、玻纤等原材料构成，成本占比分别为 42%、26%和 19%，材料选择将直接影响覆铜板的性能。铜箔方面，按粗糙度不同，电子电路铜箔主要分为高温高延伸铜箔（HTE）、低轮廓铜箔（LP）、翻转铜箔（RTF）、超低轮廓铜箔（VLP）、高频超低轮廓铜箔（HVLP）。由于铜箔在信号传输中存在趋肤效应，若铜箔粗糙度过高，需要传输的路径越长，将会造成数据损耗增加，影响信号完整性。因此高速电路一般需要搭载粗糙度（Rz）更低的铜箔，如 VLP、HVLP 铜箔。HVLP 按照粗糙度不同，又可以进一步分为 HVLP1-HVLP5，其中 HVLP4 的 Rz 仅为 0.5μm。随着 AI 算力硬件加大对更高等级覆铜板材料的应用，HVLP4 需求有望快速释放。据 SemiAnalysis 测算，2026Q1 全球 HVLP4 需求约为 592 吨/月，Q4 将进一步增长至 1,441 吨/月，而 2026Q1-Q4 供应分别为 600、600、950、950 吨/月，供需缺口较大，产品价格有望进一步走高。

表 7：电子电路铜箔分类及用途

产品	用途
高温高延伸铜箔（HTE）、低轮廓铜箔（LP）	主要应用于多种类常规覆铜板及线路板
翻转铜箔（RTF）	主要应用于高频高速板
超低轮廓铜箔（VLP）、高频超低轮廓铜箔（HVLP）	主要应用于高频高速、低损耗要求的电路板

数据来源：方邦股份2025半年报，东莞证券研究所

图 40：覆铜板成本结构



数据来源：中商产业研究院，东莞证券研究所

图 41：RTF 及 HVLP 的粗糙度



数据来源：三井金属官网，东莞证券研究所

图 42：2026 年全球 HVLP4 供需测算

	1Q26	2Q26	3Q26	4Q26
(tons/month)				
HVLP4 Supply				
Mitsui Kinzoku	300	300	400	400
Furukawa	50	50	75	75
Co-Tech	200	200	400	400
Others	50	50	75	75
Sum	600	600	950	950
HVLP4 Demand	592	1,266	1,446	1,441
Difference	8	-666	-496	-491

数据来源：SemiAnalysis，东莞证券研究所

日系企业把握高端产能，内资企业进一步突破。2021 年全球 VLP 及 HVLP 等高端铜箔销量约为 2.13 万吨，日系企业占据 1.29 万吨，占比高达 60.56%，其中日本三井金属以 7,000 吨销量排第一。国内企业德福科技拟收购的卢森堡电路以 5,500 吨销量排名第二，卢森堡电路在 2020 年和 2021 年分别研发出 HVLP4 及 HVLP5，技术实力领先，相关产品已经获得全球前四家覆铜板企业供货资质；此外公司本部 HVLP1 及 HVLP2 已经实现小批量供货，主要用于 AI 服务器、400G/800G 光模块领域，HVLP3 通过日系覆铜板企业认证，应用于国内算力板项目，下半年有望放量。此外，国内的铜冠铜箔 HVLP1-3 产品已向客户批量供货，HVLP4 铜箔处于下游客户认证过程中。

表 8：2021 年全球重点铜箔企业高频高速电路用铜箔销量

国家/地区	生产厂家	2021 年销量（吨/年）		
		RTF	VLP+HVLP	合计
日本	三井金属	8000	7000	15000
	福田金属	4200	1400	5600
	古河电工	7200	1800	9000
	JX 日矿金属	——	1500	1500
	日本电解	——	1200	1200
韩国	卢森堡电路	1250	5500	6750
	日进新材	500	100	600
台湾	南亚塑胶	9500	1800	11300
	长春化工	17000	400 (VLP)	17400
	金居开发	4200	100	4300
	李长荣铜箔	1600	——	1600
我国内资		5400	100	5500
全球其它		200	300	500
全球总计		56050	21300	77350

数据来源：PCB网城公众号，东莞证券研究所

(3) 玻纤布

电子玻纤布是覆铜板的增强材料，是决定覆铜板介电性能的核心材料之一。电子布按玻璃纤维成分可以分为 E 玻纤（E-Glass）、D 玻纤（D-Glass）、NE 玻纤（NE-Glass）、L 玻纤（L-Glass）和石英纤维布（Quartz Fiber）等。玻纤材料内部成分的构成决定了其介电性能的表现。

石英纤维是综合性能最优异的电子布增强材料之一。E 玻纤是经典的传统电子玻璃纤维材料，在 1MHz 下的介电损耗（Df）为 0.0060。D 玻纤相较于 E 玻纤拥有更好的介电损耗（Df）和更低的热膨胀系数（CTE），但是存在可制造性问题和成品的性能缺陷问题。NE 玻纤和 L 玻纤是基于 D 玻纤开发的产品，性能有进一步提升，但是同样存在可制造性问题。石英纤维布的二氧化硅含量达到 99.999%，其在 1MHz 下的介电损耗仅为 0.0001，其热膨胀系数（CTE）仅为 0.54ppm/℃，两大关键性能指标均远低于 E 玻纤、D 玻纤、NE 玻纤和 L 玻纤。

图表 38. 电子布的主要品类

Glass Fiber Type	E-Glass	D-Glass	NE-Glass	L-Glass	Quartz Fiber
SiO ₂ (%)	54.3	72-76	50-60	52-60	99.999
Al ₂ O ₃ (%)	14	0-1	10-18	10-18	-
B ₂ O ₃ (%)	8	20-25	14-20	20-30	-
TiO ₂ (%)	-	-	0.5-5	-	-
MgO (%)	-	-	1-6	4-8	-
CaO (%)	22.1	<1	<1	<1	-
ZnO (%)	-	-	-	-	-
Li ₂ O (%)	-	-	<0.3	<0.3	-
Na ₂ O (%)	-	-	<0.5	<0.5	-
K ₂ O (%)	-	-	-	-	-
Fe ₂ O ₃ (%)	0.3	-	-	-	-
F ₂ (%)	0.7	-	-	-	-

资料来源：SemiVision，中银证券

图表 39. 不同品类玻纤布的性能表现

Metric	E-Glass	D-Glass	NE-Glass	L-Glass	Quartz Fiber
Dielectric Constant (Dk, 1MHz)	6.8-7.1	4.1	4.4	<5	3.78
Dielectric Loss (Df, 1MHz)	0.0060	0.0005	0.0005	0.0006	0.0001
Insulation Resistance (Log3, K)	1473.5	1683.6	<1623.16	<1615	>2073.16
Density (g/cm ³)	2.54	2.14	2.3	2.3	2.2
CTE (*10 ⁻⁶ /K)	5.4	3.1	3.4	~3.9	0.54

资料来源：SemiVision，中银证券

根据日东纺披露的产品路线规划图，其规划有 NE、NER、NEZ、DXII、T、V 玻纤，其中 NE 为第一代低介电常数电子布（Low-Dk 一代布），NER 为第二代低介电常数电子布（Low-Dk 二代布），T 为低热膨胀系数电子布（Low-CTE 布）。在算力时代，AI 服务器和 AI 终端产品均对芯片材料提出了更高的性能要求。低介电常数电子布（Low-DK 一代布和二代布）主要应用于主板基板，低热膨胀系数电子

布（Low-CTE 布）主要应用于芯片封装基板。随着 AI 需求的快速增长，低介电常数电子布和低热膨胀系数电子布需求也快速增长。展望未来，5G millimeter wave、1.6T Switches、PCIe6.0、100Gbps 及以上 AI Server 等应用领域均对电子布介电损耗性能要求更进一步。日东纺预计将在 2026~2028 年推出 NEZ 电子布（下一代超低介电常数电子布，Low-DK 三代布）来满足未来技术发展的需求。石英纤维布有望凭借超低的介电常数和超低的热膨胀系数性能，成为下一代超低介电常数电子布的重要材料之一。

石英纤维布有望成为 Rubin 和 Rubin Ultra 服务器 CPX/Midplane/正交背板的 CCL 材料核心解决方案之一。根据福邦投顾对供应链调研结果，AI 服务器在进入 224Gbps 及以上的传输通道架构下，基于信号完整性考量，CCL 基板需要从当前的 M8 规格升级至 M8.5~M9 规格。M8.5 以 Low-DK 二代布+碳氢树脂解决方案为主，M9 以石英纤维布解决方案为主。目前英伟达 Rubin 架构服务器中，CPX 的基板和中介板（Midplane）基于信号传输距离因素会采用 M9 的石英纤维布解决方案，其余计算板（Compute Tray）和交换板（Switch Tray）会尽量考虑采用 M8（Low-DK 一代或二代）的解决方案。Rubin Ultra 的正交背板预计会采用 M9 的石英纤维布解决方案。ASIC 架构在成本效益和供给考量下会采用 M8.5（Low-DK 二代）的解决方案。

图表 42. 英伟达 AI 服务器 CCL 材料解决方案

AI 服务器	GB200 NVL72	GB300 NVL72	VR200 NVL144
时间	2025Q1 试产, 2025Q2 量产	2025H2 样机, 2026 年放量	2026H2 样机, 2027 年放量
晶圆制程	4nm	4nm	3nm
PCIe 规格	PCIe 6.0	PCIe 6.0	PCIe 6.0
CCL-计算板	M8 (Low-DK 一代)+M4	M8 (Low-DK 一代)+M4	M8 (Low-DK 一代)+M4
CCL-交换板	M8 (Low-DK 二代)+M2	M8 (Low-DK 二代)+M2	M8 (Low-DK 二代)+M2
CCI-CPX 板			M9+M6
CCL-中介板			M9

资料来源：福邦投顾《2026 年 PCB 产业展望》，中银证券

石英纤维布有望成为 1.6T 及以上交换机的 CCL 材料核心解决方案之一。根据福邦投顾对供应链调研结果，交换机在升级过程中，基于高速传输需求，其对信号传输损耗性能要求也愈高。预计 1.6T 及以上规格的交换机将会采用松下 M9 的 CCL，并搭配石英纤维布解决方案。


图表 43. 主流交换机 CCL 材料解决方案

交换机	100G	400G/800G	800G/1.6T	1.6T 及以上
材料损耗等级	Very low loss	Ultra low loss	Extreme Ultra low loss	Super low loss
介电损耗常数 Df	0.0050~0.0060	~0.0030	~0.0020	~0.0010
频率	13GHz (NRZ)	13GHz (PAM4)	28GHz (PAM4)	56GHz (PAM4)
材料设计	PPO	PPO+Low-DK 一代布	PPO+Low-DK 一代布/二代布	碳氢树脂+石英纤维布 /Low-DK 三代布/二代布
CCL 代表型号	松下 M6	松下 M7	松下 M8	松下 M9Q/M9 HF

资料来源：福邦投顾《2026 年 PCB 产业展望》，中银证券


中国大陆的低介电电子布厂商有望参与到供应链中。根据福邦投顾对供应链调研结果，预计 2026 年全球 Low-Dk 一代布需求量约 1,500 万米/月；Low-Dk 二代布需求量约 250 万米/月；Low-DK 三代布（石英纤维布）需求量约 100 万米/月。从供应端来看，2025 主要厂商（日东纺/Asahi/台玻/泰玻）低介电电子布总产能约 550~600 万米/月，预计 2026 年将增长至 1,000 万米/月。主要厂商的低介电电子布产能和需求相比存在缺口，如果考虑良率对交期的影响则供给缺口问题更甚。这也为大陆的低介电电子布厂商带来了机会。

图表 44. 2026 年低介电电子布需求量预估



资料来源：福邦投顾《2026 年 PCB 产业展望》，中银证券

图表 45. 日东纺/Asahi/台玻/泰玻低介电电子布产能预估



资料来源：福邦投顾《2026 年 PCB 产业展望》，中银证券

(4) 树脂

电子树脂是覆铜板材料中唯一具有可设计性的有机物。电子树脂是指能满足电子行业对纯度、性能和稳定性要求的合成树脂，主要用途包括制作覆铜板、半导体封装材料、印制电路板油墨、电子胶等，主要承担绝缘和粘接的功能。其中生产覆铜板是电子树脂最主要的应用领域之一。在覆铜板生产领域，电子树脂是覆铜板材料中唯一具有可设计性的有机物。应用于覆铜板生产的电子树脂一般是指通过选择特定骨架结构的有机化合物（如四溴双酚 A）和有反应活性官能团的单体（如环氧氯丙烷），经化学反应得到特定分子量范围的热固性树脂，是能够满足不同覆铜板所需要的物理化学特性需求的一类有机树脂材料。这些物理化学特性一般是指阻燃性、耐热性、耐湿热性、尺寸稳定性、介电特性和环保特性等性能，符合下游电子行业的要求。由于终端应用领域广泛，加之覆铜板性能主要通过电子树脂的特性予以实现，覆铜板生产厂商需要根据具体应用场景和下游客户的要求，选择相应功能的电子树脂，调整其用量和比例，形成适配的胶液配方。

覆铜板厂商会综合考量电子树脂的配方、成本和性价比。胶液配方并非仅包含单一种类电子树脂，而是由多种不同品类、不同特性的电子树脂按一定比例组合而成。因为配方中涉及的化合物繁多，且特性各异，混合后各组分间存在各种交叉反应，各种性能之间既可能相互促进，又可能相互抑制，因此组分的种类及比例的微小调整，均可能影响配方的性能表达。覆铜板生产厂商需要寻找最佳反应配比，以实现产品的最佳综合表现，同时还需考虑成本和性价比等因素以满足量产需求。

图表 49. 覆铜板胶液配方体系及其对覆铜板的性能影响

主要组成	组分名称	主要功能
主体树脂	溴化环氧树脂、高溴环氧树脂、MDI 改性环氧树脂、DOPO 改性环氧树脂、双酚 A 型酚醛环氧树脂、非环氧体系的新型树脂（苯并噁嗪树脂等）。	提供覆铜板各项物理化学性能，如铜箔剥离强度、玻璃化转变温度、尺寸稳定性、热膨胀系数、低信号损耗、绝缘性能、长期对环境可靠等，实现 UL-94V0 阻燃等级（最高阻燃等级）。
固化剂	双氰胺、线性酚醛树脂、含磷酚醛树脂固化剂等。	大部分主体树脂为热固型树脂，需要在加热和固化剂作用下方能形成立体的交联网状结构，使基材材料具有支撑功能。
添加剂	固化促进剂、增韧剂、偶联剂、阻燃助剂等。	添加剂具有多种类型，起到促进固化反应、提高阻燃性、增加覆铜板韧性等作用。
填料	二氧化硅、氢氧化铝、滑石粉等。	填料具有增容（体积）作用，且因其尺寸稳定性，能够降低覆铜板热膨胀系数，改善流动性，辅助阻燃。
有机溶剂	丁酮、甲苯等。	调节胶液粘度便于生产控制。

资料来源：同宇新材招股说明书，中银证券

电子树脂特性对覆铜板 CCL 和印制电路板 PCB 的性能有关键影响。电子树脂的极性基团结构、固化方式影响覆铜板的铜箔剥离强度以及层间粘结力。电子树脂的高苯环密度以及高交联密度，有助于提升覆铜板的玻璃化转变温度、增强覆铜板尺寸稳定性、降低其热膨胀系数。电子树脂中溴类、磷类阻燃元

素的含量越高，覆铜板的阻燃等级便越高。电子树脂的分子结构高度规整对称以及较低的极性基团含量，能有效降低覆铜板的电信号损耗，以适配高速高频通讯领域的应用场景。高纯度、低杂质的电子树脂能提升覆铜板的绝缘性能以及长期耐环境可靠性（如高温高湿）。


图表 50. 电子树脂对覆铜板及 PCB 关键特性的影响

电子树脂特性	覆铜板对应特性	PCB 应用主要特性
极性基团结构以及固化方式	铜箔剥离强度	PCB 加工可靠性
高苯环密度以及交联密度	玻璃化转变温度、尺寸稳定性、热膨胀系数	
溴类、磷类阻燃元素含量	阻燃等级	PCB 应用场景特性需求
分子结构高度规整对称和低的极性基团含量	低信号损耗	
高纯度低杂质	绝缘性能、长期耐环境可靠性	

资料来源：同宇新材招股说明书，中银证券

高频高速覆铜板驱动电子树脂向较少极性基团趋势发展。随着移动通信技术的发展，PCB 行业对覆铜板的介电性能有着持续提升的要求。由于环氧树脂自身的分子构型和固化后含较多极性基团，对覆铜板的介电性能和信号损耗产生不利影响，因此，基于环氧树脂的覆铜板材料逐渐难以满足高频高速应用需求。经特殊设计，具有规整分子构型和固化后较少极性基团产生的苯并噁嗪树脂、马来酰亚胺树脂、官能化聚苯醚树脂等新型电子树脂应运而生，形成具备优异介电性能和 PCB 加工可靠性的材料体系。

图表 51. 电子树脂配方体系的发展



资料来源：同宇新材招股说明书，中银证券


业内主流的电子树脂包括环氧树脂、聚苯醚树脂、双马来酰亚胺树脂、碳氢树脂、聚四氟乙烯树脂等，碳氢树脂和聚四氟乙烯树脂是高频高速树脂的热点发展方向。根据 ClydeF.Coombs,Jr 《印制电路手册》第六版数据，不同树脂搭配 E-Glass 在不同频段下呈现不同的介电性能表现，其中 PCH 树脂搭配 E-Glass 在 1GHz 频段下，介电常数 Dk 为 3.3，介电损耗 Df 为 0.0024；聚四氟乙烯树脂搭配 E-Glass 在 1GHz 频段下，介电常数 Dk 为 2.3，介电损耗 Df 为 0.0009。因此，碳氢树脂和聚四氟乙烯树脂均是目前在高频高速场景介电性能表现较为优异的材料。

图表 52. 常规树脂和增强材料的介电常数和损耗因子

树脂体系	增强材料	Dk (1MHz)	Dk (1GHz)	Df (1MHz)	Df (1GHz)
环氧树脂	E-Glass	4.4	3.9	0.0200	0.0180
无卤素环氧树脂	E-Glass	4.3	4.0	0.0150	0.0130
环氧树脂/PPO	E-Glass	3.9	3.9	0.0110	0.0100
改良的环氧树脂	E-Glass	3.9	3.7	0.0120	0.0120
环氧共混物	E-Glass	3.9	3.7	0.0090	0.0090
低损耗共混物	E-Glass	3.8	3.7	0.0060	0.0070
极低损耗共混物	E-Glass	3.5	3.4	0.0030	0.0036
氰酸酯	E-Glass	3.8	3.7	0.0080	0.0110
聚酰亚胺	E-Glass	4.3	3.9	0.0140	0.0150
APPE	E-Glass	3.7	3.4	0.0050	0.0070
PTFE	E-Glass	2.3	2.3	0.0013	0.0009
碳氢树脂	E-Glass	3.4	3.3	0.0025	0.0024

资料来源：CSDN，Clyde F.Coombs,Jr 《印制电路手册》第六版，中银证券

图表 53. 各类型树脂的介电常数



资料来源：深圳市惠科新材料股份有限公司，中银证券

图表 54. 不同等级覆铜板的树脂基材

不同等级覆铜板的树脂基材			
	覆铜板电性能等级	传输数据速率	覆铜板基材
超低损耗	Df<0.002	56Gbps	聚苯醚树脂、碳氢树脂、双马来酰胺树脂、聚四氟乙烯类
极低损耗	Df=0.002-0.005	25Gbps	树脂、液晶高分子
低损耗	Df=0.005-0.008	10Gbps	聚苯醚树脂、氰酸酯树脂、双马来酰胺树脂
中等损耗	Df=0.008-0.01	5Gbps	特种环氧树脂、苯并噁嗪类
常规损耗	Df=0.01-0.02	<5Gbps	环氧树脂
	Df>0.02		

资料来源：深圳市惠科新材料股份有限公司，中银证券

五、AI Infra 软件

AI Infra 包含三类核心软件：**1）算力管理层**：主要提供计算、存储、网络、安全等基础资源和服务；**2）模型管理层**：提供模型开发和应用所需的各种基础工具和组件，主要包括数据治理、模型部署、训练、推理、精调、集成管理等；**3）应用管理层**：主要提供资源管理、运营管理、运维管理等运营能力。目前算力管理层占主导地位，2024 年市场份额达 64.6%，但应用管理层占比持续提升，反映出 AI 应用正从探索走向深度集成。

海外 AI 软件收入增速看，AI Infra 软件公司收入增速平均值高于 2B AI 应用。因为 AI 投资遵循“算力-infra 软件-应用”的顺序，Infra 软件无论在模型训练、推理和 AI 应用部署中均有作用，但由于“Surrounded by Gs”，意为被巨头们（Google、GPT/openAI、GPU/Nvidia）包围，在训练占据主流时期，其商业机会暂未显现。2024H2 模型推理量快速增加，部分领域 AI 应用也开始渗透，能够认为 AI Infra 软件的商业机会真正来临。

表 1： 25Q1-Q3 美股 AI 软件收入增速 (%) 2C 应用>AI infra>2B 应用

类别	名称	2024Q1	2024Q2	2024Q3	2024Q4	2025Q1	2025Q2	2025Q3
AI Infra 软件	Snowflake	47.6	41.1	37.6	35.9	32.9	30.8	29.9
	MongoDB	29.0	34.5	32.8	31.1	22.3	17.2	19.0
	DataDog	26.9	26.8	26.5	26.1	24.6	26.4	27.1
	Elastic Search	17.5	17.5	18.2	18.6	18.3	17.9	17.4
	平均值 (%)	30.3	29.9	28.8	27.9	24.5	23.1	23.4
2B AI 应用	CrowdStrike	42.0	39.2	37.8	36.3	33.0	32.3	31.0
	ServiceNow	24.2	23.2	22.8	22.4	18.6	20.5	21.0
	Salesforce	11.3	11.4	11.3	11.2	10.7	9.5	9.1
	SAP	8.1	8.9	9.1	9.5	12.1	10.5	9.3
	Intuit	14.7	12.9	12.4	13.3	10.2	13.9	14.5
	平均值 (%)	20.0	19.1	18.7	18.6	16.9	17.3	17.0
类 2C AI 应用	Figma				48.4	46.1	43.3	41.3
	Duolingo	44.9	42.6	41.7	40.8	37.7	39.6	40.2
	Unity	-8.0	-12.0	-14.1	-17.1	-5.5	-3.7	-0.7
	平均值 (%)	18.4	15.3	13.8	24.0	26.1	26.4	26.9

资料来源：Wind，申万宏源研究

1、算力管理层：虚拟化与容器是核心技术

异构算力集群趋势下，算力管理和调度类的软件刚需性提升。当前国内模型厂商、云厂商等推理算力采用芯片较为多元，包括华为、寒武纪、海光信息等，一般会采用异构集群来支持。由于各芯片的底层指令集、硬件架构和软件栈均为自有，不互相兼容，在其上搭建一个软件隔绝硬件差异，就成为了推理服务和应用的刚需。

AI Infra 算力管理层软件参与者主要为云厂商，如阿里云、华为云、火山引擎等自研，或者 MaaS 初创公司。

表 1： 国内 AI infra 核心参与者以 CSP、企业级云厂商、大模型厂商、AI 应用厂商为主

厂商类型	代表厂商	AI Infra 平台能力
互联网厂商	阿里云	飞天企业版聚焦异构算力池化、推理效率等关键点，提供 GPU 虚拟化和容器调度算力能力，以及 AI 作业可观测全链路监控等产品能力，并优化 GPU 推理调度算法； 百炼专属版提供丰富多样的大模型应用开发工具，支持插件、编排、运营能力，为企业提供大模型训练与推理解决方案。
	字节跳动	火山引擎 veStack 智算版通过构建高性能异构算力底座，提供计算、存储、网络等云服务能力； 火山方舟集成模型精调、推理、评测等功能与服务，提供丰富的插件生态和 AI 原生应用开发服务。
企业级云厂商	华为云	昇腾云服务为企业用户提供 AI 算力、异构计算架构等产品能力，支撑模型训练推理和应用落地； ModelArts Studio 大模型即服务平台，基于昇腾云底座对开发工具链进行标准化，提供数据处理、算法开发、模型训练、模型部署等模型服务能力。
	天翼云	云骁智能计算加速平台，提供智能算力管理与加速服务，提供异构算力管理与调度、加速套件和全流程可观测运营能力； 慧聚一站式智算服务平台为大模型训练、推理、应用提供全栈工具链的智算服务，包含数据管理、模型开发与训练、模型评估、模型管理、服务部署等模块。
	云轴科技	ZStack AIOS 智塔聚焦异构算力管理、多模型协同加速、AI 自服务化、数据安全等领域，为企业用户提供具备算力调度、模型训推、AI 应用服务开发的私有化一站式平台；

		平台预置 AI 开发工具和服务、虚拟化和云原生、高性能存储网络，具备本地化数据管理和加密、故障自愈高可用、灾备服务等能力。
大模型厂商	零一万物	零一万物垂直整合 Infra、模型、应用三层能力，大模型开放平台为用户提供丰富的模型矩阵，具备多种能力、尺寸、价格和上下文窗口组合能力。
	智谱	Bigmodel 为企业用户提供开箱即用的大模型 AI 应用开发资源，包括语言模型、多模态模型等，同时提供丰富的工具组件，包括代码解释器和搜索功能。
人工智能软件厂商	第四范式	先知 AIOS 聚焦企业算力资源高效分配与模型推理性能提升，打造 GPU 资源池化技术和内置推理框架，并通过 Model Hub 平台提供 NLP、多模态、视觉、语音等模型的统一纳管能力。
大数据软件厂商	拓尔思	智拓·人工智能技术平台提供包括模型设计、训练、优化、评估、发布、下载等完整过程的 AI 服务能力；
初创企业	瀚晨科技	基于全流程的图形化操作界面，支持可视化建模和 Notebook 建模。
		瀚晨云平台提供 GPU 算力租赁服务，并支撑上层模型训练与推理；
	无问芯穹	ColossalAI 大模型平台集成数据收集准备、模型训练微调、推理部署、端到端交付等功能和服务，为企业用户提供大模型开发应用部署全流程能力。
		InfiniAI 异构云平台提供异构算力纳管、算力调度、算力租赁等系列服务能力；
		无穹 InfiniAI 大模型开发与服务平台聚焦多种大模型算法在多元芯片上的高效、统一部署，打造“M 种模型”和“N 种芯片”间的“M×N”中间层产品。

资料来源：赛迪顾问，申万宏源研究

算力调度功能尤为重要。因为其影响着大模型厂商的成本，模型厂商需要投入百亿级美金资金规模在预训练算力上，1%的效率提升也意义显著。其次，大模型体系从芯片、云基础设施、框架到模型与应用之间存在极强的耦合度——不同厂商的芯片在设计模式、指令和调用方式上差异巨大，要想充分发挥性能，算子、框架乃至模型本身都必须深度感知底层拓扑。

Deepseek 之后，性价比成为了国内模型的重要特性之一。在国内模型竞争背景下，Deepseek 的较低定价，锚定了国内其他大模型的定价，使其始终存在降低成本的需求。因此在这种背景下，**算力调度的能力成为大模型厂商、MaaS 厂商盈利的关键。**

表 2：国内模型 Token 收费价格较海外更低，成本更敏感

模型名称	输入价格 (元/百万 tokens)			输出价格 (元/百万 tokens)		
Deepseek V3.2						
官方	2 (缓存未命中) ; 0.2 (缓存命中)			3		
火山引擎	2 (缓存未命中) ; 0.4 (缓存命中)			8		
	1 (批量、未命中) ; 0.4 (批量、命中)			4 (批量)		
Kimi K2 Thinking	4 (缓存未命中) ; 1 (缓存命中)			16		
阿里 Qwen-turbo						
阿里云	0.3			3 (思考模式) ; 0.6 (非思考模式)		
百度 ERNIE-Lite	0 (在线推理) ; 1.2 (批量推理)			0 (在线推理) ; 2.4 (批量推理)		
字节豆包 Seed-1.6-thinking	输入长度	非批量	批量	输入长度	非批量	批量
	[0,32]千 tokens	0.8 (缓存未命中)	0.4 (缓存未命中)	[0,32]千 tokens	8	4
		0.16 (缓存命中)	0.16 (缓存命中)			
			0.16 (缓存命中)			
	(32,128]千 tokens	1.2 (缓存未命中)	0.6 (缓存未命中)	(32,128]千 tokens	16	8
		0.16 (缓存命中)	0.16 (缓存命中)			
			0.16 (缓存命中)			

	(128,256]千 tokens	2.4 (缓存未命中) 0.16 (缓存命中)	1.2 (缓存未命中) 0.16 (缓存命中)	(128,256]千 tokens	24	12
模型名称	输入价格 (美元/百万 tokens)			输出价格 (美元/百万 tokens)		
Google Gemini 3 Pro Preview (high)	输入长度	价格 (美元/百万 tokens)		输入长度	价格 (美元/百万 tokens)	
	<20 万个 token	2		<20 万个 token	12	
	>20 万个 token	4		>20 万个 token	18	
Claude Opus 4.5	5 美元 (批处理半价)			25 美元 (批处理半价)		
GPT-5.1 (high)	1.25 美元 (缓存未命中) ； 0.125 美元 (缓存命中)			10 美元		
GPT-5 (high)	1.25 美元 (缓存未命中) ； 0.125 美元 (缓存命中)			10 美元		
GPT-5.2	1.75 美元 (缓存未命中) ； 0.175 美元 (缓存命中)			14 美元		


资料来源：Deepseek 官网，阿里云官网，火山引擎官网，谷歌官网，openAI 官网，Anthropic 官网，申万宏源研究

算力调度典型产品包括华为 Flex:ai、阿里巴巴 Aegaeon、字节跳动的 Gödel 资源管理和调度系统等。但不同厂商推出产品的目的有差异：

- 1）硬件厂如华为推出 Flex:ai、英伟达推出 Run:ai 目的是强化自家硬件产品生态和粘性。
- 2）而阿里巴巴、字节跳动等则是①提升云用户体验；②降低成本，提升云业务利润率。

而实际上，海外大厂云业务的毛利率区间也较为宽泛，CY25Q3，微软、亚马逊、谷歌三大云厂云业务毛利率处于 20%~45%区间。当前毛利率差异主要来自业务结构，但能够认为未来 AI 大模型云收入持续增加的过程中，硬件调度能力对其毛利率的影响至关重要。

图 2：CY25Q3 海外 CSP 厂商云业务毛利率处于 20-45%区间



资料来源：Bloomberg，申万宏源研究

注：微软显著高主要由于微软智能云收入中包含 Office365 等高毛利业务，亚马逊 AWS、谷歌云主要为 IaaS 类业务收入

25 年 11 月华为正式发布并开源了创新 AI 容器技术 Flex:ai，Flex:ai 在发布后同步开源在魔擎社区中。华为 Flex:ai 是基于 Kubernetes 容器编排平台构建的 XPU 池化与调度软件。

Flex:ai 能够实现异构算力的调度。英伟达、昇腾及其他第三方算力资源，Flex:ai 都能够统一管理和高效利用，有效屏蔽不同算力硬件之间的差异。**Flex:ai 芯片级算力切分：**华为 Flex:ai 将单张 GPU/NPU 算力卡切分为多份虚拟算力单元，切分粒度精准至 10%，实现单卡同时承载多个 AI 工作负载，在无法充分利用整卡算力的 AI 工作负载场景下，**算力资源平均利用率可提升 30%。**


表 3：大厂自研算力调度平台能力

厂商	算力调度平台	特点
华为	Flex:ai	可异构调度，提升算力使用效率 30%
阿里巴巴	Aegaeon	Token 级调度，单 GPU 支持 7 个模型共享，GPU 用量减少 82% (1192 张—>213 张)
英伟达	Run:ai	GPU 利用率提升 5 倍
Deepseek	自研	成本利润率 545%

资料来源：华为官网，澎湃新闻，论文《Aegaeon: Effective GPU Pooling for Concurrent LLM Serving on the Market》，申万宏源研究

阿里 Aegaeon 也是 token 级的“模型调度神器”。Aegaeon 通过“token 粒度的动态调度”，实现多模型共享 GPU 资源。传统多模型服务中，GPU 资源要么被单个模型独占，要么在模型切换时产生巨大性能损耗。而 Aegaeon 创造性地将调度粒度从“模型级”下沉到“token 级”（token 是 AI 处理文本的基本单位），就像快递分拣系统从“按批次分拣”升级为“按单个包裹实时调度”。

图 3：Aegaeon token 粒度调度、阶段化计算、缓存复用、弹性扩缩容




资料来源：《Aegaeon: Effective GPU Pooling for Concurrent LLM Serving on the Market》，申万宏源研究

阿里 Aegaeon 将 10 个模型所需 GPU 数量从 1192 个锐减至 213 个，资源节约率高达 82%。通过预加载模型参数、优化显存调度等技术，将模型切换开销降低，解决了精细调度带来的性能损耗问题。

推理算力调度平台优化的核心指标是单卡吞吐，直接影响推理服务毛利率。单卡吞吐越高，硬件资源越能被充分使用。假设模型推理服务厂商使用等效。根据测算，在单日 10 亿查询量下，若使用 H800 芯片，单卡吞吐能力每提升 10%，毛利率能够提升 2-7 个百分点。

图 4：推理服务毛利率与芯片单卡吞吐敏感性分析



资料来源：申万宏源研究
注：具体假设和计算过程间见表 4、表 5

表 4：模型推理服务收入假设

日查询次数（亿次）	10
Prefill 阶段	
单价（元/百万 token）	4
tokens/单次查询	300
Decode 阶段	
单价（元/百万 token）	16
tokens/单次查询	200
日收入（万元）	440
年收入（亿元）	16.06
峰值并发查询占比	20%
峰值并发查询（亿次）	2
峰值并发处理 tokens	
Prefill (tokens/s)	16666667
decode (tokens/s)	11111111

资料来源：Deepseek 官网，申万宏源研究
注：单价假设参考 Deepseek V3 价格

表 5：推理服务毛利率与芯片单卡吞吐敏感性分析


单卡吞吐倍数假设									
	0.6x	0.7x	0.8x	0.9x	1x	1.1x	1.2x	1.3x	1.4x
prefill	4422	5159	5896	6633	7370	8107	8844	9581	10318
decode	888	1036	1184	1332	1480	1628	1776	1924	2072
所需卡数 (英伟达 H800)									
Prefill (tokens/s)	3769	3231	2827	2513	2261	2056	1885	1740	1615
decode (tokens/s)	12513	10725	9384	8342	7508	6825	6256	5775	5363
合计所需卡数 (张)	16282	13956	12211	10854	9769	8881	8141	7515	6978
八卡服务器单价 (万元)	150	150	150	150	150	150	150	150	150
算力基础设施 TCO (亿元)	38.16	32.71	28.62	25.44	22.90	20.81	19.08	17.61	16.35
年固定成本 (亿元)	7.6	6.5	5.7	5.1	4.6	4.2	3.8	3.5	3.3
毛利率 (不考虑可变成本情况下)	52%	59%	64%	68%	71%	74%	76%	78%	80%

资料来源：CSDN (中国开发者网络)，Deepseek 官方文档，申万宏源研究
注：芯片以英伟达 H800 为例，Prefill 吞吐为 7370 tokens/s，Decode 吞吐为 1480 tokens/s，参考 Deepseek 官方文档
注：H800 8 卡服务器单价 150 万/台，假设服务器成本占算力基础设施 TCO 的 80%，假设服务器使用寿命 5 年，无残值

2、模型及应用管理层：数据类 Infra 软件率先受益

AI 应用在快速渗透，推理 AI Infra 软件需求崛起。OpenRouter 统计到的 Token 消耗量一年时间内翻了近 10 倍。Openrouter 是一个开源路由工具，为 2B 端 AI 应用 API 接入各类大模型提供接口，从 2024 年 Q4 开始，从 OpenRouter 口径统计到的各类 API 接入大模型的 Token 消耗量持续增长。

图 5：OpenRouter 统计的 Token 消耗量自 2024Q4 起快速增长



资料来源：OpenRouter (AI 应用 API 接口网站)，申万宏源研究

AI 应用部署的标准流程为：首先将训练好的模型与服务代码容器化；随后在 K8s 集群中部署，并配置扩缩容与负载均衡；通过 API 网关暴露服务；推理时，应用从特征库获取实时数据，由推理引擎处理并返回结果；最后通过监控体系保障服务稳定与模型效果。以 RAG 应用为例，请求会依次经过网关、检


索向量数据库、拼接提示词、调用大模型服务并返回生成结果。其中**所需软件工具**主要包括：**Docker**用于将模型、环境及代码打包成容器；**Kubernetes**负责容器编排与资源调度；**推理服务器**（如 TensorFlow Serving、Triton 或 vLLM）提供高性能推理接口；API 网关（如 Nginx）管理外部请求；**监控工具**（如 Prometheus）追踪服务与模型性能；**特征存储或向量数据库**（用于 RAG 等场景）提供实时数据。

AI 应用推理渗透的影响，率先作用在了数据层。观察到几个趋势：1）RAG 风靡，向量数据库成为刚需；2）NoSQL+OLTP 厂商存储非结构化数据（语音、文本、图像、甚至向量索引等）、实时性高，需求正在反超，通过补充向量索引能力切入向量数据库市场；3）数据湖、数据仓库厂商（OLAP 为主）通过并购、合作方式引入 AI 模型，向全栈工具迈进；4）数据 IO 控制权由 CPU 让渡到 GPU，存储和向量数据库的技术需耦合升级。

（1）RAG 类 AI 应用渗透，向量数据库需求提升


大模型幻觉问题下，**2B 端 RAG 类应用风靡**。由于 1）大模型不能直接记住大量企业私有知识：例如公司内部文档、产品手册、FAQ 客户知识库。这些内容通常非常多，大模型无法全部放入 Prompt，也不会长期记住；2）全文搜索不能满足语义需求：传统搜索如 ES、关键词搜索只根据文本匹配，而包含某个关键词不等于语义最相关；3）大模型缺乏外部知识时，容易产生幻觉（hallucination），因此 RAG（增强现实检索）成为企业部署 AI 应用的标配。根据 Gartner，2024 年全球已有 45% 的企业在智能客服、数据分析等场景中部署 RAG 系统，预计到 2025 年这一比例将突破 68%。

图 6：Gartner 预计企业 RAG 技术采用率 25 年将达 68%



资料来源：Gartner（全球科技咨询机构），申万宏源研究

图 7：向量数据库在 RAG 类 AI 应用推理的流程



资料来源：申万宏源研究

向量数据库是 RAG 的“好帮手”，逐渐成为刚需。向量数据库本质上是一种专门用于存储向量化表示的系统。这些向量通常来源于图像、文本、音频等多模态数据，经过嵌入模型（embedding）处理后被映射到统一的高维向量空间并存储。

向量数据库的核心能力是，系统在接到查询向量时能快速返回最相似结果。这一能力源于层次图 HNSW、量化 IVF-PQ 及 DiskANN 等近似最近邻算法对“快”和“准”的兼顾。在大模型时代前，向量检索就已支撑人脸识别、推荐排序、异常检测等场景；当前 RAG 推理需要用向量回溯长上下文或私有知识，进一步促进了向量数据库领域的发展。与传统键值库相比，这类系统不仅要管理嵌入生成、索引构建及查询调度，还必须在工程层面解决混合稠密-稀疏检索等复杂挑战，以确保在海量数据和持续写入下依旧保持高吞吐与一致性。

按照开源/商用，向量数据库可分为以下几类：1）主流开源向量数据库：Milvus、Weaviate、Qdrant 等；2）商业 SaaS/云厂商：Pinecone、Opensearch Vector Engine、AzureCognitiveSearch、MongoDB Atlas 等；3）传统数据库的“向量扩展”功能：PostgreSQL pgvector、Elasticsearch vector search、MySQL HeatWave Vector，适合中小规模场景，不是专为大规模向量搜索设计。

表 6：主要的向量数据库及其特点

产品	特点
Milvus（最流行）	专为向量搜索设计，性能极强，生态完善
FAISS（Facebook）	算法库，不是完整数据库，需要自己封装
HNSWlib	高性能近邻搜索库，索引速度强
Weaviate	带 REST API、schema、扩展插件，易用
Qdrant	Rust 开发，性能稳定，支持混合搜索
Vespa（雅虎）	面向大规模内容检索的搜索平台
Pinecone	SaaS 向量数据库，免维护
OpenSearch Vector Engine	AWS 生态中集成
Azure Cognitive Search	与 Azure AI 紧密结合
MongoDB Atlas Vector Search	在文档数据库上附加向量检索功能

资料来源：申万宏源研究

向量数据库主要应对海量数据+高频查询，必须依赖高性能 ANN 搜索。当数据量达到百万到亿级，而查询需要维持毫秒级响应时，传统的精确相似度计算已经无法满足性能需求。只有通过高性能 ANN 索引（如 HNSW、IVF、PQ 等），才能在保证较高召回率的同时，实现高 QPS 的实时检索能力。


（2）OLTP+NoSQL 切入向量数据库，数据湖仓工具向应用层拓展

相比 SaaS 时代，AI 给软件工具栈的最大影响是，数据结构从“分析优先”转向“实时运营+分析协同”。传统“分析优先”架构（数据仓库/湖仓一体为主）的设计目标是批量处理、事后洞察、报表输出，适配 BI 报表、历史趋势分析等场景，但在生成式 AI、实时决策、智能交互等新需求下，趋势是：1）AI 应用实时化：RAG、智能客服、实时推荐等场景要求毫秒级响应；2）数据价值即时化：LLM 与智能体需要“数据即服务”，而非“数据即报表”，驱动业务自动决策；3）多模态数据爆发：文本、图像、音频等非结构化数据与向量嵌入成为核心数据结构。

Agent 也强化了对高实时性数据的需求。Agent 是具备感知-决策-执行闭环的智能系统，其运行依赖三个关键能力：1）实时感知环境变化：Agent 需要持续获取外部动态数据（如用户实时指令、业务系统的状态变更、传感器的实时反馈），并快速响应；2）动态自主决策：基于实时数据和预设目标，Agent 需在毫秒/秒级完成决策（如智能客服的意图识别、自动驾驶的路况判断、供应链 Agent 的库存调整）。3）交互性操作：Agent 的决策结果需要直接作用于业务系统（如自动下单、修改订单状态、发送通知），涉及频繁的增删改查（CRUD）操作。

综合来看，这些需求的本质是高频、小批量、低延迟的实时事务处理，这正是 OLTP 的核心优势。以上趋势下，OLTP+NoSQL 再次风靡。海外 Snowflake、MongoDB 等厂商的收入增速 FY2025Q2（对应 2024Q2）出现拐点，印证这一逻辑。

图 8：海外数据厂商收入增速



资料来源：Bloomberg，申万宏源研究

MongoDB：构建企业级 AI 应用，向量数据库是刚需。


AI 应用对数据结构提出前所未有的灵活性要求，传统关系型数据库因严格 Schema 限制难以应对语音识别等非结构化、半结构化数据场景。MongoDB 凭借原生支持结构化、半结构化与完全非结构化数据的统一存储能力，成为 AI 应用的理想平台。

MongoDB 凭借原生 JSON 数据模型，在 AI 时代具备显著技术壁垒。大语言模型（LLMs）原生输出与消费 JSON 格式，而 MongoDB 作为分布式文档数据库，天然适配非结构化、高动态数据场景。

除向量数据库外，MongoDB 推出的 AMP（Application Modernization Platform）平台也获得了客户高度认可，被视为帮助客户从传统关系型数据库迁移至现代文档模型的有效工具。管理层表示，AMP 将在未来成为公司新的增长点之一。


MongoDB 坚持“云中立”战略，其 Atlas 平台支持跨 AWS、Azure、Google Cloud 无缝部署，这一优势在近期多家云服务商出现服务中断后更显关键。客户对多云架构的依赖持续加深，MongoDB 的跨云一致性与高可用性构成核心竞争力。

图 8：MongoDB 营收及增速



资料来源：Wind，申万宏源研究

图 9：Snowflake 营收及增速




资料来源：Wind，申万宏源研究

Snowflake：数据仓库核心玩家，更好发挥企业级 AI 应用效果。

Snowflake Intelligence 是一个针对 AI 模型和应用部署提供的数据库平台，允许用户通过自然语言查询结构化数据，并构建智能 Agent 以提升工作效率。

Snowflake Intelligence 平台已进入公开预览阶段,目前已有超过 6,100 个账户每周使用 Snowflake 的 AI 功能，占部署用例的 25%。此外，公司还推出了 Cortex AI SQL，将 AI 原生集成到 SQL 中，使客户能够在不移动数据的情况下直接调用 AI 模型。


图 10: Snowflake 拓展数据平台边界与 TAM



资料来源: Snowflake 业绩演示材料, 申万宏源研究

Snowflake 的营收增长核心建立在“按使用付费”消费模型上，客户仅在实际使用产品并获得价值时才产生支出，该模式有效缓解客户对 AI 项目失败率高达 95%的支出焦虑，确保投入与价值直接挂钩。根据 Snowflake 法说会，25%的已部署用例已整合 AI 功能，且新客户中 50%的签约受 AI 驱动，表明 AI 正成为核心增长引擎。

图 11: Snowflake 提取多源异构数据支撑 AI 及非 AI 的各项需求



资料来源: Snowflake 业绩演示材料, 申万宏源研究

AI 将成为 Snowflake 推动自身从 50 亿美元营收迈向 100 亿美元的核心杠杆。根据 CEO 公开发言，未来 Snowflake 将覆盖数据从诞生、工程、分析到反馈优化的全生命周期。公司不再局限于“数据仓库”标签，而是通过持续迭代，将 AI 深度嵌入数据流，实现智能反馈闭环。其产品组合（Snowflake

Intelligence、Openflow、Snowpark）协同作用，形成类似 Kubernetes+云存储的平台级优势，支撑客户构建复杂 AI 应用。


（3）GPU 成为数据控制中心，数据库+存储技术升级

AI 推理迈入实时化、PB 级数据访问的新阶段，存储 IO 正从“幕后支撑”变成“性能命脉”。LLM 推理的 KV 缓存访问粒度仅 8KB-4MB，向量数据库检索、推荐系统的特征读取更是低至 64B-8KB，且需要支持数千条并行线程的并发请求。LLM 推理的存储需求已突破 10TB 级，向量数据库和推荐系统的存储规模更是达到 1TB-1PB，这种“小块高频”的访问模式，让传统存储架构性能落后。

NVIDIA 最新提出了 SCADA（Scaled Accelerated Data Access）方案，以 GPU 完全接管存储 IO 的控制路径与数据路径。SCADA 是 NVIDIA 历经 8 年研究打造的完整解决方案，涵盖硬件适配、软件栈优化和协议创新。其中硬件平台为 NVIDIA H3 Platform，具体架构：

- 1）算力层：最高支持 4 颗 H100/L40S GPU，利用 PCIe Gen5/6 与存储直连，H100 的并行处理能力可支撑数万条并发 IO 请求；
- 2）存储层：支持最多 48 块 PCIe Gen6 SSD，单盘可提供 5.4M 随机读 IOPS，44 块集群可实现 230MIOPS，接近理论峰值 237.6MIOPS；
- 3）交换层：采用 Broadcom Gen6 PCIe 交换机，带宽利用率达 96%，确保 GPU 与存储之间的低延迟通信。


图 21：英伟达 GPU 直连 SSD 的硬件设计



资料来源：存储随笔，申万宏源研究

这种“GPU-交换机-SSD”的直连架构，彻底绕开了 CPU 的性能限制。测试数据显示，1 颗 H100GPU 的 IO 调度效率是 Gen5 Intel Xeon PlatinumCPU 的 2 倍以上，即便入门级的 L40S GPU（Gen4），其 IO 效率也达到同代 CPU 的 98%，且成本更低。

图 22: H100 的 IO 调度效率是 Gen5 Intel Xeon Platinum CPU 的 2 倍以上



资料来源：英伟达技术文档，申万宏源研究

以 LLM 推理的 KV 缓存访问为例，SCADA 的工作流程如下：

LLM 模型在 GPU 上执行推理时，需要访问特定的 KV 缓存块（8KB-4MB）；

GPU 直接通过 SCADA Client 发起 IO 请求，无需 CPU 介入；

SCADA Server 通过 uNVMe 驱动向目标 SSD 发送请求，利用 PCIe Gen6 交换机实现低延迟传输；数据通过 DMA 直接写入 GPU 的 HBM 缓存，供计算核心即时使用。整个过程中，CPU 仅负责系统级的资源管理，不参与任何 IO 请求的发起与调度——这使得小数据块的 IO 延迟从毫秒级降至微秒级，完全匹配 AI 推理的实时性需求。

SCADA 的成功离不开生态伙伴的支持，目前 Marvell、Micron、三星、KIOXIA 等头部存储厂商已深度参与 SCADA 的优化。

新的技术架构对向量数据库有什么影响？原本向量数据库分“三层存储”，核心靠硬盘+普通内存：1）核心工作区（CPU 内存/DDR）：像仓库的“工作台”，放高频访问的向量数据和索引，方便快速取用，但容量小、成本高。2）长期存储区（NVMe SSD/硬盘）：像仓库的“货架”，存全量向量数据，容量大、成本低，但访问速度比内存慢，类似货架取货要走几步。3）备份区（云存储/异地硬盘）：像仓库的“储物间”，存冷数据和备份，几乎不参与实时工作。

原本的工作流程是：CPU 先接需求，从“货架”（SSD）把目标向量数据搬到“工作台”（CPU 内存），CPU 再把数据拷贝到 GPU 显存，让 GPU 做相似性计算（比如对比用户向量和商品向量），GPU 算完后，把结果传回 CPU，CPU 再整理反馈给用户。

这种模式下，数据要“硬盘→CPU 内存→GPU 显存”三次拷贝，绕路又耗时；且 CPU 擅长串行任务系统级调度，但不擅长并行干活，面对亿级向量的批量计算，会成为瓶颈；其次内存墙问题凸显，内存容量小，超大规模向量数据放不下，只能频繁从硬盘调数据，越算越慢。

GPU 直连之后，存储不发生变化，但数据从 SSD 直接提取到 GPU 显存中。**为了适配这个新逻辑，向量数据库需要“升级改造”：**

- 1) 适配 GPU”：把向量数据的存储方式改成 GPU 适配的列式存储，不用 GPU 再花时间转换；
- 2) 索引和算法“适配 GPU 并行”：把原本给 CPU 设计的检索算法（比如 HNSW），改成 GPU 能并行处理的版本，例如让 GPU 的多个计算核心同时对比不同向量，因此涉及算子重写；
- 3) 自己管理 GPU 显存：向量数据库要学会分配 GPU 显存——哪些数据常驻显存、哪些数据用完放回 SSD，避免显存不够用。

3、国内本地部署特色，涌现新需求

AI Infra 层面，深信服凭借私有云能力切入全栈 AI Infra 领域；数据厂商层面，国内达梦数据、英方软件等开始发力 AI。

达梦数据：核心能力在于 OLTP，开始切入 NoSQL。达梦数据是国产关系型数据库厂商翘楚与 MongoDB 类似，达梦数据近期也推出向量数据库，践行“智算多模”的技术理念与创新实践，其提出的原生多模存储引擎，实现了图、关系、键值、文档、向量等数据模型的统一存储。相比传统关系存储引擎，这一方案具有显著优势：消除了异构数据库间的迁移操作、冗余存储、兼容性问题及同步延迟，更借助图技术实现了性能的量级提升。

英方软件：数据复制及灾备厂商，OLAP 服务生成 AI 的“好助手”。与 Snowflake 静态数据仓库的方式不同，英方软件推出 i2Stream 实时数据流处理平台，能够实现大规模数据流的实时同步，满足智能制造、智慧城市、AI 大模型等领域对数据实时处理的需求。

图 23：英方软件数据复制和同步产品在 AI 应用的业务逻辑



资料来源：英方软件官网，申万宏源研究

六、AI 基础设施厂商

1、阿里云：为企业级用户提供了全栈自研 AI 基础设施

阿里云是 AI 基础设施领域的领导者。阿里云以基于 AI 场景全面重构底层硬件、计算、存储、网络、数据库、大数据等 AI 基础设施层，已初步形成以通义为核心的操作系统和以 AI 云为核心的下一代计算机。平台层方面，阿里云百炼已集成两百多款大模型 API，覆盖国内外主流开源和闭源模型。

图表41：阿里云 AI 基础设施

基础设施层/平台层	性能
平台即服务	提供全尺寸、全模态、多场景的模型及服务；阿里云百炼已集成两百多款大模型 API。
湖仓一体化平台 OpenLake	大数据搜索、AI 一体化能力体系
多模数据管理平台 DMS	多模数据、向量支持、无感集成、灵活可用、推理加速
人工智能平台 PAI	推理一体化、弹性调度；实现了十万卡级别的训练推理一体化弹性调度。
容器	容器服务 ACK 支持 15000 节点；容器计算 ACS 支持多种生态的 Serverless GPU 容器算力。
灵骏智算集群	支持 10 万卡规模的稳定互联。
磐久 AI 计算服务器	可高效支持多种 AI 芯片，单柜支持 128 个 AI 计算芯片。高性能并行文件存储 CPFS 单客户端吞吐提升至 40GB/s；新增“向量存储桶”以强化其对象存储服务（OSS）。新一代高性能网络 HPN8.0，存储网络带宽拉升至 800Gbps，GPU 互联网络带宽达到 6.4Tbps，可支持单集群 10 万卡 GPU 高效互联。

来源：阿里巴巴/阿里云公众号，国金证券研究所

阿里云全栈自研 AI 基础设施具备完善的自有生态网络、大规模商用实践经验以及稳定安全的 AI 基础设施架构。**1）全栈自研、积极创新：**阿里云通过全栈自研构筑壁垒，从底层的算力到 AI 平台，始终坚持全栈技术创新。其自研产品及功能包含但不限于倚天等自研芯片、自研训推服务框架、自研 HPN7.0 网络架构等。**2）完善的自有生态网络：**阿里云拥有强大的生态系统，一方面阿里云拥有完善的产品服务生态；另一方面阿里云拥有 12,000+ 家生态合作伙伴，与高校和科研机构保持紧密的合作关系，此外，阿里云还发起了全国最活跃的开源模型社区-魔搭社区。强大的生态优势进一步增强了阿里云的用户粘性与应用场景的深入。**3）安全稳定的基础设施架构：**阿里云为企业级用户提供了强大的安全防护体系与领先的网络架构。阿里云采取了 DDoS 高防、Web 应用防火墙、云防火墙与数据安全中心等措施全面协助用户保护 AI 基础设施免受攻击。此外，阿里云提供了多种方式来监控和评估节点的健康状态，帮助用户快速定位问题并进行故障排查，满足用户对于产品安全稳定的要求。

阿里云在增长指数排名第一，在以下指标项得分最高。在安全合规与风险管理模块方面：阿里云在 AI 训推全流程提供数据存储、传输、处理安全保护，多租户环境下通过数据隔离、加密、全链路可信身份传递、合规审计强化数据安全；提供模型知识产权保护、防恶意操纵技术保障模型安全与完整性；通过 AI 伦理委员会、偏见检测工具、决策透明度技术践行 AI 伦理承诺；基础设施安全层面依托 DDoS 高防、WAF、云防火墙、数据安全中心及动环监控、物理接口加固，全面抵御网络攻击与物理安全风险。**在生态系统与集成能力模块方面：**阿里云 PAI 平台提供自研+第三方分布式训练框架、数据处理加速、推理优化工具提升训推效率；拥有超 1.2 万家覆盖渠道、ISV、SI、MSP 全类型的生态合作伙伴，设 AI 基础设施专项伙伴；通过“云工开物”计划支持超 150 所国内外高校、超 1000 项合作项目；积极参与开源，是 Apache 基金会顶级赞助商，发起中国最大开源模型社区 ModelScope，自研千问系列开源模型衍生数量超 Llama。

阿里云在创新指数排名第二，在以下指标项得分最高：存储架构设计方面，提供对象存储 OSS、高性能文件存储 CPFS、文件存储 NAS 等丰富存储系统；**AI 特化存储优化方面，**通过 PAI-DLC 平台 EasyCkpt、AIMaster 容错监控、SanityCheck 健康检查提升容错，以支持 AI 模型检查点的高效存储和恢复。**智能数据管理方面，**覆盖数据版本控制、元数据管理、生命周期分层冷热数据分层存储等，支撑 AI 工作流。**在架构可扩展性及多样化部署选项方面：**阿里云 PAI 灵骏智算服务具备 AIMaster 自动容错弹性训练、训练任务弹性伸缩能力，保障扩展性能一致性；依托专有云与公共云技术同源，支持本地部署的专有云平台平滑同步公共云产品升级，满足用户扩展升级灵活性。

2、腾讯云：打造了算、存、网、数一体的高性能智算底座

腾讯云集结软硬自研产品能力，打造了算、存、网、数一体的高性能智算底座。凭借 AI 基础设施产品的智能性能与稳定性、积极创新的研发态度与各行业丰富的经验领先行业。**1) 智算性能和稳定性：**腾讯云可实现集群千卡单日故障数低至 0.16，为行业水平的 1/3。此外，腾讯云的集群千卡 1 分钟能完成万卡 checkpoint 写入，数据读写效率为业界的 10 倍，通信时间更为业界的一半。**2) 积极创新：**腾讯云集结软硬自研产品能力，打造了算、存、网、数一体的高性能智算底座，在 AI 高性能计算、AI 高性能存储、AI 高性能网络、向量数据库等方面均进行了系统性的优化与创新，打破了算存网的“木桶”效应。**3) 应用场景丰富：**腾讯云产品应用场景丰富，其覆盖 B 端大客户、中小型企业与开发者等不同类型用户。覆盖包含互联网应用、出行与智能驾驶、大模型训练、广告搜索推荐、智能制造、医疗与教育等 15+ 个行业，积累了丰富的行业实践经验。




腾讯云在增长指数排名第二，在以下指标项得分最高。**资源配置与成本模型方面：**提供丰富工具协助成本预估与优化，通过费用中心实时监控识别浪费，开源 Crane 项目利用预测算法提前触发弹性伸缩，避免滞后。**能源效率与可持续性方面：**采用先进技术架构，第四代数据中心通过模块化预制设计降低碳排放，运营阶段年均 PUE 达 1.2，节能效果显著。**安全运营与响应方面：**构建“感知-决策-响应”一体化体系，智能监控风险，通过“三步应急”机制最小化事件影响并优化防护策略。

腾讯云在创新指数排名第一，在以下指标项得分最高。**资源利用率优化管理方面：**集成 TACO-DiT 和 TACO-LLM 等推理加速工具，大幅提升吞吐性能并降低运营成本；提供多样化调度与优化工具，通过 TCCL、星脉网络等优化，显著提升负载性能、通信效率及训练效率。**网络性能优化方面：**提供基于 RoCEv2 的智能高性能网络 IHN（星脉）；针对 AI 高带宽需求，通过构建全局拓扑与动态感知调度实现流量规划，相比传统方式显著提升通信性能与全网吞吐。

3、百度智能云：中国 AI 领域首个基于产业深度实践的基础设施

百度智能云 AI 大底座作为中国 AI 领域首个基于产业深度实践的基础设施，为广泛行业用户提供了一站式自主创新的解决方案，支撑企业在智能算力基础设施建设上实现集约化建设、高性能应用与持续性增强。



百度智能云坚持将自研技术贯穿完整架构，以构筑自主可控的核心产品与技术。其自研的 AI 大底座为各行业客户提供了从 IaaS 到 PaaS 的自主可控、自我进化的解决方案。**1) 广泛的行业覆盖：**百度智能云的 AI 基础设施解决方案已覆盖互联网、制造、能源、金融、交通物流等多个领域。此外，百度智能云拥有庞大的开发者社区和合作伙伴生态，为企业提供全方位支持，以确保客户建立长期合作关系。**2) 领先的自主创新能力：**百度智能云自研的“AI 大底座”由百度百舸计算平台与百度 AI 中台解决方案两大平台构成，为企业用户提供了从 IaaS 到 PaaS 的全栈自研、自主可控、自我进化的解决方案，支撑企业在智能算力基础设施建设上实现集约化建设、高性能应用与持续性增强。**3) 高性能“云智一体”架构：**百度智能云坚持“云智一体”架构，以各行各业的核心场景为切入点，构建更低成本的异构算力和更高效的开发运营能力，为各行业用户提供极致能效。

百度智能云在增长指数排名第三，在以下指标项得分最高。性能与成本平衡：通过算子融合、显存优化提升算力效率，并行与自适应调度提高利用率，多芯策略降低成本；针对不同规模任务提供差异化方案，大规模场景优化训练效率，小模型场景通过 GPU 切分共享降低生产成本。**行业客户与场景应用方案：**凭借 AIAK 加速框架、昆仑芯片等领先技术及完善服务体系，沉淀可观客户规模；应用场景全面覆盖金融、互联网、汽车等行业，与头部厂商密切合作，形成核心优势。

百度智能云在 AI 特化存储优化模块得分最高。PFS 采用内存缓存元数据管理+客户端缓存机制，减少网络与磁盘访问开销；通过 PageCache 缓存小文件，适配 AI 训练场景；依托 NVMe SSD 存储、元数据服务器扩展等完善方案，提升 GPU 与存储吞吐量、降低访问延迟；高性能 checkpoint 保存框架，单次保存耗时较开源方案最高减少 93%-99%。

4、星环科技：AI Infra 全栈解决方案供应商

从 **Data Infra** 延伸至 **AI Infra**。公司以大数据技术起家，AI 数据工程基因纯粹，具有大数据基础平台、分布式数据库、数据开发与智能分析工具、数据云平台等完整产品矩阵，覆盖大数据全生命周期管理。基于数据工程基因，大模型时代浪潮下公司业务定位由数字基础设施提供商进一步延伸至 AI 基础设施企业，通过整合大数据、人工智能等技术，推出知识平台 TKH，完善了 AI 从基础设施到应用的产业链条。

据星环科技公众号，5 月 27 日，星环科技主办“AI×Data：新一代 AI Infra”2025 年度产品发布会，星环科技正式发布 AI-Ready Data Platform 概念，并全面展示其构建新一代 AI 基础设施的核心能力。星环科技在此次发布会上重点介绍了 **Sophon LLMOps 1.6** 平台的四维进化，作为企业级 AI 基础设施，Sophon LLMOps 统一支撑空间管理、模型、算力管理、数据管理、通用工具，实现智能体驱动的 AI 全流程运营，实现了从数据到智能、从模型到应用的闭环升级，全面催化 AI×Data 的深度融合。

图15: Sophon LLMOps 1.6 平台的四维进化



资料来源：星环科技公众号，民生证券研究院

据星环科技公众号，星环科技在此次发布会上推出的新一代 **AI Infra**，不仅是一套完整的人工智能基础设施技术架构，更是一次关于未来企业智能化如何落地的系统性思考。新一代 AI Infra 旨在解决企业在 AI 落地过程中面临的数据和应用挑战。这一架构包含四大核心平台：**Knowledge Platform**（知识平台）、**AI Platform**（AI 平台）、**AI-Ready Data Platform**（AI 就绪数据平台）和 **Resources Platform**（资源平台）。

图16: 星环科技新一代 AI Infra



资料来源：星环科技公众号，民生证券研究院

5、达梦数据：全栈数据产品赋能 AI 落地

据达梦数据公众号，达梦数据聚焦数据管理、多模型训练、智能体生成，为用户解决智能客服、运维故障分析等场景问题。技术融合催生了新的增长极，达梦数据不仅深耕关系型数据库领域，还积极推动图数据库、缓存数据库、时序数据库、文档数据库等非关系型数据库和云数据库方面的全面布局，为 AI 时代筑基。

图19：达梦数据全栈数据产品



资料来源：达梦数据公众号，民生证券研究院

据达梦数据公众号，在基础资源层面，平台集计算、网络、算力、存储，构建了高度集成的硬件基础设施；模型底座集成 DeepSeek、Meta LLAMA3、Qwen3 等主流大模型，通过 vLLM 实现模型托管与推理加速。平台核心处理则实现多模型管理与智能体编排，支持模型接入、部署与启停的全流程管控。达梦启云数据库智能运维平台就是基于 LLaMA3.x、QWen2.5 等通用大模型做模型微调，能实现参数优化、SQL 生成与优化、数据探查、AI 自动优化数据库参数，解决人工调参效率低、难度高的问题。

图20：达梦智能运维专家



资料来源：达梦数据公众号，民生证券研究院

6、深信服：AI+超融合持续渗透

深信服提供包括虚拟化、超融合、轻量云等不同的基础设施产品和解决方案。深信服私有化部署的方案适合中国国情特点，通过一体机硬件搭载模型部署、同意纳管、微调、模型加密、应用开发等软件工具，通过硬件打市场、软件提供能力溢价的方式，能够认为未来在大型企业客户加速部署 AI 应用的进程中受益。

图 24：深信服的 AI Infra 工具提供从一体机-MLops-应用开发的一站式平台



资料来源：深信服科技官网，申万宏源研究

国际数据公司（IDC）最新发布的《中国软件定义存储以及超融合系统市场追踪报告，2025Q1》显示，深信服超融合在 2025 年第一季度，以 25.1% 的市场占有率位居中国全栈超融合市场第一。

AI 时代，超融合作为数字化转型的重要基础设施，用户对其期待已不仅是单一的承载应用能力，而是可以促进业务创新和高效运营的、真正面向未来的数字化底座。据深信服科技微信公众号，用户“未来化”的需求，需要数字化底座具备这些特性：可演进：从技术到架构可以持续演进；混合云：云上与云下协同构建混合云；通算智算融合：在通算基础上快速融入智算能力。因此，深信服超融合再次升级，将以轻量云实现用户的全栈需求。

图12：深信服超融体系




资料来源：深信服科技微信公众号，民生证券研究院

7、慧辰股份：实现从 AI Infra 到 AI 应用的全面打通

据慧辰股份公众号，2025 年，在 AI 软硬件融合方面，公司联合行业智算硬件合作方，基于 DeepSeek、Qwen 等大模型与慧 AI 数字员工产品，构建数字员工一体机解决方案。提供从“底层算力、大模型部署、推理训练、数字员工应用”的全栈解决方案，助力各领域用户完成“硬件+大模型+智能应用”的一站式部署，在知识检索、日常办公、知识库问答、数字客服等多个场景中，帮助用户形成覆盖“业务-服务-运营-决策”的智能应用能力。

图21：慧 AI2.0 数字员工



资料来源：HCR 慧辰股份公众号，民生证券研究院

据慧辰股份公众号，为推动算力普惠化，慧辰股份参与共建技术-资源-市场协同的“智算云产业生态”，签署“AI 公共算力平台软件”项目等，合作模式逐步由技术层面不断向产业生态深度延伸，与合作伙伴们从技术共建迈入商业化联合运营的新阶段，为千行百业提供高效、可信、便捷的智能算力服务。

图22：预置 AI 应用开发工具套件



资料来源：HCR 慧辰股份公众号，民生证券研究院

七、参考研报

1. 申万宏源-计算机行业 GenAI 系列报告之 65：AI Infra，应用渗透下的又一卖铲人
2. 申万宏源-计算机行业周报：AI Infra 梳理！物理 AI—数字孪生、具身智能实现基石！
3. 申万宏源-计算机行业周报：AI Infra，重点关注数据层软件及 MaaS
4. 东莞证券-电子行业 2026 上半年投资策略：AI Infra 市场有望高增，端侧创新在路上

5. 东莞证券-电子行业东莞 AI 产业系列报告之一：AI Infra 规模高增，PCB 产业链有望受益
6. 民生证券-计算机行业周报：国产 AI Infra 崛起，从算力到云与数据库
7. 沙利文&头豹研究院-2025 年中国 AI 基础设施行业市场报告
8. 国金证券-阿里巴巴~W-9988.HK-重启新篇章：聚焦、增长、重估
9. 中银国际-AI 算力行业产业链更新报告：需求闭环+供给放量，AI infra 供应链加速迭代
10. 中银国际-电子行业：AI Infra 升级浪潮中的材料革命，电子布、铜箔、树脂构筑 AI PCB 介电性能核心壁垒