

克莱尔

一种用于韧性估计的因果机器学习方法

塔利普·基利奇 马
科·莱塔 皮尔卢基·
蒙塔尔巴诺 费德里
卡·佩特鲁切利



WORLD BANK GROUP

发展经济学 发展数据组
2026年1月



Reproducible Research Repository

本文的验证可复现性包可在 <http://reproducibility.worldbank.org> 获取，点击此处直接访问。 [这里](#)

摘要

本文提出了一种新的韧性指数CLARE (Causal machine Learning Approach to Resilience Estimation)，它基于一个影响评估框架以及在纵向家庭调查数据中应用的因果机器学习算法。该指标是模型无关的、数据驱动的、可扩展的，并且规范性地锚定在福祉阈值上，可以是特定冲击的或通用的韧性度量指标。本文提供了一个构建CLARE韧性指数的经验证明，利用了来自19项由马拉维、尼日利亚、坦桑尼亚和乌干达国家统计局于2009-20年间实施的多主题纵向调查的超过28,000个家庭观测数据，这些调查与世界银行生活标准测量研究合作进行。尽管本文侧重于衡量干旱韧性，但所提出的指数适用于任何类型的冲击。分析表明

表明clare比现有的恢复力指标和预测粮食不安全性的替代方法（无论是在未来（动态预测）还是在留出的国家（横截面预测）中）表现更优。该指数可以被分解以因果地识别能够使人口免受冲击的恢复力能力的相对重要性。因此，它可以在设计、定位和监测旨在加强恢复力的政策和投资中得到应用。clare的实施——伴随着对国家纵向调查平台的持续投资——可以提升早期预警系统和恢复力建设干预措施的有效性，同时允许将恢复力政策建议从数据丰富的环境转移到可能无法立即提供所需纵向调查数据以进行指数估计的数据贫乏环境。

本文是发展数据组、发展经济学的一个产出。它是世界银行的一项更大努力的一部分，旨在向公众开放其研究成果，并为全球发展政策讨论做出贡献。政策研究工作论文也发布在 <http://www.worldbank.org/prwp> 上。作者可以通过 tkilic@worldbank.org 和 marco.letta@uniroma1.it 联系。本文的验证可重复性软件包为 [这里](http://reproducibility.worldbank.org) 可在<http://reproducibility.worldbank.org>获取，点击此处直接访问。



政策研究工作论文系列发布研究中的成果，以促进有关发展问题的思想交流。该系列的一个目标是迅速发布研究成果，即使展示的文稿并不完全完善。论文注明作者姓名，并应相应引用。本文中表达的研究成果、解释和结论完全是作者的个人观点。它们不一定代表国际复兴开发银行/世界银行及其附属机构、世界银行执行董事或他们所代表的政府观点。

克莱尔：一种用于韧性估计的因果机器学习方法

塔利普·基利奇

[‡]

，马尔科·莱塔

[§]

，皮耶鲁吉·蒙特阿尔巴诺

[§]

，费德里卡·佩特鲁切利

^{§1}

由海山·傅授权发行，世界银行集团发展经济学发展数据组首席统计师及主任

JEL代码：C31; O12; O15.

关键词 韧性；因果机器学习；纵向家庭调查，影响评估；预测分析；政策瞄准。

¹
tkilic@wordbank.org；

[§] 社会科学系与经济学院 [‡] 发展数据组，世界银行；罗马大学； marco.letta@uniroma1.it； pierluigi.montalbano@uniroma1.it；

federica.petrucelli@uniroma1.it。我们感谢克里斯·巴雷特对本工作早期版本的宝贵建议和深刻见解，以及阿莱迈尤·安贝尔、阿德里亚娜·帕奥兰托尼奥、多纳托·罗马诺、卢卡·蒂贝蒂、菲利普·沃尔堡，以及参与者们的 *CSAE 2025* 会议在牛津，*X开发者大会* 在罗马，和 *为更好的工作和生活提供更佳数据：人工智能时代调查测量创新* 在华盛顿举行的会议上，我们感谢他们的有益评论和建议。我们也感谢西奥班·默里在整合地理空间天气数据方面的帮助。

1. 简介

在多危机时代,识别最需要韧性建设干预的主体至关重要。有效瞄准和评估这些干预的必要要求包括韧性指标的规模性、它们与影响福祉的众多冲击和压力源的明确关联,以及所采用的韧性措施与其旨在反映的福祉结果的协调一致。换句话说,韧性指标应能准确地预测样本外福祉指标。所谓“样本外预测”,是指韧性指标在应用于先前未见数据时准确识别福祉结果的能力。这些数据可以来自同一时间点的其他家庭、地区或国家,也可以来自未来的时间段的全新数据。然而,现有的韧性措施往往缺乏规模性,未明确与冲击关联,并且在对样本外福祉结果进行预测方面最多只有中等能力(Upton 等,2022)。随着韧性概念被越来越多的捐助者、机构和国际组织所接受,并正在塑造人道主义和发展议程(贝内 等,2017),这些问题转化为对日益扩大的韧性导向干预措施的重大政策障碍。事实上,政策讨论越来越多地强调,气候韧性——作为更广泛韧性议程的一个突出维度——不仅受限于资源有限,还受制于测量系统薄弱,无法识别谁具有韧性、受何种冲击以及通过何种渠道。例如,世界银行近期的研究强调跟踪韧性仍存在局限,并且韧性建设政策中的瞄准和学习需要更好的、与决策相关的指标(希尔比 等,2025)。

我们通过利用机器学习(ML)算法来构建一个新颖的家庭韧性指标。这些算法擅长于预测样本外数据,并且被设计用来解决预测政策问题(Kleinberg等人,2015年;Athey & Imbens,2019年)。然而,我们不单纯依赖预测性的机器学习技术,这些技术现已成为实证经济学家计量经济学工具包中的标准工具。我们的方法结合了因果机器学习(ML)的最新创新(Wager & Athey,2018年;Chernozhukov等人,2018年;Chernozhukov等人,2024年),通过采用最先进的机器学习算法,这些算法专门用于预测异质性因果效应而不是结果。我们指标构建背后的原理——标记为CLARE(一个用于韧性估计的因果机器学习方法的缩写)——是直白的。CLARE是一个标准化的韧性子成分(在专业文献中通常被识别)的简单加权平均,在0-100尺度上进行了标准化以方便解释,并通过对超过规范福祉概率进行重新缩放。

冲击下的阈值。

²

新颖之处在于使用因果机器学习来构建一个数据驱动的权重方案，用于聚合韧性组件，这些组件源于对福祉、冲击和韧性驱动因素之间潜在因果关系的反事实评估。因此，CLARE基于一种使用非线性估计权重的线性聚合方法，从而平衡

因此，CLARE 解决了可信度这一具有挑战性的问题 复杂性和可解释性。

将不同的韧性子成分汇集到一个单一的韧性复合指标中。虽然复合指标能对研究对象现象提供综合和全面的了解，特别是对韧性这类潜变量而言，但它们也使得难以确定每个成分的具体作用和权重。在聚合过程中普遍且常常是随意采用假设相等权重或其他主观选择的做法——通常是为了简单起见——存在显著的方法论和实践挑战。这包括与真实世界数据生成过程的复杂性不一致，以及潜在威胁到政策目标的可靠性，政策目标常常依赖复合指标来指导优先排序和资源分配。

这正是我们因果机器学习方法发挥作用的地方：我们使用它来为每个韧性子组件推导重要性权重，以中介因果关系的建立 在感兴趣的冲击与旨在衡量复原力的结果之间。因此，整个因果机器学习流程的主要目的是进行关于福祉结果、协变量冲击和中介变量之间关系的初步反事实估计。这种估计最终会为CLARE中包含的每个韧性子组件生成凸性聚合权重，以及在有冲击情况下高于给定规范福祉阈值（例如，粮食不安全）的样本外概率。随后，最终指标在家庭层面计算为所有子组件的加权平均值，聚合权重（非负且总和为1）是在数据中学习到的因果模式上确定的，并通过家庭特定的冲击下粮食安全概率进行重新缩放。这种方法与合成控制方法（Abadie等人，2010）中为构建处理单元结果的反事实演变而重新加权捐赠池中的控制单元有些相似。

²

通过韧性子成分，我们指的是复合韧性指标的基本组成部分。在我们的语境中，这些代表了冲击对福祉结果的条件平均处理效应的驱动因素，按重要性排序。因此，这个术语不指框架如RIMA或TANGO中发现的中间结构，例如韧性“支柱”或“能力”，因为CLARE直接从原始韧性成分到最终复合指标，绕过了中间结构。

重要的是，虽然在我们说明的应用中我们展示了如何使用特定技术——因果森林（Athey等人，2019年；Wager & Athey，2018年）来计算CLARE，但CLARE并不依赖于任何特定方法。只要所选择的方法能够估计细粒度和异质性的处理效应，并能够建立起异质性驱动因素的客观层次，任何因果同样地，定义机器学习技术可用于识别潜在的根本因果关系。“变量重要性”可能因所采用的方法和重要性排序方法的不同而有所差异（例如，SHAP值、排列特征重要性）。因此，尽管CLARE基于因果机器学习技术家族中的一种方法使用，但它模型无关。

尽管CLARE以数据驱动为基础，但它并非一个黑箱。首先，对潜在因果关系的识别完全根植于潜在结果框架（Imbens & Rubin, 2015）。其次，虽然CLARE对于各个子维度在缓冲冲击影响方面的相对重要性保持中立，但在估计过程中所选的子维度——即所谓的“处理效应调节器”（Athey & Imbens, 2016）——完全依赖于关于家庭韧性主要驱动因素和决定因素的前期研究（Upton et al., 2022）。与此同时，CLARE的灵活性使其能够在全面捕捉韧性所有相关维度的代表性与识别进行稳健样本外预测所需的最小变量集合之间取得平衡。这使得即使在数据收集困难、昂贵或两者兼有，必须做出优先选择的情况下，也能精准定位干预措施。因此，我们指标的建设并未牺牲透明度和可解释性。

在这个以冲击为中心的韧性建模框架中，冲击起着核心作用，CLARE的估计完全围绕并将冲击从最初就纳入分析，解释每个分析的韧性子组成部分在决定冲击的异质性效应中发挥的保护作用。

³ 因此，CLARE得分可以被解释为“确保压力和冲击不会产生长期负面发展后果的承载能力”（Constas等人，2014年）。在本文中，我们应用该方法来构建一个指标。干旱韧性使用干旱作为关键冲击，并将粮食安全作为结果。我们还讨论和展示如何结合多种冲击，并在CLARE框架内估计一个“通用型”的恢复力指标。更一般地，CLARE可以适应影响福祉的任何类型的冲击以及任何福祉结果。

³ 重要的是要认识到，如果由（未保险）风险敞口造成的重大损害主要源于家庭为应对冲击的可能性而做出的行为调整，那么我们的衡量标准（与其他现有的韧性指标类似）可能无法充分捕捉这些风险。在这方面，我们估计的冲击效应应该被解释为下限——对这种冲击真实影响的一个保守估计。

这种多功能性和对冲击的明确挂钩与现有指标相比是新颖的，这源于这样一个事实：就其核心而言，CLARE是建立在一个影响评估理念的基础上，而这一点我们也与其他关于韧性的近期研究（Alloush & Carter, 2024）共享。

Claire 的重要特性之一是其可扩展性：一旦使用因果机器学习估计了权重和条件概率，在冲击、结果和韧性子组件之间关系所依据的数据生成过程的稳定性或不变性假设下，对新数据计算指标就变得简单直接。只需在冲击场景下对样本外预测超过或低于规范阈值的概率，并将韧性子组件的新值代入，使用预计算的权重来计算它们的加权平均值即可。关键点在于，当从另一个地区（甚至国家）计算新数据的指标时（因此旨在实现横截面预测），用户必须假设各种组件的相对重要性权重保持不变。使用机器学习算法对保留的测试数据进行预测可以提供关于这一假设可信度的间接证据。例如，在一个国家集合上训练的模型在由来自未知国家的观察值组成的测试集上表现良好，会表明没有分布偏移，模型能够很好地泛化到新数据，因此可以用于迁移学习。类似地，如果新数据代表未来数据点（预测），则假设福祉结果、冲击和条件变量之间的关系随时间保持稳定。重要性权重的稳定性也可以通过我们在后面章节中展示的经验方法进行评估。

在这些假设下，CLARE 可用于数据稀缺环境中的迁移学习，其中仅提供横截面数据，或用于旨在为易受冲击地区脆弱家庭（或更宏观的单位）实施危机准备和预警机制的目标预测。

⁴ 此外，估计数据驱动权重能够建立韧性组成部分之间的客观层次。这反过来又为机构和政策制定者提供了机会，从成本效益的角度出发，确定在特定情境下能够最大程度提高整体韧性能力的最重要可靶向家庭特征。

这项工作属于发展韧性文献中的定量研究。具体而言，我们借鉴了Upton等人（2022年）建立的方法论框架——尽管在不同的背景下

⁴ 原则上，CLARE的方法论可以适应用于估计社区和价值链等较大分析单元的韧性指标。

以脆弱性为重点，由Doan等人（2023年）构建和测试我们的韧性指标，使用全国代表性、多主题的 *纵向* 来自世界银行生活标准测量研究（LSMS）的家庭调查数据。这些数据因其对构建韧性指标至关重要的关键属性而被选中，包括其纵向结构、多主题覆盖、数据协调以及允许与气候、冲突和环境等地理空间数据集成以提供冲击暴露客观指标的地理参考数据收集。具体而言，我们分析了来自四个撒哈拉以南非洲国家（马拉维、尼日利亚、坦桑尼亚和乌干达）的纵向调查数据，这些国家目前都将韧性作为主要政策议题，该数据集包含超过35,000个初始观测值和19次调查波次。该数据集比之前在专业文献中使用的那些数据集要大得多，在外部效度方面为我们的研究结果提供了比较优势。我们的结果表明，CLARE表现出良好的样本外性能，无论是在预测已排除国家（横截面预测）的数据中的粮食不安全，还是在预测未来已排除观测值（动态预测）的粮食不安全。在这些任务中，CLARE始终优于Upton等人（2022）研究中表现最佳的韧性指标——即从Cissé和Barrett（2018）基于条件矩方法得出的经验参数化规范——以及其他现有的韧性指标和替代估计方法。CLARE表现更好的原因可能在于因果机器学习工具能够灵活捕捉由于初级韧性组件的差异而导致的协变量冲击对福祉影响的家庭层面异质性，以及它们处理潜在数据生成过程中的非线性和交互作用的能力（Hastie等人，2009）。最后，我们提供了CLARE在多个天气冲击数据集和备选韧性组件集合中表现稳健的证据。

本文的主要贡献是实质性的：我们向韧性实践者的工具箱中引入了一个新的韧性指标，该指标足够灵活，可以应用于不同的冲击和实证背景。如所解释，CLARE被构想为一个介于冲击与发展结果之间的解释变量，并作为连续指标进行估计。然而，CLARE也可以产生一个二元指标，将家庭分类为“有韧性”或“无韧性”，这可能在政策瞄准目的上更实用。它表现出内部一致性，并且，按设计，与一个规范性阈值或福祉标准相关联，这与韧性的另一个关键定义相一致：“即使在面对冲击和压力因素时，也能实现并维持可接受的福祉标准”（Barrett & Conostas, 2014）。因此，CLARE也可以作为目标变量的结果变量。

评估目的。

⁵更广泛地说，我们为关于多维福祉指数聚合的发展文献做出了贡献。这些指数常常因为将各个组成部分合并成一个综合指标所涉及的任意选择而受到批评（Duclos等人，2006年）。在这种情况下，正如本工作所概述的，基于事后评估的数据驱动权重理念，可以为聚合超出韧性的综合指标提供一种更客观的方法。

本文其余部分安排如下。第二节介绍相关文献和概念框架。第三节描述了方法。第四节展示了对该方法构建干旱韧性综合指标的实证应用。第五节总结。

2. 相关文献和概念框架

这项工作与两个主要领域的文献相关：一是利用机器学习算法进行开发的方法论文献，我们在此基础上提出因果机器学习方法，以创建复合开发指标；二是关于开发韧性的理论和实证文献，我们从其中汲取支撑我们韧性指标概念框架的理论基础。

从方法论角度来看，我们首次使用因果机器学习算法构建家庭韧性指标，更一般地，构建发展领域的一个复合指标。尽管机器学习最近已被广泛用于发展中预测和映射贫困和粮食安全结果，并且也结合使用非传统数据源（例如，Aiken等人，2022年；Aiken等人，2023年；Baez等人，2024年；Barriga-Cabanillas等人，2025年；Blumenstock等人，2015年；Browne等人，2021年；Constenla-Villoslada等人，2025年；Echevin等人，2024年；Hossain等人，2019年；Jean等人，2016年；McBride和Nichols，2018年），但因果机器学习工具尚未被采用。

⁶在韧性文献中，只有少数研究（Garbero & Letta, 2022; Knippenberg 等, 2019; Villacis 等, 2024）在韧性测量情境中采用了机器学习算法。具体而言，Garbero 和 Letta (2022) 采用一组监督机器学习算法，使用国际农业发展基金会的跨国数据来预测从冲击中恢复的主观能力。Knippenberg 等

⁵使用 CLARE 进行后续影响评估意味着将其作为结果变量，以估计某个项目对家庭韧性的影响。目前，唯一可用于此目的的韧性指标是 Cissé 和 Barrett (2018) 的韧性得分。然而，将 CLARE 作为影响评估的结果变量，需要采用合适的方法进行推断并考虑不确定性（例如，自举法），因为结果将是一个估计值而非观测值。

⁶最近的一个例外是Letta等人（2024年）的研究，他们使用因果森林研究了气候移民响应中的异质性。

(2019) 使用 LASSO 和随机森林识别应对策略指数 (CSI) 的最佳预测因子，使用来自马拉维的高频（每月）数据。Villacis 等人 (2024) 使用食物不安全体验量表作为韧性能力的代理指标，并使用来自世界银行四个非洲国家的两次电话调查数据，表明机器学习模型可以在分类框架内有效预测韧性。

重要的是要理解我们研究中使用ml与上述讨论中使用的ml之间的根本区别。在后一组中，ml被用来简单预测给定一定的韧性行测，揭示预测因素中与结果高低相关的系统性模式以及“异常变量”。这些预测模型只能揭示韧性预测因素与韧性能力之间的关联和相关性模式。然而，在韧性分析中，因果关系很重要：冲击、福祉和韧性驱动因素之间的关系是因果关系，而不仅仅是相关性，因此需要严格的因果推理技术。我们的因果机器学习方法不同，因为我们使用的是预测治疗效果而不是结果的新技术，并且这些技术完全嵌入在因果推断计量经济学中的潜在结果框架中。为此，我们针对由一组调节变量定义的特定子群体——在我们的案例中是韧性子组分——估计了细粒度的治疗效果。估计的CATE指标了潜在机制 (Knäuper, 2022)。

因此，因果机器学习是估计韧性的理想工具，因为它解构了福祉与冲击之间的因果关系，并识别出能够使不同子群体免受或暴露于冲击不利后果的韧性能力和组成部分。最后，由于针对纵向调查数据开发，CLARE比Garbero和Letta (2022)以及Villacis等人 (2024)更有效地追踪韧性动态。同时，它不需要高频数据，而Knippenberg等人 (2019)提出的预测机器学习方法则依赖于此。这对所提出指标的可扩展性而言很重要：在发展中，高频数据很少，大多数调查轮次最好每两到三年进行一次。

从概念层面来看，我们提出的方法与多种理论基础相符。具体而言，CLARE 解决了 Barrett 等人 (2021) 确定的韧性两种主要类型，即韧性作为 *事前产能* 和韧性作为 *规定条件*。

⁷
事前能力

⁷ 巴雷特等人(2021)引入了第三种韧性概念：韧性作为一种恢复到均衡状态。这种方法描述了一个条件——具体而言，对冲击的事后恢复——而不是试图明确建模最终导致恢复的各种能力。然而，这种韧性概念与更紧密地

概念化（即最常用方法）将韧性视为一个潜变量，它能捕捉个体、家庭或更大单元中可观测和不可观测属性的综合影响，这些单元能够减轻来自事前风险和/或事后冲击对福祉的负面影响（Béné等人，2014）。像潜变量一样，测量这类韧性类型仍然是一个挑战。在这种情况下，一些学者（Quandt等人，2019；Woolf等人，2016）从资产角度强调家庭韧性，认为在一系列标准资产类别（包括人力和社会资产）中得分较高的家庭更有可能具备韧性。其他人，如FAO RIMA（FAO，2016；D’Errico & Di Giuseppe，2018；D’Errico等人，2019）和TANGO（Smith和Frankenberger，2018），提议使用因子分析来推导一些可操作的“韧性能力”或“支柱”，作为解释变量并呈现它们与福祉结果的关联。同样地，Béné（2013）进一步强调了适应策略在风险暴露中的作用。

关于韧性被概念化为一种规范条件，Barrett和Costas（2014）以及Cissé和Barrett（2018）将其定义为在一系列可观察特征和冲击暴露的条件下，个体达到某种最低生活水平标准的概率。这种规范韧性的经验性衡量指标的局限性在于：(i)对所采用的福祉衡量指标选择的敏感性；(ii)在经验识别冲击暴露方面的挑战；以及(iii)不可观测因素（如社会资本、认知，以及更广泛地，定性和心理社会因素的作用）的混杂影响（Carr，2019）。Cissé和Barrett（2018）提出的基于概率矩的方法提供了一个经验框架，通过整合捕捉韧性动态的随机元素来估计韧性作为一种规范条件，特别适合于政策及项目评估，并且最近已在若干韧性测量研究（Upton等，2016；Knippenberg等，2019；Upton等，2022；Scognamillo等，2023）以及影响评估（例如，Premand & Stoeffler，2022；Ranucci等，2025）中应用和扩展。

使用埃塞俄比亚（2011年至2016年三个调查波次）和尼日尔（2011年至2015年两个波次）的纵向LSMS调查数据，对三个主流韧性指标进行比较评估，Upton等人（2022）认为这些指标缺乏实证检验。具体而言，他们发现了这三个指标分布中存在显著差异，以及它们

以生态学中使用的韧性概念为依据，其在发展实践中效用有限，学者和实践者通常会处理不良的初始状态，例如贫困或粮食安全（Montalbano和Romano，2022）。

在家庭韧性方面的相对排名。此外，他们还表明，这些方法在样本外表现令人失望。表现最好的指标——迄今为止由 Cissé 和 Barrett (2018) 开发的那个——在其应用中仅实现了适度的整体准确率，而 RIMA 和 TANGO 的表现不比随机猜测好。此外，没有一个韧性指标预测得比使用最新观察到的福祉值来预测未来福祉的远更简单的方法明显更好。因此，Upton 等人 (2022) 认为，这些指标在预测和目标定位性能方面所带来的额外价值仍然不明确。总的来说，作者们得出结论：“目前正在使用的这些方法，充其量是不完美的，而最坏情况下则是存在严重缺陷。”因此，毫不奇怪的是，迄今为止韧性指标主要被用来推动发展干预，但用于目标定位或影响评估的就非常少 (Barrett 等人，2021)。

尽管有这些令人失望的证据，发展韧性测量处于新一轮实证研究的前沿。这源于对有效的靶向方法和稳健的实证评估的需求日益增长，以支持韧性建设干预措施。作为这一努力的一部分，Alloush和Carter (2024) 提出了一个韧性测量的反事实方法，该方法在理论上和实证上根植于影响评估传统，并基于一个可定量估计的韧性指标，以与家庭福祉的无冲击反事实测度相关联。引入这个无冲击（且可能无风险）反事实基准，使他们能够解决Cissé和Barrett (2018) 基于条件矩的方法的局限性，即依赖于预先定义的福祉水平（例如贫困线），这限制了非贫困家庭韧性动态的全面分析，以及对该福祉指标选择的敏感性。我们的工作基于类似的假设，即我们数据驱动的权重的推导也是基于在无冲击情景下识别和估计家庭特定的反事实结果以及相关的条件平均处理效应。

李等人 (2025) 也解决了使用预定义福祉指标的限制。他们认识到，使用不同指标构建的复原力指标会导致家庭排序不一致，这削弱了旨在提高发展复原力的干预措施的有效性。他们探索了如何通过不同的加权方案来汇总这些结果，以创建一个更全面的复原力指标，该指标植根于 (a) 西塞和巴雷特 (2018) 基于概率矩的复原力测量方法与 (b) 阿尔基尔和福斯特 (2011) 的多维度贫困测量框架的整合。这种整合的优点在于能够

更广泛地识别发展韧性。与此同时，单变量和多维度韧性指标表现出不同的分布并暗示不同的家庭排名这一事实，仍然未能解决与项目/政策目标定位和影响评估相关的关键问题。他们使用不同福祉代理指标的综合权重，与我们的使用数据驱动型机器学习技术来推导韧性组成部分的综合权重的方法相类似。我们的工作，其重点在于韧性指标的解释组成部分的综合，而非结果指标，因此与其方法是互补的，并且有可能与其整合。

在此背景下，CLARE 通过运用数据驱动技术，识别并评估介导冲击、结果和韧性子成分之间关系的最相关传输渠道的相对权重，推进了该领域的研究现状。这种方法完全透明、灵活且可复制。它能够进行非线性多重均衡经济轨迹的非参数实证识别，完全符合韧性及贫困陷阱文献，并能够确定替代政策行动的优先级。在这方面，CLARE 具有双重作用：它作为一种规范性工具将家庭分类为韧性或非韧性，并作为一种解释性（或中介）变量，综合地将冲击与发展结果联系起来。它遵循最相关的实证文献，旨在平衡纳入新维度的信息价值增加与可能损害样本外性能的潜在覆盖范围损失。尽管所选代理指标可能具有情境特殊性并引发关于最合适的韧性评估指标的进一步讨论，CLARE 识别了支持可靠样本外评估所需的最少代理指标——即使在数据稀缺的环境中也是如此。

3. 方法论

CLARE的构建涉及三个顺序步骤：(1)估计，(2)聚合，(3)评估。每个步骤下面将详细描述。

3.1 估计

构建CLARE涉及估计两个主要要素：(1) 弹性子组件在驱动结果和冲击之间的关系中的数据驱动重要性权重，以及(2) 如果冲击发生，家庭特定的超越或低于规范福祉阈值的条件概率。

为了估计这些效应，我们采用因果机器学习技术。虽然各种方法都适合这个目的，

⁸

我们专注于 **因果森林**，用于估计条件平均处理效应 (CATEs) (即基于选定协变量的处理效应异质性非参数估计) (Athey & Imbens, 2016; Athey et al., 2019; Wager & Athey, 2018)。它们将随机森林——一种强大的监督机器学习方法，用于根据一组输入预测结果 (Breiman, 2001; Hastie et al., 2009)——应用于预测因果效应的异质性。同样，对于变量权重，我们依赖于该特定方法产生的重要性排序。然而，在可解释机器学习领域有几种替代的重要性度量方法可用。其中大多数是模型无关的 (例如，SHAP 值、排列特征重要性)，也可以用于聚合 CLARE 分数。

⁹

因果森林算法构建了一个因果树集成。每棵因果树由数据驱动的样本分割定义，这些分割形成叶子，然后基于一组条件特征 (所谓“处理效应调节器”) 在终端节点进行因果效应预测 (Athey & Imbens, 2016)。目标是分割数据以最大化叶子的效应异质性。为了防止过拟合风险，该算法采用“诚实方法” (Athey & Imbens, 2016)，将样本随机分成两半：一半 (预测样本) 定义样本分割，另一半 (估计样本) 估计预测的 CATE。这一过程重复进行，直到森林中的树数量 (在我们的应用中为 2,000 棵)。每棵树根据候选协变量识别出处理效应差异最大的子群，最终预测是跨树预测的加权平均值。这个平均值是一致的，并且渐近正态分布 (Wager & Athey, 2018)。此外，因果森林可以应用于观察性研究的纵向数据 (如本例) 或随机对照试验，以估计异质性处理效应 (Athey et al., 2023; Britto et al., 2022; Knittel & Stolper, 2025; Letta et al., 2024; Miller, 2020; Johnson et al., 2023; Zhang & Luo, 2023)。

在构建我们的模型之前，我们将样本分为两个不同的集合：一个训练集，我们在其中估计韧性组件的权重并开发我们的模型，以及一个测试集，我们在其中评估模型的预测性能。这些集合的定义取决于预测目标。如果目标是预测，则训练集应包括早期的波次，测试集应包括后期的波次。对于横截面预测，例如“国外”预测，训练集应轮换以包括除一个国家之外的所有国家，测试集则是被遗漏的国家。

⁸

对于此类方法的全面综述，参见 Chernozhukov 等人 (2024)。

⁹

参见 Molnar (2020) 对这些技术的概述。

在我们纵向设置中，我们将结果、冲击、韧性分量和混杂因素之间的关系建模为公式1所示：

$$y_{it} = (\alpha_i + \beta_i t) + \gamma_i (y_{i,t-1} - \alpha_i) + \epsilon_{it} \quad (1)$$

在说明性应用中，“粮食安全”状态，即定义为粮食消耗

表示一个与规范阈值锚定的二元福祉结果。即，在我们的ion评分等于或低于35时，使用与Upton等人（2022年）相同的阈值，用于家庭 i 在调查波 t 是捕捉冲击暴露的二元变量，定义为单一类型的冲击（如干旱、洪水、冲突等）或冲击的发生至少一个（或另一个阈值）在多次冲击之中。是于时间测量到的时变混杂因素的向量 $t-1$, which should also include some or

捕捉时间

如果研究人员认为他们能够自主影响结果，那么所有韧性子组件都可以独立于它们在冲击方面的保护作用之外发挥作用

；和是

包含所有时变控制量的单位特定和波特定平均值的Mundlak型控制量 - 不变和时变未观测异质性

和 () 捕捉了冲击的异质性效应，这些效应取决于一个特定于家庭的值的数量（我们稍后用索引表示 j ）中的韧性子组件

受冲击影响，且不存在“不良控制”问题

测量于时间 $t-1$ ，确保它们不是

玩耍中。

这个部分线性模型旨在非（

），捕获混杂效应。它在结构和之间取得平衡

参数化估计冲击效应

（，具有灵活性和可解释性，因为冲击效果是可加的和可解释的，而

在未处理潜在结果的生成过程中，条件是其可以表现出几乎任意的复杂性）

切罗诺祖科夫等人，2024)——一种复杂性，我们使用完全非

参数方法。冲击变量被假定为

独立于潜在结果

基于控制 (Angrist et al., 2019) 是必要的主要识别Upton等人（2022年）所建议的，并且允许估计低于（或高于）这样一个规范性阈值的条件概率。然而，CLARE后来被估计为一个连续指标，该指标可以被二值化，并可与连续或二元福祉结果进行比较，正如我们在应用中将要展示的。

为了捕捉未被观察到的异质性（参数设置中的固定效应），我们包含Mundlak型控制变量（Mundlak, 1978）。这种方法涉及将随时间变化的协变量的单位和时间特定平均值作为共同解，以控制时间不变和随时间变化的未被观察到的异质性——不仅适用于标准的预测机器学习，也适用于因果机器学习方法以及其他旨在解释群体水平未被观察到的异性的新因果推断技术（Arkhangelsky & Imbens, 2024; Chernozhukov et al., 2024; Wooldridge, 2021）。为了实现这种方法，我们使用了Johannemann等人（2019）提出的分类变量充分表示的方法，该方法是 *sufrep*，一个同包 *grf*。

不是我们的主要关注点。相反，我们专注于两个估算CLARE所需的关键要素：(i)如果冲击发生，高于规范阈值的概率，这是冲击下低于阈值的概率(例如，粮食不安全)的补集；(ii)基于训练集数据、仅有的因果森林的变量重要性排序，它为每个韧性子组件提供数据驱动的估计重要性值，以调解冲击与结果之间的因果关系。每个韧性子组件的重要性权重是从因果森林模型生成的变量重要性度量中推导出来的。“变量的重要性”是通过韧性组件的频率来衡量的 j 在分割上。将重要性度量解释为“权重”意味着它们反映了每个变量对减轻冲击对家庭福祉的负面影响的贡献程度。

12

在因果森林方法中，数据根据条件特征进行递归划分，形成具有异质效应的子组。在树的每个分裂点，算法选择最适合将数据划分为具有不同处理效应的组的变量。这个过程在森林中的所有树中重复进行，每个协变量在这些分裂中被使用的频率表明其相对重要性。形式上，协变量的重要性权重影响家庭的整体反应性。一个反应性分量 α_j 在 j 中出现的频率越高，它在解释不同家庭如何响应冲击 j 方面的作用就越关键。 α_j 是森林中所有 j 中作 j 分裂变量的分割比例。 α_j 个权重 α_j 反映了的作用 j 确定了相同冲击的变量。我们使用凸相对重要性权重，这些权重是非负的，并且总和为1。

13

关键在于，数据驱动权重的估计完全使用训练集数据执行，而不是在将要对CLARE性能进行测试的测试数据（用于预测和横截面预测的后续波次或其他国家，分别对应）上进行。因果森林的整个开发过程仅在训练数据的子集上运行，因此特征重要性排序反映了每个组件在决定冲击对结果的影响中所起的作用。训练数据集。这很重要，因为它允许我们将权重“导出”到其他数据中，为插入新值

12

某些变量实际上可能会放大而不是减轻冲击的影响，例如市场距离。在这些情况下，如我们后面解释的，我们使用估计的权重，但在最终聚合中取标准化变量的补数，因此，如示例所示，市场距离的补数对整体韧性得分有积极贡献，其权重由森林估计。

13

关于纳入处理效应调节因素集合中的相关变量问题，有一个重要的注意事项。大多数建立特征重要性排序的机器学习技术——包括我们此处关注的因果森林产生的变量重要性度量——对相关特征是敏感的，其含义在于添加一个相关变量可以通过在他们之间分配归因来降低其相关特征的重要性（如 Molnar，2020 年所述）。这可能导致两者一起纳入时特征重要性都较低，但在模型中排除相关变量时，每个特征的重要性都很高。

这些新数据中的韧性组件，并在保留的观测值上计算它们的加权平均值。其基本假设是权重在不同数据集之间保持一致，并且在训练集中估计的输入-输出关系在新的环境中也成立。在预测方面，这转化为估计关系的时间稳定性；对于基于其他国家数据的横截面预测，这意味着一旦过滤掉国家固定效应和许多其他混杂因素，不同韧性组件的权重及其层次结构在不同国家之间是相同的。

最后，虽然权重后来用于变量聚合，但在因果森林估计结束时，在测试集可用且与训练集使用相同的变量集的情况下，对于新观察值，因果效应的预测和低于阈值的条件概率——用于重新调整加权平均分量（见下一小节）——是进行样本外预测的。在我们的情况下，我们为完整样本（包括测试集）产生样本外预测，而不仅仅是后者，因为我们想要为整个样本估计CLARE。然而，CLARE的样本外性能将专门在测试数据上测试，该数据在训练阶段模型从未见过。

在进行CLARE的最终计算之前，有两个额外的要点需要说明。首先，与其他韧性估计方法不同，上述方法是完全灵活和非参数的，在关于潜在数据生成过程的功能形式方面不作任何假设。这种灵活性允许对福祉和韧性动态特征的非线性福利关系进行平滑估计，如第2节所述，并在非线性福祉和贫困动态以及基于资产的贫困陷阱文献中得到强调（Barrett等人，2016；Carter和Barrett，2006）。相比之下，这种非线性在其他韧性指标中，如Cissé和Barrett（2018）的韧性得分，只能通过包含福祉多项式来部分解释。

其次，这种方法论不一定与特定方法相关联，即因果森林。其他因果机器学习方法可以被采用来估计目标量，只要它们(i)估计特定家庭的条件平均处理效应和概率，以及(ii)输出变量重要性排名或类似结果（例如可解释人工智能文献中的SHAP值（Lundberg & Lee，2017）或局部替代模型（Molnar，2020）），这些能够解释机器预测并可用于推导韧性组件的数据驱动权重。

14

¹⁴ 参考 Chernozhukov 等人 (2024) 对适用于治疗效果异质性的替代因果机器学习方法进行的综述。

3.2 聚合

在估计的第二步中，重要性权重和条件概率被聚合到最终的CLARE指标中。具体来说，CLARE被计算为预先冲击值的加权和 J 弹性子组件，必须在0-1范围内预先归一化才能聚合。

¹⁵ 每个子组件 j 弹性组件向量的 z 家庭使用 i 乘以其从因果森林得出的相应重要性权重。然后将加权子组件通过求和进行聚合，并根据冲击发生时处于规范阈值（粮食安全）以上的概率进行重新缩放。更具体地， $\square$ 算CLA $\square\square\square\square$ 的公式 $\square\square\square\square$
Re 在式2中给出：

$$CLARE_{it} = \sum_{j=1}^J \omega_j Z_{it-1} * (1 - Pr(W_{it} \leq \underline{W} | S_{it}, X_{it-1}, X_i, X_{t-1})) \quad (2)$$

where

$\square = 1$
($1 - \square$) (冲击情景下的福利阈值。这种聚合方法确保了子c
 $\sum \square\square\square\square \square\square\square\square \square\square\square\square \square\square\square\square \square\square\square\square \square\square\square\square\square\square\square\square$
与韧性相关性更大的组件，如因果森林所识别的，
 $\square\square\square\square\square\square\square\square$
最终指标。 $-PPrrWw \leq Ww$ 是数据驱动的加权平均值。 J 滞后的弹性组件，和
 $\square$
, , ,)是超过规范的条件概率 |
重新 $\square$ 放 $\square\square\square\square \square\square\square\square\square\square\square\square \square\square\square\square \square\square\square\square\square\square\square\square - 1$
通 $\square$ 在冲 $\square$ 下的食品保障条件概率完成 $\square\square\square\square \square\square\square\square$ 。
 $\square\square\square\square \square\square\square\square$
 $\square\square\square\square - 1$
e 在其中权重更大，因为分量加权的平均值关系到由于冲击而发生的福祉变化；因此它不一定与福祉水平相关。然而，复原力指标应该与其他福祉水平变化相关（Upton 等人，2022年）。由于归一化加权平均值和概率都在0-1范围内，所以它们的乘积CLARE也在这个范围内。然后我们将其乘以100以增强可解释性，就像对其他复原力指标所做的那样。

注意我们在时间上索引CLARE t ，但是用于计算索引的元素都基于只有当的信息创建 $t-1$ 或者（在时间趋势的情况下），不需要数据收集和在本轮中可用性。这是因为CLARE被设计为前瞻性

¹⁵ 韧性组件在不同尺度上被衡量。因此，为了使组件之间具有可比性，在进行聚合之前必须对变量进行标准化——通常通过将其归一化到均值为0和标准差为1。此外，复合指标的所有组件必须具有相同的极性，即组件与感兴趣现象之间的关系符号。因此，与粮食安全结果呈负相关（例如，距市场的距离或农村地区的虚拟变量）的标准化变量被视为其补充，这样它们可以正向地贡献于韧性能力，同时保持其与结果的绝对相关值。这符合RIMA和TANGO等主流指标聚合的既定做法。

从福祉状况角度进行评估，并适用于预期政策目标。例如，当前波次中的高CLARE分数表明，根据前几波次的数据，如果一个家庭受到冲击，它很可能保持在规范性阈值之上。可以使用不同的标准构建二元分类，具体取决于应用以及优先考虑的假阳性与假阴性之间的权衡，同时也要考虑成本效益。在应用中，我们遵循Lee等人（2025）的研究，使用中位数CLARE分数来区分有韧性家庭和无韧性家庭。

3.3 评估

对任何模型的预测性能进行严格的外部样本测试，必须使用模型未训练过的先前未见数据。这引入了“防火墙”原则：生成预测函数所涉及的所有数据都不能用来评估它（Mullainathan & Spiess, 2017）。测试集中保留数据的模型性能可被视为“真实”性能的可靠度量（Hastie et al., 2009）。我们对两种外部样本测试感兴趣：

- i) 使用仅基于从前几波数据估算的量计算得到的CLARE值，预测未来未被包含时段中观测对象的福祉状态。
- ii) 使用在不同训练国家（基于家庭数据估计权重）计算的CLARE值，对排除的（测试）国家的家庭福祉状态进行预测（横断面预测）；我们将这项预测任务标记为“跨国家”测试。

我们的样本划分不是标准的机器学习中的随机划分，而是基于时间或国家来避免在将机器学习应用于纵向数据时出现“数据泄漏”（Cerqua 等人，2025），即导致过于乐观评估的训练集污染。在为每个任务分别估计目标量之后，可以使用一系列适用于回归（例如，均方误差（MSE）、R平方、相关系数）和分类任务（例如，混淆矩阵、AUC-ROC）的指标来评估CLARE的样本外性能。然后，可以将其性能与其他现有指标进行比较。

CLARE的完整流程总结在表1中。在下一节，我们将该流程应用于第4节所述的纵向调查数据，用于样本外预测和国家外预测粮食不安全。

表1：CLARE流程

1. 初步——数据划分
我们将完整数据集划分为一个训练集，我们将在其上计算韧性权重和条件在冲击情景下低于规范阈值的发生概率，以及一个测试集，我们稍后将测试样本外的性能。训练集和测试集的定义取决于预测目标：如果目标是预测，训练集应包含早期的波浪，测试集应仅包括后者的；如果目标是横截面预测——例如，境外——则训练集应该是包含所有除一个国家之外的旋转的，测试集应该是被遗漏的那个国家。
2. 估计——仅使用训练集
在这一步，我们使用因果机器学习工具（例如，因果森林）来估计冲击的异质性效应（例如，干旱）对二元福祉结果（例如，粮食不安全状况），在冲击发生前的条件下弹性子组件的值。基于二次正交的非参数估计消除混杂效应，而异质性效应的估计基于残差对残差在弹性子成分上的回归。在本步骤结束时，我们推导出基于数据的来自韧性子组件的变量重要性排序的权重。
3. 预测
配备了在训练集上估计的模型，我们在完整样本上预测结果，该样本包括测试集观测值。这允许推导出超过规范值的条件概率冲击下的阈值，以及冲击的异质性、特定于家庭的影响。
4. 聚合
我们接着按照如下方式计算CLARE：i) 权重聚合：我们对一个特定家庭的加权标准化韧性子组件的平均值，权重来自步骤2；ii) 重新缩放：我们按冲击下超过阈值的概率估计对该加权平均值进行缩放；iii) 索引缩放：我们乘以 100 得到一个 0-100 指数；iv) 离散化：连续指示器可以使用不同的标准离散化为一个二进制。这个过程是针对全部进行的。用于估计所有观测值的韧性指标样本；然而，样本外性能测试必须仅在测试集数据点上执行。
5. 评估 - 仅使用测试集
我们评估了CLARE在预测被遗漏的wellbeing结果上的样本外性能测试集（用于预测中的后期波次；用于跨国预测的境外国家）使用各种常见回归和分类任务的性能指标，分别使用连续和二进制结果和指标的对。我们还比较了CLARE与其他主流的性能。恢复力指标和替代方法。

4. 经验应用

4.1 数据

4.1.1 调查数据

我们分析的调查数据来自世界银行生活标准测量研究 (LSMS) 支持的，由马拉维、尼日利亚、坦桑尼亚和乌干达国家统计局在2009-20年间进行的纵向调查。

¹⁶ 这些调查有几个关键特征，使其成为构建韧性指标所必需的。首先，纵向数据至关重要，因为韧性本质上具有动态性，追踪家庭随时间变化能够识别冲击、韧性能力和福祉之间的因果关系。其次，多主题调查捕捉了韧性的多维性，整合了关于家庭人口统计、资产、能源获取、教育、生计和社区层面的因素等数据——所有这些对于韧性的综合衡量都至关重要。关于家庭农业活动的详细数据收集对于韧性分析也至关重要，特别是在农业作为气候冲击影响福利结果的主要传导渠道发挥核心作用的发展环境中。第三，这些调查依赖于跨国可比的数据收集方法，促进了协调数据集的创建，进而增强了研究的外部效度，并允许不仅对同一国家的未来波次（预测）进行样本外表现评估，也对横截面预测测试中遗漏的国家进行评估。后者对于确保在开发CLARE时将其应用于其发展所使用的国家之外的新数据时建立信心非常重要。第四，这些调查对家庭位置进行地理参照，这允许其与地理空间数据源集成，例如遥感气候数据，这些数据提供了极端天气事件的客观暴露衡量指标。

国家选择反映了计算和技术因素，例如平衡广泛的地理覆盖范围以确保外部效度，同时满足应用机器学习算法和开发韧性指标所需的最小数据要求——例如调查波次的数量。不同国家的变量基于可用信息一致构建，确保数据可比性，这有两个目的。首先，它确保通过使用所有国家的单一统一数据集，我们保持信息的一致性，这对于准确的跨国比较至关重要。

¹⁶ 这些调查是在LSMS综合农业调查 (LSMS-ISA) 倡议下进行的
<https://www.worldbank.org/en/programs/lsmis/initiatives/lsmis-isa> 和可以从世界银行获取（微数据库。）

比较。其次，该指标的性能在外部效度方面高于以往依赖更有限数据集的研究。最终数据集反映了在最大化所有国家韧性组件的纳入和最小化样本规模损失之间取得平衡。虽然每个国家都提供相同的核心信息，但在调查波次的数量、构成和时间上存在一些差异。表2提供了调查数据的概述，包括与每个国家相对应的波次数。

¹⁷ 数据集的构建始于35,000个初始观测值，包括来自每个国家的基线调查数据。在为第二次调查浪潮创建变量滞后后，最终分析样本包括28,112户家庭。

表2：家庭数据来源

国家	调查名称	年	最终n
马拉维	综合家庭面板调查 (IHPS)	2010/2011	基线
		2013	1,282
		2016-2017	1,823
		2019	1,719
尼日利亚	一般家庭调查 (GHS)	2010/2011	基线
		2012/2013	3,619
		2015/2016	3,650
		2018/2019	1,219
坦桑尼亚	坦桑尼亚国家小组调查 (TZNPS)	2010/2011	基线
		2012/2013	317
		2014/2015	687
		2019/2020	654
乌干达	乌干达国家面板调查 (UNPS)	2009/2010	基线
		2010/2011	2,214
		2011/2012	2,211
		2013/2014	977
		2015/2016	2,607
		2018/2019	2,666
		2019/2020	2,467
总数	4个国家	19波浪	28,112

¹⁷ 在 **马拉维**，我们使用集成 *家庭面板调查2010-2013-2016-2019 (长期面板, 102个评估单元)* 由马拉维国家统计局办公室实施，并得到了LSMS-ISA倡议的支持。在 **尼日利亚**，我们采用 *统一面板数据集* 该数据源自尼日利亚国家统计局实施的尼日利亚家庭调查 - 面板 (GHS-Panel) 的历次轮次，该调查由LSMS-ISA倡议提供支持。该面板涵盖了2010-2011年、2012-2013年、2015-2016年和2018-2019年的波次。对于 **坦桑尼亚**，我们利用坦桑尼亚国家统计局 (NBS) 在2008-2009年、2010-2011年、2012-2013年、2014-2015年和2019-2020年实施的坦桑尼亚国家面板调查 (TZNPS) (在LSMS-ISA倡议的支持下) 所产生的数据，创建了一个面板数据集。由于第一波数据不包含构建我们的主要结果变量——即食品消费指数 (FCS) 所需的信息，因此我们将其排除在分析之外。对于坦桑尼亚，由于关键韧性组成部分存在大量缺失数据，导致原始样本中有大量观测值丢失，最终样本量较小。在 **乌干达**，这些数据来自乌干达国家统计局实施的乌干达国家面板调查 (UNPS)，得到LSMS-ISA倡议的支持。我们使用2009-2010、2010-2011、2011-2012、2013-2014、2015-2016、2018-2019和2019-2020年收集的数据回合构建了一个面板。对于所有国家，我们保留了至少在三个时间段内被观察到的家庭——其中一个计算滞后韧性分量所必需的，其余的是在面板背景下进行最小估计所必需的——纳入最终数据集。

4.1.2 结果变量

CLARE 旨在被明确索引至一项福祉指标。在本研究中，我们使用食品消费得分（FCS）（Wiesmann 等人，2009）作为一项关键福祉指标。这种选择的原因有两个：首先，这是Upton 等人（2022）比较研究中采用的食品不安全基准指标；其次，因为它是在所有波次和国家中始终一致的唯一指标（不同于食品消费变量），确保了跨时间和跨国家的可比性。FCS 是一种按频率加权的膳食多样性指标，通常被称为“食物频率指标”。它通过分析家庭在调查前七天内从八个特定食品组中消费特定食品项目的频率来计算。构建FCS的过程始于将食品项目分组到指定类别。对于马拉维、尼日利亚和坦桑尼亚，这种分组始终使用各自数据源提供的模块进行。然而，在乌干达的情况下，由于食品类别没有预定义，我们在计算FCS之前手动将食品项目分组。然后将每个食品组的消费频率相加，每组最多限制七个实例。每个食品组得分被加权

¹⁸并且加权分数被加总以产生总体 根据其营养重要性，FCS。遵循Upton等人（2022年），该连续分数随后被转换为一种分类变量，捕捉粮食不安全状态：FCS≤35的家庭被视为粮食不安全。最后，请注意，这一结果与食物消费相关，与家庭财富相比，更难预测（Barriga-Cabanillas等人，2025年）。

4.1.3 弹性组件和混杂因素

如前所述，此项分析是使用一个统一的数据集进行的，通过构建一个相同的变量集，确保所有国家的一致性。为了保持方法论严谨性和可比性，我们与Upton等人（2022年）所使用的框架密切对齐变量选择，该框架基于Cissé和Barrett（2018年）发展起来的方法论方法。变量经过仔细匹配，以反映马拉维、尼日利亚、坦桑尼亚和乌干达的LSMS调查中的数据可用性，确保数据集符合理论和实证标准。

具体而言，用于本分析的作为解释变量的原始韧性组成部分集合包括家庭特征，例如户主年龄、性别和教育水平，以及

¹⁸ 八个组，括号内为相应权重，如下：主食（2）、豆类（3）、蔬菜（1）、肉和鱼（4）、水果（1）、牛奶和乳制品（4）、糖（0.5）、油（0.5）。

家庭成员工龄超过小学和中学教育水平的比例。此外，我们还包括家庭参与各种生产行动的指标，以及家庭规模和构成——按年龄和性别分组细分，以准确捕捉人口结构——同时考虑家庭是位于农村还是城市地区。为了评估家庭财富，我们包括热带牲畜单位（TLUs）作为牲畜持有量的指标，以及通过主成分分析（PCA）得出的资产指数，这是近期发展文献中捕获长期剥夺的标准做法（例如，Aiken等人，2023；Ratledge等人，2022）。此外，我们纳入社区层面的指标，包括获得基本服务和到最近市场的距离。总共，我们包括18个原始韧性子成分，并且使用相同的指标集来保持可比性——尽管以不同的形式，如滞后值与同期值——用于构建CLARE和Cissé与Barrett（2018）的韧性得分，我们使用后者进行对比评估。

19

所依赖变量FCS及其恢复力成分的描述和汇总统计数据，如表A.1和A.2所示，基于包含所有FCS及其一阶滞未缺失观测值的完整样本。然而，从这一完整样本开始，随后根据每种方法的特定要求得到特定方法的数据集。这解释了以下各节中表格呈现的样本量差异，因为每种方法都规定了不同的纳入标准。由于不同方法的缺失数据模式和/或变量选择不同，因此分析结果是在具有异质样本量的数据集上进行的。例如，CLARE构建仅依赖于滞后恢复力成分的使用，而Cissé和Barrett（2018）方法主要使用当期恢复力变量。因此，相同变量的滞后值和当期值之间存在缺失数据差异。然而，将用于构建不同恢复力指标的原始恢复力子成分集是完全相同的。

在进行因果森林估计之前，关于在结果变量和冲击变量的双重正交化中包含的混杂因素集，我们包括了所有18个韧性组成部分的冲击前值，因为这些变量也独立于其中介作用影响福祉

19

关于弹性子组件间的特征相关性（参见脚注13），仅有两个变量——具有小学教育程度的家庭成员数量和具有中学教育或以上程度的家庭成员数量——表现出超过0.7的强相关性（具体为0.78），而大多数其他成对组合显示出极低的相关性。我们保留了这两个变量在组件集中，以保持与Upton等人（2022）的一致性，但读者应注意这可能导致对教育整体重要性低估（Molnar，2020）。

关于冲击。这意味着，对于此应用，向量 *相同*
 通过将冲击与结果之间直接的中介关系作为变量向量，会直接影响粮食安全，而与冲击是否发生无关。 □
 □□□
 包括
 □□□□□□□-1
 . 原因是这些变量不仅对恢复能力——重要，而且还因为它们此外，我们通过包含由组成的Mundlak型控制变量来考虑时间不变和随时间变化的未观察到的异质性
 □□□□ □□□□□□□-1
 可以-家庭层面和特定波次的这些变量 (Chernozhukov等，2024；Wooldridge，2021) 的平均值。在我们的最终样本中，我们保留所有具有完整结果和协变量数据的观察值。

4.1.4 冲击数据

由于冲击在CLARE框架中起着核心作用，在这个说明性应用中，我们实验了不同的冲击定义和衡量方式。如上所述，CLARE可以作为一个冲击特定的或通用韧性指数来计算。我们这里关注的是构建一个 *干旱* 韧性；我们还报告了基于遭受几种不同冲击的 CLARE 得分的性能。

为了纳入干旱冲击，我们将地理参考的家庭调查数据与从公开可用的第三方来源获得的遥感气象数据相结合。作为干旱指标，我们使用蒸发需求干旱指数 (EDDI) (Hobbins等人，2016年) 的高分辨率数据，这是一种基于物理、多尺度的近期干旱指数，它通过专注于大气蒸发需求中的异常来补充受降水驱动的指标。(E_o)。E_o是通过美国土木工程师协会 (ASCE) 开发的标准化参考蒸散量 (ET) 方程计算的 (Walter等人，2000年)，该方程基于基于物理的Penman–Monteith公式 (Monteith，1965年)。这种方法结合了辐射和空气动力学成分来估算大气蒸散需求，依赖于温度、湿度、风速和太阳辐射等气象输入。它在标准化地表条件下提供了一种一致且广泛接受的计算参考ET的方法，通常假设参考作物水分充分，并提供约0.125° (12公里) 的空间分辨率。EDDI值通过非参数逆正态变换进行标准化，得到的值通常介于-2.09和+2.09之间 (基于36年的气候学)。正EDDI值表明大气需求比正常情况更干燥，并预示着干旱的开始或加剧，超过+1和+2的值分别对应于中等和极端的蒸散异常。

由于其对于短期变化的敏感性，EDDI特别擅长捕捉闪旱和持续性干旱，并且通常比传统的供给侧指标能提供更早的预警。为了将EDDI数据与我们的主要家庭数据集相结合，我们在调查的普查区（EA）层面平均EDDI值，并使用GPS坐标将其与家庭进行匹配。

²⁰

值得注意的是，我们使用真实的、保密的家庭地理坐标，而不是公开的、空间匿名化（混淆）的GPS坐标。这种区别很重要，因为最近的研究表明，高分辨率的遥感气象产品对空间匿名化敏感，这可能会导致测量误差（Michler等人，2022年）。我们将干旱月份定义为EDDI超过+1的月份，表明存在中度干旱条件。

为了捕捉对农业成果和相关福祉变化有影响的天气状况，我们仅关注 *生长期* eddi (gs-eddi)，定义为两次浪潮之间的生长季节月份期间的eddi值。为了识别生长期，我们依赖于美国农业发展署（usaID）提供的粮食早期预警系统网络（fews net）——按地区区分的作物历。由于在每个浪潮和访问中，家庭在不同的日历月份接受采访，我们关注每个家庭根据其采访日期的特定gs-eddi值。这意味着，对于每个家庭，我们检查他们上次和当前采访之间的所有生长季节月份中居住地的天气条件。然后我们从这些连续的天气数据中构建一个二元冲击指标，捕捉干旱暴露。我们按以下方式构建这个变量：我们的冲击虚拟变量在家庭在一段时间内的部分生长季节月份经历了干旱（即gs-eddi高于+1）时取值为1

th

分布的百分位数，否则为0。这种选择与两次浪潮超过先前75%的文献（Harari & La Ferrara，2018），并且是出于这样的考虑，即所有生长季节月份的GS-EDDI值的简单平均值会掩盖与家庭福祉相关的天气条件中的显著变化。在主要样本中，生长季节月份中有干旱发生的75分位数的份额为12%。因此，如果家庭在两次调查浪潮之间的生长季节期间经历了超过12%的干旱（参见附录A中的表A.2），则将其归类为受到冲击。这构成了我们的主要冲击变量，其对本CS的影响，如由韧性子组件驱动，将使用表1中描述的方法论流程进行估计。

²⁰

非迁移户在统计区（EA）层面提取值，迁移户在户层面提取值。

约瑟夫森等人 (2025) 的最新研究表明，基于纵向调查数据估计天气条件与社会经济结果（特别是农业生产能力）之间的关系，对所采用的天气数据来源极为敏感，并强调证明关键结果不依赖于所选择的天气数据产品的重要性。因此，为了稳健性，我们还采用了标准化降水蒸散指数 (SPEI)，这是一个由贝格里亚等人 (2014) 开发的多尺度干旱指数，可在全球SPEI数据库中公开获取。SPEI综合考虑了降水量、潜在蒸发量和气温，这使其在简单的降雨或温度指标上具有独特优势，因为它将这些变量之间的相互作用纳入了确定农民农业产出的考量中（贝尔托利等人，2022；哈拉里与拉法拉，2018）。它在文献中越来越多地被用来捕捉与农业相关的天气冲击，并且研究发现它在预测作物产量方面优于其他指标（维森特-塞拉诺等人，2012）。SPEI是通过降水量（ P ）和潜在蒸散量（ PET ）： $D = P - PET$ ，然后， D 被标准化，以便指示器表示，蒸散量（ PET ）： D 根据对数逻辑分布）。负的SPEI值与干旱事件（降雨量较低）相关，而正的SPEI值则捕捉到湿润事件（降雨量较高）。这些SPEI数据的分辨率较低（ $0.5^\circ \times 0.5^\circ$ ），为构建冲击暴露变量，我们采用上述用于EDDI数据的相同程序。

最后，我们说明了如何基于多重冲击构建韧性指标。在最近的发展韧性理论框架（Barrett & Conostas, 2014）中，高风险环境下的家庭和个人并不一定关心他们所暴露的特定风险来源，因为许多风险在时间和空间上都存在相关性。因此，允许基于多重暴露构建韧性分数非常重要，这些分数能更好地反映现实生活中对各种冲击和压力源的脆弱性。为此，我们用冲击虚拟变量替换上述定义的干旱冲击变量，该变量在两次调查波期间等于1，如果家庭经历了以下至少一种冲击：

- 干旱冲击（基于GS-EDDI数据）- 洪水冲击
- 价格投入冲击 - 价格产出冲击 - 家庭成员死亡

- 家庭成员患病 - 农作物生产相关冲击 - 畜牧业
养殖/生产相关冲击

由于 EDDI (以及 SPEI) 数据适合捕捉干旱但不适合测量洪水，因此对于后者，我们依赖气候灾害小组红外降水站点 (CHIRPS) 的高分辨率降水时间序列 (Funk 等人，2015 年)，我们使用该数据来构建标准化降水指数 (SPI)，进而构建一个洪水冲击虚拟变量——其构建方式与干旱相同 (即，如果在生长季节月份中有超过 75% 的月份经历了洪水 (SPI 值低于 -1)，则该变量取值为 1)。

th 分布的百分位数，否则为 0)。所有其他协变量和特质冲击的数据基于家庭的自报信息。此附加练习的 CLARE 估计遵循用于干旱冲击的表 1 流程，唯一区别是替代冲击变量。近 60% 的家庭至少遭受了其中一种冲击 (参见附录 A 中的表 A.2)。

4.2 主要结果

我们从四个撒哈拉以南非洲国家的跨国纵向数据集中报告了 CLARE 在干旱韧性方面的实证应用结果。我们首先从预测任务开始，然后转向对保留国家的横截面预测。这两个任务的结果、冲击、混杂因素和韧性组成部分是相同的，并在数据部分进行了描述。此外，我们比较了 CLARE 的样本外表现与其他备选方案的样本外表现，主要关注 Cissé 和 Barrett (2018 年) 的韧性评分，该评分根据 Upton 等人 (2022 年) 的综合研究被确定为表现最好的韧性指标。最后，我们展示了预测性能在不同冲击指标和定义以及不同韧性组成部分集下的稳健性。在呈现结果时，我们首先从 CLARE 的二值版本开始，因为二值韧性评分是对政策制定者最直观和有吸引力的，用于目标制定 (Upton 等人，2022 年)。

21

²¹ 在所有实证分析中，为了在保持极性的同时不改变与结果的相关性，以下标准化变量已被作为补充项包含在最终的 CLARE 聚合 (事后估计) 中：户主年龄 (滞后)；距市场的距离 (滞后)；户主性别 (滞后)；农村 (滞后)；女性成员 > 65% (滞后)；男性成员 16-65 岁 % (滞后)；男性成员 > 65% (滞后)。

4.2.1 预测

在这项预测测试中，我们在包含马拉维、尼日利亚、坦桑尼亚和乌干达第一至三期调查波数的综合训练集上训练和调优了我们的模型。相应地，测试集包括马拉维、尼日利亚和坦桑尼亚第四期调查波数，以及乌干达第四至第七期调查波数。因此，我们的训练集共有11个波数，测试集有7个波数。目标是基于仅基于训练集早期波数估计的韧性权重和样本外条件概率，预测出现在测试集未来波数中的家庭粮食（不）安全状况。纵向数据集是不平衡的，我们不需要相同家庭必然出现在训练和测试集波数中。实际上，一旦在训练集上估计了权重和输入输出关系，就可以对新数据进行预测，前提是数据包含相同的变量集。对于CLARE的二进制版本，我们遵循Lee等人（2025年）的做法，使用国家特定的韧性分数中位数对连续指标进行离散化：分数高于该阈值的家庭被定义为有韧性，而分数低于它的家庭被定义为无韧性。为了完整起见，我们也报告了在使用25分位数

²²我们从回归练习的结果开始，然后 百分位数作为替代阈值。用于二元指示器。

B附录报告了关于干旱冲击对福祉的平均效应和异质效应的完整估计结果（图B.1），数据驱动韧性权重的值（图B.2），以及因果森林估计的准确性检验（附录B中的表B.1）。关于冲击效应，我们估计干旱冲击后，成为粮食不安全概率平均增加了5.3个百分点，且该结果在1%水平上具有统计显著性。

²³围绕这一平均值存在显著的异质性。关于权重（图B.1），三个最具影响力的韧性成分——合计占总权重的50%以上——是食品消费指数（FCS）的滞后值、资产指数和市场距离。这些位居前列的变量与贫困陷阱的概念框架紧密一致，反映了诸如资产的关键作用、福祉的持续存在、非线性福利动态的重要性以及市场邻近的核心地位等既定模式（Carter & Barrett, 2006; Dercon, 2004;

²²作为一种提醒，CLARE的离散化可以使用任何阈值，这取决于用户的选择；在这里我们使用这些截止值纯粹是为了说明目的。

²³经历粮食不安全状况的无条件概率为20.3%（参见附录A中的表A.2）。为作比较，这种干旱估计的平均效应与Upton等人（2022年）为尼日尔和埃塞俄比亚报告的持续FCS效应一致。

法夫尚, 1992 年)。这种一致性加强了该方法的理论基础，并提高了实证分析的信誉。

转移到样本外性能的评估，从回归任务开始，表3报告了CLARE分数0-100版本与食品消费得分之间的Pearson成对和Spearman等级相关系数，以及根据训练集波次的CLARE对FCS回归，在测试集波次上预测FCS的均方根误差（RMSE）与FCS样本均值的比率。后者是Upton等人（2022年）进行的一项测试，用于评估连续韧性指标预测能力。它是通过在训练集中对FCS对CLARE进行回归，然后对测试集的未见数据进行预测，并最终计算测试集RMSE（通过测试集样本中FCS的平均值进行归一化）来计算的。我们还报告了测试集中CLARE的平均估计值。

指标表明，CLARE 与未来 FCS 之间存在中等程度的较高相关性，这表明该指标可以以相对较高的准确度预测连续福祉结果，考虑到在包含未来数据点以及许多算法未曾遇到过的家庭的大型跨国家数据集上进行预测的复杂性，这一点尤为引人注目，仅依赖来自

²⁴和数量估计 更早的波次收集了先前数年来自一个独立的训练集的数据。

表3：使用CLARE对食品消费得分进行样本外预测

– 所有国家，第4至第7波

指标	值
皮尔逊相关系数	0.534
斯皮尔曼等级相关系数	0.524
标准化均方根误差（RMSE对FCS样本均值）	0.320
平均CLARE得分	33.558

注意：该表格报告了CLARE模型在预测所有国家和第4波至第7波的连续食品消费得分（FCS）方面的样本外性能。

²⁴ 参见 Constenla-Villoslada 等人 (2025) 关于当训练数据过时或未更新时，使用机器学习预测未来粮食安全结果的挑战的讨论。

转向分类任务，表4报告了混淆矩阵，该矩阵说明CLARE在预测混合测试集中家庭食物不安全状况的样本外准确率。提醒一下，食物不安全是一个二元变量，定义为食物消费得分等于或低于35。敏感性，即识别真阳性的能力，超过82%。这意味着CLARE可以提前正确识别这四个国家中未来波次中超过十分之八将面临食物不安全状况的家庭。特异性，即识别真阴性（即食物安全家庭）的能力较低，约为57%，而总准确率是61%。

表4：使用CLARE对样本外食物不安全感进行预测

—所有国家，第4至7波；中位数CLARE截止值

		食物不安全 ($FCS \leq 35$)		
		粮食不安全 = 0	粮食不安全 = 1	总数
二进制 CLARE (中位数截断)	非弹性 = 0	5,788	366	6,154
	非弹性 = 1	4,427	1,728	6,155
	总数	10,215	2,094	12,309
	正确预测	56.7%	82.5%	61.1%

备注：该表格展示了二元CLARE模型在预测食物不安全（定义为 $FCS \leq 35$ ）方面的样本外分类性能，涵盖所有国家和4至7次周期。分类使用CLARE中值作为截止值。行表示预测值（基于CLARE），列代表观察到的食物不安全状态。

这些数字当然取决于我们用来离散化连续CLARE指标所选择的标准。而这一点又取决于政策制定者在最小化假阳性与假阴性之间的偏好。在这方面，认识到存在权衡取舍很重要。例如，选择一个低于中位数的标准会增加特异性与总体准确率，但代价是降低灵敏度。这将导致假阴性减少，但也意味着会识别出较少的非韧性家庭。

不存在单一的“正确”或“最佳”阈值，因为选择取决于政策制定中设定的具体优先事项。可以论证，错误地将一个粮食不安全家庭分类为粮食安全的成本高于相反的情况，即，假阴性比假阳性成本更高。根据这种偏好，一个基于这些考虑的韧性建设计划会优先考虑灵敏度而不是特异度。

并且准确性，碰巧与中位数截止值的情况一样，尽管不是有意为之。这样做，它将为未来不久有粮食不安全风险的四分之五的家庭提供预防性支持。另一方面，其他人可能会认为，将公共资金用于帮助最终没有风险的家庭，构成了资源的低效利用。为此，用户可能更喜欢将较小比例的家庭归类为非复原性——具体来说，那些得分低于CLARE分布的第25百分位的家庭。表5展示了相应的混淆矩阵。按设计，此阈值大幅提高了特异性，并使总体准确性达到82%以上和78%以上。虽然灵敏度有所下降，但仍能识别59%的非复原性家庭。

表 5：使用 CLARE 对样本外食物不安全状况进行预测

– 所有国家，第4至第7波；25

th
百分位数 CLARE 截止

		食物不安全 ($FCS \leq 35$)		
		粮食不安全 = 0	粮食不安全 = 1	总数
二进制 CLARE (25 th 百分位数 截止)	非弹性 = 0	8,365	866	9,231
	非弹性 = 1	1,850	1,228	3,078
	总数	10,215	2,094	12,309
正确预测		81.9%	58.6%	77.9%

备注：该表格展示了二元CLARE模型在预测食物不安全（定义为 $FCS \leq 35$ ）方面，针对所有国家和第4至第7波次的样本外分类性能。分类使用了25

th以CLARE的百分位数作为截断值。行表示预测值（基于CLARE），列表示实际粮食不安全状况。

4.2.2 国外预测

在国外测试中，我们基于包含三个国家的轮换训练集训练和调优模型，并在被排除的国家上进行样本外预测。目标是在其他国家数据中估计出的韧性权重和样本外条件概率的基础上，预测不同国家户家庭的食物（安全）状态。对于CLARE的二进制版本，我们使用特定国家的韧性能力中位数来将连续指标离散化。高于该阈值的得分家庭被定义为有韧性，而低于该阈值的得分家庭则被定义为无韧性。请注意，我们此处进行的是横截面预测——政策制定者在数据匮乏且无法及时获取更新面板的环境中进行迁移学习时可能感兴趣的一种练习——与预测练习不同，每个国家的轮换测试集中包括

该国所有波次的数据，其他国家也是如此。

跨国结果如表6和表7所示。对于回归任务，表6中连续CLARE分数的性能指标甚至优于预测练习中的指标，跨国相关系数接近0.6。

²⁵对于分类任务（表7），结果与预测练习的结果相似：特异性约为58%，灵敏度83%，准确率超过63%。

表 6：使用 CLARE 预测国外食品消费得分——所有国家

指标	值
皮尔逊相关系数	0.567
斯皮尔曼等级相关系数	0.562
标准化均方根误差（RMSE对FCS样本均值）	0.320
平均CLARE得分	52.990

备注：该表格报告了CLARE模型在所有国家预测连续型食物消费得分（FCS）的跨境表现。

表7：使用CLARE预测跨国粮食不安全状况

——所有国家；中位数CLARE截止

		食物不安全（FCS≤35）		
		粮食不安全 = 0	粮食不安全 = 1	总数
二进制 CLARE (中位数截断)	非弹性 = 0	13,089	967	14,056
	非弹性 = 1	9,315	4,741	14,056
	总数	22,404	5,708	28,112
正确预测		58.4%	83.1%	63.4%

备注：该表格展示了二进制CLARE模型在预测所有国家的粮食不安全（FCS ≤ 35）方面的跨国外分类性能，使用中位数CLARE值作为截止值。行显示预测值（基于CLARE），列表示观察到的粮食不安全状态。

²⁵平均CLARE得分与预测练习中的得分相比显著更高。这是因为样本中的FCS随时间增加，因此当模型在来自某些国家的所有波次上训练，而不是只在早期波次上训练时，会导致对保留国家的估计量值更高。无论如何，CLARE是一个 相对 韧性指标，其估计值针对训练集进行了定制，导致跨不同数据集进行比较不恰当。

虽然绝对数值上并不令人印象深刻，但考虑到任务的复杂性，将它们置于具体情境中非常重要。其核心思想是：即使某个国家只有一份包含构建18个韧性子组件必要信息的横截面数据集，且政策制定者优先考虑以增加假阳性为代价来最大化灵敏度，一个在完全不同国家的数据上训练的CLARE模型仍然能准确识别未来83%以上有粮食不安全风险的家庭。

26

4.3 与其他韧性措施和替代方法比较

性能方面重要的是，不是绝对指标 *本身而言*，但是CLARE与现有方法相比如何。由于我们所采用的样本不同（规模更大且更异质），以及用于衡量福祉的结果和韧性特征集合不同，因此上述结果不能直接与其他关于韧性措施研究报告中报告的性能进行比较。

27

因此，我们使用三种其他指标复制了几节的预测练习：Cissé和Barrett（2018）的复原力得分、使用滞后粮食不安全或FCS值预测未来状态的朴素方法，以及RIMA和TANGO采用的已实现复原力指标。对于Cissé和Barrett（2018）指标，我们重复了预测和境外预测练习。对于其他两个复原力指标，我们仅报告预测练习的比较，但不报告境外预测的比较。最后，我们展示了CLARE相对于潜在替代和更简单估计方法的增值，包括使用标准监督机器学习进行粮食不安全预测，以及基于对复原力子成分进行简单平均且权重相等的复合指标构建。为便于更清晰的比较，本节末尾的图1和图2总结了主要结果，包括上述表格中显示的CLARE指标的综合性能。完整结果提供在在线附录中。

28

4.3.1 西塞和巴雷特（2018）韧性评分

我们基于 Cissé 和 Barrett (2018) 的基于矩的方法，复制了 Upton 等人 (2022) 进行的样本外检验，正如第 2 节所预期的那样，该方法提供了一个稳健的框架

26

由于空间限制，从现在起，我们仅将使用中位数截止法报告分类结果。具有

th

对国外预测的截断值，然而，与预测练习的那些值相似。 可选 25

27

例如，由于与基于资产的指标相比（Barriga-Cabanillas等人，2025年；Lee等人，2025年），消费相关指标波动幅度大得多，因此难以预测，因此我们的绩效指标无法与Cissé和Barrett（2018年）的应用进行比较，该应用将热带牲畜单位作为因变量

o

28

在线附录可在此处访问：<https://shorturl.at/fvP3I> .

将韧性作为规范条件进行衡量。此方法基于Barrett和Constas (2014年)提出的概念框架，将韧性定义为个人或家庭即使在受到压力和冲击的情况下，仍能维持在最低规范福祉标准（如贫困线、食物消费指数（FCS）或营养阈值）之上的概率。与静态的福祉衡量方法不同，Cissé和Barrett的方法整合了随机元素以捕捉韧性的动态变化，使其特别适用于政策与项目评估。

西塞和巴雷特方法采用条件矩方法将韧性作为概率度量进行估计，依赖于一个两阶段的计量经济学建模过程。在第一阶段，通过普通最小二乘法（OLS）回归估计福祉指标（以FCS为例）的条件均值。因变量被回归到福祉指标的滞后值上，包括高阶项以解释非线性动态，以及随时间变化的家庭和社区特征以及冲击。然后，将这个回归的平方残差用于第二阶段的回归，以使用与第一方程相同的一组协变量来模拟福祉指标的条件方差。这两个方程提供了福祉指标的条件均值和方差，这些值随后在假设的两参数概率分布（在这种情况下是伽马分布）下组合起来，以导出特定于家庭的概率密度函数。从这一点出发，韧性分数（RS）被计算为家庭福祉超过FCS规范阈值35的概率。得到的韧性分数最初在0到1之间，通过乘以100转换为百分比。

²⁹

然后创建一个二元变量来区分有韧性和无韧性的家庭。与CLARE类似，可以使用不同的阈值来将指标离散化。为确保指标之间的一致性，我们使用特定国家的中位数值来离散化韧性得分。韧性得分在或高于中位数的家庭被归类为有韧性，而得分低于中位数的家庭则被视为无韧性。

我们使用先前用于CLARE并由Upton等人(2022)采用的相同指标来呈现结果。连续测试的结果如图1所示，揭示FCS与C&B RS之间存在较弱的关联（皮尔逊和斯皮尔曼系数）以及更高的归一化RMSE。

³⁰

表明与CLARE相比，该指标的连续版本的整体预测精度较低。二元指标的结果表明CLARE表现优于

²⁹ 关于Cissé和Barrett (2018) 恢复力分数的估计详情，请参见附录b。

³⁰ rmse越小，表示韧性指标的解释力越强。

西塞和巴雷特方法在所有评估指标上（参见摘要图2和在线附录中表C.1的完整混淆矩阵）

³¹

）。总体而言，虽然连续测试与C&B RS的差异很大，但在分类练习中，这种差异并不那么大，这可能是由于指标的离散化导致的变化和信息损失。

迁移到跨国预测，我们采用Upton等人（2022年）在横断面预测中使用的程序，并实现Cissé和Barrett（2018年）的方法。他们使用一个国家75%的家庭样本估计韧性分数，然后对剩余的25%样本外进行预测。类似地，我们使用一个由三个国家组成的轮换训练样本来估计C&B韧性分数（RS），然后对保留的国家进行韧性分数预测。我们将所有跨国家的韧性分数进行汇总，并将其与相同家庭的观察到的福祉状态进行比较。网络附录中的表C.2报告了连续结果的预测性能指标，而表C.3则展示了二元指标的混淆矩阵。与预测比较类似，这两张表都表明该模型相对于CLARE表现不佳，分类指标较低，标准化RMSE较高。在相关系数方面，差距尤为明显。

4.3.2 ‘朴素’方法

我们也评估了预测未来粮食不安全的最简单方法，该方法包括将二元粮食不安全变量的滞后值作为后续观测值的预测。该方法利用了粮食安全数据中的时间连续性，假设最近的粮食安全状况提供了有关未来状况的宝贵信息。Upton等人(2022)强调，即使是上一节中显示的最佳性能恢复措施，如C&B RS，也往往无法始终超越这种直接方法。基于这些发现，我们现在将我们的指标CLARE与这一基线进行比较，以评估其预测性能和增值，并在汇总的图1(回归)和图2(分类)中呈现结果。

³²

查看图1，我们观察到CLARE在所有检查的回归指标上都显著优于朴素方法。与Upton等人（2022）的研究结果一致，这对Cissé和Barrett的RS不适用，RS的预测能力与使用滞后福祉来预测未来相当

³¹

倒数第二次的波对应于所有具有相应第四波FCS值的国家的第三波。然而，鉴于乌干达有额外的波次，分析扩展到包括第四波和第五波、第五波和第六波以及第六波和第七波的RS和FCS对。图1展示了从这项分析的每次迭代中得出的平均C&B RS值。

³²

分类练习的综合结果报告在在线附录的表C.4中。

福祉。对于分类（图2），结果显然取决于用于对CLARE进行离散化的规则。当使用中位数作为二值化的截断值时，滞后变量方法在总体准确率方面优于二值CLARE，但在灵敏度方面表现严重不足，即识别事前粮食不安全家庭的能力，这是我们评估的重点。这种较低的灵敏度意味着该方法更有可能将粮食不安全家庭误分类为粮食安全。换句话说，因为在测试集中大多数家庭是粮食安全的，朴素方法面临罕见事件问题，导致其为了提高总体准确率而高估多数类。然而，这以严重误分类少数类为代价，导致灵敏度比随机猜测更低（34.7%）。相比之下，使用25分位数截断值构建的二值CLARE版本实现了与朴素指标的总体准确率相当的准确率，同时提供了显著更高的灵敏度。

4.3.3 “已实现韧性”方法（RIMA和TANGO的二进制指标）

与其他现有韧性指标的第三次也是最后一次比较涉及“已实现的韧性缺失”的概念，该概念被定义为观察到的粮食不安全状况随时间变化的负变化，作为对家庭韧性的额外检验。这种方法与粮农组织的韧性指数测量与分析（RIMA）模型和TANGO国际采用的二元韧性指标相类似。尽管他们的韧性方法基于复合连续指标的建设，但在实践中他们通常需要二元分类来识别有韧性或无韧性的家庭。根据粮农组织（2016）的指南，RIMA通常不用于将家庭分类为粮食安全/不安全或贫困/非贫困，这在对韧性建设目标的进展评估中提出了挑战。当需要二元分类时，粮农组织建议使用“已实现的韧性”，定义为纵向数据中感兴趣福祉指标随连续时期变化的非负变化。类似地，TANGO的方法基于通过多种指标的因素分析估计的潜变量构建韧性能力指数（RCI）。然而，当需要二元分类时，TANGO也采用了已实现的韧性标准。

基于这一概念，对于分类任务，我们采用先前波次中实现的韧性缺失，这是一个虚拟变量，当家庭食物消费得分（FCS）在两个波次中滞后出现负面变化时取值为1，否则为0，来预测当前波次中的粮食不安全状况。对于回归任务，我们使用先前波次中食物消费得分（FCS）的连续变化量。如图1和图2所示，以及在表C.5中的详细混淆矩阵所示，该指标在回归和分类任务中的样本外表现均不佳，并且表现劣于我们评估的所有其他指标。

4.3.4 基于监督机器学习的粮食不安全预测

与文献中日益常见的针对粮食不安全问题的标准预测模型相比，我们的因果机器学习方法有何增值？这些标准预测模型也被用于预测家庭韧性（Knippenberg等人，2019；Villacis等人，2024）。为了评估这一点，我们通过开发一个简单的粮食不安全预测模型（使用随机森林，包含1,000棵树）和CLARE构建中包含的18个韧性组成部分集，进行了一个分类练习。结果如图2所示。

³³ 便于直接比较。为与表4中基准CLARE结果保持一致，我们将中位数预测概率作为阈值来将家庭划分为有韧性或无韧性。研究发现，虽然随机森林模型在样本外准确率方面表现与Cissé和Barrett（2018）的二进制指标相当，但在所有评估指标中，当使用CLARE二值化的中位数截止点以及随机森林评分的50%概率进行离散化时，它始终表现不佳。

4.3.5 弹性子组件的简单平均值


最后，我们展示了使用CLARE及其数据驱动权重方案在构建复合指标方面的优势，相比于依赖标准化韧性子组件简单平均的朴素方法（在我们的案例中为1/18，反映了18个组件）。在图1中，我们看到这是所有连续指标中表现最差的指标。对于分类任务（图2），我们看到简单平均指标——当使用与基准CLARE相同的中间值截止方式二值化时——表明仅仅聚合韧性子组件不足以获得优异性能。相反，聚合必须由反映潜在复杂关系的标准指导。

³⁴

³³ 详细结果见表C.6，见在线附录。

³⁴ 分类任务的完整结果报告在在线附录的表C.7中。


图1：预测回归任务的汇总比较评估
– 所有国家，第4至第7波



笔记 该图总结了在未见未来数据上预测食物消费分(FCS)时，连续 (0-100) CLARE指标与其他几种替代措施的样本外性能比较。测试集包含第4至第7波中所有国家的观测值。报告的值对应于相关性和归一化RMSE (即Upton等人(2022年)使用的相同指标；括号中的值为平均指标得分)。

图2：预测分类任务的总结比较评估

– 所有国家，第4至第7波



备注：该图提供了二进制CLARE (使用中位数和25th

百分位数截止值)相对于几种替代指标。测试集包含来自第4波到第7波的所有国家的观察值。观察值数量(括号中所示)因数据需求和方法结构的变化而有所不同。替代指标的详细结果报告在在线附录中。

4.4 额外分析和稳健性检验

已经证实 CLARE 表现优于其他方法，我们现在评估其鲁棒性和性能稳定性。为了便于比较，预测回归任务的主要结果汇总在图3中，预测分类任务的主要结果汇总在图4中。请注意，轴范围与图1和图2相同。上述比较评估得出的见解，无论相对于替代方法考虑哪种 CLARE 版本，都依然有效。二元分析结果的完整集报告在在线附录中。

4.4.1 更小的弹性组件集合

CLARE使能够在难以到达或数据稀缺的环境中计算弹性，其中数据

收集困难、成本高或两者兼具。为确保其在这些环境中的适用性，有必要保证，如果仅使用相关的关键预测子集来估计CLARE，其性能不会显著下降。图3和图4显示了，在进行预测练习时，当仅使用根据基线结果被确定为具有最高重要性权重的三个原始韧性组件来估计CLARE时的性能指标，即附录B中图B.2报告的FCS、资产指数和距市场的距离。如读者所见，对于连续和二元的指标，结果都只发生微小的变化

³⁵ 指标，表明性能没有显著下降。这表明，CLARE可以通过仅收集这些关键变量的数据，在任何数据匮乏的环境中有效估算，而不会影响其识别最脆弱家庭的外部样本能力。此外，该模型在性能方面表现出稳定性，即使仅关注顶级韧性决定因素并丢弃不太重要的组成部分也是如此。这对于实地工作和政策设计具有实际意义，表明可以通过优先考虑一组核心变量来简化数据收集工作。这是我们指标的一个特别有价值的特征，使其能够在有问题的环境中进行迁移学习。为此，有限的关键变量的一份数据就足以计算韧性指标，从而为在数据匮乏的环境中优先考虑针对更容易受到粮食不安全影响的家庭的政策干预提供定量支持。类似的推理也适用于在这些环境中优先考虑数据收集工作以进行跨国预测。

4.4.2 可替代天气数据


我们还检验了模型性能和组件权重的灵敏度以及相对于所使用的干旱冲击数据来源的稳定性。图3和图4（在线附录中的表C.9，详细结果）展示了，包括在内的一些结果，即使用从数据小节中引入的SPEI数据集推导出的干旱冲击估计的CLARE的连续和二元版本。在线附录中的图C.1报告了相应的变量重要性权重。令人欣慰的是，尽管依赖于完全不同的天气数据源来捕捉干旱状况，但性能指标和子组件权重仍然高度一致，并且略低于表3中报告的结果，这可能是由于用于计算冲击的天气数据分辨率较低。关于权重，尽管存在更广泛的变化，但整体一致性仍然很强，因为在前三位和后两位变量的重要性排名中是相同的，尽管

³⁵ 在线附录中的表C.8显示了完整的混淆矩阵。

不同顺序。

图3：不同CLARE版本之间的总结比较评估


预测回归任务——所有国家，第4波至第7波



注意：此图展示了在不同CLARE版本中预测回归任务的性能指标。测试集包含第4波至第7波中所有国家的观测值。图例中标记为“CLARE”的红菱形代表用于预测分析的基线CLARE指标。括号中的数值表示平均指标得分。

图4：不同CLARE版本之间的总结比较评估

预测分类任务——所有国家，第4波至第7波



备注：该图展示了在不同CLARE版本中预测分类任务的性能指标。图例中标记为“CLARE (P50)”的红色菱形 测试集包含所有国家在第四波到第七波中的观测值。代表用于预测分析的基线CLARE指标。对于所有CLARE版本，连续指标的二值化切分点使用中位数值。观测值数量以括号表示。每个规格的详细结果在在线附录中提供。

4.4.3 多重冲击暴露

上述所有结果均与一个特定冲击版本的CLARE相关，即衡量干旱韧性的指标。我们现在介绍基于除干旱之外的更广泛冲击集暴露（参见4.1小节关于替代冲击变量的详细信息）构建的替代通用版本CLARE的预测性能和变量重要性。性能指标报告在图3和图4中。

³⁶当相应的变量重要性排名显示在在线附录的图C.2中。再次，预测性能完全可与干旱特定CLARE的性能相媲美，变量重要性排名仍然非常相似。平均冲击

³⁶参见C.10表，了解关于混淆矩阵的深入结果。

效果较小——2.23个百分点——但在1%的水平上具有统计学显著性。这种减弱的影响很可能源于一般冲击变量是如何定义的：如果一户家庭经历了多种可能冲击中至少一种，它就取值为1，从而只捕捉了多重冲击暴露相关效应的下限。在多冲击框架下对CLARE估计的更深入探讨留待未来工作。

4.4.4 替代资产衡量指标，重点关注电力获取和能源消耗

此外，我们展示了稳健性检查的结果，在构建我们的干旱特异性CLARE指标过程中，我们将一般家庭资产指数替换为仅包含与电力获取和能源消耗相关项目的电力资产指数（参见附录A中的表A.4了解这些项目的清单）。

韧性框架不应局限于狭隘地关注可持续发展目标1和可持续发展目标2，而应将视角从仅仅衡量最终结果转变为认识到使能条件的关键作用。获得能源——以及拥有能源相关资产——在建立抵御气候冲击的韧性方面发挥着关键作用。能源获取增强了基本服务的功能性，支持气候适应型农业，确保清洁水的供应，并促进教育和灾害准备。这些要素共同加强了家庭和社区适应气候压力因素的能力（世界银行，2023）。

秉持可持续发展目标7的精神，能源获取不应仅仅被视为一个行业目标，而应被视为在干扰期间为家庭、服务和地方经济提供稳定性和连续性的基础组成部分。能源获取的不足阻碍经济复苏，削弱韧性，并破坏减少贫困的进程。相反，能源获取改善了生活质量，并扩展了服务、就业和市场的支持环境。特别是，农村地区电力的生产性使用促进了社会经济发展和创收，为社区层面的韧性和可持续增长奠定了基础（世界银行等，2025年）。纳入此类目标使韧性视角重新聚焦于塑造结果的潜在条件。

这种推理推动了旨在评估能源相关资产是否作为气候冲击影响福祉的关键传导渠道的稳健性检验。若得到证实，这将强调能源获取和消费导向的政策和计划作为支持农村发展地区气候适应工具的重要性。绩效结果报告在图3和图4中（参见在线附录中的表C.11以获取完整的二元结果），而在线附录中的图C.3

附录展示了相应的变量重要性排序。尽管回归和分类性能指标在定性上保持稳定，但家庭电力资产指数成为干旱对粮食安全影响的最重要驱动因素之一。这表明，针对该指数的组成部分制定政策可以增强受干旱影响（以及更广泛地受与气候相关的压力因素影响）的家庭的恢复能力。

4.4.5 摘要统计

最后，我们根据其韧性得分是否高于或低于中位数，比较了被分类为有韧性与非韧性的家庭的关键特征。网络附录中的表C.12列出了两组的社会经济和人口变量均值，以及它们之间差异的统计显著性。我们使用预测练习中对完整样本估计的基准CLARE得分。结果如预期所示，揭示出有韧性家庭与非韧性家庭之间存在显著差异。有韧性的家庭食品消费得分显著更高，并报告了更低的食物不安全状况。有韧性的家庭规模往往更大，识字水平更高，有更多成员达到小学、中学或高等教育程度。尽管两组都以农村为主，但韧性家庭表现出更好的资产拥有情况，如更高的家庭资产指数和相似的牲畜拥有水平（TLU）。在村内获得关键服务的程度在两组间相似，但韧性家庭离市场更近。重要的是，两组在冲击暴露方面——由GS-EDDI测量的干旱条件——没有显著差异。

5. 讨论 и 结 论

精确衡量家庭韧性对于设计、定位和评估旨在减轻冲击脆弱性的干预措施至关重要，尤其是在低收入、易受冲击的国家。尽管全球发展议程中越来越重视韧性（Béné 等人，2017 年；Barrett 等人，2021 年），但现有的韧性指标往往缺乏可扩展性，没有明确包含冲击和压力源的关键作用，并且无法在其原始生产环境之外的背景下准确预测福祉结果。这一局限性阻碍了它们在指导韧性建设政策和干预措施方面的作用（Upton 等人，2022 年；Barrett & Conostas，2014 年）。随着对以韧性为重点的干预措施的需求不断增长，特别是在以系统性冲击、大流行病、气候变化和多种其他压力源为标志的多重危机时代，迫切需要更稳健和可扩展的韧性估算方法（Barrett 等人，2024 年）。

本文介绍的方法通过采用因果机器学习技术，开发了一个复合韧性指标，能够克服主流方法的局限性。CLARE利用数据驱动的权重进行聚合，并采用灵活的因果机器学习模型估计冲击下（非）粮食安全的条件概率（Wager & Athey, 2018; Chernozhukov et al., 2018, Chernozhukov et al., 2024），捕捉冲击对不同家庭子群体产生的异质性影响。这使得韧性估计更加精细和基于实证，解决了各种子组成部分如何复杂地削弱不良事件对家庭福祉的影响。重要的是，CLARE不依赖于任何特定方法。只要所选方法能够估计粒状和异质性的处理效应，并允许在异质性驱动因素之间建立客观层次，任何因果机器学习技术都可以用于识别冲击、结果和韧性组成部分之间的潜在因果关系。类似地，韧性组成部分的数据驱动重要性可以使用解释性机器学习中常用的各种特定模型或模型无关方法进行估计（Lundberg & Lee, 2017; Molnar, 2020）。

CLARE的一个显著优势在于其可扩展性和灵活性。因果机器学习的应用能够基于实证证据估计和定制变量重要性权重，从而以数据驱动的方式促进韧性子组件的聚合。这不仅提高了韧性测量的准确性，还确保了CLARE可以在不同的地理和时间背景下应用。CLARE可用于计算与不同特定冲击（例如，干旱、洪水、冲突、市场冲击）相关的韧性能力指标，或是一个包含多种不同冲击的通用冲击度量，并且可以采用任何可能的福祉结果。最后，它能够适应政策制定者在优先级和资金效率方面的不同偏好。通过为优先考虑敏感性而非准确性设定客观阈值，它通过替代最小化程序隐含地对韧性干预措施进行成本效益分析，这允许减少假阴性数量以提高项目效率，或增加假阳性数量以确保更广泛的覆盖范围。总而言之，得益于所有这些特性，我们方法的可适应性允许在数据稀缺的环境中迁移学习，并可以为易受特定冲击（如气候脆弱性热点）地区提供更有效和及时的分析，从而实现更有针对性和主动的韧性建设干预措施。

然而，我们的方法并不是万能药。虽然CLARE解决了现有方法的许多不足之处

指标，但它并不能解决所有问题。首先，和任何其他预测方法一样，CLARE 对非平稳性问题敏感，在机器学习文献中被称为分布偏移。当训练数据分布与模型在测试过程中遇到的数据分布不同时，会发生分布偏移，导致性能严重下降。关于这一点，Constenla-Villoslada 等人最近（2025）的一项研究表明，在使用监督机器学习技术预测急性儿童营养不良时，使用高频监控数据可以大大减少非平稳性问题。类似地，通过将标准面对面调查与高频电话调查或高时间分辨率遥感数据相结合，CLARE 对此问题的敏感性有可能得到降低。

其次，CLARE 仅与冲击相关，而非应激因素，如方程式1仅定义为随机变量的实现。这个问题不仅影响CLARE，也影响其他关键韧性指标（例如，Cissé & Barrett, 2018；Alloush & Carter, 2024）。CLARE只能衡量福祉对发生的冲击的敏感性。但如果（未投保）风险暴露的大部分损害来自于家庭为应对冲击的可能性而做出的行为适应，那么反事实已经考虑了风险预期的行为反应

³⁷

这反过来可能导致对冲击真实影响的低估，其中一部分冲击。通过事前风险机制影响福祉。解决这个问题的一个方案可能是将观察到的永久波动性指标作为风险下行为变化的代理指标，从而将脆弱性指标整合到韧性指标中。

第三，李等人（2025）的最新研究表明，韧性措施如何对用作衡量基准的福祉指标的选择非常敏感，并提出了几个多维替代方案。我们没有在这里解决这个问题。然而，我们认为他们的工作——专注于韧性估计方程的左侧——是对我们在这篇论文中为改进右侧的韧性估计所做的努力的补充。虽然CLARE可以应用于任何福祉结果，并且其权重和性能原则上可以证明在不同福祉衡量标准（例如，粮食安全、资产衡量、消费等）之间是稳健和稳定的，但这与使用数据驱动方法将多个结果衡量标准完全整合为一个指标，然后在这个指标上估计多维CLARE分数有所不同。所有这些都是未来研究的关键途径。

最后，CLARE的成功运行从根本上依赖于多种

³⁷
我们感谢克里斯·巴雷特指出了这一点。

主题、纵向和地理参考调查数据。加强非洲现有的国家纵向调查系统，并在其他地方复制类似的本土调查系统，应是那些已明确加强韧性目标的国家、国际组织和发展伙伴的战略优先事项。当这些系统与创新的韧性测量方法（如CLARE）相结合时，就有潜力确保韧性建设努力既有证据依据又具响应性，保障福祉并加速向可持续发展目标迈进。最近证据表明，基于机器学习的营养不良预测依赖于高频调查数据（Constenla-Villoslada等人，2025年），且非传统数据来源单独使用，即使结合机器学习工具，也无法复制随机实验中对关键结果（如粮食安全）的治疗效应估计（Aiken等人，2025年）。然而，为了更有效地为韧性议程做出贡献，下一代调查系统应考虑优先考虑：（a）更精简、更以受访者为中心的面对面调查，这些调查成本更低、数据传播更快；（b）韧性测量的调查内容跨国协调；（c）将严格的面对面调查转变为混合模式操作，通过在面对面轮次之间进行电话访谈来提高数据收集的适应性和频率——借鉴自新冠大流行以来的动力（Gourlay等人，2021年），以及（d）自适应抽样设计，不仅要在基线阶段过度抽样脆弱家庭（一种新方法），还要在未来从可能受气候变化、冲突和/或环境冲击影响的地区抽样额外家庭。

参考文献

阿巴迪, A., 戴蒙德, A., & 海恩穆勒, J. (2010). 比较案例研究的合成控制方法：估计加利福尼亚州烟草控制计划的效果。 *美国统计协会杂志* , 105 (490), 493-505.

艾肯, E. L., 贝多亚, G., 布卢门施托克, J. E., & 库维尔, A. (2023). 基于机器学习和手机数据的干预项目针对性研究：阿富汗反贫困干预的证据。 *发展经济学杂志* , 161 , 103016.

艾肯, E., 贝尔, S., 布鲁姆斯坦, J. E., 卡尔兰, D., & 乌迪, C. (2025). 通过调查与数字足迹估算影响：来自多哥随机现金转移的证据。 *发展经济学杂志* , 175 , 103477.

艾肯, E., 贝尔, S., 卡尔兰, D., 乌迪, C., & 布卢门施托克, J. E. (2022). 机器学习和电话数据可以改进人道主义援助的目标。 *自然* , 603 (7903), 864-870.

阿尔基尔, S., & 福斯特, J. (2011). 对多维贫困测量的理解和误解。 *经济不平等杂志* , 9 (2), 289-314.

阿劳什, M., & 卡特, M. (2024). 基于反事实的经济韧性定义与估计。 *美国国家经济研究局 (NBER) 工作论文* , 33290号

阿尔汉格尔斯基, D., & 贡萨洛·维多·伊门茨 (2024). 固定效应与广义门德洛克估计量。 *经济学研究评论* , 91 (5), 2545-2571.

阿特希, S., & 伊姆本斯, G. (2016). 针对异质因果效应的递归划分。 *美国国家科学院院报* , 113 (27), 7353-7360.

阿特希, S., & 埃姆宾斯, G. W. (2019). 经济学家应该了解的机器学习方法。 *经济学年度评论* , 11 (1), 685-725.

贝兹, J. E., 克希尔萨加尔, V., & 斯库里菲亚斯, E. (2024). 干旱敏感型目标定位与南部非洲儿童生长迟缓。 *世界发展* , 182 , 106702.

巴雷特, C. B., & 卡特, M. R. (2013). 贫困陷阱和持续贫困的经济学: 实证

以及政策影响。 *发展研究杂志* , 49(7), 976-990.

巴雷特, C. B., & 康斯塔斯, M. A. (2014). 迈向国际发展应用中的韧性理论. *美国国家科学院院报* , 111 (40), 14625-14630.

巴雷特, C. B., 加尔格, T., & 麦克布莱德, L. (2016). 福祉动态与贫困陷阱. *资源经济学年度评论* , 8 (1), 303-327.

巴雷特, C. B., 格泽兹-科佩尔, K., 霍丁诺特, J., 霍马米, N., 泰南特, E., 汤普森, J., & 吴, T. (2021). 关于发展韧性文献的综述:理论、方法和证据. *世界发展* , 146 , 105612.

布卢门施托克, J. E., 莱伯特, T. J., & 普特曼, D. S. (2025). 探索移动电话元数据在贫困预测和影响评估中的局限性. *发展经济学杂志* , 103462.

Béné, C., Chowdhury, F. S., Rashid, M., Dhali, S. A., & Jahan, F. (2017). 画圆求方：在韧性影响评估中协调严谨需求与现实. *世界发展* , 97 , 212-231.

Béné, C., Newsham, A., Davies, M., Ulrichs, M., & Godfrey-Wood, R. (2014). 综述：韧性、贫困与发展. *国际发展杂志* , 26(5), 598-623. doi:10.1002/jid.2992.

布鲁门施托克, J., 卡达穆罗, G., & オン, R. (2015). 基于手机元数据的贫困与财富预测. *科学* , 350 (6264), 1073-1076.

布朗, C., 马特森, D. S., 麦克布莱德, L., 胡, L., 刘, Y., 孙, Y., ... & 巴雷特, C. B. (2021). 多元随机森林预测贫困和营养不良的普遍性. *PloS ONE* , 16 (9), e0255519.

卡尔, E. R. (2019). 特性和项目：协调复原力和转型以适应和发展. *世界发展* , 122, 70-84.

卡特, M. R., & 巴雷特, C. B. (2006). 贫困陷阱和持续贫困的经济学：一种基于资产的方法. *发展研究杂志* , 42 (2), 178-199.

塞库拉, A., 莱塔, M., & 皮诺, G. (2025). 关于 (误) 使用机器学习与面板数据。 *牛津经济学与统计学公报* , 1-13.

切尔诺祖科夫, V., 切特韦里科夫, D., 德米尔尔, M., 杜福尔, E., 汉森, C., 纽埃, W., & 罗宾斯, J. (2018). 双/双重偏差机器学习用于处理和结构参数。 *计量经济学杂志* , 21(1), C1-C68.

切尔诺祖科夫, V., 汉森, C., 卡卢斯, N., 斯宾德勒, M., & 西尔甘尼斯, V. (2024). 基于机器学习和人工智能的应用因果推理。 *arXiv预印本 arXiv:2403.02467* .

西塞斯, J. D., & 巴雷特, C. B. (2018). 估计发展韧性：基于条件矩的方法。 *发展经济学杂志* , 135 , 272-284.

康斯坦斯, M., 弗兰肯伯格, T., & 霍迪诺特, J. (2014). 韧性测量原则：迈向测量设计议程。 *粮食安全信息网络, 韧性测量技术工作组, 技术系列* , 1 .

康斯坦拉-维洛斯拉达, S., & 刘, Y., & 麦克布莱德 L., & 奥马, C., & 莫坦达, N., & 巴雷特, C.B. (2025). 高频监测支持机器学习预测急性儿童营养不良以实现早期预警。 *美国国家科学院院报* , 122(23), e2416161122.

德·让维里, A. & 萨杜莱, E. (2015). 发展经济学：理论与实务. 罗德出版公司.

戴尔, M., 琼斯, B. F., & 奥尔肯, B. A. (2014). 我们从天气中学到了什么？新的气候经济文献。 *经济学文献杂志* , 52 (3), 740-798.

德康, S. (2004). 增长与冲击：来自埃塞俄比亚农村的证据。在 *宏观经济政策与贫困* (p. 308-329). 劳特利奇出版社。

德·埃里科, M., & 迪·吉尤塞佩, S. (2018). 乌干达的韧性流动：动态分析。 *世界发展* , 104 , 78-96.

德·埃里科, M., 莱塔, M., 蒙塔尔巴诺, P., & 皮泰雷利, R. (2019). 对温度异常的韧性阈值：对坦桑尼亚农村地区的长期检验。 *生态经济学* , 164 , 106365.

Duclos, J. Y., Sahn, D. E., & Younger, S. D. (2006). 鲁棒多维贫困比较. The

经济学杂志, 116(514), 943-968。

多安, M. K., 希尔, R., 哈勒盖特, S., 科拉尔·罗达斯, P. A., 布伦克霍斯特, B. J., 阮, M., ... & 奈卡尔, E. G. (2023). 统计受到气候变化影响、易受气候变化影响或面临气候变化高风险的人群——一种方法论。 *世界银行政策研究工作论文* 编号10619。世界银行。

埃谢温, D., 福索, G., 布鲁比, Y., 库卢姆布, H. & 李, Q. (2025). 结合调查和普查数据进行半监督深度学习改进的贫困预测。 *发展经济学杂志*, 172, 103385.

法夫香普斯, M. (1992). 经济作物生产、食品价格波动以及第三世界农村市场一体化。 *美国农业经济学杂志*, 74 (1), 90-99.

联合国粮食及农业组织 (2016年)。韧性指标测量与分析——II：分析韧性以实现更好的目标定位和行动。粮农组织。可在以下网址获取：
<https://openknowledge.fao.org/server/api/core/bitstreams/c61a9a8c-feb4-4199-8cb1-7085c84908c8/content>

Funk, C., 彼得森, P., 兰德斯菲尔德, M., 佩德雷罗斯, D., 维尔丁, J., 沙克拉, S., ... & 米哈塞伦, J. (2015). 气候灾害红外降水与站点—a新的环境记录用于监测极端事件。 *科学数据*, 2 (1), 1-21.

加尔博罗, A., & 列塔, M. (2022). 使用机器学习预测家庭韧性：初步跨国测试。 *经验经济学*, 63 (4), 2057-2070.

高乐 S.、基利奇 T.、马尔图斯切利 A.、沃尔堡 P. 和泽扎 A. (2021). 观点：关于COVID-19的高频语音调查：良好实践、开放性问题。 *食品政策*, 105, 102153.

哈拉里, M., & 费拉拉, E. L. (2018). 冲突、气候和细胞：一种细分分析。 *经济学与统计学评论*, 100 (4), 594-608.

哈斯蒂, T., 蒂比希尔拉尼, R., 弗里德曼, J. H., & 弗里德曼, J. H. (2009). *统计学习的基础：数据挖掘、推断与预测* (第2卷, 第1-758页)。纽约：斯普林格。

霍宾斯, M. T., 伍德, A., 麦克沃伊, D. J., 亨廷顿, J. L., 莫顿, C., 安德森, M., & 海恩, C. (2016). 蒸散发需求干旱指数。第一部分：将干旱演变与变化的联系

蒸发需求。水文气象学杂志, 17(6), 1745-1761。

霍辛, M., 马拉利, C., & 阿萨杜拉汗, M. N. (2019). 基于热量的粮食安全指标的替代方案：机器学习方法的应用 *食品政策*, 84, 77-91.

Imbens, G. W., & Rubin, D. B. (2015). *统计学、社会学和生物医学科学中的因果推理* 剑桥大学出版社。

让·N., 伯克·M., 谢·M., 戴维斯·W. M., 洛贝尔·D. B., & 艾尔蒙·S. (2016). 结合卫星图像和机器学习来预测贫困。 *科学*, 353 (6301), 790-794.

约瑟夫森, A., 米勒, J. D., 基利奇, T., & 默里, S. (2025). 天气的误测量：利用地球观测数据进行社会经济结果的估计。 *发展经济学杂志*, 103553.

克萊因伯格, J., 卢德维格, J., 穆拉纳扬, S., & 奥伯迈耶, Z. (2015). 预测政策问题。 *美国经济评论*, 105 (5), 491-495.

克瑙斯, M. C. (2022). 在无混杂性下的双机器学习程序评估 *计量经济学杂志*, 25 (3), 602-627.

Knippenberg, E., Jensen, N., & Conostas, M. (2019). 使用高频数据量化家庭韧性：时间动态与方法选项。 *世界发展*, 121, 1-15.

Knittel, C. R., & Stolper, S. (2025). 利用机器学习精准施策：家庭能源使用案例分析。 *经济月刊*, 即将出版。

李承敏; 阿巴伊, 基布罗姆 A.; 巴雷特, 克里斯托弗 B.; 和 霍丁诺特, 约翰 F. (2025). 估算多维发展韧性。 *发展经济学杂志* 即将出版。

莱塔, M., 蒙塔尔巴诺, P., & 保拉·奥尼奥, A. (2024). 气候不动困局：一个家庭层面的检验。 *世界银行政策研究工作论文* no.10724.

Lundberg S., & Lee, S.I. (2017). 一种解释模型预测的统一方法。A *神经信息处理系统进展*, 30.

麦克布莱德, L., & 尼科尔斯, A. (2018). 利用样本外验证重新调整贫困瞄准

机器学习。《世界银行经济评论》32(3), 531-550。

米勒, J. D., 约瑟夫森, A., 基利奇, T., & 默里, S. (2022). 隐私保护, 测量误差, 以及遥感与社会经济调查数据的整合。《发展经济学杂志》, 158, 102927.

Molnar, C. (2020). 可解释机器学习. Lulu.com.

蒙蒂奇, J. L. (1965). 蒸发与环境. 在《实验生物学学会专题讨论会》(第19卷, 第205-234页)。剑桥大学出版社 (CUP), 剑桥。

蒙塔拉沃, P., & 罗马诺, D. (2022). 对粮食和营养不安全性的脆弱性和复原力: 走向统一框架的文献综述。《生物基与应用经济学》, 11(4), 303-322.

Mullainathan, S., & Spiess, J. (2017). 机器学习: 一种应用计量经济学方法。《经济学展望杂志》, 31 (2), 87-106.

Mundlak, Y. (1978). 关于时间序列和截面数据的合并。《计量经济学: 经济计量学会期刊》, 69-85.

Premard, P., & Stoeffler, Q. (2022). 现金转移、气候冲击与萨赫勒地区的韧性。《环境经济学与管理杂志》, 116, 102744.

昆特, A., 诺伊费尔特, H., & 麦卡比, J. T. (2019). 建设生计韧性: 农林业扮演什么角色? 《气候与发展》, 11(6), 485-500.

兰努奇, I., 罗马诺, D., & 提贝蒂, L. (2025). 天气冲击和粮食不安全性的恢复能力: 探讨性别和亲属规范的作用。《世界发展》, 188, 106847.

拉特利奇, N., 卡达穆罗, G., 德·拉·奎斯塔, B., 斯蒂格勒, M., & 布尔克, M. (2022). 利用机器学习评估电力获取对生活的影响。《自然》, 611 (7936), 491-495.

斯科格纳米洛, A., 宋, C., & 伊格纳丘克, A. (2023). 无人是一座孤岛: 一种空间明确的方法来衡量发展韧性。《世界发展》, 171, 106358.

希尔皮, F., 卡恩, M.E., & 伯格, C. 2025. 重新思考韧性: 适应气候变化。先期版。《世界银行政策研究报告》 华盛顿特区: 世界银行。

史密斯, L. C., & 弗兰克纳伯格, T. R. (2018). 弹性能力是否减少了冲击对家庭粮食安全的负面影响? 来自2014年孟加拉国北部洪水的证据。 *世界发展* , 102 , 358-376.

乌普顿, J. B., 西塞, J. D., & 巴雷特, C. B. (2016). 粮食安全作为韧性: 协调定义和测量。 *农业经济学* , 47 (S1), 135-147.

乌普顿, J., 康斯坦利亚-维洛斯拉达, S., & 巴雷特, C. B. (2022). 慎用之: 对韧性测量方法的比较评估。 *发展经济学杂志* , 157 , 102873.

维拉克里斯, A. H., 巴德尔杜扎, S., & 米什拉, A. K. (2024). 基于机器学习对韧性和粮食安全的探索。 *应用经济学视角与政策* , 第46卷, 1479-1505.

wager, s., & athey, s. (2018). 基于随机森林的异质性治疗效果估计与推断。 *美国统计学会杂志* , 113 (523), 1228-12.

沃尔特, I. A., 艾伦, R. G., 埃利奥特, R., 詹森, M. E., 伊滕菲苏, D., 梅奇姆, B., ... & 马丁, D. (2000). ASCE的标准化参考蒸发蒸腾公式。 *流域管理及运营管理* , 2000 , 1-11.

维斯曼, 多丽丝, 露西·巴塞特, 托德·本森和约翰·霍丁诺特 (2009)。世界粮食计划署膳食消费评分和家庭粮食安全替代指标的有效性检验。国际食品政策研究所讨论文件 00870。

伍德里奇, J. M. (2021). 双向固定效应、双向 mundlak 回归和双重差分估计量。 *在ssrn上可以找到* 3906 345 .

伍尔夫 S., 特威格 J., 帕里克 P., 卡拉奥卢 A., & 查亚布 T. (2016). 迈向可衡量的韧性: 一个评估贫民窟韧性水平的新型框架工具。 *国际灾害风险 Reduction杂志* , 19 , 280-302.

世界银行; 国际能源署; 国际可再生能源署; 联合国统计司; 世界卫生组织。(2024年)。追踪可持续发展目标7: 能源进展报告2024 (英文版)。华盛顿特区: 世界银行。

世界银行 (2023年)。通过能源获取改变东部和南部非洲人民的生活。 *世界银行成果简介* 华盛顿特区: 世界银行。

附录 A – 数据详情

表 A.1：变量描述

变量名	定义
食物消费得分 (FCS)	食物消费评分
粮食不安全	FCS≤35
干旱月份占比	生长季节月份经历干旱的份额 (GS-EDDI > +1)
干旱 (GS-EDDI)	=1若干旱GS-EDDI占比>75百分位数 国家特定分布
多冲击	= 1如果家庭经历了任何冲击
家庭主户年龄	户主年龄
家庭户主性别	=1如果女性户主
家庭规模	家庭规模
% 成员 男性 ≤15岁	% 成员 男性 ≤15岁
% 成员 男性 16-65 岁	% 成员 男性 16-65 岁
% 成员 女性 16-65岁	% 成员 女性 16-65岁
% 成员 男性 >65岁	% 成员 男性 >65岁
% 成员 女性 >65岁	% 成员 女性 >65岁
农村	如果家庭居住在农村地区，则为1
HH成员识字人数	HH成员识字人数
拥有初中学历的家庭户成员数	拥有初等教育的户主数量
拥有初等教育或更高学历的家庭户成员数量	拥有初等教育或更高学历的家庭户成员数量
家庭资产指数	家庭资产指数
移动拥有	=1 如果家庭拥有移动电话
TLU今天	调查时热带牲畜单位数量
村庄内关键服务的数量	社区内关键服务的数量 (5)
到市场距离	市场距离 (km)

注意：此表提供了分析中使用的关键变量的定义。

表A.2：汇总统计——完整样本

变量	obs	均值	标准差	明	最大
食物消费得分 (FCS)	28,112	51.049	19.848	0	126
FCS (延迟)	28,112	50.78	19.864	0	126
粮食不安全	28,112	.203	.402	0	1
食物不安全 (滞后)	28,112	.21	.408	0	1
干旱月份占比	28,112	.086	.093	0	.6
干旱 (GS-EDDI)	28,112	.25	.433	0	1
多冲击	28,112	.597	.491	0	1
家庭主户年龄	28,047	49.224	15.278	10	113
hh主要负责人的年龄 (滞后)	28,112	47.539	15.537	14	150
家庭户主性别	28,112	.262	.44	0	1
家庭户主性别 (滞后)	28,112	.245	.43	0	1
家庭规模	28,112	6.27	3.298	1	35
家庭规模 (滞后)	28,112	6.021	3.164	1	35
% 成员男性 <=15岁	28,112	.19	.173	0	.857
% 成员男性 <=15岁 (滞后)	28,112	.2	.179	0	.857
% 成员男性 16-65岁	28,112	.23	.196	0	1
% 成员男性 16-65岁 (滞后)	28,112	.241	.204	0	1
% 成员女性 16-65岁	28,112	.247	.171	0	1
% 成员女性 16-65岁 (滞后)	28,112	.255	.173	0	1
% 成员男性 >65岁	28,112	.053	.129	0	1
% 成员男性 >65岁 (滞后)	28,112	.044	.12	0	1
% 成员女性 >65岁	28,112	.067	.158	0	1
% 成员女性 >65岁 (滞后)	28,112	.052	.142	0	1
农村	28,112	.737	.441	0	1
农村 (滞后)	28,112	.737	.44	0	1
HH成员识字人数	28,099	3.127	2.358	0	22
hh成员有文化程度数量 (滞后)	28,112	3.003	2.333	0	18
拥有初中学历的家庭户成员数	28,099	1.006	1.282	0	13
拥有初中学历的家庭户成员数 (lag)	28,112	1.181	1.445	0	15
拥有中等教育的户主数量 28,099 或更高		.851	1.387	0	13
拥有初中学历的家庭户成员人数 28,112 或更高 (延迟)		.798	1.322	0	15
家庭资产指数	28,112	-.018	.978	-1.23	8.532
家庭资产指数 (滞后)	28,112	-.012	.96	-1.174	8.107
移动拥有	28,094	.69	.462	0	1
移动拥有 (延迟)	28,112	.668	.471	0	1
TLU今天	27,719	1.203	5.607	0	480.9
tlu今天 (延迟)	28,112	1.253	7.740	0	490.260
村庄内关键服务的数量	27,261	3.632	1.509	0	5
村庄内关键服务的数量 (滞后)	28,112	3.668	1.473	0	5
到市场距离	24,899	36.965	37.914	0	214.36
市场距离 (滞后)	28,112	36.118	38.149	0	214.36

备注：该表格报告了分析中使用的变量的描述性统计量，包括当前值和滞后值。汇总指标基于跨国家和周期的完整合并数据集。

表A.3：家庭资产指数的组成部分

马拉维	尼日利亚	坦桑尼亚	乌干达
研钵研杵	家具 (3/4件沙发套装)	收音机和磁带录音机	房子
床	家具 (椅子)	电话 (固定电话)	其他建筑
表	家具 (桌子)	电话 (手机)	地
椅子	床垫	冰箱或冷冻箱	家具/装饰品
风扇	床	缝纫机	家用电器
空调	mat	电视	电视
无线电 (‘无线’)	缝纫机	视频 / DVD	收音机/卡带
磁带或CD/DVD播放器； HiFi	燃气灶	椅子	生成器
电视	炉灶 (电动)	沙发	太阳能电池板/电动 逆变器
VCR	燃气灶 (餐桌)	表格	自行车
缝纫机	炉灶 (煤油)	手表	摩托车
煤油/柴油炉	冰箱	床	机动车辆
电磁炉或燃气灶；热 板	冷冻箱	橱柜，箱式柜 抽屉，箱子，衣柜， 书架	船
冰箱	空调	灯笼	其他交通方式
洗衣机	洗衣机	计算机	珠宝和手表
自行车	电动烘干机	炊具，杯，其他 厨房用具	手机
摩托车/踏板车	自行车	蚊帐	计算机
汽车	摩托车	铁 (木炭或电力)	网络访问
微型巴士	汽车和其他车辆	电/燃气灶	其他电子设备
卡车	生成器	其他炉灶	其他家庭资产 (例如，割草机)
啤酒酿造鼓	风扇	热水器	
包垫椅，沙发套装	无线电	收录机，磁带 录音机	
咖啡桌 (用于坐) 房间)	磁带录音机	完整音乐系统	
橱柜，抽屉，书桌	高保真 (音响系统)	书籍 (非教科书)	
灯笼 (石蜡)	微波	机动车辆	
桌	铁	摩托车	
时钟	电视机	自行车	
铁 (用于熨烫衣物)	电脑	购物车	
计算机设备& 配件	DVD播放器	动物小推车	
卫星天线	卫星天线	船/独木舟	
太阳能电池板	乐器	独轮车	
生成器		房屋	
		空调	
		抛物面天线/解码器	


表 A.4：家庭电力资产指数的组成部分

马拉维	尼日利亚	坦桑尼亚	乌干达
风扇	炉灶（电动）	收音机和磁带录音机	电视
空调	燃气灶（餐桌）	电话（固定电话）	收音机/卡带
磁带或CD/DVD播放器； HiFi	炉灶（煤油）	电话（手机）	生成器
电视	冰箱	冰箱或冷冻箱	太阳能电池板/电动 逆变器
VCR	冷冻箱	缝纫机	手机
缝纫机	空调	电视	计算机
电磁炉或燃气灶；热 板	洗衣机	视频 / DVD	网络访问
冰箱	电动烘干机	计算机	其他电子设备
洗衣机	自行车	铁（木炭或电力）	其他家庭资产 （例如，割草机）
铁（用于熨烫衣物）	摩托车	电/燃气灶	
计算机设备& 配件	汽车和其他车辆	热水器	
卫星天线	生成器	收录机，磁带 录音机	
生成器	风扇	完整音乐系统	
	无线电	空调	
	磁带录音机	抛物面天线/解码器	
	高保真（音响系统）		
	微波		
	铁		
	电视机		
	电脑		
	DVD播放器		
	卫星天线		
	乐器		

附录B——方法学附件


- 因果森林预测问题的结果

图B.1：冲击效应分布



注意：垂直的虚红线对应ATE。

图B.2：预测任务的变量重要性权重



备注：该图报告了主要预测任务的可变重要性权重，使用因果森林估计得到。为了保持极性而不改变与结果的相关性，以下标准化变量已被作为补充包含在最终的CLARE聚合中（事后估计）：户主年龄（滞后）；距市场的距离（滞后）；户主性别（滞后）；农村（滞后）；女性成员>65%（滞后）；男性成员16-65岁%（滞后）；男性成员>65%（滞后）。

表B.1：因果森林拟合

校准测试	估计	标准误差t值		P(>t)
平均森林预测	0.999	0.149	6.690	0.000***
微分森林预测	0.995	0.286	3.473	0.000***

备注：这是Athey等人（2019年）推荐的校准测试结果，用于评估因果森林拟合的质量。“均值森林预测”的系数为1表示均值森林预测是正确的，而“差分森林预测”的系数为1则进一步表示森林中的异质性估计得到了良好的校准。参见 [这里](#) 了解更多详情。最后，过量误差低于 7.8×10^{-6}

-6

估计 Cissé 和 Barrett (2018) 复原分数的方法细节

西塞和巴雷特（2018）（C&B）方法将韧性理论操作化为西塞和科斯塔斯（2014）所提出的规范条件，并指维持超过临界福祉阈值的高概率概念。C&B方法利用计量经济学技术估计福祉指标的条件矩。下面，我们提供对韧性评分估计中涉及的步骤的详细分解。

在这个分析中，我们采用与CLARE估计相同的变量集。然而，在这种情况下，所有变量都在时间点 t 而不是滞后于 $t-1$ ，以与原始方法保持一致。为确保所有观察中的样本量保持一致，我们在时间点处理缺失值 t 通过使用相应变量的过去值进行填充。总体填充率约为1.32%。鉴于这个低百分比，填充对数据集的影响很小。虽然我们承认这种填充方法可能不是最严谨的方法论，但它使我们能够在使用Cissé和Barrett方法估计韧性得分时保持一个全面的数据集。

为了进行样本外检验，我们使用数据集的前三波数据估计Cissé和Barrett韧性得分。然后，通过比较从第三波数据得出的韧性得分（RS）的二分类与第四波观察到的粮食不安全结果（ $FCS \leq 35$ ）来评估预测性能。对于乌干达——由于有更长的面板数据可用——这项检验被扩展并在额外的波对中进行迭代估计，具体为第四波和第五波、第五波和第六波，以及第六波和第七波。

第一步涉及使用普通最小二乘法 (OLS) 回归估算 FCS 的条件均值：

$$it = \frac{k}{\square \square \square \square} \quad it-1 \quad 1 \quad it \quad it \quad it$$

在哪里滞后幸福指□（上□表示多□式□数。水平□量，即我□的恢复能力□件； $\sum_{t=0}^{B-1}$
□□□□□□□） □□□□ □□□□ □□□□□□□□ □□□□ □□□□□□□□□□□□
□□□□□□□□-1
估□，并且残差□（□□□□）表示□差□。□□□□□□□□□□□□ □□□□
□□□□）形容了幸福感的□□特性，而
□□□□□□□□ □□□□ 包括家庭特征和社区特征
□□□□□□□□
是我们在CLARE中使用的相同二进制冲击指标

第一的平方残差 □□□□ □□□□□□□□ 两阶段回归被用作第二阶段回归的因变量，以如下方式估计条件方差：

在线附录

本文的在线附录可在以下网址获取：<https://shorturl.at/fvP3l>。
