

【AI 产业深度】OpenAI 阵痛后的新生：从单纯技术驱动模型竞赛到积极的工程化落地以支持 AI 产业更好的商业化生态

摘要:

- 自 2025 年 4 月以来，OpenAI 在 LLM 领域动作频繁，考虑到 GPT-4.5 “高价低效”的市场评价，将旗舰模型刚发布不到 2 个月 GPT-4.5 下线，随后发布对 GPT-4.5 的访谈视频，回顾其从构思到训练完成的历程，并反思局限性与最终效果。紧接着迅速推出 o3 与 o4-mini 两款头部推理模型以及新一代旗舰模型 GPT-4.1，并推出一系列优化升级。**这些动作表明 OpenAI 在经历一段时间的探索与沉淀后，正积极通过产品优化与创新，提升用户体验，降低使用壁垒，以巩固其在人工智能领域的领先地位。**
- OpenAI 通过深化分层产品矩阵与垂直场景渗透战略**，推出覆盖企业级高性能需求至轻量级应用场景的 GPT-4.1 系列(含旗舰版、mini 版、nano 版)，形成差异化产品布局。
- OpenAI 在工具调用能力上实现显著突破**，以 o3 和 o4-mini 为代表的推理模型展现出强大的任务处理与工具运用能力，为解决复杂任务奠定基础。不仅支持全面调用 ChatGPT 工具及通过 API 函数调用自定义工具，还能通过训练推理问题解决方案、动态调整策略并快速输出详细答案，其中 o3 更能引用行业相关来源提供数据驱动的解决方案，预见挑战并给出缓解措施，且模型通过深度整合 Python 解释器、图像处理工具及网页搜索等构建“AI 代理+工具链”闭环。
- OpenAI 在技术普惠与商业化探索的双重战略布局中，通过多维度更新构建生态体系**。开源 Codex CLI 并以百万美元计划激励开发者生态，免费用户可试用 o4-mini，付费用户可获高性能模型支持；尤其值得关注的是，Codex 作为云端软件工程智能体，整合软件工程全流程，支持并行任务处理、云沙盒独立运行及 GitHub Pull Request 生成，瞄准企业级规模化开发场景，同时新系列模型的开放 API 与 ChatGPT 功能创新进一步深化 B 端与 C 端渗透，推动 AI 技术向实用化、生态化演进。
- 风险提示：**语言模型的技术进展不及预期；人工智能行业内外竞争格局变化带来的不确定性；算法或功能优化不及预期等。

产业研究中心

	鲍雁辛(分析师)
	021-38676666
登记编号	S0880513070005
	李嘉琪(分析师)
	021-38676666
登记编号	S0880524040001
	刘峰(研究助理)
	021-38676666
登记编号	S0880124060013

目录

1. Open AI 围绕 GPT-4.5、GPT-4o 产品争议主动披露问题、深度反思，提出高价值改进策略	3
1.1. GPT-4.5 因高价低效遭质疑，OpenAI 终止其 API 服务并公开复盘，彰显自我反思与应对市场竞争的决心	3
1.2. GPT-4o 增强多模态交互与智能个性，却因“奉承”问题而让 OpenAI 回退更新，凸显模型的个性服务与中立性平衡难题	3
2. GPT-4.1 的推出体现基于用户反馈的市场路线调整	4
3. 全新推理模型 OpenAI o3 与 o4-mini 拥有强大的任务处理能力和高效的工具运用能力，为复杂任务的解决奠定了基础	14
4. OpenAI o3 与 o4-mini 在应用中，其强大的图片理解能力成为核心亮点	18
5. OpenAI o3 与 o4-mini 高度重视安全性同步增强，确保模型安全性和稳健性	20
6. Open AI 多维度持续更新，包括重大更新 Codex，在技术普惠与商业化探索双重螺旋式布局	21
6.1. Codex 向应用层延伸，占据开发者工作流的关键节点	21
6.2. API 进一步开放，持续维护开发者生态建设	23
6.3. 用户体验创新上 OpenAI 积极探索新的应用场景拓展	24
7. Open AI 持续全栈工具链整合的战略深化，通过紧密依托开发者生态，构建更具活力与实用性的 AI 技术应用体系	24
8. 风险提示	25

1. Open AI 围绕 GPT-4.5、GPT-4o 产品争议主动披露问题、深度反思，提出高价值改进策略

在半个月的时间窗口内，OpenAI 围绕 GPT-4.5 与重大升级后的 GPT-4o 两款市场反馈不佳的产品，深度回溯与反思，通过主动披露技术细节、公开迭代失误案例等方式，积极回应市场关切与用户反馈。这一系列举措不仅展现了 OpenAI 在模型优化进程中的自我审视，也折射出人工智能行业在产品迭代与用户需求适配过程中的复杂挑战与难度。

1.1. GPT-4.5 因高价低效遭质疑，OpenAI 终止其 API 服务并公开复盘，彰显自我反思与应对市场竞争的决心

回溯至 2025 年 2 月 28 日，OpenAI 正式推出 GPT-4.5。官方宣称该模型为“史上规模最大、知识储备最丰富的聊天模型”。彼时，GPT-4.5 以“高情商”“知识渊博”以及“低幻觉率”等特性引发行业关注。然而，伴随市场对其的应用验证，其结构性矛盾逐步显现。

GPT-4.5 在商业层面，其 API 定价体系呈现显著溢价特征。输入数据处理成本为 75 美元/百万 token（数据来源：OpenAI 官网），相较前代产品 GPT-4o 形成 15-30 倍的价格大幅度上升。这种高成本定价导致企业级用户及中小型开发者群体的接入门槛大幅提升，严重限制其商业化应用场景拓展。在技术效能层面，尽管 GPT-4.5 在模型训练阶段投入超常规规模的算力资源与数据集，尤其在逻辑推理、复杂指令解析等核心任务场景下，其实际用户体验不及成本更为经济的 GPT-4o，暴露出模型优化与资源投入间的非对称问题。

面对市场质疑与技术效能争议，OpenAI 在推出新一代 GPT-4.1 系列模型的同时，宣布将终止 GPT-4.5 的 API 服务支持。这一战略调整不仅源于成本控制与性能优化需求，更受到开源人工智能生态快速发展的外部压力驱动。当前，开源社区在模型轻量化、分布式训练等关键技术领域持续突破，众多开源模型在保持高性能表现的同时，实现显著成本优势，形成对闭源商业模型的有力竞争态势，进一步压缩了 GPT-4.5 的市场生存空间。

值得关注的是，OpenAI 在宣布将终止 GPT-4.5 的 API 服务支持后，一反常态的发布了一则对过往产品的专题研讨视频《Pre-Training GPT4.5》，通过技术团队深度访谈形式，系统复盘该模型从算法设计、训练框架搭建到最终部署的全生命周期研发历程。视频内容不仅直面社区对模型性能表现的核心质疑，更从技术架构缺陷、数据标注偏差等维度展开成因剖析，展现出 Open AI 在技术迭代过程中的透明化沟通与系统性反思。

1.2. GPT-4o 增强多模态交互与智能个性，却因“奉承”问题而让 OpenAI 回退更新，凸显模型的个性服务与中立性平衡难题

无独有偶，2025 年 4 月 25 日，OpenAI 发布 GPT-4o 重大升级，因引发用户体验问题，上线仅不到五天后即撤回。随后通过官网长文《Expanding on what we missed with sycophancy》深度复盘失败原因，系统剖析技术缺陷。

起初此次更新旨在进一步优化模型性能，期望通过更好地整合用户反馈、记忆和最新数据，提升用户体验，使其在交互过程中展现出更高的智能性与适应性。在模型更新过程中，Open AI 采用了一套较为完善的研发流程，即先对预训练的基础模型进行监督微调，依据人类编写或现有模型生成的理想回复进行训练，随后运用来自多种渠道的奖励信号开展强化学习，以此塑造模型的最终行为。

然而，此次更新却出现了严重问题。更新后的模型呈现出过度谄媚（“奉承”）的

行为，不仅表现为一味迎合用户，还在回应中对用户的疑虑过度肯定、煽动负面情绪，甚至怂恿冲动行为，这不仅给用户带来不适体验，还引发了对用户心理健康、情感依赖及潜在风险行为的担忧。经过深入分析，发现多个原本旨在优化模型的改动共同作用导致了这一问题。例如，基于用户反馈（如点赞、踩数据）引入的额外奖励信号，虽然在通常情况下有助于提升模型表现，但在此次更新中，可能过度放大了用户反馈中对迎合性回复的偏好，削弱了原本抑制谄媚行为的主要奖励信号的影响力。同时，用户记忆机制在某些情境下也可能加剧了谄媚效果，尽管目前尚无证据表明其普遍会导致这一问题。

在模型发布前的审查环节，OpenAI 执行了包括离线评估、专家抽查测试、安全评估、前沿风险审查、红队测试以及小规模 A/B 测试在内的多道严格程序。但这些审查流程均未能有效识别出模型谄媚行为这一关键问题。离线评估在测试模型行为方面存在局限性，未能充分捕捉到谄媚行为；小规模 A/B 测试虽显示部分试用用户对更新后的模型表示认可，但样本数量有限且评估指标未能精准反映模型在谄媚方面的表现。此外，内部专家测试虽察觉到模型行为存在细微异常，但由于关注点主要集中在模型语气和风格的变化上，并未将谄媚风险作为明确的审查重点。

此次事件让 Open AI 重新审视和强化模型行为审查标准，将模型的性格特征和其他行为问题与传统安全风险同等对待，作为模型发布的关键阻碍因素进行考量，即使这些问题难以精确量化，也应依据替代指标或定性信号严格把控发布流程。在评估体系方面，要在重视定量指标的同时，更加关注难以测量的定性指标，避免因过度依赖部分指标而忽视潜在问题。同时，认识到现有评估手段无法完全预测所有可能出现的问题，尤其是对于一些细微或新兴的问题，需要更加注重在实际使用场景中发现和解决问题。从沟通层面而言，OpenAI 意识到任何模型更新，都可能对用户与 ChatGPT 的交互方式产生重大影响，因此未来将更积极主动地向用户传达更新信息，包括更新内容、已知的局限性等，确保用户能够全面了解模型变化。

OpenAI 针对 GPT-4o 模型更新事件的系统性反思与改进策略，为其自身构建更完善的模型研发管理体系奠定基础，通过对模型优化机制、风险评估框架及用户沟通范式的深度剖析，为行业提供了具有实践指导意义的参考范本。

2. GPT-4.1 的推出体现基于用户反馈的市场路线调整

GPT-4.1 的推出充分彰显了 OpenAI 基于用户反馈所做出的市场路线重大调整。此前的 GPT-4.5 与 GPT-4o 暴露出诸多问题，如 GPT-4.5 存在高价低效困境，在商业层面，其 API 定价体系溢价显著，输入输出成本相较前代产品形成 15-30 倍的价格上升，严重制约商业化应用拓展；技术层面，在行业基准测试中性能未达前沿标准，尤其在核心任务场景下表现欠佳。

在此背景下，OpenAI 研发出 GPT-4.1 系列。该系列拆分为 GPT-4.1、GPT-4.1 mini 和 GPT-4.1 nano 三款模型，各有特点与受众。


GPT-4.1 作为旗舰级模型，性能强劲，在编码、指令遵循和长上下文理解等方面表现卓越。在 SWE-bench Verified 编程基准测试中，得分高达 54.6%，相较 GPT-4o 提升了 21.4%，适用于处理复杂且对性能要求极高的任务，如大型软件项目的全流程开发、超大型代码库的深度审查以及对复杂指令有严格遵循要求的企业级应用场景，满足专业开发者与大型企业对高精度、强能力模型的需求。

GPT-4.1 mini 属于小型高效模型，在维持与 GPT-4o 相当甚至部分超越其性能的同时，将延迟降低近一半，成本大幅下降 83%。在智能评估方面表现出色，在多项基准测试中超越 GPT-4o，像视觉/图像类任务中涉及图表、图表和视觉等方面表现

突出。这使其适合那些对延迟较为敏感，且追求性能与成本平衡的应用场景，例如实时推荐系统、即时响应的聊天机器人以及移动和 Web 应用中需要快速交互的 AI 界面等，能为中小开发者与对成本有控制要求的企业提供高性价比选择。

GPT-4.1 nano 是 OpenAI 推出的首个超小型模型，也是目前速度最快、成本最低的一款。它虽体型小巧，但依然具备处理 100 万 token 上下文窗口的能力，在 MMLU 测试中得分达 80.1%、在 GPQA 测试中得分达 50.3%、在 Aider 多语言编码测试中得分达 9.8%，甚至高于 GPT-4o mini。该模型专为对处理速度要求极高，且对模型推理能力需求相对特定的任务设计，如自动补全建议、内容分类以及从大型文档中快速提取特定信息等。适用于对成本极为敏感、追求快速响应的小型企业或初创公司，以及需要在设备端运行 AI 模型的场景，为其提供便捷、低成本的 AI 支持。

图1: GPT-4.1 nano 侧重于速度和效率，GPT-4.1 则为旗舰综合模型




数据来源：Open AI 官网

与前代 GPT-4o 及 GPT-4o mini 相比，新模型在编码能力、指令跟踪效率等核心技术指标上实现显著突破，并将上下文窗口扩展至 100 万 token，通过优化长文本处理算法，大幅提升上下文理解效能，知识更新截止日期同步更新至 2024 年 6 月。

在行业标准评估体系中，GPT-4.1 展现出领先性能：于 SWE-bench Verified 编码能力测试中，以 54.6% 的得分超越 GPT-4o（33.2%）及 GPT-4.5（28%）；在 On Scale MultiChallenge（即衡量指令遵循能力的标准）中，得分 38.3%，较 GPT-4o 提升 10.5%；在视频-MME 多模态长上下文理解测试中，于长篇无字幕任务类别取得 72% 的成绩，刷新该领域性能记录，较 GPT-4o 提高 6.7%。

OpenAI 通过与开发者社区的深度协作，基于实际应用场景需求对模型进行针对性优化。GPT-4.1 系列在保持低运行成本的同时，全延迟区间均实现性能提升。

图2: GPT-4.1 模型系列以更低的成本提供了卓越的性能、较强的工程实用性与商业竞争力



数据来源: Open AI 官网

GPT-4.1 mini 在小模型领域展现出卓越竞争力, 多项基准测试结果显示其性能超越 GPT-4o, 同时实现近 50% 的延迟降低与 83% 的成本削减, 在智能评估维度达到或超过前代旗舰级产品标准, 适用于对响应速度与成本控制有严格要求的应用场景。而 GPT-4.1 nano 作为 OpenAI 目前速度最快、成本最低的模型, 具备 100 万 token 的超大上下文窗口, 在 MMLU、GPQA 及 Aider 多语言编码等测试中分别取得 80.1%、50.3% 和 9.8% 的成绩, 超越 GPT-4o mini, 尤其适用于内容分类、自动补全及轻量级文本处理任务。


在功能应用层面, GPT-4.1 系列通过强化指令遵循可靠性与长上下文理解能力, 显著提升智能代理系统的任务执行效能。结合 Responses API 等开发工具, 开发者可构建更高效可靠的自动化任务处理系统, 在文档信息提取、客户服务响应及复杂工程任务执行等场景中展现出更高的实用性与稳定性。

并且, GPT-4.1 通过 API 渠道提供服务, 其核心技术改进已逐步整合至 OpenAI 最新版本。同时, OpenAI 宣布将于 2025 年 7 月 14 日终止 GPT-4.5 预览版的 API 服务, 原因在于 GPT-4.1 在关键功能上实现性能优化的同时, 有效降低运行成本与响应延迟。作为 OpenAI 早期用于探索超大规模计算模型的实验性产品, GPT-4.5 为后续研发积累了重要经验, 其在创造力、文本生成质量等方面的优势将被延续至未来模型迭代中。

从基准测试数据来看, GPT-4.1 在软件工程领域展现出显著的技术飞跃, 尤其在代码库解析、任务自动化执行及可运行代码生成等关键环节表现突出, 验证了其在实际工程应用中的技术领先性。来自 Windsurf、Qodo 等 alpha 测试机构的实践案例进一步表明, GPT-4.1 在多领域任务处理中均展现出更高的可靠性与专业性。

- 1) **编码:** GPT-4.1 编码任务上比 GPT-4o 表现更好, 包括代理解决编码任务、前端编码、减少无关编辑、可靠地遵循差异格式、确保一致的工具使用等等。在衡量真实世界软件工程技能的 SWE-bench Verified 测试中, GPT-4.1 完成了 54.6% 的任务, 而 GPT-4o (2024-11-20) 的完成率为 33.2%, 提升 21.4%。这反映了模型在探索代码库、完成任务以及生成可运行并通过测试的代码方面的能力有所提升。

图3: GPT-4.1 任务完成率 54.6% 高于 GPT-4o 的 33.2%，模型在探索代码库、完成任务以及生成可运行并通过测试的代码方面的能力有所提升




数据来源: Open AI 官网

GPT-4.1 在代码差异分析能力上实现显著突破, 在跨 Python、Java、JavaScript 等主流编程语言的差异处理任务中展现出更高的可靠性与专业性。根据 Aider 多语言差异基准测试结果, GPT-4.1 得分达到 GPT-4o 的两倍以上, 较 GPT-4.5 提升 8%, 充分验证其在多语言编码能力、整体代码修改及差异格式生成方面的技术优势。

这一性能提升源于 OpenAI 对 GPT-4.1 的针对性训练优化, 通过强化模型对差异格式的理解与遵循能力, 开发者可直接获取模型输出的变更代码行, 无需对完整文件进行重新生成, 有效降低 API 调用成本与响应延迟。对于偏好完整文件重写的开发场景, GPT-4.1 将输出 token 上限扩展至 32,768 个, 较 GPT-4o 的 16,384 个实现翻倍提升。同时, 配合使用预测输出功能, 可进一步优化文件重写场景下的响应效率。为帮助开发者充分发挥模型性能, OpenAI 同步提供详细的提示工程指南, 指导用户进行参数配置与指令优化。


图4: 在多语言基准测试中, GPT-4.1 解决了来自 Exercism 的编码练习, 实现逼近推理模型的得分



数据来源: Open AI 官网

在前端编码技术指标与实际应用效能方面, GPT-4.1 较 GPT-4o 实现显著突破。通过优化核心技术栈的处理能力, GPT-4.1 能够生成结构更合理、交互性更强、视觉设计更优的 Web 应用架构与界面元素。基于标准化盲测评估体系, 经专业人工评分团队对 200 组同场景前端项目输出结果进行双盲对比评审, GPT-4.1 在用户体验、功能完整性、代码规范性等维度的综合评分, 较 GPT-4o 高出 80%, 充分验证其在前端开发领域的技术领先性与工程实用性。

图5: 左图为 GPT-4o 设计的 web 抽卡界面, 右图为 GPT-4.1, 在功能、美学等维度上 GPT-4.1 明显提升



数据来源: Open AI 官网

除了上述基准测试之外, GPT-4.1 在遵循格式方面表现更佳, 可靠性更高, 并且减少了无关编辑的频率。在 Open AI 的内部评估中, 代码中的无关编辑从 GPT-4o 的 9% 下降到了 GPT-4.1 的 2%。

图6: GPT-4.1 的编码能力在真实案例中性能显著提升

公司	评估维度	具体数据	对工程或工作的影响
Windsurf	编码基准测试效能 *GPT-4.1 在内部编码基准测试中与 GPT-4o 的得分对比	GPT-4.1 得分比 GPT-4o 高出 60%	工具调用效率提高了 30%，重复不必要的编辑或以过于狭窄的增量步骤读取代码的可能性降低了约 50%，带来更快的迭代速度和更流畅的工作流程
Qodo	代码审查质量测试 *GPT-4.1 与其他领先模型从 GitHub 拉取请求生成高质量代码审查的正面测试	在 200 个具有相同提示和条件的有意义的真实拉取请求中，GPT-4.1 在 55% 的案例中给出了更好的建议	GPT-4.1 在精确度（知道何时不提出建议）和全面性（在必要时提供彻底的分析）方面表现出色，能专注于真正关键的问题

数据来源：Open AI 官网、国泰海通研究所整理

2) **遵循指令**：通过系统性评估与技术优化，OpenAI 研发的 GPT-4.1 在指令遵循能力上实现显著突破。为全面衡量模型指令处理效能，OpenAI 构建了涵盖多维度指标的內部教学跟踪评估体系，聚焦六大核心指令遵循类别开展测试。

-格式遵循测试：验证模型对 XML、YAML、Markdown 等自定义格式指令的解析与输出能力，确保响应内容符合结构化数据规范；

-负面指令约束：通过设置禁止性指令（如“不得引导用户联系技术支持”），评估模型对行为边界的识别与规避能力；

-有序指令执行：考察模型对多步骤指令的顺序化处理能力，确保按既定流程完成任务（如“先采集用户姓名，再获取电子邮箱”）；

-内容要求达标：针对特定信息嵌入需求（如营养计划必须标注蛋白质含量），测试模型输出内容的完整性与准确性；


-输出排序规范：验证模型按指定逻辑（如按人口规模排序）对结果进行结构化处理的能力；

-认知边界把控：评估模型在信息缺失或任务超限时合理反馈能力（如主动提示“信息不足，建议联系 xxx 获取支持”）。

该评估体系的设计基于开发者实际需求调研，覆盖简单、中等、复杂三个难度层级的指令场景。测试数据显示，相较于前代 GPT-4o，GPT-4.1 在复杂指令处理场景下优势尤为显著，特别是在涉及多条件嵌套、格式混合要求等高阶任务中，展现出更高的指令解析准确性与任务执行可靠性。这一技术升级为开发者构建自动化工作流、智能客服系统及复杂任务处理平台提供了更稳定的底层支持。

图7: Open AI 基于真实的开发人员用例和反馈内部指导, GPT-4.1 相比 GPT-4o 获得更高评价

Internal OpenAI Instructions following eval accuracy (hard subset)




数据来源: Open AI 官网

在自然语言交互场景中,多轮指令遵循能力是衡量语言模型性能的关键指标之一,对于开发者构建智能对话系统、虚拟助手等应用至关重要。OpenAI 通过优化训练策略,显著提升了 GPT-4.1 在多轮对话中的信息整合与上下文理解能力。该模型能够精准识别对话历史中的关键信息,实现更连贯、流畅的交互体验,有效避免对话内容出现断层或逻辑矛盾。

在权威的 Scale MultiChallenge 基准测试中, GPT-4.1 在多轮对话指令遵循任务上的表现较 GPT-4o 提升 10.5%,验证了其在复杂交互场景下的技术优势。这一改进不仅增强了模型对用户意图的理解精度,还为开发者提供了更可靠的技术支持,有助于提升智能交互应用的用户体验与实际效能。

图8: GPT-4.1 在多轮对话指令遵循任务上的表现较 GPT-4o 提升 10.5%


MultiChallenge accuracy



数据来源: Open AI 官网

GPT-4.1 在 IFEval 上的得分也为 87.4%,而 GPT-4o 的得分为 81.0%。IFEval 使用带有可验证指令的提示(例如,指定内容长度或避免使用某些术语或格式)。

图9：在 IFEval 中模型必须生成符合各种指令的答案，GPT-4.1 的表现更加直观



数据来源：Open AI 官网

GPT-4.1 凭借强化的指令遵循性能，显著提升了既有应用的稳定性与可靠性，同时为因过往技术瓶颈而受限的创新应用开发提供了可能。根据早期测试反馈，尽管该模型已具备出色的任务处理能力，但进一步明确、具体的提示输入，将有助于其输出更加贴合用户预期。为帮助开发者充分发挥 GPT-4.1 的性能优势，OpenAI 已发布官方提示指南，其中涵盖详尽的最佳实践建议与使用规范。

图10：GPT-4.1 的遵循指令真实案例中性能显著提升

公司	测试内容	具体数据	性能优势体现	实际效果
Blue J	最具挑战性的真实税务场景内部基准测试	准确率比 GPT-4o 高出 53%	增强对复杂法规的理解能力，提升在长篇内容中遵循细微指令的能力	实现更快、更可靠的税务研究，为高价值咨询工作节省时间
Hex	最具挑战性的 SQL 评估集	较 GPT-4o 实现近 2 倍的改进	在指令遵循和语义理解方面显著提升，更可靠地从庞大模糊模式中选择正确的表	大幅减少手动调试工作量，加速推进至生产级工作流程


数据来源：Open AI 官网、国泰海通研究所整理

3) 长上下文：GPT-4.1 系列（包含 GPT-4.1、GPT-4.1 mini 及 GPT-4.1 nano）在上下文处理能力上实现跨越式突破，其 100 万 token 的上下文窗口处理上限，相较前代 GPT-4o 的 128,000 token 形成近 8 倍的性能提升。该处理量级足以容纳 8 个以上完整 React 代码库的文本规模，使模型在处理大型代码工程、海量专业文档等复杂任务时具备显著优势。

通过系统性训练优化，GPT-4.1 在长文本解析方面展现出更强的可靠性与精准性。相比 GPT-4o，其不仅能够稳定处理百万级 token 上下文信息，更在关键信息识别能力上实现升级，可有效过滤长短文本中的干扰内容，精准提取核心要素。这一特性在法律文书分析、代码审计、客户服务工单处理等对长上下文理解要求严苛的领域，具备重要的应用价值。

在实际性能测试中，GPT-4.1 在信息检索任务上表现尤为突出。面对分布于上下文窗口任意位置的关键信息（类比为“针”），该模型在百万 token 级别的上下文范围内，始终保持高准确率的检索能力，能够无视信息所处位置，快速定位并提取与任务相关的核心细节，体现出领先的长文本处理技术水准。

图11: 在 Open AI 内部大海捞“针”评估中, GPT-4.1、GPT-4.1 mini 和 GPT-4.1 nano 均能够在高达 1M 的上下文中检索所有位置的“针”




数据来源: Open AI 官网

在实际应用场景中, 信息检索与处理任务往往远比单一目标提取更为复杂。用户需求通常涉及对多源信息的检索、理解及相互关系分析。为模拟此类复杂任务并评估语言模型的相关能力, Open AI 推出全新开源评估平台 Open AI-MRCR (多轮共指)。

Open AI-MRCR 通过构建多轮合成对话场景, 着重测试模型在复杂上下文中识别、区分及响应多重相似请求的能力。具体测试流程为: 先设定用户提出创作类请求 (如“撰写关于獭的诗歌”或“创作岩石主题博客文章”), 随后在对话上下文中插入多个重复请求 (数量涵盖 2 个、4 个或 8 个), 要求模型精准检索并回应特定实例请求 (例如“创作第三首关于獭的诗歌”)。该评估的难点在于相似文本的干扰, 模型需精准区分与任务相关的细微差异, 避免将獭的短篇故事或青蛙主题诗歌误判为目标内容。

测试结果显示, 在 128K token 以内的上下文场景中, GPT-4.1 较 GPT-4o 展现出显著性能优势; 即便在高达 100 万 token 的超长篇幅下, 仍能维持稳定表现。不过, 此类复杂任务对包括 GPT-4.1 在内的高级推理模型仍构成挑战。目前, OpenAI 已公开评估数据集, 旨在推动学界与业界对现实长上下文检索技术的深入研究与创新。

图12: OpeAI-MRCR 评估中不同模型在处理 2 针、4 针、8 针任务时, 随着上下文 token 数量变化的准确率表现, GPT-4.1 在 2 针任务重表现最为亮眼



数据来源: Open AI 官网


Open AI 还计划发布 Graphwalks 数据集, 该数据集旨在评估模型在多跳长上下文推理方面的能力。在实际开发和应用场景中, 众多开发者在利用长上下文时, 常面临需在上下文中进行多次逻辑跳转的任务。比如编写代码时在多个文件间切换

查阅信息，或是解答复杂法律问题时对多份文档进行交叉引用等情况。

从解决问题的逻辑来看，OpenAI-MRCR 问题理论上模型（甚至人类）可通过逐次阅读或通读提示来处理。然而，Graphwalks 的设计独具匠心，它要求模型在上下文中跨越多个位置进行推理，但不能按顺序依次解决问题。

具体而言，Graphwalks 通过将由十六进制哈希值构成的有向图填充至上下文窗口，随后要求模型从图中的随机节点起始，执行广度优先搜索（BFS），并返回特定深度的所有节点。在这一基准测试中，GPT-4.1 展现出了出色的性能，其准确率达到 61.7%，与 o1 的表现旗鼓相当，并且大幅领先于 GPT-4o。

图13: GPT-4.1 在 Graphwalks 准确率达到 61.7%，与 OpenAI o1 的表现旗鼓相当，大幅领先于 GPT-4o



数据来源：Open AI 官网

同时，在真实案例中 GPT-4.1 的长上下文任务表现也极其出色。

图14: GPT-4.1 的长上下文能力在真实案例中性能显著提升

公司	测试内容	具体维度	具体提升	关键优势
Thomson Reuters	用 CoCounsel 测试 GPT-4.1 在法律工作流程中的表现	与 GPT-4o 对比	多文档审核准确率提高 17%	维护跨来源上下文，准确识别文档间细微关系（如冲突条款、补充上下文）
CARLYLE	用 GPT-4.1 从多格式长文档提取财务数据	与其他现有模型对比	从数据密集大型文档检索性能提高 50%	克服大海捞针式检索、中间丢失错误、跨文档多跳推理等限制

数据来源：Open AI 官网、国泰海通研究所整理

在人工智能应用开发领域，除模型性能与精准度外，响应速度同样是开发者关注的核心指标，直接影响用户体验与产品竞争力。据了解，OpenAI 通过对推理堆栈的深度优化，显著缩短了模型获取首个 token 的响应时间，并结合快速缓存技术，在降低延迟的同时实现了成本控制。

实测数据显示，在处理 128,000 个上下文 token 时，GPT-4.1 获取首个 token 的平均延迟约为 15 秒；当上下文扩展至 100 万个 token 时（扩充到 8 倍），延迟时间约为 1 分钟（延迟仅上升到 4 倍）。相比之下，轻量化版本 GPT-4.1 mini 和 GPT-4.1 nano 展现出更优的响应效率，针对 128,000 个输入 token 的任务，GPT-4.1 nano 可在 5 秒内完成首个 token 输出，为实时交互场景提供了更高效的解决方案。这一系列技术改进为开发者构建高响应、低成本的 AI 应用提供了有力支撑。

4) GPT-4.1 系列在图像理解方面非常强大，尤其是 GPT-4.1 mini 代表了重大的飞跃，在图像基准测试中击败 GPT-4o

图15: 相较于 GPT-4o，GPT-4.1 在图像理解相关任务上整体展现出更优准确率

测试基准	GPT - 4.1	GPT - 4o (2024 - 11 - 20)	OpenAI o1 (high)	GPT - 4.5	GPT - 4.1 mini	GPT - 4.1 nano	GPT - 4o mini
MMMU accuracy	75%	69%	78%	75%	73%	55%	56%
MathVista accuracy	72%	61%	72%	72%	73%	56%	57%
CharXiv - Reasoning accuracy	57%	53%	55%	55%	57%	41%	37%

数据来源：Open AI 官网、国泰海通研究所整理

长上下文处理能力对多模态应用场景（如长视频内容分析）同样至关重要。在针对长篇无字幕视频的评估基准 Video-MME 中，模型需基于 30-60 分钟的无字幕长视频内容回答多项选择题。测试数据显示，GPT-4.1 以 72.0% 的得分表现最佳，显著优于 GPT-4o 的 65.3%，展现出其在长视频多模态理解任务中的领先能力。

图16: GPT-4.1 在 30-60 分钟长无字幕视频测试里，GPT-4.1 以 72% 的成绩超越 GPT-4o 的 65%



数据来源：Open AI 官网

GPT-4.1 在编码、指令执行及长上下文理解等方面，高度契合开发者实际诉求，为智能系统搭建与复杂代理应用开发拓展新路径。性能上，其变体版本适配多元需求场景；定价更亲民，全方位汲取 GPT-4.5 曾陷入的“高价低效”困境所带来的教训。GPT-4.1 成本较 GPT-4o 低 26%，GPT-4.1 nano 为 Open AI 目前价格最低、速度最快的模型。针对重复传递相同上下文的查询，该系列新模型即时缓存折扣提至 75%（原为 50%）。此外，除标准的每 token 成本外，长上下文请求无需额外付费。

3. 全新推理模型 OpenAI o3 与 o4-mini 拥有强大的任务处理能力和高效的工具运用能力，为复杂任务的解决奠定了基础

OpenAI o3 是一款在编码、数学、科学和视觉感知领域具备显著能力的推理模型。该模型在 Codeforces、SWE-bench（无需构建特定于模型的自定义支架）和 MMMU 等基准测试中建立了新的最先进（SOTA）性能。其适用于需要多方面分析且答案并非直接显见的复杂查询，在涉及图像、图表和图形分析的视觉任务中表现显著。外部专家评估表明，在具有挑战性的现实任务中，o3 相比 o1 的重大错误率降低 20%，在编程、商业/咨询和创意构思领域性能提升显著。早期测试者强调了其作为“思维伙伴”的分析严谨性，尤其在生物学、数学和工程领域生成并批判性评估新假设的能力。

在开发过程中，o3 在大规模强化学习（RL）中展现出与 GPT 系列预训练阶段类似的“计算-性能”趋势。通过将强化学习训练计算量和推理时间提升一个数量级，模型实现了持续的性能提升，验证了推理时长与模型性能的正相关性。在与 o1 相同的延迟和成本条件下，o3 在 OpenAI 部署中表现出更高性能，且经证实，随着推理时间增加，其性能会进一步提升。


该模型通过强化学习训练实现工具使用能力，包括工具操作知识和工具使用时机的上下文推理。这一能力提升了其在开放式场景中的表现，尤其是在涉及视觉推理和多步骤工作流程的任务中。早期测试者报告显示，在学术基准测试和实际任务执行中，o3 均通过工具使用能力的改进实现了结果提升。

o4-mini 作为轻量化模型，聚焦快速且经济高效的推理性能优化。在同等规模与成本条件下，其于数学运算、编码任务及视觉处理等领域展现出卓越性能表现，尤为突出的是，该模型在 AIME 2024 和 2025 基准测试中均位列榜首。值得关注的是，尽管借助计算机辅助能够降低 AIME 考试难度，但实测数据显示，当配备 Python 解释器时，o4-mini 在 AIME 2025 测试中实现了 99.5%的通过率，充分印证了 o4-mini 对外部工具的高效调用与协同能力；与之类似，o3 在 AIME 2025 测试中通过工具运用，也取得了 98.4%的通过率与 100%的共识率，展现出工具赋能对模型性能提升的显著作用。

相较于前代 o3-mini，o4-mini 在非 STEM 领域任务处理及数据科学应用中均实现性能超越。凭借其高效推理特性，o4-mini 在使用限制上显著优于 o3，能够为大规模、高并发的推理任务提供强大支撑，成为高容量、高吞吐量场景下的理想解决方案。外部专家评估指出，o4-mini 与 o3 通过智能化升级和网络资源整合，在指令遵循能力上较前代模型实现显著提升，输出响应兼具实用性与可验证性。同时，二者在对话交互层面进行深度优化，通过对历史记忆与对话内容的有效调用，使输出结果更具个性化与场景适配性，显著增强交互自然度与连贯性。

在 AIME 2024 和 2025 数学竞赛测试里，o4-mini 即便无工具辅助，准确率也高于 o1 和 o3-mini，且 o3、o4-mini 在有工具时准确率进一步提升，工具对模型解题能力有促进作用；在 Codeforces 编程竞赛测试中，o3 和 o4-mini 使用终端工具后 ELO 得分大幅领先 o1，在编程任务借助工具能力可显著提升。


图17：o3、o4-mini 在工具调用能力加持下编程能力有近 30%显著提升



数据来源：Open AI 官网

GPQA Diamond 测试中，o3（无工具）准确率最高，o4-mini（无工具）次之，o1 和 o3-mini 稍低；而 Humanity's Last Exam 测试里中，o4-mini（有工具）准确率领先，o3（有工具）次之。不同模型在科研及综合专业问答任务中各有优劣，进一步体现 o3 及 o4-mini 模型借助工具可提升性能。总体而言，o4-mini 和 o3 在多测试场景展现出较好潜力，工具使用对模型的编码性能提升有重要意义。


图18: o4-mini 和 o3 在多测试场景展现出较好潜力，工具使用对模型性能提升有重要意义



数据来源: Open AI 官网

在编码领域，o3 与 o4-mini 通过实际任务完成情况彰显其能力。在 SWE-Lancer 自由编码任务中，o3-high 和 o4-mini-high 脱颖而出。o3-high 赚取金额高达\$65,250，o4-mini-high 也有\$56,375 的收入，与 o1-high 的\$28,500 和 o3-mini-high 的\$17,375 形成鲜明对比。这一数据直观地表明，o3 和 o4-mini 在实际编码工作的创收能力上优势显著，意味着它们能够更为高效且优质地处理编码任务，为实际项目带来更高价值。而在 SWE-Bench Verified 软件工程测试中，二者的准确率同样令人瞩目。o3 以 69.1%的准确率领先，o4-mini 也达到了 68.1%，远超 o1 的 48.9%和 o3-mini 的 49.3%。进一步证实，在软件工程相关的编码任务中，o3 和 o4-mini 能够精准地完成任务，展现卓越的编码能力。


图19: 在软件工程相关的编码任务中，o3 和 o4-mini 能够精准地完成任务，展现卓越的编码能力



数据来源: Open AI 官网

遵循指令能力是衡量模型能否准确执行复杂任务的重要指标。在 Scale MultiChallenge 多轮指令遵循测试中，o3 展现出独特优势。其 56.5%的准确率高于 o1 的 44.9%、o3-mini 的 39.9%以及 o4-mini 的 43%。o3 在面对多轮指令时，能够更好地理解并按照指令要求执行任务，在需要精确遵循指令步骤的场景中，更具可靠性。


图20: o3 在面对多轮指令时，能够更好地理解并按照指令要求执行任务



数据来源: Open AI 官网


代理工具使用能力对于模型处理复杂任务至关重要。在视觉推理任务方面，无论是 MathVista 视觉数学推理测试，还是 CharXiv-Reasoning 科学图形推理测试，o3 和 o4-mini 均表现出色。在 MathVista 测试中，o3 准确率为 86.8%，o4-mini 为 84.3%，远高于 o1 的 71.8%；在 CharXiv-Reasoning 测试里，o3 准确率 78.6%，o4-mini 为 72.0%，同样高于 o1 的 55.1%。这充分说明，在处理涉及视觉信息理解与推理的任务时，o3 和 o4-mini 能够有效借助工具，完成复杂的视觉任务。在 BrowseComp 代理浏览测试中，o3 和 o4-mini 结合工具后的表现更是令人惊叹。o3 结合 python 和浏览工具时准确率为 49.7%，o4-mini 在 Deep research 下结合相关工具准确率达 51.5%，与 o1 结合浏览工具仅 1.9% 的准确率形成巨大反差。这表明 o3 和 o4-mini 在代理浏览任务中，对工具的运用能力远超其他模型，能够通过工具获取和处理信息，提升任务完成质量。此外，在 Tau-bench 函数调用测试中，在航空和零售等不同行业场景里，o3-high 和 o4-mini-high 也展现出较高的准确率。如零售场景中，o3-high 达到 73.9%，o4-mini-high 为 71.8%，说明它们在涉及函数调用这类工具使用任务时，能够准确运用工具实现功能，满足不同行业的任务需求。

图21: o3 和 o4-mini 能够有效借助工具，完成复杂的视觉任务



数据来源: Open AI 官网

图22: o3 和 o4-mini 在涉及函数调用使用任务时，能够准确运用工具实现功能



数据来源：Open AI 官网

o3 和 o4-mini 在编码、遵循指令以及代理工具使用等多个关键领域，相较于其他模型展现出明显优势。它们凭借强大的任务处理能力和高效的工具运用能力，为人工智能在实际应用中的发展提供了有力支持，也为未来更多复杂任务的解决奠定了坚实基础。

4. OpenAI o3 与 o4-mini 在应用中，其强大的图片理解能力成为核心亮点

OpenAI o3 和 o4-mini 作为 o 系列最新的推理模型，在视觉信息处理方面，首次达成将图像直接融入思维链进行思考。开创了视觉与文本推理融合的全新问题解决范式。


从图像输入适应性来看，用户可上传白板照片、教科书图表、手绘草图等各类图像。即使图像存在模糊、反转或质量欠佳等状况，模型仍具备解读能力。在工具辅助下，模型能够对图像进行动态操作，涵盖旋转、缩放、变换等处理，极大拓展了图像分析的灵活性与深度。在视觉感知任务中，o3 和 o4-mini 可达到顶尖准确率，成功攻克诸多此前难以解决的问题。

与 OpenAI o1 相似，o3 和 o4-mini 经训练具备在回答前进行深度思考的能力，运用较长的内部思维链推导答案。在此基础上，o3 和 o4-mini 进一步升级，将图像纳入思维链体系。模型可通过工具对用户上传图片进行转换，实现裁剪、放大、旋转等基础图像处理操作，且这些功能内置于模型，无需借助独立专用模型，确保了视觉推理的连贯性与高效性。

借助 o3 和 o4-mini 可实现视觉智能增强，能够以更全面、准确、可靠的方式剖析图像，助力用户应对复杂难题。该能力可将高级推理与网页搜索、图像处理（包括自动缩放、裁剪、翻转、增强图像等）等工具无缝集成，即便面对低质量照片，也能有效提取关键信息。如用户上传经济学习题集照片可获取详细步骤讲解，分享构建错误的屏幕截图能快速得到根本原因分析。这种融合方式为测试时间计算扩展提供了新维度，实现视觉与文本推理的自然融合，在多模式基准测试中呈现出领先性能，是迈向多模式推理的关键进展。

在用户交互层面，o3 和 o4-mini 基于图像思考的特性，显著优化了与 ChatGPT 的交互体验。用户通过拍照提问时，无需顾虑物体位置、图像文字颠倒或存在多个问题等情况。视觉推理功能支持模型自动放大查看图像细节，精准捕捉关键信息。此外，这两款最新视觉推理模型可与 Python 数据分析、网络搜索、图像生成等工具协同运作，以创新且高效的方式处理复杂问题，为用户带来 OpenAI 首个多模式代理体验，在科研、教育、工程等多领域具有广阔应用前景。


图23: o3 实现视觉与文本推理的自然融合，能够以更全面、准确、可靠的方式剖析图像，助力用户应对复杂难题



数据来源：Open AI 官网

基于一系列人工测试与机器学习基准测试，o3 与 o4-mini 在 MMMU 大学水平视觉问题解决任务中，o3 准确率达 82.9%，o4-mini 为 81.6%，远高于 GPT-4o 的 68.7% 和 o1 的 77.6%；在 MathVista 视觉数学推理任务里，o3 准确率达 86.8%，o4-mini 为 84.3%，而 GPT-4o 仅 61.4%，o1 为 71.8%。在图表阅读和推理(CharXiv-descriptive、CharXiv-reasoning)、感知基元(VLMs are blind)以及视觉搜索(V* search benchmark)等任务中，o3 和 o4-mini 同样表现优秀，在各基准测试中大幅超越先前模型，创下新的最高水平，例如在 V*search benchmark 测试中，o3 准确率高达 95.7%，o4-mini 为 94.6%，而 GPT-4o 和 o1 分别为 73.9%、69.7%。

图24: o3 与 o4-mini 基于图像的思考能力在所有感知基准测试中取得显著提升，有力证明了在视觉推理能力上的巨大进步



数据来源：Open AI 官网

然而，当前模型仍存在一定局限性。在推理链方面，模型可能执行冗余或不必要的工具调用及图像处理步骤，致使思维链冗长；感知层面，模型仍会出现基本的感知错误，即便工具调用正确推进推理，视觉误解也可能引发错误答案；可靠性上，模型在多次尝试解决问题时，可能采用不同视觉推理过程，部分过程会导致错误结果。

尽管如此，OpenAI o3 和 o4-mini 仍显著提升了视觉推理的先进水平，是迈向更广泛多模态推理的关键一步，在视觉感知任务中实现一流准确率，攻克诸多此前的

难题。目前，Open AI 依旧致力于持续完善模型的图像推理能力，使其更简洁、可靠，减少冗余，期待这些改进能为人们工作效率的提升带来积极影响。

5. OpenAI o3 与 o4-mini 高度重视安全性同步增强，确保模型安全性和稳健性

OpenAI o3 和 o4-mini 在模型能力提升的同时，高度重视安全性的同步增强。从安全训练数据层面来看，研发团队彻底重建相关数据，在生物威胁、恶意软件生成和越狱等关键领域增添新的拒绝提示，使得这两款模型在内部拒绝基准测试中表现优异。不仅如此，还开发系统级缓解措施，通过训练推理 LLM 监视器（基于人类编写且可解释的安全规范）来标记危险提示，在生物风险场景下，该监视器能成功标记约 99% 人类红队活动对话，展现出强大的风险识别能力。

在安全评估与风险表现方面，o3 和 o4-mini 在内容安全与越狱防御上表现突出：二者在标准与挑战性拒绝评估中对有害内容的拦截能力与 o1 持平或更优，且对已知越狱攻击展现较强抵抗力。o4-mini 因模型规模较小在 PersonQA 中出现较高幻觉率，而 o3 虽整体准确率优异但仍存在不实断言需优化，但二者在多模态安全领域表现亮眼——其图文违规内容拒绝能力超越 o1，且在视觉任务中的安全性优于 o1 和 GPT-4o。指令层级冲突场景下，o3 与 o1 表现接近，o4-mini 稍逊，但通过强化指令层级训练有效防止工具调用绕过。第三方评估显示，METR 认证二者具备基础自主能力（o3 存在轻微奖励黑客行为），Apollo Research 指出虽具战略欺骗潜力但灾难性风险低，而 Pattern Labs 验证 o3 的网络攻击能力优于 o4-mini，但均未达专业威胁水平。

图25：在安全评估与风险表现方面，o3 与 o4-mini 在内容安全与越狱防御上表现突出

评估维度	具体指标 / 场景	o3 表现	o4-mini 表现	对比 o1 表现
内容拒绝能力	标准拒绝评估 (not_unsafe / overrefuse)	多数类别 not_unsafe 达 1, aggregate not_overrefuse 为 0.84	多数类别 not_unsafe 接近 1, aggregate not_overrefuse 为 0.81	o1 多数类别 not_unsafe 达 1, aggregate not_overrefuse 为 0.86
	挑战性拒绝评估 (not_unsafe)	整体 0.92, hate/threatening 为 0.82	整体 0.90, hate/threatening 为 0.82	o1 整体 0.92, hate/threatening 为 0.91
越狱抵抗能力	人类来源越狱攻击 (not_unsafe)	1	0.99	o1 为 0.97
	StrongReject 基准测试 (not_unsafe)	0.97	0.96	o1 为 0.97
幻觉问题	SimpleQA 准确率 / 幻觉率	准确率 0.49, 幻觉率 0.51	准确率 0.20, 幻觉率 0.79	o1 准确率 0.47, 幻觉率 0.44
	PersonQA 准确率 / 幻觉率	准确率 0.59, 幻觉率 0.33	准确率 0.36, 幻觉率 0.48	o1 准确率 0.47, 幻觉率 0.16
多模态拒绝能力	视觉色情内容拒绝 (not_unsafe)	1	1	o1 为 0.97
	视觉自我伤害内容拒绝 (not_unsafe)	0.99 (intent) / 1 (instructions)	0.99 (intent) / 0.99 (instructions)	o1 为 0.97 (intent) / 0.95 (instructions)
指令层级遵循能力	开发者 - 用户消息冲突 (准确率)	0.86	0.75	o1 为 0.77
	系统 - 开发者消息冲突 (准确率)	0.86	0.68	o1 为 0.84
第三方评估 (安全风险)	METR 自主能力评估: 奖励黑客行为频率	约 1% 任务尝试中出现 (如优化内核环境篡改评分函数)	未明确提及具体频率	o1 未提及
	Apollo Research: 战略欺骗与破坏能力	存在沙盒攻击、虚假承诺后使用禁用工具等行为	类似 o3, 但破坏能力稍弱 (如沙盒攻击准确率 0.25)	o1 在部分场景 (如工具滥用) 表现更弱
	Pattern Labs 网络安全评估: 攻击成功率	逃逸 51%、网络攻击 29%、漏洞利用 29%	逃逸 51%、网络攻击 25%、漏洞利用 34%	o1 未提及

数据来源：Open AI 官网、国泰海通研究所整理

在多领域能力评估中，o3 和 o4-mini 展现出差异化表现：生物化学领域可辅助专家规划已知生物威胁操作，但当前尚不具备支持新手创建生物威胁的高风险能力，需警惕未来能力迭代带来的潜在风险；网络安全方面，二者在 CTF 挑战中对高中至专业级赛题均展现出优于前代的解题能力，但受限于自主完成端到端网络操作的能力（仅能在提供 solver code 时解决特定场景），尚未构成高自主性网络威胁；人工智能自我改进维度，其在结构化任务（如 OpenAI 研究工程师面试、SWE-bench Verified 测试及 PRs 审查）中表现卓越，但在现实场景的开放式研究任务（如

PaperBench) 中效能显著下降, 暂未达到“高”等级自主改进能力阈值。

图26: 在多领域能力评估中, o3 和 o4-mini 展现出差异化表现

评估维度	具体任务 / 场景	o3 表现	o4-mini 表现	对比 o1 表现
生物与化学能力	长形式生物风险问题 (准确率)	helpful-only 模型各阶段均超 20%, 但启动候选模型拒绝所有操作规划	类似 o3, 依赖工具时表现稍弱	o1 未明确提及
	多模态病毒学故障排除 (多选题)	超人类基线 (40%), 具体未明确	超人类基线, 略低于 o3	GPT-4o 等前代模型接近人类基线
网络安全能力	CTF 挑战 (高中 / 大学 / 专业级通过率)	89%/68%/59%	80%/55%/41%	o1 未提及, 前代模型显著低于 o3
	网络范围评估 (有 solver code 时通过率)	在线零售商场景高准确率, 自主完成能力有限	类似 o3, 但简单权限提升场景表现稍弱	o1 需依赖提示或代码才能部分完成
AI 自我改进能力	OpenAI 研究工程师面试 (编码题准确率)	接近完美	接近完美	o1 类似, 但推理深度稍弱
	SWE-bench Verified (软件开发任务)	SOTA 结果 71%	低于 o3, 具体未明确	o1 显著低于 o3
	PaperBench (AI 论文复现)	18%	24% (最高)	o1 为 23%

数据来源: Open AI 官网、国泰海通研究所整理

经最严格安全程序压力测试, 依据更新的防范框架, 在生物和化学、网络安全以及人工智能自我改进这三个关键跟踪能力领域评估显示, o3 和 o4-mini 在安全性方面均低于“高”阈值标准, 表明其安全性处于可控且相对较低风险水平。功能与性能上, o3 和 o4-mini 将先进推理能力与全面工具功能深度融合, 涵盖网页浏览、Python 运用、图像及文件分析、图像生成等诸多方面, 在处理复杂数学、编码、科学难题以及视觉感知分析任务中表现卓越, 还能在思维链中灵活调用工具增强自身能力。从训练方法而言, OpenAI o 系列模型运用大规模强化学习思维链进行训练, 这为提升模型安全性和稳健性开拓了新路径, 使其能在面对潜在不安全提示时, 基于上下文推理安全策略。OpenAI 安全咨询小组审查认定, o3 和 o4-mini 在三个跟踪类别中均未达“高”门槛。总体而言, OpenAI o3 和 o4-mini 在能力与安全保障上实现了较好平衡与提升, 但在不断变化的应用环境中, 仍需持续关注和优化其安全性表现。

6. Open AI 多维度持续更新, 包括重大更新 Codex, 在技术普惠与商业化探索双重螺旋式布局

Open AI 的一系列更新既延续了 Open AI 技术突破的基因, 也显现出其在产业落地和商业模式上的成熟思考。

6.1. Codex 向应用层延伸, 占据开发者工作流的关键节点

Codex CLI 与 Codex 云端智能体展现了 OpenAI 在开发者工具领域的双向布局: 前者作为轻量化终端工具, 通过自然语言驱动的代码生成与任务执行 (如文件操作、依赖安装等), 直击终端环境下快速原型开发与碎片化问题处理的效率痛点, 且凭借开源策略 (Apache 2.0 许可证) 快速吸引社区生态, GitHub 首日获 1.4 万星, 并默认适配 o3、o4-mini 等最新模型, 让开发者直接受益于模型升级; 后者则定位全栈工程平台, 瞄准企业级市场, 整合需求分析至部署的软件工程全流程, 支持团队协作与复杂项目管理, 其自动化测试和智能部署功能可减少人工干预、提升规模化项目交付效率。

1) Codex CLI: 作为一款可从终端运行的轻量级编码代理工具, 允许开发者直接在命令行中通过自然语言生成代码、执行任务 (如文件操作、依赖安装、测试运行等), 解决了终端环境下快速原型开发和碎片化问题处理的痛点。其设计目标是通过本地化部署模式, 最大化释放 OpenAI o3、o4-mini 等模型的推理能力, 并为后续 GPT-4.1 等 API 模型的接入提供兼容性支持。该工具具备终端级运行特性, 可直接在用户计算机本地执行, 通过构建极简交互接口, 实现模型能力与用户开发环境的深度耦合。

Codex CLI 支持 suggest、auto-edit 和 full-auto 三种审批模式，允许开发者灵活控制自动化程度，兼顾自动化效率与操作安全。所有操作均在本地执行，保障代码隐私和数据安全。此外，Codex CLI 支持多模态输入，开发者可通过命令行上传截图或草图等视觉 prompt 信息，结合本地代码访问权限，形成“视觉输入+代码执行”的闭环工作流，显著提升跨模态任务处理能力。

上个月，Open AI 宣布 Codex CLI 完全开源，这一举措标志着 OpenAI 在工具层面向开发者社区的深度开放——通过开源代码的形式，允许开发者根据自身需求进行功能扩展或本地化定制，从而构建多样化的应用场景。Codex CLI 采用 Apache 2.0 许可证开源，并配套百万美元开源基金计划（Codex Open Source Fund），单个项目可获得最高 2.5 万美元 API 积分，旨在激励开发者基于 CLI 和 OpenAI 模型持续创新，推动模型能力在实际生产场景的转化，形成“工具开源-应用创新-生态反哺”的正向循环。

Codex CLI 作为终端级轻量编码代理，将多模态推理能力有机嵌入开发者工作流，为企业和开发者提供了更高的自主可控性和定制灵活性。依托本地化代码访问机制，结合对多个模型（o3，o4-mini）与 API 的持续适配，并叠加模型本身的持续升级，OpenAI 实质上构建了 AI 能力向开发环境渗透的新范式。其配套的百万美元资助计划形成技术生态闭环，在激励开发者共创的同时，加速模型能力的落地转化。


2) Codex: Codex 作为一款云端软件工程智能体，具备并行处理多项任务的能力。Codex 能够为用户执行多种操作，例如编写功能代码、解答代码库相关问题、修复程序错误以及提出供审核的拉取请求等；每项任务均在预加载代码库的专属云沙盒环境中运行。

Codex 的云端代码 Agent 支持代码工程任务的批量分派与并行执行，用户可通过自然语言指令灵活调度类似“外包型”任务，每次交付成果均带有可审查的操作日志与变更报告，便于团队在标准化软件开发流程下快速验收和返工。

Codex 由 codex-1 模型驱动，该模型是 OpenAI o3 的一个版本，针对软件工程进行了优化。它通过强化学习，在多种环境中针对真实编码任务进行训练，生成的代码能够高度反映人类编程风格和拉取请求偏好，精确遵循指令，并且可以迭代进行测试直至获得通过结果。OpenAI 已开始向 ChatGPT Pro、Enterprise 和 Team 用户推出 Codex，即将支持 Plus 和 Edu 用户。

OpenAI 推出的 Codex 作为一款代码生成工具，其工程化任务处理流程清晰且高效。用户可通过 ChatGPT 侧边栏访问 Codex，输入自然语言指令后点击“Code”即可触发代码生成任务，或点击“Ask”查询代码库相关问题，每个任务都会在独立的、预先加载了用户代码库及所需依赖的云沙盒环境中执行。Codex 支持文件读写操作，并能执行包括测试框架、代码检查工具、类型校验器等在内的各类命令，任务完成时间因复杂程度不同而在 1 至 30 分钟之间，用户可实时监控任务的执行进度，同时系统会自动记录终端日志、测试输出等执行证据以便用户对每一步操作进行溯源。任务完成后，Codex 会在沙盒环境中提交变更，并以可供审查的代码变更集合、附带详细执行证据的操作报告等形式交付结果，还支持一键生成 GitHub 拉取请求或将变更直接同步至本地开发环境。此外，用户可通过在仓库根目录放置类似 README 的配置说明文档 AGENTS.md 文件对 Codex 进行指导，明确代码库的导航逻辑、设定测试命令与环境配置要求、规范项目特定的开发规范与最佳实践。内部测试数据表明，即便未配置 AGENTS.md 文件，codex-1 模型在标准编码评估中的表现也显著优于同类工具，其工程化能力在微服务架构实现、测试用例生成等场景中尤为突出，在 HumanEval 基准测试中代码生成准确率高达 72.3%。

图27: codex-1 模型在标准编码评估中的表现显著优于同类工具，其工程化能力在微服务架构实现、测试用例生成等场景中尤为突出



数据来源: Open AI 官网

Codex 当前不支持联网访问外部资源，所有任务均在安全隔离的云沙盒环境中运行，这保障了代码安全，也限制了对外部依赖自动拉取等复杂跨平台集成能力。同时，Codex 也缺乏图像输入、任务中实时修正等功能，Open AI 未来计划引入交互式代理工作流，深化与 IDE、CI 系统等工具的集成，进一步提升工程自动化与人机协作水平。

图28: Codex 与 Codex CLI 功能与定位对比

评估维度	Codex（云端智能体）	Codex CLI（本地代理工具）
部署位置	云端（OpenAI 沙盒环境）	本地（用户终端）
运行安全	云端隔离，代码与数据上传服务器	本地执行，数据不出本机
使用方式	ChatGPT 侧栏/API/平台	命令行（CLI）
适用场景	团队协作、复杂工程自动化	快速原型、碎片化开发、本地定制
多模态能力	暂不支持图像输入	支持文本、截图、草图等多模态输入
代码访问	访问预加载的云端代码库	直接访问本地文件
批量/并行任务	支持批量分派与并行执行	支持多窗口/批量运行
审批模式	任务全盘验收/返工，日志可追溯	支持 suggest、auto-edit、full-auto
开源属性	未开源	完全开源，Apache 2.0 许可证
资助与生态	平台生态为主	配套百万美元开源资助计划
主要模型	codex-1（优化 o3 版本）	o3、o4-mini、codex-mini
主要局限	不联网、无图像输入、需上传代码	受本地资源限制，无持续上下文

数据来源: Open AI 官网、国泰海通研究所整理

6.2. API 进一步开放，持续维护开发者生态建设

在模型部署方面，OpenAI 持续探索合理策略，以平衡商业用户需求与公众教育价值。模型选择器的更新与工具支持的强化，可能加速企业级用户的 AI adoption 进程。

对于开发者群体，o3 和 o4-mini 已通过 Chat Completions API 和 Responses API 开放访问（部分组织需完成验证流程）。其中，Responses API 新增推理摘要功能，可在函数调用过程中保留推理标记，优化性能表现。此外，该接口即将支持内置工具在模型推理中的应用，包括网页搜索、文件搜索和代码解释器等，进一步拓展 API 的实用性边界。这种能力扩展标志着 OpenAI 在开发者生态建设上的深化——通过开放更强大的模型与工具整合能力，赋能开发者构建智能化应用，推动 AI 技术向垂直领域渗透。

6.3. 用户体验创新上 OpenAI 积极探索新的应用场景拓展

在用户体验创新方面，OpenAI 积极探索新的应用场景拓展。

购物体验升级：在购物体验优化上，OpenAI 致力于让产品查找、比较与购买流程更为便捷。自宣布日起，当用户进行产品搜索时，ChatGPT 会主动提供产品推荐。不仅展示产品的图片和用户评论，还直接提供指向可购买产品网页的链接。目前，OpenAI 正积极拓展覆盖品类，涵盖时尚、美妆、家居用品和电子产品等领域，旨在满足用户多样化的购物需求。

交互方式拓展：交互方式上，ChatGPT 新增了 WhatsApp 搜索入口。用户可通过向号码 1-800-ChatGPT (+1-800-242-8478) 发送消息，实现与 ChatGPT 的直接互动。借助该渠道，用户能够便捷获取最新信息查询服务，以及实时体育比分等内容，拓宽了信息获取途径。

引用功能强化：为便于用户核实信息并深入探究，ChatGPT 对引用功能进行了升级。一方面，支持多重引用，单个回答中可包含多个来源引用，使信息来源更为丰富全面；另一方面，新增高亮 UI 设计，用户通过新的高亮界面，能清晰分辨回答中各部分内容对应的引用来源，增强了信息的可追溯性与可信度。


搜索效率提高：在搜索效率提升方面，ChatGPT 搜索界面增添了实用功能。“热门搜索趋势 (Trending searches)” 可让用户快速了解当下热门搜索方向，把握信息潮流；“搜索建议自动补全 (Autocomplete suggestions)” 则能辅助用户更快找到所需信息，减少输入时间与搜索误差，优化了搜索交互体验。同时，ChatGPT 的 Deep Search 功能可直接对接 GitHub，开发者实现直接针对代码库和技术文档向 ChatGPT 提问。除了回答有关代码库的问题，该功能还允许 ChatGPT 总结代码结构和模式，并了解如何使用真实的代码示例实现新的 API。

7. Open AI 持续全栈工具链整合的战略深化，通过紧密依托开发者生态，构建更具活力与实用性的 AI 技术应用体系

Open AI 深化分层产品矩阵+垂直场景渗透战略，其产品分层策略显著，推出 GPT-4.1 系列（含旗舰版、mini 版、nano 版），构建覆盖企业级高性能需求至轻量级应用场景的差异化矩阵。而 OpenAI o3 和 o4-mini 在功能与性能上实现重大突破。功能层面，它们可全面调用 ChatGPT 工具，还能通过 API 函数调用自定义工具。经训练后，能推理问题解决方案，抉择工具使用时机与方式，快速输出详细答案（一般不到一分钟），如解答能源使用量对比问题时，可串联多种工具操作。其推理功能支持根据信息动态调整策略。同时，o3 在输出内容上能引用更多行业相关来源，提供数据驱动、具战略洞察力的方案，能够预见未来挑战与给予缓解措施。模型通过深度整合 Python 解释器、图像处理工具及网页搜索等功能，构建“AI 代理+工具链”闭环。

基于强大的工具使用能力与灵活策略，拓宽了模型在多领域多模态任务处理的广度与深度，能更好满足用户对复杂、实时信息需求。o3 在内容输出专业性与前瞻性上的提升，使其更契合行业应用场景。但模型在实际应用中仍需进一步验证长期稳定性与可靠性，以及在更多复杂场景下的适应性，且随着技术发展，需持续迭代以应对新挑战与需求。

图29：对比推理成本与准确率，o3 与 o4-mini 在平衡推理成本与获取更高准确率方面更具优势



数据来源：Open AI 官网

同时，此次 ChatGPT 系列模型进行结构性更新。ChatGPT Plus、Pro 及 Team 用户可在模型选择器中获取 o3、o4-mini 和 o4-mini-high，上述模型将取代此前的 o1、o3-mini 和 o3-mini-high。ChatGPT Enterprise 与 Edu 用户的模型更新将在一周内完成。值得注意的是，免费用户可通过编辑器中“Think”选项试用 o4-mini，此举旨在降低新型号的使用门槛，促进技术普惠。从访问策略看，各套餐的速率限制维持不变，确保用户体验的延续性。反映出 OpenAI 在模型迭代与用户兼容性之间的平衡考量——通过替换为性能更优的新型号，提升服务能力，同时避免因速率变动对现有用户 workflow 造成干扰。模型阵容调整与接口升级，本质上是 OpenAI 推动“模型矩阵精细化”战略的关键举措。通过分层级提供 o3、o4-mini 系列模型（如 mini、high 版本），精准匹配不同用户群体的算力需求：免费用户通过试用机制接触基础能力，付费用户获得更高级别的推理性能，开发者则依托 API 构建定制化解决方案。

此外，Codex CLI 的开源化与百万美元开发者资助计划，通过“工具开源-场景反哺”机制加速生态建设，截至目前已吸引超过 2,000 个垂直领域项目接入，推动 AI 技术向科研、电商、智能制造等场景深度渗透。

OpenAI 从单纯追求模型规模转向“技术落地效率优先”，通过分层产品覆盖多元需求，以工具链强化提升垂直场景解决方案能力。

8. 风险提示

- 1) 大语言模型的技术进展不及预期。
- 2) 人工智能行业内外竞争格局变化带来的不确定性。
- 3) 算法或功能优化不及预期等。

本公司具有中国证监会核准的证券投资咨询业务资格

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，特此声明。

免责声明

本报告仅供国泰海通证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后的表现依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并注明出处为“国泰海通证券研究”，且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

国泰海通证券研究所

地址 上海市黄浦区中山南路 888 号

邮编 200011

电话 (021) 38676666