

从能力领先到入口级产品：阿里押注模型、生态与 AI 基础设施

计算机

评级：

增持

姓名	电话	邮箱	登记编号
杨林(分析师)	021-23183969	yanglin2@gtht.com	S0880525040027
朱瑶(分析师)	021-23187261	zhuyao@gtht.com	S0880526010002
钟明翰(研究助理)	021-38031383	zhongminghan@gtht.com	S0880124070047

本报告导读：

阿里 AI 顶层战略由比模型转向拼体系，依托千问入口化与云钉百炼平台协同，并加大云与 AI 基础设施资本开支，打造闭环能力以争夺下一代平台主导权。

投资要点：

- 投资建议：阿里的顶层战略正在发生变化，从“比模型”转向“拼体系”，用“模型+生态+AI Infra”争夺下一代平台。进入 2025 年后，阿里 AI 战略的核心不再是单一模型规模或跑分，而是把“通义千问”与阿里数字经济体高频场景（电商、本地生活、支付、出行、办公等）系统性打通，形成“能办事、办成事”的闭环体验，并把 AI 从流程“外挂”升级为用户接入服务的首要界面（AI 即入口）。内部提出“通云哥”概念，将通义实验室、阿里云、平头哥绑定为一体化的“黄金三角”，强调算力供给、模型能力与系统工程协同，试图从基础设施层构建 AI 时代通用底座。推荐：税友股份、卫宁健康、恒生电子、安恒信息、七牛智能、千方科技、光云科技、浪潮信息、中科曙光、捷顺科技、数据港。相关标的：新开普、宏景科技、寒武纪、海光信息、润建股份。
- AI2C 负责用户规模与超级应用，AI2B 面向企业商业化。千问 App “入口化宣言”落地，以“办事能力+生态级连接”建立差异化。2026 年 1 月进一步重大升级，全面接入淘宝、支付宝、淘宝闪购、飞猪、高德等生态业务，标志着阿里将 C 端“入口之战”从构想推向实战。钉钉被定位为“企业级 AI 智能体平台”，承载把模型能力嵌入企业工作流与业务系统；供给侧“云钉一体”与百炼共同指向 Agent 规模化，商业模式从卖功能订阅走向“卖效果、卖产出”。
- 明确将资金大规模投向云与 AI 基础设施。数据中心扩建、服务器集群、高性能 GPU 采购与部署、通过平头哥推进前沿 AI 芯片自研，以支撑模型与平台扩张在产能侧，资本也在加速转化为实际算力供给：推进全球数据中心与节点建设、扩建现有设施并新增 AI 专用套件，服务其“超级云计算平台”路径。
- 风险提示：AI 技术发展不及预期，AI 商业落地不及预期，市场竞争加剧的风险。

相关报告

计算机《计算机周观点第 33 期：底层基础设施迭代加速，AI 原生力量重塑软件产业格局》
2026.02.08
计算机《未来产业之脑机接口：资本与政策赋能，迎产业窗口期》2026.02.05
计算机《政策注入消费动能，看好三方收单“铲子”公司》2026.02.03
计算机《计算机 2026 年 2 月研究观点：模型边界多路径演进，应用分化与世界模型探索》
2026.02.01
计算机《制度闭环叠加 AI 催化，迎接数据要素“价值释放年”》2026.01.28

目录

1. 2022年以前：以“云+数据智能”为底座，从业务实战走向云上输出.....	3
2. 2023—2024：阿里全面进入大模型时代，形成“通义千问+云平台+业务重做”的新框架.....	7
2.1. 战略与组织：2023作为“全面开启AI时代”的拐点.....	7
2.2. 大模型底座：通义千问发布与多模态矩阵快速补齐.....	8
2.3. 云侧竞争：从IaaS走向“全栈AI”，在GenAI IaaS与MaaS双线发力.....	14
3. 2025年及以后：阿里AI从能力领先走向入口级产品，以“模型+生态+AI Infra”争夺下一代平台.....	18
3.1. 总体战略：核心武器是“模型+生态”，从能力领先走向入口级产品.....	18
3.2. 组织与责任体系：AI2C/AI2B分工清晰，入口与商业化并重.....	21
3.3. 资本开支与融资：以基础设施投入支撑模型与平台扩张.....	22
3.4. 云与算力：AI Infra“为AI重做一遍”，软硬一体化成为竞争焦点.....	25
3.5. 平头哥：从“芯片公司”到“算力基础设施单元”的角色转变.....	28
3.6. 通义实验室：从模型调用走向Agent应用，强化开源生态.....	31
3.7. 2C入口：千问App打开生态级连接，蚂蚁阿福接力生活闭环.....	35
3.8. B端合作生态：行业大客户+开发生态共同提升平台粘性.....	41
4. 建议关注与风险提示.....	44

1. 2022 年以前：以“云+数据智能”为底座，从业务实战走向云上输出

战略主线：业务驱动的“实用型 AI”，把 AI 做成可量化的生产力

在大模型尚未成为产业领域的焦点之前，阿里对 AI 的定位，更偏向于服务真实产业场景的系统性生产力工具。

电商平台的核心诉求在于“帮助用户更高效地找到并选购心仪商品”，因此智能推荐、精准搜索与智能客服，成为 AI 技术率先深度渗透的关键业务链路。

物流网络的核心目标是“在订单波峰波谷交替与多重约束条件下，保障履约服务的稳定性”，于是需求预测、智能调度和最优路径规划，便成为技术落地的核心方向。

金融科技的核心命题则是“在极短时间内完成风险识别与判断，并持续对抗黑灰产侵袭”，故而实时风控与智能信用评估，成为技术应用的重中之重。

我们认为，正是得益于这些场景自带的海量数据储备、高效的业务反馈闭环，以及转化率、履约时效、资损率、人工成本等可量化的考核指标，阿里得以将 AI 从一项单纯的“技术能力”，成功转化为驱动业务增长的“核心经营能力”。

更关键的是，这种“实用型 AI”的策略并不止步于内部提效：当某类能力在内部经受住“双 11”级别的极限压力、并形成可复用的方法论后，阿里会把它产品化、平台化，并通过阿里云对外提供标准化服务，从而把内部效率优势转化为外部商业化与生态优势。

底层技术与算力：飞天（Apsara）统一算力与数据处理，为后续 AI 全栈打地基

要让“实用型 AI”真正跑在生产系统里，仅有算法远远不够，最难的部分反而是算力、数据与工程体系。阿里在这方面的核心底座是“飞天（Apsara）”大规模分布式计算系统。

这条“先云化、再智能化”的路线，带来两点长期收益：统一调度与资源池化：使得训练与推理、离线与在线、数据治理与特征计算能够在同一套云基础设施之上协同演进。飞天的核心任务是把海量服务器的计算、存储、网络做资源池化与统一调度，并通过 API 输出一致服务。软硬协同的自主可控：逐步补齐。阿里还通过平头哥自研芯片来增强云服务全流程自主可控，以降低外部不确定性与地缘政治风险。

图1: 阿里云开放飞天智算平台



资料来源: DTDATA

图2: 阿里云启动智算中心



资料来源: DTDATA

平台化产品: PAI 与城市大脑, 把“内部能力”打包成“可复制产品”

当业务线里出现越来越多模型与算法之后, 真正的规模化不是“多做几个模型”, 而是把能力标准化, 让更多团队、更多客户能用起来。阿里在 2022 年以前较具代表性的两类平台化输出是 PAI 与城市大脑。

PAI: 让机器学习从“手工活”变成“流水线”

PAI 作为面向企业与开发者的一站式机器学习平台, 将阿里内部多年积累的算法、框架与工具整合输出, 甚至提供“拖拉拽”式操作以训练模型并开发 AI 应用。根据阿里云官方产品文档介绍, PAI 定位为端到端的 AI 开发平台, 覆盖从数据标注与建模、分布式训练到在线部署的全流程能力。PAI 使“AI 应用开发”不再局限于少数算法专家, 转变为可规模化、工程化复制的标准化流程, 显著降低了企业应用 AI 的门槛。与此同时, 这也帮助阿里将内部技术积累转化为云上的产品竞争力与商业收益, 进一步增强生态粘性。

城市大脑: 以视频分析与城市数据融合, 输出城市治理方案

“城市大脑”项目于 2016 年在杭州诞生, 旨在通过人工智能解决交通拥堵问题, 并迅速发展为综合性的城市智能管理平台。其核心是将城市数据(如交通流量、视频监控)转化为可计算资源, 利用 AI 算法进行实时分析和自动调度, 优化城市运行。截至 2021 年底, 阿里城市大脑已从单一应用演变为覆盖数百场景的城市级智能基础设施。它通过降低城市治理门槛, 将“经验决策”转向“数据智能决策”, 已为阿里云在智慧城市领域构筑了深厚的产品、案例与生态壁垒, 为其后续融入“云钉一体”战略并向“全域数字治理”升级奠定了坚实基础。

图3: 2019 年阿里机器学习平台 PAI 3.0



资料来源: AI 前线

图4: 城市大脑-交通全网模型



资料来源: 阿里云官网

核心业务 AI 化: 电商、物流、金融三大“实战场”沉淀出可复用能力资产

如果说飞天是“底座”，PAI/城市大脑是“输出形态”，那么淘天、菜鸟、支付宝就是阿里 AI 能力最重要的“训练场”和“压力测试场”。

淘天（电商）：推荐、客服、视觉检索构成交易效率引擎

在 2022 年之前，阿里已通过深度整合自研 AI 技术，全面重塑了其电商核心业务链路，将效率优势系统性地固化为了平台的核心竞争力。这一布局的核心逻辑在于利用人工智能技术，全面优化并缩短用户“发现-咨询-决策-下单”的每一个环节。

在“发现”与“决策”环节，推荐算法构成了 AI 应用的核心。阿里电商基于海量用户行为数据（浏览、点击、收藏、加购），利用其自研的深度兴趣网络（DIN）等先进模型，实现了对用户动态兴趣的精准捕捉与预测。这一能力被广泛应用于“猜你喜欢”等信息流产品中，特别是 2018 年推荐系统全面升级后，“猜你喜欢”已融入搜索、购物车、支付成功页等几乎所有购物环节，实现了从“人找货”到“货找人”的智能匹配，极大提升了流量分发效率和用户沉浸体验。

在“咨询”环节，智能客服系统“阿里小蜜”扮演了关键角色。作为面向消费者和商家的统一智能助理，它在 2017 年“双 11”期间就实现了智能服务占比超过 95% 的突破，每日处理平台数亿次咨询。这不仅大幅降低了人工客服成本，更通过 7x24 小时的即时响应，解决了用户购物过程中的绝大多数前置疑问，是保障交易顺畅、提升服务确定性的关键基础设施。

在连接“发现”与“决策”的搜索场景，阿里则展现了其在计算机视觉（CV）领域的深厚积累。以“拍立淘”为代表的图像搜索技术，允许用户通过拍照直接寻找同款或相似商品，创造了一种全新的、直觉式的商品发现路径，有效补充了传统关键词搜索的不足。

图5：阿里小蜜平台体系



资料来源：阿里云开发者社区

图6：阿里小蜜平台展示

阿里小蜜平台介绍-产品展示



资料来源：DataFunTalk

菜鸟（物流）：用“智慧物流大脑”对抗极端峰值与多约束调度

菜鸟的 AI 布局聚焦于前端“人货匹配”不同，其核心价值在于作为庞大物流复杂系统的“智慧大脑”，通过运筹优化与精准预测，为整个电商履约网络实现系统性降本增效，特别是在“双 11”这类极限峰值场景下保障稳定运行。

其 AI 应用贯穿物流全链路：在仓储环节，算法调度数百台 AGV 机器人协同作业，实现高效自动化的分拣与搬运，在末端配送环节，路径优化算法综合实时路况、包裹位置与预约时间，动态规划最优派送路线，在至关重要的预测与规划环节，机器学习模型结合历史数据与营销活动，提前精准预测包裹洪峰，指导全国仓库、分拨中心及运力资源的前置性配置，从源头上规避

“爆仓”风险。


这些能力的深远意义在于，它们不仅提升了物流速度与运营效率，更重要的是构筑了整个电商交易的确定性底盘。对消费者而言，稳定、可预期的履约体验是建立购物信任的关键一环，对平台和商家而言，可靠的物流服务能力本身就是促进交易转化、提升用户忠诚度的核心基础设施。因此，截至 2022 年，菜鸟 AI 已成为将阿里电商的效率优势，从线上虚拟交易延伸至线下实体交付、并最终固化为全平台核心竞争力不可或缺的一环。

图7: 菜鸟网络布局



资料来源：物流指南

图8: 菜鸟履行调度



资料来源：物流风向标

支付宝（金融）：实时风控、信用评估与理赔自动化


在金融领域的 AI 应用，核心挑战在于平衡极致安全与无感体验。这一要求催生了以支付宝为中心、贯穿风险、信用、服务三大核心维度的 AI 技术体系，其目标是在毫秒级的决策中，将风控转化为一种无形的信任基石，进而创造新的商业价值。

在最为核心的风控领域，以“Alpha Risk”为代表的智能风控引擎构成了金融交易的底层神经系统。它能在用户支付的 0.1 秒内，综合设备、行为、关系网络等数千维度特征进行实时图计算与异常检测，将资金损失率控制在亿分之一的量级。这种近乎实时的、高精度的风险拦截能力，是支撑大规模电子支付与信贷业务得以安全运行的前提。

这一风控能力又进一步转化为正向的信用资产。通过“芝麻信用”这一机器学习信用评估模型，将个人复杂的履约历史与行为数据量化为直观的信用分。这不仅是风险识别的副产品，更成为了开拓“信用即服务”新场景的关键：从免押金租赁到“先享后付”，信用分降低了无数小额交易的门槛与摩擦，创造了全新的商业模式。


同时，AI 也在重塑金融服务的效率与体验。例如，面向保险行业的“定损宝”，利用计算机视觉技术自动识别车辆损伤并完成定损，将理赔流程从数小时缩短至分钟级。这不仅是对传统人力密集型流程的颠覆，更将理赔从一项成本中心，转变为提升客户满意度和留存的关键服务触点。

图9: 蚂蚁金服智能风控引擎 Alpha Risk 风险分析



资料来源：跳动的数据

图 10: 蚂蚁金服智能风控引擎 Alpha Risk 风险识别



资料来源：跳动的数据

我们认为，把阿里在 2022 年以前的 AI 发展放到更长周期里看，会发现它并非走“概念先行”的实验室路线，而是一条典型的“业务驱动—工程沉淀—平台化输出”路径：先在电商、物流、金融等高频刚需场景中把算法跑通、把系统扛住，围绕交易流转效率提升、物流运营成本压降与金融风险管控等核心目标持续迭代，待能力稳定成熟后，再将其产品化、标准化，依托阿里云封装为云产品与行业解决方案对外复制扩张，最终形成“内部场景实践—技术沉淀—生态赋能”的商业价值闭环。

2. 2023—2024: 阿里全面进入大模型时代, 形成“通义千问+云平台+业务重做”的新框架

2.1. 战略与组织：2023 作为“全面开启 AI 时代”的拐点

2023 年的组织重塑与战略重构,共同构成阿里“全面开启 AI 时代”的宣言。组织上,为 AI 打造了独立而强大的承载主体(云智能),战略上,为 AI 赋予了面向用户与市场的前沿使命。这预示着阿里的未来,将是一个以云智能为技术底座,以用户价值为最终导向,由 AI 驱动所有业务深刻再造的新阶段。

“1+6+N”组织变革让云智能业务的使命变得前所未有的清晰和独立。2023年3月，阿里集团启动史上最大规模的组织调整，转型为控股公司，旗下阿里云智能集团与其他五大业务集团获得高度独立经营权，可独立融资与上市。这一调整的深层逻辑在于，在生成式AI的激烈竞争中，“模型—算力—平台—场景”已形成高度耦合、缺一不可的链条。将云智能推向独立前台，意味着阿里决心将其打造为承载这一完整链条的核心主体——它不再仅仅是内部业务的算力支持者，而是要直接对外成为面向千行百业的大模型基础设施提供商与平台运营者，从而在商业和生态上完成从技术供给到价值变现的闭环。

同年9月管理层完成交接后提出的“用户为先、AI驱动”双战略，彻底扭转了AI在公司内部的定位。过去，AI主要作为后台的“效率引擎”，服务于降本增效，2023年开始，它被提升至驱动“产品与入口竞争”的前台核心动力。战略意图非常明确：在C端，必须利用大模型技术重塑电商导购、搜索、本地生活等核心场景的用户体验，重新定义流量分发方式与用户心智，以应对来自新形态应用的挑战，在B端，则需基于统一的云平台，提供能深度改造业务流程的智能服务。这一转向，标志阿里的AI之战已从内部的技术优化，升级为面向未来市场格局的全面竞争。

图 11: 阿里 1+6+N 组织架构



资料来源：中企图库

2.2. 大模型底座：通义千问发布与多模态矩阵快速补齐

通义千问的发布：从“自研模型”到“全业务接入”的集团级工程

2023 年 4 月的阿里云峰会，是阿里 AI 战略的公开转折点。公司不仅正式发布“通义千问”大模型，更关键的是，时任阿里云 CEO 的张勇宣布将把通义千问“接入阿里所有业务并进行改造”。这一声明，将通义千问的定位从一项技术成果，提升为一项牵引整个集团进行 AI 原生转型的系统性工程。

这一工程的核心任务，在于构建一个能够被所有业务单元（BU）高效、标准化调用和改造的通用能力基座。它要求统一调度庞大的底层算力资源（如阿里云飞天系统及自研芯片），建立标准化的模型训练与推理体系，并构建一套完善的数据治理、安全合规框架以及面向各业务线的标准化产品接口与工程规范。因此，通义千问在诞生之初，其设计目标就超越了做一个优秀的对话 AI，而是成为一个可被业务“调用、改造、二次开发”的 API 化智能内核。此举旨在打破此前各业务线 AI 能力“烟囱式”发展的局面，通过统一的技术底座，实现 AI 研发资源的集约化、能力的标准化输出与经验的快速复用，为后续大规模、高效率的 AI 应用创新奠定基础。

2023 年下半年：密集补齐垂直与多模态能力，构建“通义产品矩阵”

发布通用底座只是第一步，让技术真正创造价值，必须与具体场景结合。因此，在 2023 年 6 月至 12 月间，阿里展开了一场高效的产品“闪电战”，密集发布了多款基于通义千问的垂直场景应用，快速构建起一个立体的“通义”产品矩阵：

- **通义听悟**：定位于音视频内容理解与知识沉淀工具。它能够实时将会议、课程等音频转化为文字，并自动生成摘要、提炼待办事项，甚至进行多语言翻译，直击办公与学习场景的效率痛点。
- **通义万相**：主打文生图与多风格视觉生成。用户通过自然语言描述即可生成高质量、多种风格（如二次元、现实主义、国风等）的图像，极大

地降低了创意设计门槛，为电商、营销、内容创作等领域提供生产力工具。

- **通义灵码**：作为智能编程助手，集成在主流开发环境中，能够提供代码补全、注释生成、代码解释、智能调试乃至单元测试生成等功能，旨在成为开发者的“副驾驶”，提升软件开发效率。
- **通义法睿**：聚焦法律垂直领域，具备法律条文理解与推理、合同智能审查、法律文书自动生成、案例检索分析等专业能力，服务于律师、法务及普通用户的法律需求。
- **通义智文**：定位于智能文本精读与知识萃取工具。它能快速解析书籍、论文、报告等长文本，自动提炼核心观点、生成知识图谱、标注重点内容，还支持多格式文档导入与问答交互，显著提升阅读与信息处理效率，是学生、研究者与职场人士的高效辅助工具。
- **通义星尘**：主打虚拟角色与剧情的 AI 生成与定制。用户通过自然语言描述角色设定、性格特征与故事背景，即可生成具备独特人设、多维度性格的虚拟角色，并支持续写剧情、生成对话脚本，为内容创作者、游戏开发者、IP 运营者提供低成本、高自由度的角色创作能力。
- **通义点金**：聚焦金融投研场景，提供全链条智能分析能力。它能实时整合宏观经济数据、行业研报、公司公告等信息，自动生成事件点评、估值分析与风险预警，支持多因子策略回测与智能问答，帮助投资者与研究员快速把握市场机会、降低信息不对称。
- **通义晓蜜**：面向企业的全渠道智能客服解决方案。它具备多轮对话理解、意图识别与上下文记忆能力，可覆盖售前咨询、售后问题处理、订单查询等场景，支持文本、语音等多模态交互，并能自动沉淀常见问题库，降低企业客服人力成本，提升客户响应效率。
- **通义仁心**：定位于家庭健康管理的 AI 辅助工具。它能解读体检报告、分析症状描述、提供个性化健康建议，支持用药提醒、饮食运动规划，并对接医疗知识库提供疾病科普与就医指引，帮助用户实现日常健康监测与预防管理，提升家庭健康防护能力。

这一系列产品并非彼此孤立的小工具，而是通义千问统一技术底座之上的“场景化封装”。其内在逻辑非常清晰：通义千问作为“大脑”，提供了强大的通用语言理解、逻辑推理和多模态交互核心能力，而听悟、万相、灵码、法睿等则是这个大脑的“感官”与“手脚”，它们将底座的通用能力，结合特定领域的知识库、工作流和交互界面，封装成用户开箱即用、可直接融入业务流程的解决方案。这种“基座+场景应用”的组合，标志着阿里的大模型战略进入了“可用、可交付、可规模化”的实战阶段，也为其后续的生态化发展提供了产品原型。

图 12: 通义大模型家族



资料来源：全云在线

模型能力迭代与开源生态形成外溢效应

在激烈的 AI 竞赛中，模型的持续进化能力与生态的构建速度同等重要。进入 2024 年，阿里在通义大模型的发展上呈现出“双轮驱动”的鲜明特征：一是模型性能的快速迭代，二是开源生态的积极构建。

在模型迭代方面，阿里保持了高频的升级节奏。公司相继推出了 Qwen1.5、Qwen2 等系列版本，在模型规模、推理能力、代码生成、多语言支持等方面持续提升。特别是后续发布的 Qwen2.5 系列及专门针对深度推理任务优化的模型，在多项国际基准测试中表现优异，不断缩小与国际顶尖模型的差距，证明了其技术路线的有效性。

更具战略眼光的是阿里的开源策略。阿里将通义千问系列模型的多个版本（如 Qwen-7B、Qwen-14B 等）在 GitHub 等平台开源，并采用了友好的 Apache2.0 等协议。这一举措产生了深远的外溢效应：

- 降低门槛，建立信任：全球开发者可以免费下载、研究并在受限范围内使用这些先进的模型，极大地降低了体验和试错成本，帮助通义千问迅速建立了技术影响力和开发者心智。
- 汇聚生态，形成标准：开源吸引了大量开发者、研究机构和企业围绕通义模型进行二次开发、工具链适配和应用创新。这种广泛的社区参与，有助于形成以通义模型为中心的事实技术标准与软件生态，增强了技术路线的粘性。
- 反哺商业，驱动增长：开源与商业化并非对立，而是构成了一个高效的漏斗。阿里形成了“模型研发-开源推广-云服务变现-生态反哺”的闭环逻辑。开发者在开源模型上验证想法后，自然会将需要更高稳定性、更大算力或私有化部署的商业项目迁移到阿里云的“百炼”平台等商业化产品上，为阿里云带来模型训练、推理托管、行业解决方案等可持续的付费收入。同时，开源社区的反馈也成为驱动模型改进的宝贵资源。

图 13: 阿里所有产品将接入大模型



资料来源：阿里云

两条产品线并行：“对内重塑业务”+“对外平台化输出”

在确立了通义千问作为统一技术底座后，阿里面临的挑战是如何将大模型的能力转化为真实世界的价值。对此，阿里采取了清晰的双轨并行策略：对内，以前所未有的广度和深度，将大模型注入核心业务的每一条“毛细血管”，推动从功能优化到体验重构的根本性变革，对外，则将经过内部锤炼的能力体系化、平台化，从过去的“机器学习工具提供商”升级为“大模型时代的基础设施与生态运营商”。这条“内外兼修”的产品路径，共同指向一个目标：将大模型从一项前沿技术，转变为驱动自身增长与赋能千行百业的核心引擎。

1) 对内：用大模型“重做一次”——从功能叠加走向 AI 原生重构

阿里集团内部对 AI 的应用，早已超越了早期“单点提效”的阶段。2023 年，随着“用户为先、AI 驱动”战略的确立，集团上下形成了一个明确的共识与口号：“面向 AI 时代，所有产品都值得用大模型重做一次”。这并非一句空洞的口号，而是一场涉及产品哲学、交互逻辑乃至商业模式的系统性工程，其核心是从“功能叠加”转向“AI 原生重构”。

首批试验田：钉钉与天猫精灵的范式转变

钉钉和天猫精灵成为了这场重构运动的先行者。它们并非简单地增加一个 AI 聊天入口，而是将大模型能力深度融入其产品肌理。钉钉从一个协同办公平台，进化为智能工作助理。基于通义千问的“通义听悟”等能力，钉钉实现了会议内容的实时转写、多语种翻译、自动提炼纪要与待办事项。更进一步，AI 能根据会议讨论自动生成工作方案草稿，或在聊天中根据上下文智能推荐下一步操作。这意味着，AI 不再是一个需要被主动调用的功能，而是变成了无处不在、主动提供支持的“副驾驶”，重构了信息沉淀与任务流转的路径。

天猫精灵则从语音指令响应设备，转变为具备深层理解和内容生成能力的家庭伙伴。借助大模型的对话与生成能力，它能进行多轮、开放域的深度对话，根据孩子的年龄和兴趣讲述定制化的故事，或为家庭成员生成个性化的健身计划与菜谱。产品内核从执行固定命令，转向理解意图并创造内容，用户体验从“操控”变为“交互与合作”。

图 14: 天猫精灵升级接入大模型



资料来源：天猫精灵

核心战场：电商逻辑的深度重塑

这一重构逻辑在阿里的核心电商业务——淘天集团中体现得最为深刻。传统的电商模式建立在“关键词搜索”与“猜你喜欢”的“货架+流量”逻辑之上。而大模型带来的变革是颠覆性的，其代表产品是全面升级的“淘宝问问”。

交互革命：从“搜索”到“对话式需求表达”：用户不再需要费力组合关键词，而可以用自然语言直接描述复杂场景需求（如“下个月要去大理旅游，早晚温差大，帮我推荐几件适合拍照又方便穿脱的外套”）。大模型能理解场景、风格、功能等隐含需求，将模糊的意愿转化为精准的商品筛选条件。

导购革命：从“匹配”到“理解与生成”：传统的推荐算法是基于历史行为的协同过滤，本质是“匹配”已知商品。而 AI 导购则能“理解”商品详情、用户评价、时尚趋势，并能“生成”个性化的购买建议与搭配方案。例如，它不仅推荐一件外套，还能生成一段解释为何这件外套适合大理气候与拍照场景的文案，并自动搭配出内搭和裤装组合。

全链路改造的伏笔：这种交互与决策方式的改变扩散至整个电商生态。它为后续的“AI 营销”（根据商品特性与目标人群自动生成海量差异化营销素材）、“智能客服升级”（从问答式升级为能处理复杂退换货纠纷的谈判式客服）、“个性化内容生成”（为每个用户动态生成专属的商品展示视频或图文）铺平了道路。最终，这不仅仅是效率提升，而是将电商从“人找货”的场，部分重塑为“货懂人”的智能商业体。

图 15: 淘宝问问-AI 电商



资料来源：淘宝问问

全面渗透：AI 原生化成为标配，席卷了阿里几乎所有核心业务线：

- 夸克：从智能搜索引擎升级为 AI 学习与生活助手，基于大模型提供从解题辅导到文档创作的全链路服务。
- 高德地图：宣布全面 AI 化，目标是超越导航工具，成为能理解“我想找一家适合带孩子过生日、有包厢且停车方便的餐厅”这类复杂需求的出行生活规划师。
- 菜鸟：AI 从优化单一环节的“智慧大脑”，进化成为能预测、调度、动态调整的全局物流智能体，应对更复杂的供应链需求。
- 闲鱼：AI 实现从商品信息自动识别填写、智能定价到全程 AI 托管代售，重塑二手交易体验。

阿里的“对内重塑”是一条从头部应用到核心业务，再到全生态渗透的激进路线。其目标不是修补，而是通过大模型这一全新的“原子能力”，重构用户与产品交互的根本方式，从而在 AI 时代重新定义自身业务的竞争力。

2) 对外：从“机器学习平台”升级为“大模型中台/平台”，降低行业落地门槛

对外输出“建生态”，阿里云承载了将内部 AI 能力转化为通用商业价值的使命。其策略清晰地从过去的“机器学习平台（如 PAI）——主要提供算法工具和算力——升级为“大模型中台/平台”，核心是提供端到端的、低门槛的大模型应用构建与部署能力。

核心平台：百炼与魔搭（ModelScope）的协同

百炼定位为一站式的大模型应用开发平台，它为企业客户提供了“模型+工具+服务”的完整套件：


- 丰富的模型库：不仅集成了通义千问全系列模型（Qwen 文本模型、万相视觉模型、听悟语音模型等），也接入了如 DeepSeek 等第三方优秀开源模型，形成“模型百货商店”，企业可按需选用。
- 可视化的开发与调优环境：提供精细化的模型微调（Fine-tuning）、提示

词工程、检索增强生成（RAG）编排等工具，大幅降低专业 AI 工程师的研发门槛。

- 安全可控的部署与管理：支持公有云 API 调用、专有云部署乃至完全本地化的私有化部署，满足金融、政务等行业对数据安全的苛刻要求。同时提供完整的监控、评测和成本管理工具。

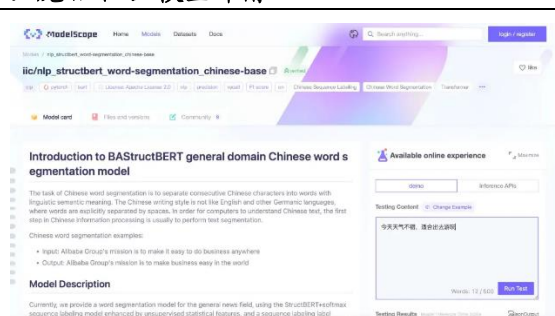
魔搭（ModelScope）社区——开放开源的开发生态：作为中国最大的模型开源社区之一，魔搭汇聚了通义系列等海量开源模型、数据集与工具链。它扮演了生态“育苗场”和“连接器”的角色，通过开源降低技术获取门槛，吸引全球开发者，让创新在社区中自由生长。开发者在魔搭上体验、创新，其成熟的商业需求则可能自然流向提供企业级支持与服务的百炼平台，形成从开源到商业的良性循环。

图 16: 魔搭社区模型选择



资料来源：魔搭社区

图 17: 魔搭社区模型详情



资料来源：魔搭社区

阿里的对外平台化策略，可转化为企业客户能清晰感知的三步价值主张：首先提供“可选的模型库”，让客户无需从零训练模型，直接选用经过验证的通用或垂类模型，其次通过百炼平台提供“可控的开发与部署环境”，支持企业在安全边界内调优模型并合规部署，最后提供“从验证到生产的工程化路径”，通过全生命周期工具确保 AI 应用稳定落地，成为可靠的生产力系统。

阿里正通过“开源建立技术标准、百炼平台沉淀商业场景、云服务实现商业变现、生态反哺技术迭代”的闭环逻辑，推动自身从云计算基础设施供应商，向“AI 生态运营商”转型。这意味着，阿里的角色不仅是出售算力和模型，更是为企业提供在 AI 时代生存和竞争所需的整套能力、工具与生态连接。

2.3. 云侧竞争：从 IaaS 走向“全栈 AI”，在 GenAI IaaS 与 MaaS 双线发力

市场结构变化：GenAI 推动竞争从“通用计算”转向“AI 计算+平台能力”


生成式 AI 对云计算的需求是结构性的。海量参数的模型训练需要巨量、稳定且高效互联的 GPU 集群，复杂的推理场景则对算力弹性、延迟和成本提出了极致要求。这导致云市场的价值重心发生偏移：

当前行业的竞争维度已发生升级，单纯比拼 IaaS 的规模与价格不再是制胜关键，核心能力转向三个方面：一是 AI 算力的稳定供给与高效调度能力，包括大规模 GPU 集群管理、高性能网络和液冷技术等，二是将复杂 AI 工程体系打包为可交付平台的能力，比如分布式训练框架、推理优化工具和一体化开发环境，三是构建行业解决方案与伙伴生态网络的能力，最终实现技术向具体业务价值的转化。

阿里云的护城河与市场地位：在这一转型中，阿里云凭借长期的投入构建了

显著优势。其自研的“飞天”操作系统实现了超大规模数据中心的统一调度，自研的“含光”、“倚天”等芯片则在 AI 推理和算效比上进行了深度优化。2024 年第二季度，阿里云在中国公有云 IaaS 市场份额维持在约 34.2%，持续领跑市场。其在 PaaS 市场同样占据约 25% 的份额。这不仅证明了其在传统云基础市场的统治力，更意味着其庞大的客户基数和复杂的平台服务经验，是承接 AI 计算需求的天然土壤。AI 驱动的需求正在推动其收入增速回升，验证了其从“通用云”向“AI 云”转型的初步成功。

图 18: AI 模型提供商能力维度评比



资料来源: Gartner

图 19: 云 AI 开发者魔力象限榜单



资料来源: Gartner

“全栈 AI” 的含义: 不止卖 GPU, 更要卖“模型+工具链+交付”

“全栈 AI” 是阿里云应对新竞争格局的核心战略。它意味着云服务的价值链被重新切分和深化, 阿里云致力于在每一层都构建差异化能力, 并将其整合为无缝的体验:

- 底层: 算力与网络 (硬软一体优化): 这超越了单纯的 GPU 供给。阿里云通过自研的“磐久”服务器 (针对 AI 负载设计)、高性能 RDMA 网络、以及“飞天+CIPU”架构, 实现计算、存储、网络的协同优化, 目标是在提供稳定算力的同时, 最大化资源利用率和能效比。与国产芯片的适配, 也为其应对供应链不确定性提供了保障。
- 中层: 训练与推理工程体系 (效率与成本的关键): 这是将原始算力转化为 AI 生产力的“炼油厂”。阿里云提供了大规模分布式训练框架、模型量化与压缩工具、以及灵活的推理服务 (如弹性实例、预留实例、抢占式实例)。其核心价值在于帮助客户显著降低训练成本、提升推理速度并优化整体拥有成本 (TCO)。
- 上层: 模型与应用平台 (价值实现的直接触点): 这是“全栈 AI”最外显、也最具粘性的一层。其核心产品是“百炼”平台和“通义”大模型家族。从通义千问 (文本) 到通义万相 (图像/视频)、通义听悟 (语音), 阿里提供了覆盖多模态的模型家族。这些模型不仅是服务, 更是吸引开发者、定义技术标准的“锚点”。

通过这三层的协同, 阿里云的产品逻辑从提供芯片、服务器到模型、开发工具乃至行业模板的完整 AI 解决方案。百炼平台和通义模型, 正是其“模型即服务 (MaaS)”与“平台即服务 (PaaS)”能力的核心抓手, 旨在将 AI 能力转化为可规模化复制的产品。

图 20: AI Infra 系列产品及能力



资料来源：阿里云

图 21: 阿里云弹性计算产品家族



资料来源：阿里云

图 22: 阿里云 AI 基础设施全景图



资料来源：连通梦想

生态与资本布局：用投资“补齐供给侧”，将不确定性转化为协同

生成式 AI 的供给侧高度复杂且快速演进，涉及基础模型、算力芯片、数据工程、对齐安全、行业知识及下一代形态（如机器人）。单靠内部研发难以全面覆盖所有创新前沿。因此，阿里在 2023-2024 年显著加强了以资本为纽带的生态布局，其投资图谱具有清晰的战略意图：

表 1: 阿里 2023-2024 年投资情况

投资时间	公司名称	主营业务	投资主体	性质/备注
2023 年 2 月	PanopticAI	AI 医疗诊断（影像/数据分析）	阿里巴巴创业者基金（AEF）	股权投资（早期）
2023 年 6 月	生数科技	AI 医疗影像分析 / 生成式 AI（多模态方向）	蚂蚁集团	股权投资（早期）
2023 年 7 月	奇点临近	轻量化 AR 眼镜研发	阿里巴巴集团	股权投资（公开披露信息有限，建议后续补轮次/金额证据）
2023 年 7 月	Rice Robotics	服务机器人（配送/清洁）	阿里巴巴创业者基金（AEF）	股权投资（成长期）

2023 年 10 月	智谱 AI	AI 大模型开发与应用	阿里巴巴集团、蚂蚁集团	股权投资（战略/生态； 公开披露为多轮/多方参与）
2023 年 10 月	百川智能	大模型技术研发（含多模态生成）	阿里巴巴集团	股权投资（战略）
2023 年 11 月	零一万物（01.AI）	通用大模型研发	阿里巴巴集团（阿里云）	股权投资（领投/战略）
2024 年 2 月	月之暗面（Moonshot AI）	通用大模型研发（长文本/对话方向）	阿里巴巴集团（部分报道亦提及蚂蚁参与生态）	股权投资（重仓/财报披露级别；公开披露曾含持股比例口径）
2024 年 3 月	MiniMax	多模态大模型研发	阿里巴巴集团（领投）	股权投资（战略/生态）
2024 年 4 月	爱诗科技	AI 视频生成技术	蚂蚁集团	股权投资（生成式内容； 公开披露细节有限）
2024 年 4 月	墨芯科技	AI 芯片设计（算力/推理优化）	蚂蚁集团	股权投资（芯片/算力侧）
2024 年 7 月	逐际动力（LimX Dynamics）	机器人研发（人形/通用机器人）	阿里巴巴集团	股权投资（具身智能/机器人）
2024 年 8 月	秘塔科技	AI 搜索与写作工具	蚂蚁集团（领投）	股权投资（应用层工具）
2024 年 10 月	地平线	智能驾驶芯片及解决方案	阿里巴巴集团	基石/资本市场投资（非一级股权轮次）
2024 年 11 月	星海图	具身智能（机器人全链路技术）	蚂蚁集团	股权投资（公开披露细节有限，建议后续补轮次公告/工商变更）
2024 年 11 月	边塞科技	大模型强化学习对齐技术	蚂蚁集团（全资收购）	并购（收购/整合技术团队）
2024 年 12 月	AEF NextGen 基金	AI 初创企业投资（覆盖多个行业）	阿里巴巴创业者基金（AEF）	基金设立（对外投资载体，非单一标的）

资料来源：阿里官网，新浪财经，腾讯网，雪球等，国泰海通证券研究

这一系列布局服务于三大核心战略目标：

- 1) 将外部创新内化为云上供给：通过投资建立紧密联盟，将这些明星创业公司的模型（如 Kimi、GLM）和应用优先引入阿里云百炼平台或通过 API 提供服务。这极大地丰富了阿里云 MaaS 层的模型货架，形成了“云平台+明星模型”的联合解决方案，增强了客户吸引力，并可能带来收入分成。
- 2) 提前卡位未来入口与形态：对机器人、AR 等领域的投资，并非追求短期财务回报，而是对未来人机交互范式和大模型物理载体的战略押注。这确保了阿里在 AI 从数字世界向物理世界渗透的长期演进中不缺席。
- 3) 补齐关键“短板”技术：在强化学习对齐、特定领域芯片设计等需要长期深耕且风险较高的“硬科技”领域，通过资本支持外部尖端团队，以更灵活的方式获取能力，弥补自身研发体系的不足，共同提升整个生态的技术水位。

我们认为，阿里云在 GenAI 时代的竞争策略，构成了一个清晰的增长飞轮：以坚实的 IaaS 基本盘和全栈 AI 技术能力为底座，通过百炼平台和通义模型提供直接价值输出，再以资本投资和开源社区为手段吸纳外部最前沿的创新与生态力量，反哺和丰富其平台能力，进而吸引更多客户与开发者，进一步巩固其市场地位。这一战略的本质，是将阿里云从一个“资源型”公用

事业公司，升级为一个“能力型+生态型”的 AI 创新平台。它不仅在销售 AI 算力，更在定义 AI 开发与部署的流程和标准，并通过资本与生态构建了一个强大的创新协同网络。在生成式 AI 这场重塑所有行业的长跑中，阿里云正试图通过“全栈 AI”与“生态协同”的双重引擎，确保自己不仅是一个算力供应商，更是整个智能化转型浪潮中不可或缺的核心枢纽。

3. 2025 年及以后：阿里 AI 从能力领先走向入口级产品，以“模型+生态+AI Infra”争夺下一代平台

3.1. 总体战略：核心武器是“模型+生态”，从能力领先走向入口级产品

进入 2025 年，阿里 AI 战略的顶层设计愈发清晰：其核心竞争力不再是单一的模型参数规模或基准测试分数，而是“通义千问大模型”与“阿里数字经济体生态”的深度融合。通过将模型能力与电商、本地生活、支付、出行、办公等高频场景的系统性打通，构建一个能为用户“办成事、办好事”的闭环体验，这是任何纯技术公司或单一场景应用难以复制的结构性优势。

战略定调：“通云哥”雏形初现

阿里巴巴对自身角色与核心竞争力的重新界定正在加速成型。内部提出的“通云哥”概念，首次将通义实验室、阿里云和平头哥半导体明确绑定为一个整体，构成阿里 AI 战略的“黄金三角”。AI 竞争已经不再是单一模型能力或某个爆款应用的比拼，而是一场围绕算力供给、模型能力与系统工程协同的综合性竞争。阿里集团管理层判断，未来十年云计算最大的变量与增量都将由 AI 驱动，而真正具备长期竞争力的云公司，必须同时掌握模型、算力与底层硬件的协同能力。正是在这一背景下，阿里将“云 + AI + 芯片”上升为科技战略的核心支点，试图从基础设施层面构建 AI 时代的新型“通用底座”，并以此支撑更长周期的发展。

从历史路径看，“通云哥”并非一蹴而就，而是阿里十余年技术积累的集中呈现。阿里云自去 IOE 起步，通过飞天系统逐步建立起大规模分布式计算能力；平头哥自 2018 年成立后，从 AI 推理芯片含光 800，到通用服务器 CPU 倚天 710，再到近年来进入规模化阶段的真武 PPU，持续补齐算力与硬件能力；通义实验室则在大模型浪潮到来前完成技术储备，并在开源路线下快速扩展生态。关键在于，这三条技术线并未被阿里视为相互独立的“业务板块”，而是被纳入同一套 AI 基础设施体系中统一设计与演进。阿里的做法不是简单的“叠加”，而是从模型的计算范式出发，反向推导算力需求与系统架构，再据此定制芯片形态与云侧调度方式，尽可能减少接口损耗与协同成本。平头哥的芯片优先在阿里云真实业务中落地，通义模型与云平台深度耦合优化推理与交付效率，这种系统级协同被视为阿里降低不确定性、提升可控性的关键路径。

图 23: “通云哥” 黄金三角锻造国产 AI 脊梁



资料来源：21 世纪经济报道

战略升维：从“工具赋能”到“入口定义”

2025 年，“AI 化”战略焦点已转向“AI 原生”(AI-native)和“AI 即入口”。这意味着 AI 不再仅仅是优化现有流程的“外挂”，而是成为用户接入阿里各项服务、甚至处理各类生活与工作任务的首要界面和中枢神经。

阿里在 C 端发力的关键在于“模型能力优势+生态协同效率”。阿里希望通过生态融合、超长上下文理解等差异化能力，形成独特的用户价值主张。“免费（降低使用门槛）+增值（提供深度服务与体验）+B 端开源（扩大开发者生态与行业渗透）”的三位一体模式。

图 24: AI 进入企业应用的全栈视图



资料来源：阿里云栖大会

逻辑内核：从“会聊天”到“能办事”

这一战略转向的背后，是对大模型竞争本质的深刻洞察：在模型能力日趋同质化的背景下，单纯“会聊天、会生成”的 AI 助手护城河正在变浅。用户最终留存和付费的核心驱动力，在于 AI 能否真正理解复杂意图，并调动资源可靠地完成实际任务。例如，用户说“周末我想去杭州放松一下，预算 5000 元”，理想的 AI 助手应能自动完成：查询天气与高铁/机票时刻、推荐符合预算和偏好的酒店、规划景点路线、甚至预订餐厅和演出门票——这需要跨越多项服务的数据、账户和支付能力。

阿里恰好拥有构建这一“办事闭环”所需的几乎全部高频场景资产：

- 电商与零售：淘宝、天猫、天猫国际、淘宝买菜、盒马。
- 本地生活与即时零售：饿了么、口碑、淘宝闪购。
- 出行与位置服务：高德地图（中国领先的地图与导航服务）。
- 支付与金融：支付宝（连接 10 亿+用户及庞大商户网络）。
- 文娱与内容：优酷、大麦网、阿里影业。
- 商务与协同：钉钉（服务数亿企业用户）。
- 旅行：飞猪旅行。

一旦这些能力通过统一的智能体（Agent）层被“通义千问”高效调度，AI 就有机会从一个对话式的“问答应用”，演变为贯穿用户生活与工作的“个人智能操作系统”。阿里正致力于将千问打造为“生活与工作操作系统”。

图25: 超级人工智能 ASI



资料来源：阿里云栖大会

战略落地：千问 App 的公测与入口化宣言

2025 年 11 月 17 日，阿里正式官宣其个人 AI 助手“千问 App”开启全面公测，并明确其免费开放的策略。官方强调，千问 App 的定位不仅是智能对话，更将深度集成地图导航、外卖点餐、机票酒店预订、办公协同、学习辅导、商品购物等场景，核心目标就是增强其“办事能力”。2026 年 1 月 15 日，千问 App 完成重大功能升级，全面接入淘宝、支付宝、淘宝闪购、飞猪、高德等阿里生态业务。

这一动作标志着阿里将 AI 的 C 端“入口之战”从战略构想推向全面实战。通过一款独立的、功能强大的超级 App，阿里试图直接触达最广泛的用户群体，与国内外其他 AI 助手展开正面竞争，而其制胜法宝正是背后庞大的生态服务体系。

图26: 千问 APP 全面接入阿里生态场景



资料来源: 千问 APP 发布会

我们认为, 进入 2025 年阿里的 AI 战略已从“比模型”转向“拼体系”, 核心竞争力在于通义千问大模型与阿里数字经济生态的深度耦合: 通过打通电商、本地生活、支付、出行、办公等高频场景, 以统一智能体层调度数据、账户与交易能力, 把 AI 从“会聊天、会生成”的工具升级为“能办事、办成事”的闭环系统。AI 不再是流程外挂, 而是用户接入各类服务的首要界面与中枢, 在 C 端依靠“模型能力优势+生态协同效率”形成差异化, 并以“免费降低门槛+增值服务提升体验+B 端开源扩展开发者与行业渗透”的三位一体模式放大规模效应。千问 App 的全面公测与后续深度接入淘宝、支付宝、飞猪、高德等业务, 是“入口化宣言”的落地动作, 标志着阿里将 C 端入口之战从战略构想推向实战, 试图以“个人智能操作系统”定位, 在正面竞争中用生态服务体系构建难以复制的结构性优势。

3.2. 组织与责任体系: AI2C/AI2B 分工清晰, 入口与商业化并重

阿里组织架构以 2025 年 8 月确立的四大业务板块为核心, “1+6+N” 架构正式退出。四大板块包括阿里中国电商集团、阿里国际数字商业集团、云智能集团及所有其他业务, 其中饿了么、飞猪并入中国电商集团, 强化即时零售生态, 云智能集团聚焦 AI 算力与云计算技术落地, 菜鸟、高德、大文娱等非核心业务归入“其他”板块, 以轻量化运营为主。管理层面, 蔡崇信任董事会主席, 吴泳铭任 CEO, 核心资源持续向电商与云+AI 双赛道倾斜, 战略从分权创新转向聚焦核心、集权攻坚, 提升决策效率与技术转化能力。

图27: 阿里组织架构



资料来源: 2025 年公司公告

为支撑“入口级产品”的战略雄心, 阿里在 2025 年对其 AI 相关的组织架构进行了清晰而有力的调整, 明确了不同板块的责任与协同关系。

“双轮驱动”的责任体系

AI2C: 面向消费者入口, 核心目标是获取用户规模、提升使用频次、打造超级应用。这是实现“AI 即入口”战略的尖兵部队。以千问 C 端事业群为核心, 覆盖通义系列面向消费者的产品团队、夸克、UC、书旗、天猫精灵及各类消费级 AI 硬件。

AI2B: 面向企业与企业级客户, 核心目标是实现商业化落地、提供行业解决方案、深耕企业服务市场。这是确保技术投入产生商业回报的主力军。以钉钉为核心载体, 钉钉不再仅仅是一个办公 IM 工具, 而是被定位为“企业级 AI 智能体平台”。它承载着将千问大模型能力融入企业 workflow、管理流程和业务系统的重任, 是阿里 AI 实现企业级商业化变现的关键通道。

这种“入口 (AI2C) 抓规模, 平台 (AI2B) 抓收入”的并行结构, 旨在系统性地解决生成式 AI 时代的一个核心矛盾: 如何同时实现用户规模的指数级增长与可持续的商业模式。免费、好用的千问 App 吸引海量用户, 培养使用习惯, 展现生态价值, 而深度、专业、可定制的企业级解决方案则在钉钉及阿里云平台上实现价值转化。

云智能集团继续扮演至关重要的“发动机”和“底座”角色。它负责 AI 基础设施 (算力、存储、网络)、平台能力 (开发平台、模型服务平台)、以及底层大模型技术的研发与迭代 (承载达摩院、通义实验室等研发成果)。

成立“千问 C 端事业群”, 强化入口建设

为集中力量打好 C 端入口之战, 阿里在 2025 年 12 月进行了一次关键的组织重组: 新成立“千问 C 端事业群”。该事业群由原“智能信息事业群”和“智能互联事业群”合并重组而来, 整合了包括千问 App、夸克智能搜索、UC 浏览器、书旗小说、天猫精灵、AIoT (物联网) 及智能眼镜等业务。

将“千问”从一个大模型产品, 提升为一个需要倾注全公司流量与产品资源的“超级 App”项目。通过将信息分发 (夸克、UC)、内容服务 (书旗) 和硬件入口 (天猫精灵、AIoT) 与千问深度协同, 阿里旨在构建一个多层次、立体化的用户触点矩阵, 为千问的规模化增长铺路。

图 28: 阿里主要业务

下圖按分部列出我們在 2025 財年運營的主要業務：



资料来源: 2025 年公司公告

3.3. 资本开支与融资: 以基础设施投入支撑模型与平台扩张

AI 竞争是一场关乎技术、生态, 同时也是关乎资本耐力的长跑。2025 年及以后, 阿里通过一系列大手笔的资本运作, 为其 AI 战略提供了坚实的“弹药”保障。

三年超 3800 亿元的基础设施投入

2025 年云栖大会上，阿里集团 CEO 吴泳铭正式宣布，公司正全力推进一项总额超过 3800 亿元人民币的 AI 基础设施建设计划。这一数字的震撼性在于，它已超过阿里过去十年在云和 AI 硬件领域投入的总和，创下了中国民营企业的投资纪录。这并非终点，公司明确表示将在此基础上“追加更大额度投入”，展现了其资本承诺的强度与灵活性。

图 29: 阿里云全球基础设施布局




资料来源：2025 公司公告

明确的北极星指标：锁定 2026 年 AI 云市场增量 80%

如果说资本开支是“弹药”，那么市场目标就是“靶心”。2026 年初，阿里云智能集团资深副总裁刘伟光提出了一个极具进攻性的市场目标：“拿下 2026 年中国 AI 云市场增量的 80%”。这意味着，阿里云不仅满足于保持现有市场份额，更要主导未来几乎全部的增长。刘伟光对此解释称：“下一年增量的 10% 都会大于上一年的全量，所以过去取得了什么成绩并不重要，变化才刚刚开始。”这一目标清晰地表明，2025 年之后的阿里云已全面进入“进攻模式”。

图 30: 2025H1 阿里云市占情况



资料来源：英富曼（Omdia）数据

构建一个从底层硬件到全球网络，再到上层生态的完整 AI 基础设施帝国

硬件基础设施：构筑算力基石

资金将大规模投向服务器集群、高性能 AI 计算芯片 (GPU) 的采购与部署，以及前沿 AI 芯片的自主研发（通过平头哥半导体）。在 2025 云栖大会上，阿里发布了自研的“磐久 AI Infra 2.0”128 卡超节点 AI 服务器，单柜即可支持 128 个 AI 计算芯片，并将高性能网络 (HPN 8.0) 升级至 800G，以支撑未来单集群 10 万卡 GPU 的超大规模高效互联。这些投资直接服务于一个长期目标：到 2032 年，阿里云全球数据中心的能耗规模将较 2022 年提

升 10 倍，这意味着算力投入将呈现指数级增长。

全球产能扩张：从“可用区”到“超级计算平台”

资本正在全球范围内加速转化为实际算力产能。阿里计划将其数据中心可用区从 89 个扩展到 95 个，覆盖地域从 29 个增至 30 个。2025 年以来，已在北京、上海、杭州及泰国、韩国、墨西哥等全球 8 个地区新启用数据中心。同时，阿里云宣布在巴西、法国、荷兰首次设立云计算节点，并在日本、迪拜等五地扩建现有设施，新增 28 个 AI 专用套件，以服务国际客户。这一全球化布局服务于吴泳铭的核心论断：“AI 云是下一代计算机”，未来全球可能仅存 5-6 个超级云计算平台，阿里旨在成为其中之一。

生态与商业模式：“重资本投入”换取“需求锁定”

阿里资本战略的闭环在于，用重资本投入建立的供给侧优势，吸引并锁定需求侧。其核心逻辑是提供“软硬一体”的全栈 AI 能力。在阿里云上调用大模型 API（模型即服务，MaaS）的客户中，有 70% 同时在使用其 GPU 算力服务。这表明，通过领先的“通义”大模型家族（如性能跻身全球前三的 Qwen3-Max）吸引开发者与客户，再将其对算力的需求自然沉淀在阿里云上，已形成有效的商业协同。吴泳铭将这一战略类比为打造“AI 时代的安卓”，通过开源开放策略构建生态，最终目标是让“下一代操作系统”（大模型）与“下一代计算机”（AI 云）形成飞轮效应。

支撑千亿级开支，需要多元、灵活且低成本的资金来源

庞大的电商主业依然是现金牛，为战略性亏损投资提供基础。但公司也在进行战略收缩与聚焦，例如在 2025 年 9 月，阿里成功发行了约 32 亿美元的零息可转换优先票据。此次募集资金净额中，80% 将分配用于增强云基础设施，包括扩大数据中心、升级技术及优化服务以满足增长需求。其余 20% 将用于拓展国际商业运营，重点进行运营投资。此次融资的净收益明确将用于增强云基础设施能力和支持国际商业业务的战略聚焦，这为 AI 攻坚战提供了直接的“弹药”补充，同时优化了资产负债结构。

因投资即时零售业务，季度利润可能出现大幅下滑。在明确的长期战略赛道（AI 与云）上进行饱和投入，同时坦然接受短期利润的波动。2025 年阿里云收入同比增长 26%、AI 相关产品收入连续多个季度三位数增长的数据，初步验证了资本开支向收入转化的可行性，给了市场一定的信心。

图 31：阿里宣布完成发行零息可转换优先票据



资料来源：公司公告

我们认为，阿里的“3800 亿”资本开支计划，本质上是全球科技巨头算力军备竞赛在中国市场的集中映射：在微软、亚马逊等国际巨头大手笔投入 AI 与数据中心、国内百度智能云、腾讯云、华为云同样加码的背景下，阿里云提出“拿下 80% 增量”的目标，意味着必须从强敌环伺的存量竞争中硬夺增长，竞争烈度显著升级。2025-2026 年的资本开支图谱显示阿里已从试探转向总攻：以确定性投入和激进市场目标为牵引，将资金加速转化为算力硬件、数据中心网络与开源生态，试图在“模型竞赛”升级为“系统竞

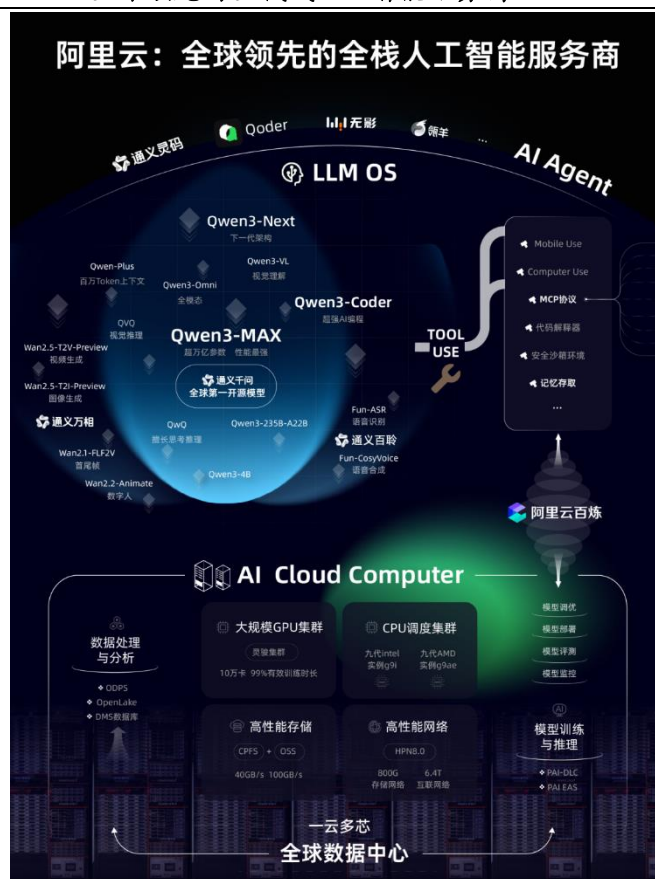
赛”的阶段，通过资本耐力同时打造通义大模型与超级 AI 云的耦合优势，争夺未来全球少数“超级 AI 云平台”的入场券，并由此重塑产业格局。

3.4. 云与算力：AI Infra “为 AI 重做一遍”，软硬一体化成为竞争焦点

支撑其宏伟的 AI 战略，离不开下一代云计算基础设施的彻底重构。进入 2025 年后，阿里云的核心命题之一是：让云计算本身为 AI 负载而重生——不再把大模型当作“跑在云上的一个应用”，而是把 AI 当作云的第一性需求，把云重塑成一台面向智能体时代的“新计算机”。

阿里云要做的不是“在云上加一个 AI 层”，而是以 AI 为中心重排整个技术栈：模型（通义/Qwen）是操作系统，超级 AI 云是计算机，百炼/ModelStudio 是开发与交付平台，开源与生态是网络效应。这套组合拳背后的判断非常明确：AI 竞争已经从“模型竞赛”升级为“系统竞赛”，最终胜负取决于能否构建一个可规模复制的全栈供给体系——既能训练、也能推理、还能快速做应用、并以生态持续放大。

图32：阿里云：全球领先的全栈式人工智能服务商



资料来源：财联社

“为 AI 重做一遍云”：从互联网云到 AI 云的范式切换

阿里云高管在接受媒体采访时明确表示：“阿里云的基础云架构，为 AI 重做了一遍。”这句话的含义并非修辞，而是一次范式切换：传统云架构主要服务 Web 与移动互联网，强调弹性、可用性与成本，但大模型时代的训练与推理对计算密度、网络拓扑、存储吞吐、数据流水线、调度方式与服务形态提出了颠覆性要求。于是阿里云的“重做”，实际是在 IaaS 与 PaaS 两层进行系统性再设计，使其天然适配 AI 负载。

图 33: 阿里云定位全栈式人工智能服务商



资料来源：阿里云云栖大会

从技术分解看，AI 云的关键约束主要落在四个方向：

1) 计算：从“弹性算力”到“集群工程”

训练侧需要大规模 GPU/异构算力集群，关注的不只是峰值算力，更是集群稳定性、可用率、作业成功率与端到端效率，推理侧关注吞吐、延迟与成本，并要求更灵活的弹性扩缩容与更细粒度的资源切分。更棘手的是“训推一体”：同一套基础设施要在不同时间窗口服务训练与推理，调度系统必须更智能、更敏捷，才能把昂贵算力的空转压到最低。

2) 网络：从“云网络”到“训练网络”

大模型训练本质上是分布式系统工程，尤其在万卡甚至十万卡级别训练中，网络延迟与带宽直接决定训练效率。因此需要超高带宽、超低延迟的 RDMA 能力与更面向 AI 的网络架构（不仅是“能连”，而是“连得快、连得稳、跨域协同效率高”），训练网络与推理网络的诉求不同，AI 云必须能在同一底座上兼顾两者，并支持跨地域/跨可用区的协同与容灾。

3) 存储与数据：从“对象存储”到“向量化数据底座”

大模型时代的数据形态以非结构化为主：文本、图像、视频、音频、日志、点击流，训练与推理都依赖大规模数据读写与高吞吐，仅有对象存储远远不够，还需要更强的文件系统、高性能并行读写、冷热分层与更低延迟的访问路径，对推理尤其是 RAG 类应用而言，向量化检索成为关键能力：从“存得下”升级到“找得到、找得准、找得快”，并能实现全文检索+向量检索的混合检索与多模态数据检索。

4) 软件栈：从“虚拟化+容器”到“AI 工程化平台”

AI 负载需要新的开发框架、编译器、训练/推理加速、显存优化、模型压缩、服务化框架与全链路观测，更重要的是，企业落地不只要“能跑模型”，还要“能上生产”：安全、隔离、审计、数据治理、权限、成本可视化、回滚、灰度、A/B 等工程能力，都是“AI 真正可用”的前提。这要求云不仅提供底层资源，还要提供面向业务交付的工程平台与标准化组件。

图34: 阿里云卓越架构



资料来源: AI 云原生智能算力架构

图35: 阿里云 AI 搜索开发平台



资料来源: AI 云原生智能算力架构

因此,阿里云在 2025 年前后做的升级,不是单点产品的叠加,而是以 AI 负载为中心对 IaaS/PaaS 进行系统性改造:推出新一代高性能计算实例、大规模 RDMA 能力、面向 AI 优化的存储与向量检索能力,并把数据标注、清洗、特征与知识库构建等能力纳入更可复用的流水线,使企业能够以更短路径完成“数据→训练/对齐→部署→应用”的闭环。

软硬一体化: 阿里云把“AI 云的护城河”定义为系统工程能力

阿里云将其在 AI 基础设施领域的竞争力总结为“软硬一体化”。这并不是传统意义上的“自研硬件+自研软件”的口号,而是面向 AI 负载的系统工程:硬件要理解工作负载,软件要榨干硬件效率,平台要把复杂性封装给开发者与企业用户。

硬件层面: 从“集成 GPU”到“构建可控的 AI 基础设施体系”

阿里云采购并集成主流 GPU,但其目标不是成为简单的硬件搬运工,而是围绕集群、服务器形态、散热供电、网络互联、可靠性与运维体系构建完整能力。这种能力体现在对服务器与集群形态的持续优化(例如高密度服务器/超节点思路、液冷与供电工程等),让“算力规模化”从采购问题变成工程能力。同时,阿里体系还强调自研与可控:包括云基础设施处理器(如 CIPU)等关键部件与平头哥等体系内的芯片探索,以在特定场景补位并增强供应链韧性。

图36: 阿里云全栈 AI 技术体系



资料来源: 科技喵

软件层面: 把“训练/推理效率”当作一项长期核心技术资产

AI 云真正的成本壁垒来自效率:同样的算力,谁能训练更快、推理更省、稳定性更高,谁就能形成更强的性价比。这需要在分布式训练框架、推理加速、显存优化、模型压缩、调度策略、异构资源协同等方面持续积累。更关

键的是把这些能力沉淀成“可用产品”，而不是停留在工程团队手工优化。阿里云的目标是把复杂的 AI 工程能力产品化，让企业用户像使用云服务一样使用 AI 能力。

专有云与全球化：双 I 主线，把 AI 能力带到“关键行业与海外市场”

在政企与关键行业场景，专有云的重要性不容小觑。阿里提出“AI+International（双 I）”的组合：一方面以 AI 推动行业智能化升级，另一方面以全球化布局承接中国企业出海与本地化合规需求。更关键的是，阿里云并未把“公共云 vs 专有云”做成割裂的两套体系，而是强调“公共云技术优先”：飞天企业版与公共云飞天在技术上同根同源，组织上虽然分为公共云、政企、国际三大事业部，但产品形态并不割裂，这使得公共云在 AI 时代积累的能力可以更顺滑地向政企/专有云复制与下沉，避免专有云陷入“版本分叉、能力落后”的老问题。

在这一逻辑下，专有云不是公共云的替代，而是公共云技术能力的延伸形态：底座同源、技术优先级以公共云为基准，同时通过“一云多芯/一云多算”等能力适配异构硬件与行业合规要求。工程交付层面，飞天企业版也给出了清晰的“可交付、可运营”规模画像：全球服务 15+ 国家和地区、管理计算资源 2400 万 vCPU、支撑两座万卡级智算集群稳定运行。这些指标在 B 端的意义非常直接——既意味着“能交付大”，也意味着“能交付稳”，特别适配安全、稳定、合规要求更苛刻的政企与关键行业客户。面向海外市场，阿里云则在专有云/混合云路径上推进本地化交付：通过主权云合作、金融云实践复制、以及从传统虚拟化向 AI 原生云升级（V2C）等方式落地，并以合规认证、7×24 服务体系与本地化团队构建全球交付能力，使 AI 能力能够真正进入海外与强监管行业的生产系统。

图37：阿里云 AI+International 布局



资料来源：财中社

3.5. 平头哥：从“芯片公司”到“算力基础设施单元”的角色转变

平头哥已不再是传统意义上“为集团内部降本”的芯片部门，而是被明确纳入阿里“云+AI+芯片”三位一体的全栈体系之中，成为承载算力确定性与系统可控性的核心单元。阿里并未将平头哥简单视作一家对标英伟达或寒武纪的国产 GPU 公司，而是将其置于云计算、大模型与基础设施协同演进的长期战略框架下理解。平头哥通过自研芯片与系统级优化，为整个体系提供可预测、可规模化、可持续演进的算力底座。这种定位决定了平头哥从一开始就不是“做一颗好芯片”，而是围绕真实业务负载、真实集群规模和真实交付需求来反向定义芯片与系统架构，其本质更接近一家 AI 时代的基础设施型企业。

体系化研发路径决定了平头哥的差异化优势，真武 PPU 的意义在于“可交付算力”而非单卡对标

与大多数国产算力芯片公司以“实验室指标—市场推广”为主线的研发逻辑不同，平头哥的技术路径从源头上就深度嵌入阿里云的生产环境之中。平头哥的芯片研发并非先完成设计、流片后再寻找应用场景，而是从阿里云真实的智算需求出发，由模型训练与推理的计算图、算子结构和资源瓶颈反向推导系统架构与芯片微架构，再进一步匹配数据中心网络、存储与调度系统。这种“模型—系统—芯片”协同设计的方式，使得平头哥的产品在单点性能指标上或许并非全面领先，但在能效比、稳定性、可调度性以及总拥有成本等系统级指标上形成了明显优势。正因如此，平头哥能够较早实现万卡级集群的长期稳定运行，并在实际业务中不断通过迭代验证来修正技术路线，这种在真实生产环境中反复打磨的能力，构成了其最难被复制的核心护城河。

表 2：国产高端芯片对比

	平头哥（阿里）	摩尔线程	沐曦	寒武纪
成立时间	2018 年	2020 年	2020 年	2016 年
核心战略定位	以云为底座的“体系型选手”	最接近通用 GPU 正统路线	面向数据中心的务实工程派	先发者，处于转型阶段
代表性高端芯片	真武 810E（PPU）	华山芯片	曦云 C600	思元 370
主要应用场景	AI 推理、部分训练、自动驾驶	通用 GPU（训练/图形）	AI 训练与推理	AI 推理、边缘计算
商业化进展	累计出货数十万片	未披露	未披露	已商业化

资料来源：平头哥官网，摩尔线程官网，沐曦官网，寒武纪官网，国泰海通证券研究

真武 810E 的正式亮相，使外界第一次系统性地看清了平头哥在高端 AI 算力领域的真实进展。从公开参数与实际部署情况来看，真武 PPU 采用自研并行计算架构和片间互联技术，配备大容量高带宽显存，并已在阿里云内部与外部客户中实现数十万片规模的部署。真武 810E 在部分典型推理负载下的性能表现已接近英伟达 H20，在国产算力阵营中处于第一梯队，但其真正价值并不在于全面追赶 H100 或 H200，而在于为阿里云提供一类“性能可预期、供给可控、成本结构清晰”的推理算力资源。在当前全球算力供给高度不确定的环境下，这种能力比单纯的峰值性能更具现实意义。也正因此，阿里已明确在未来算力结构中，将平头哥真武系列芯片作为云端推理算力的重要支撑，并在部分训练场景中与第三方芯片形成互补，从而构建更加稳健的算力供给体系。

图 38：央视报道阿里自研 AI 芯片

国产卡与 NV 卡重要参数对比	
厂商	平头哥 / NV
型号	PPU / A800
显存类型	96G HBM2e / 80G HBM2e
片间带宽 (GB/s)	700 / 400
PCIe	5.0x16 / 4.0x16
功耗 (W)	400 / 550

表 3：平头哥与英伟达 AI 芯片核心参数对比

对比维度	平头哥 真武 810E (PPU)	NVIDIA H20	NVIDIA H200 / B200
芯片类型	PPU（并行处理单元，非通用 GPU）	GPU	GPU
架构定位	专为并行计算与大模型优化	通用 GPU 架构	通用 GPU 架构
显存容量	96GB HBM2e	96GB HBM3	141GB HBM3e / 192GB HBM3e
显存带宽	700GB/s	900GB/s (NVLink)	4.8TB/s (H200) / 8.0TB/s (B200)
片间互联	自研 ICN, 700GB/s	NVLink	NVLink 5
接口	PCIe 5.0	PCIe 5.0	PCIe 5.0
单卡功耗 (TDP)	≤ 400W	~550W	~700W / ~1000W

多产品线布局构成纵深而非单点突破，从阿里内部能力到行业级算力节点的演进

如果仅从真武 PPU 观察平头哥，容易忽视其更深层的战略纵深。事实上，平头哥已经形成覆盖“算力、存力、端侧与生态”的多层次产品矩阵。倚天 710 作为自研服务器 CPU，是阿里“一云多芯”战略的重要支点，通过在通用计算层面实现部分自主可控，为 AI 工作负载释放更高价值的加速资源；镇岳 510 SSD 主控芯片在云存储与高并发数据库场景中实现规模化商用，为数据密集型 AI 应用提供低时延、高可靠的存力支持；而玄铁 RISC-V 处理器体系，则通过开源与生态建设，在端侧和 IoT 领域持续扩大影响力，为阿里在更长周期内掌握指令集与生态主动权奠定基础。这种从数据中心到端侧的全栈布局，使平头哥不依赖单一产品成败，而是通过系统协同不断放大整体价值，进一步强化其作为基础设施型角色的战略属性。

平头哥正处在从“集团内部能力单元”向“具备独立市场价值的算力基础设施提供者”转变的关键阶段。其芯片产品已服务于国家电网、中科院、小鹏汽车、新浪微博等数百家客户，商业化不再停留在示范层面；同时，阿里明确支持其未来独立上市的信号，也意味着平头哥需要逐步证明自身在阿里体系之外的持续交付能力。

表 4：平头哥核心产品汇总

产品/系列	产品定位	关键规格/能力	典型场景/进展
真武 810E (PPU)	AI 训推一体加速芯片（高易用；自研并行计算架构 + ICN 互联 + 全栈软件栈）	96GB HBM2e; 互联带宽 700GB/s; PCIe 5.0 x16; 每颗 7 个 ICN 端口; 支持多卡组合	阿里云多个万卡集群部署; 用于 AI 训练/推理/自动驾驶/多模态; 服务 400+ 客户
		Arm v9; 128 核; 主频 2.75GHz; 8 通道 DDR5; 96 通道 PCIe 5.0; 最大功率 250W; CoWoS 2.5D	云端 AI 推理、电商、大数据分析、视频编解码等
倚天 710	高效能服务器 CPU	3400K IOPS; 14GB/s; 时延 4 μs; 误码率 10 ⁻¹⁸ ; PCIe 5.0/DDR5; 420K IOPS/W; 支持 32TB+; QLC/TLC/pSLC	在线交易、分布式存储、AI 推理/训练; 规模化部署; 出货超 50 万片
镇岳 510	高性能 SSD 主控芯片		
羽阵 611	超高频 RFID 电子标签芯片	单端口; 灵敏度 -24dBm; 全自动阻抗调谐	零售、物流、供应链、航空、资产管理等
羽阵 600	超高频 RFID 芯片（羽阵系列）	未披露关键参数	物流场景规模化应用
含光 800	AI 推理芯片（NPU）	12nm; 170 亿晶体管; 峰值 820 TOPS; ResNet-50 推理 78563 IPS; 能效比 500 IPS/W	数据中心、边缘服务器; 云端推理算力服务输出
玄铁（XuanTie）处理器 IP（系列）	RISC-V 处理器 IP（玄铁系列）	累计授权芯片出货超 30 亿颗	计算视觉、数据存储、工业互联、网络通信、智能家居、信息安全等
玄铁 C910（生态/开发）	RISC-V CPU（玄铁 C910 生态）	64 位; 三发射; 深度乱序; 12 级流水线; 向量/AI 加速能力	Linux SDK/生态支持持续维护

资料来源：平头哥官网，阿里云开发者，文鰩热设计，国泰海通证券研究

我们认为，平头哥的意义并不在于是否能在短期内全面替代英伟达，而在于其是否能在中国 AI 产业中率先跑通“系统级算力交付”的路径。在国产高端算力从“可用”走向“可持续”的过程中，这种以云为底座、以真实负载为牵引、以系统能力为核心的路线，或许比单点性能竞赛更具长期价值。平头哥的重要性在于：它让阿里在“云+大模型”的竞争中拥有可控、可规模化的自研算力底座，把外部不确定的芯片供给风险转化为内部可迭代的系统能力与成本优势。

3.6. 通义实验室：从模型调用走向 Agent 应用，强化开源生态


2025 年之后，阿里 AI 的产品形态发生了根本性变化：其重心已从提供基础模型的 API 调用，全面转向构建以智能体（Agent）为核心的应用开发、分发与运行平台，并辅以强大的开源生态加速市场渗透。通义实验室以“通义/千问”系列为核心，确立了“开源 + 全模态 + 全尺寸”的发展路线：一方面依托阿里云的 PAI、百炼及模型服务与企业数据空间等平台能力，将模型能力工程化并推向规模化落地；另一方面置身于“通云哥”的全栈体系之中，与云计算与芯片能力进行训练—推理协同与系统级联合优化，从而在效率、成本与迭代速度上持续取得优势。

产品形态进化：构建“模型-平台-应用”全栈链条

阿里的 AI 产品矩阵已形成清晰的三层结构:

- 底层：通义千问基础模型系列：包括从轻量到超大规模（如参数量超万亿的 Qwen3-Max-Preview）的完整模型家族，提供强大的认知与生成能力。
- 中间层：Agent 开发与调度平台：这是战略升级的关键。阿里提供了包括百炼（一站式大模型应用开发平台）、Model Context Pro2Col 生态等在内的工具与协议，帮助开发者将大模型能力转化为可执行复杂任务、调用外部工具、读写企业数据的智能体应用。
- 上层：原生 AI 应用与生态应用：既包括阿里自研的“万相”、“灵码”、“听悟”等垂直场景应用，也包含海量第三方开发者及企业利用阿里平台构建的行业智能体。

图39: 全球主要开源大模型衍生模型数



资料来源：北大纵横

图 40: 通义大模型家族



资料来源：阿里云开发者社区

阿里“通义/Owen”大模型的关键迭代

通义千问-Max

通义千问系列最新旗舰文本生成模型，对标 GPT-4 和 Claude Opus，拥有约 1 万亿参数与 36 万亿 Token 训练数据，支持 262,144 Token 超长上下文窗口。在数学、编程等任务中表现突出，针对检索增强生成（RAG）和工具调用优化，幻觉现象少，适合学术写作、法律文书、财务报告等高精度场景。

通义千问-Plus

基于密集模型与 MoE 混合架构(235B/470B 参数),支持 128K 上下文长度。通过稀疏 MoE 技术降低推理成本,适配复杂推理与快速响应需求,兼容图像、表格等结构化数据输入,适用于科研数据分析、企业智能客服和跨语言内容本地化。

通义千问-Flash

极致轻量化设计，支持 1M Token 上下文缓存，推理速度提升 3 倍，单次响应延迟低于 500ms。牺牲部分深层推理能力换取高速度与低成本，适用于实时聊天机器人、电商评论摘要、新闻标题生成等高并发场景。

通义千问 VL

具备视觉理解能力的文本生成模型，支持 OCR、内容总结与推理，可从商品图提取属性、根据习题图解题。支持超高分辨率和极端长宽比图像，在细粒度文字识别上表现出色，典型应用包括电子病历分析、工业质检报告生成及广告创意素材优化。

通义千问 Omni

全模态交互模型，支持文本、图片、音频、视频等多模态组合输入，可生成文本或语音回复，提供多种拟人音色及多语言、方言语音输出，适用于视觉识别、情绪感知、教育培训等音视频聊天场景。

通义千问 Coder


支持 Python、Java、JavaScript 等多语言，最新 Qwen3-Coder-Plus 系列具备强大 Coding Agent 能力，擅长工具调用与环境交互，可实现自主编程。适用于自动化测试脚本生成、低代码平台辅助开发及 AI 编程助手场景。

表 5：通义文本生成模型

商业版	开源版
通义千问 Max (qwen3-max、qwen-max)	Qwen3: qwen3-next-80b-a3b-thinking、qwen3-next-80b-a3b-instruct、qwen3-235b-a22b-thinking-2507、qwen3-235b-a22b-instruct-2507、qwen3-30b-a3b-thinking-2507、qwen3-30b-a3b-instruct-2507、qwen3-235b-a22b、qwen3-32b、qwen3-30b-a3b、qwen3-14b、qwen3-8b、qwen3-4b、qwen3-1.7b、qwen3-0.6b
通义千问-Plus (qwen-plus)	Qwen3: qwen3-next-80b-a3b-thinking、qwen3-next-80b-a3b-instruct、qwen3-235b-a22b-thinking-2507、qwen3-235b-a22b-instruct-2507、qwen3-30b-a3b-thinking-2507、qwen3-30b-a3b-instruct-2507、qwen3-235b-a22b、qwen3-32b、qwen3-30b-a3b、qwen3-14b、qwen3-8b、qwen3-4b、qwen3-1.7b、qwen3-0.6b
通义千问 Flash (qwen-flash)	Qwen2.5: qwen2.5-14b-instruct-1m、qwen2.5-7b-instruct-1m、qwen2.5-32b-instruct、qwen2.5-14b-instruct、qwen2.5-7b-instruct、qwen2.5-3b-instruct、qwen2.5-1.5b-instruct、qwen2.5-0.5b-instruct
通义千问 VL (qwen3-vl-plus)	Qwen-VL: qwen3-vl-30b-a3b-thinking、qwen3-vl-30b-a3b-instruct、qwen3-vl-8b-thinking、qwen3-vl-8b-instruct、qwen3-vl-235b-a22b-thinking、qwen3-vl-235b-a22b-instruct
通义千问 Omni (qwen-omni-turbo)	qwen2.5-omni-7b、qwen3-omni-30b-a3b-captioner
通义千问 Coder (qwen3-coder-plus、qwen3-coder-flash)	qwen3-coder-480b-a35b-instruct、qwen3-coder-30b-a3b-instruct、qwen2.5-coder-32b-instruct、qwen2.5-coder-14b-instruct、qwen2.5-coder-7b-instruct、qwen2.5-coder-3b-instruct、qwen2.5-coder-1.5b-instruct、qwen2.5-coder-0.5b-instruct

资料来源：阿里云官网，阿里云开发者社区，国泰海通证券研究

通义千问Qwen模型家族



通义千问-文生图

在复杂文本渲染上表现突出，擅长中英文融合生成。技术流程为“语义编码→图像潜在表示生成→图像输出”，Image Plus 是主力模型，支持多分辨率和艺术风格，可自动生成图像文字，适用于广告设计、海报创作。

通义千问-图像编辑

具备精准的中英双语文字编辑能力,可实现调色、物体增删、风格迁移等复杂操作。通过语义分割和 GAN 网络实现局部精细化处理,保持图像整体一致,适用于电商视觉优化、UI 原型设计、影视概念图制作。

通义万相-文生图

采用全新多模态架构，能解析复杂描述生成高保真图像，支持照片写实、动漫等多种风格和多语言输入。覆盖产品设计、游戏美术等场景，已在工业设计、建筑可视化等领域规模化应用。

通义万相-通用图像编辑

支持文本、单图或多图输入,可实现主体一致的图像编辑与多图融合。能将产品图无缝融入不同场景,或合成统一风格合影,适用于电商视觉优化、广告素材生成、影视概念设计。

通义万相-文生视频

通过统一多模态架构,纯文本输入即可生成带声画的 1080p 视频,支持生成对话、音效和背景音乐。用时间序列建模保证帧间连贯,适用于广告脚本可视化、短视频批量生产、虚拟旅游场景构建。

通义万相-图生视频

采用 3D 变分自编码器+扩散 Transformer 架构，视频重建速度提升 2.5 倍。可固定人物外观并生成连贯动作与环境音效，适用于游戏角色动画生成、工业设备故障模拟演示。

通义万相-视频编辑

支持文本、图像、视频输入,可执行剪辑、特效添加、场景替换等复杂操作。
支持多语言字幕嵌入、视觉风格迁移,适用于视频内容动态重构与精细化编

辑。

通义万相-数字人

基于单张人物图像和音频输入，生成动作自然的说话、唱歌视频。通过姿态迁移和唇形同步技术实现口型与语音匹配，支持表情控制与动作编排，已应用于虚拟偶像直播、在线教育、企业数字员工等场景。

Qwen-TTS

支持中文、英文及混合文本的流式音频输出，端到端延迟仅 97ms，支持 10 种语言和 17 种发音（含方言）。采用 Transformer 架构，语言切换流畅，适用于智能客服、有声读物、导航播报等实时场景。

通义千问 3-Live Translate-Flash-Realtime

多语言音视频实时翻译模型，可识别 18 种语言并翻译为 10 种语言音频。结合视觉内容提升翻译准确性，延迟低至 3 秒，能生成自然拟人语音并适配语气情感，适用于国际会议、跨境直播、多语种客服。

表 6：通义多模态与专用模型

模型类型	模型名称
图像生成模型	通义千问-文生图（qwen-image-plus、qwen-image）
图像生成模型	通义千问-图像编辑（qwen-image-edit）
图像生成模型	通义万相-文生图（wan2.5-t2i-preview、wan2.2-t2i-plus、wan2.2-t2i-flash）
图像生成模型	通义万相-通用图像编辑（wan2.5-i2i-preview、wanx2.1-imageedit）
视频生成模型	通义万相-文生视频（wan2.5-t2v-preview、wan2.2-t2v-plus）
视频生成模型	通义万相-图生视频（wan2.5-i2v-preview、wan2.2-i2v-plus）
视频生成模型	通义万相-视频编辑（wan2.1-vace-plus）
视频生成模型	通义万相-数字人（wan2.2-s2v-detect、wan2.2-s2v）
语音合成（文本转语音）	Qwen-TTS（qwen3-tts-flash、qwen-tts、qwen3-tts-flash-realtime）
语音识别（语音转文本）	通义千问 3-LiveTranslate-Flash-Realtime

资料来源：阿里云开发者社区，国泰海通证券研究

Agent 化：从“拥有模型”到“驾驭智能”

Agent 化代表了“应用生产方式”的变革。对企业而言，真正的挑战往往不是获取一个高性能模型，而是如何让这个模型可靠地理解业务指令、调用内部系统 API、处理结构化数据、执行多步骤流程并保证结果准确可控。

阿里正通过其平台层能力解决这一痛点。例如，其积极推动的 MCP 生态是“AI 时代的 USB-C 接口”。MCP 是一种允许 AI 模型安全、标准化地连接和使用外部工具、数据源和服务的协议。它的繁荣意味着开发者可以轻松地为千问模型“插上”成千上万种能力扩展，从查询实时股价到控制智能家居，极大地丰富了 AI 的应用边界和实用性，也提升了开发者对阿里平台的粘性。

开源生态：构建“外部供给侧”的飞轮

通义千问坚定不移的开源策略，是阿里 AI 布局中极具远见的一环。截至 2025 年底，通义开源模型家族的二次开发与微调衍生模型数量已突破 17 万个。开源带来了多重战略价值：

- 开发者心智占领：降低研究和应用门槛，吸引全球开发者基于通义模型

进行创新，使其成为事实上的技术标准之一。

- 场景快速渗透：开源模型容易被企业下载、私有化部署并进行行业定制，从而以“毛细血管”的方式渗入阿里云触角难以直接覆盖的长尾和垂直领域。
- 反馈驱动进化：海量的实际使用场景和数据反馈，反哺阿里官方模型的迭代优化，形成良性循环。
- 商业转化路径：“B端开源”模式，开发者和企业在使用开源模型解决初步需求后，当面临更大规模、更高要求的场景时，往往会自然转向阿里云提供的更高性能的闭源模型、更强大的算力集群、以及更完整的平台服务（PAI、百炼等），从而完成从开源到商业化的转化。

3.7. 2C入口：千问 App 打开生态级连接，蚂蚁阿福接力生活闭环

在 C 端战场，阿里正全力以赴将“千问 App”打造为新一代的超级入口，其核心打法是通过与生态内应用的“系统级对接”，实现从“智能问答”到“智能办事”的跨越。

图42: 千问 APP 发布会



资料来源：模力算

千问 App 的迅猛启动与增长雄心

千问 App 的定位被明确为“能聊天、会办事”的个人 AI 助手，并在产品形态上对标 ChatGPT 最新版本，其来源是通义 App+夸克 AI 对话助手的升级整合，同时接入通义实验室最新的 Qwen3-Max 模型作为底座能力。这也解释了千问在早期就强调“模型能力成熟度+Agent 生态成熟度”：团队认为一方面是模型整体性能达到可支撑消费级体验的水平，另一方面集团内外的生态与授权能力已到可以被模型普遍调用、解决更多问题的阶段。

自 2025 年 11 月 17 日全面公测以来，千问 App 以指数级增速刷新行业纪录，短短两个月内便实现月活跃用户（MAU）突破 1 亿大关，成为国内增长最快的 AI 应用之一，强势奠定阿里在 C 端 AI 入口争夺战中的核心地位。公测初期，其 MAU 仅用 23 天就突破 3000 万，30 天时跃升至约 4428.58 万，增长曲线持续攀升，印证了阿里系生态流量扶持与免费策略的强大赋能。

2026 年 1 月 15 日，千问 App 完成重大版本升级，全面打通淘宝、支付宝、高德、飞猪等阿里核心生态，上线超 400 项“一句话办事”功能，从对话型 AI 正式迈入办事型 AI 阶段。用户无需跨 App 跳转，即可完成购物下单、出行预订、政务办理等全链路服务，形成“感知-推理-执行”的生态闭环，

大幅提升用户粘性。

阿里已成立千问 C 端事业群，由集团副总裁吴嘉牵头统筹，进一步整合资源攻坚。其增长雄心明确，目标 2026 年一季度 MAU 突破 2 亿、年底日活达 5000 万，全力向数亿级国民应用迈进。依托阿里生态不可复制的协同优势，千问正重塑 AI 与生活服务的融合范式，开启行业“AI 办事时代”。

生态闭环：定义“能办事”的 AI

千问 App 的差异化竞争力，在于它能调用阿里生态内其他应用的“原子能力”：

- 生活消费闭环：用户对千问说“帮我找一家附近评分高的粤菜馆，并点几个招牌菜外卖到家”。千问可调用高德地图的 POI（兴趣点）和定位服务寻找餐厅，查看饿了么或淘宝闪购的菜单与配送信息，完成选菜、下单、支付（支付宝）的全流程。
- 商旅出行闭环：用户指令“下周一去上海出差，订上午的机票和公司附近五星级酒店”。千问可联动飞猪查询航班与酒店，结合企业差旅政策进行筛选，并一键完成预订。
- 工作学习闭环：在钉钉中，千问能根据会议对话自动生成纪要并提炼待办事项，能辅助编写周报、制作 PPT，甚至能在审批流程中自动核对发票信息并调用支付宝完成报销支付。

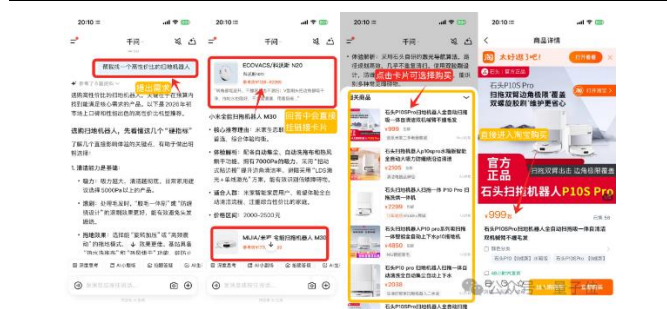
这些用例的关键在于跨业务单元（BU）、跨数据孤岛的深度打通。这要求底层账户、数据、权限和 API 接口的高度协同，而这正是拥有完整生态的阿里相对于初创 AI 公司或单一业务巨头的巨大壁垒。

图 43：千问 APP 点外卖



资料来源：量子位

图 44：千问 APP 购物



资料来源：量子位

“系统级对接”典范：千问×高德

2025 年 12 月，千问与高德地图宣布实现“系统级对接”。这远非简单的 API 调用，而是意味着千问深度接入了高德的海量地图数据、实时交通信息、地理位置服务引擎和出行规划能力。

这使得千问具备了强大的“时空理解与规划能力”。AI 不仅能理解“去机场”的指令，还能结合实时路况、用户当前位置、航班起飞时间，自动规划最优出行方式（驾车/地铁）与出发时间，甚至提前预订网约车。这种与环境实时交互、进行条件约束下规划的能力，是生活助理类 Agent 走向实用的关键一步。

图45: 千问 APP 调用高德



资料来源：电商派 Pro

迈向“任务助理”：从对话到自动化执行

千问 App 的“任务助理”在产品形态上不再只是对话界面里的“更聪明回答”，而是朝着“能规划、能拆解、能执行”的代理式能力迈进。任务助理 1.0 已在 2026 年 1 月 15 日随千问 App 的大版本升级正式推出，并以 App 与 Web 端的定向邀测方式开放，测试结束后将全面免费开放。

任务助理是千问“从聊天到办事”的关键模块，它强调把用户一句话背后的复杂需求，转成可落地的“多步骤任务链”，完成“规划—拆解—执行—交付”的闭环，而不仅停留在提供建议或生成文本。围绕这一思路，阿里在对外表述中把这次升级归入更典型的 Agentic AI 路线——通过把集团核心服务能力转化为 AI 可调用的“可执行能力”，让 AI 能直接完成端到端动作，例如点外卖、在对话内完成支付、规划并预订旅行、甚至代用户拨打电话沟通细节等。

- 对话式：用户与 AI 多轮交互，逐步明确需求并完成操作。例如：“我想订酒店。”“您想去哪里？”“上海。”“什么时间？”“明天晚上。”
- 任务式：用户用一句话表达复杂意图，AI 自动拆解为子任务、调用相应工具、并在关键节点寻求确认或自主决策，最后交付完整结果。例如：“帮我规划一个为期三天、预算 5000 元的杭州家庭游，包含机票酒店门票预订。”

千问 App 作为“入口与交互层”，任务助理则承担“执行与交付层”，它试图把跨应用、多环节的流程封装成用户可一句话触发的执行链路。后续评估其成熟度，重点不在于“能不能演示”，而在于三项更硬的指标：端到端闭环率（计划能否真正落到下单/支付/预订/沟通并完成）、跨服务编排的稳定性（多系统协作是否可靠）、以及邀测走向全量后的免费策略与功能边界如何落地。任务助理的成熟度，将直接决定千问能否真正成为用户信赖的“数字管家”，实现使用频次和粘性的质的飞跃。

图46: 千问 APP 任务助理




资料来源: 量子位

夸克: AI 搜索与 AI 浏览器的“超级框”路径, 承接存量用户的 AI 化

夸克在阿里 C 端 AI 版图中承担的是“AI 搜索与 AI 浏览器”的角色。千问团队的表述很直接: 千问这样的 chatbot 与夸克“超级框”并不矛盾, 类似“Gemini 不会让 Google Search 不重要”。也因此, 夸克更像是以搜索与浏览为底座, 把 AI 能力嵌入到信息获取、理解、整理与再分发的流程中, 核心目标是“重构信息获取方式”, 成为用户探索数字世界的入口。夸克实际 DAU 在 5000—6000 万区间。同时, 夸克在 2025 年围绕 AI 的产品动作频繁, 包括超级框、高考志愿大模型、AI 创作平台、AI 眼镜、AI 对话助手等。

2025 年上半年阿里确实希望通过夸克尝试 AI 时代入口, 因为夸克有既有用户与产品基础, 且用户群更年轻, 但随着 AI 能力提升, 团队判断“对话式 AI 助手是更好的形式”, 接下来会重点发展千问, 并“把它放进夸克”。这意味着夸克的中长期形态可能是: 以超级框承接搜索/浏览主入口, 同时内嵌千问式的对话与任务能力, 实现“查信息—做决定—去执行”的更短闭环。

图47: AI 应用榜单排名



资料来源: 新京报

蚂蚁: AI 时代再定位, 锚定支付、金融 与 医疗健康

在经历整改与低调期后, 蚂蚁集团在 2025—2026 年间逐步完成了一次战略自我校准。蚂蚁不能只停留在“支付和金融”的既有舒适区, 也无法简单复制通用大模型的技术竞赛路径。新任 CEO 韩歆毅在多次公开表达中坦言, 过去几年蚂蚁一度对“下一个十年的创新支点”感到焦虑——通用 AI 是否会吞噬入口、蚂蚁还能否再造一个“支付宝”, 都是悬而未决的问题。最终, 蚂蚁给出的答案并非转向宏大叙事或技术炫技, 而是回到自身长期积累最深、同时又具备长期确定性的领域, 重新锚定支付、金融与医疗健康这“三条腿”。这一选择既是对自身能力边界的清醒认知, 也是对 AI 时代竞

争本质的判断：当通用能力逐渐同质化，真正的护城河来自对垂直场景的理解力、长期投入的系统能力，以及用户信任的积累。


图48: 蚂蚁集团将“AQ”正式更名为“蚂蚁阿福”



资料来源：降噪

蚂蚁集团在 2025 年底将旗下 AI 健康应用 AQ 正式升级为“蚂蚁阿福”，这是蚂蚁在 AI2C 领域最重要的一次战略落子，也标志着其健康业务从长期铺垫走向台前。不同于早期偏工具属性的健康问答产品，阿福被重新定位为“AI 健康朋友”，核心目标并非一次性解答问题，而是围绕个体健康提供持续、可信的智能陪伴与管理服务。依托蚂蚁在支付、医疗数字化与 AI 模型上的积累，阿福目前已覆盖疾病初筛、用药建议、体检报告解读、健康管理及陪伴式服务等高频场景，并可进一步连接真实医生资源完成问诊、挂号与支付，形成从咨询到服务的完整链路。

图49: 蚂蚁阿福 AI 问诊



资料来源：老友智汇

在产品策略上，阿福明确避开了传统互联网医疗依赖广告和竞价排名的变现路径，而是将专业性与信任作为核心资产进行长期经营。这一选择也体现在其增长曲线上：升级上线后，阿福月活用户规模已突破 3000 万，成为国内增长最快的垂直 AI 应用之一，且用户中来自三线及以下城市的比例显著，反映出其在医疗资源相对稀缺地区所承接的真实需求。围绕阿福，蚂蚁同步完成了组织层面的战略确认，将健康业务升级为独立事业群，并在近两年持续投入数十亿元级资源，通过引入好大夫在线等能力补齐，推动业务从“连

接医疗资源”向“提供健康服务”转型。

在蚂蚁集团 CEO 韩歆毅的表述中，健康并非一次试水或短期风口，而是一条“必须要赢”的确定性赛道。与支付和金融相比，健康承载的是更长期、更高频、也更具社会价值的需求，其战略目标并非快速变现，而是成为继支付之后，支撑蚂蚁长期发展的第二个超级入口。阿福由此不只是一个 AI 应用，而被赋予了蚂蚁“下一个十年”的关键角色。

图50: 蚂蚁阿福就医服务



资料来源：老友智汇

蚂蚁集团推出的全模态通用 AI 助手“灵光”，核心卖点是“自然语言 30 秒生成可运行小应用”，并用下载数据来证明其爆发力——上线首日下载量突破 20 万、两天内达到 50 万。这种“从对话到可运行应用”的路径，本质是把 AI 从“问答机/内容生成器”拉向“低代码/无代码的创造工具”，用更强的可交付结果感来建立产品心智。在技术与生态叙事上，灵光背后有自研的百灵大模型，并整合多家第三方模型形成“1+N”模型体系，其目标不止是做一个聊天助手，而是借“小应用生成”去抢占类似“AI 应用商店/模板生态”的入口位置。灵光更倾向于图文结合、结构化呈现，像“PPT 方式”输出更便于直接使用，千问则更偏知识普及与逻辑分析。

灵光与千问在叙事上被放在“战友/兄弟关系”的框架下，后续更可能以协同方式“见面”，而不是单纯内耗。这意味着可以把灵光理解为阿里 C 端 AI 生态中更偏“生产力与创作工具”的一极：用应用生成能力与模板生态吸引更多需求的用户群（开发者/创作者/效率工具用户），与千问的通用助手、夸克的信息入口形成分工。

图51: 千问 VS 灵光



资料来源：新识研究所

蚂蚁 AI 战略的一条清晰主线：不是向上追逐抽象能力极限，而是向下扎根具体生活。无论是“阿福”在健康场景中的陪伴与决策支持，“灵光”让普通人用自然语言生成小应用，还是“碰一下”将支付进一步隐形化，这些产品看似分散，却围绕同一种价值取向展开——用 AI 降低专业服务门槛，回应普通人最关切的“有钱花”和“有命花”。在这一逻辑下，蚂蚁并未放弃对基础模型和前沿技术的探索，但它们更多承担的是“研发飞轮”的角色，而非战略重心。真正被放在核心位置的，是高度聚焦的应用落地与长期投入的耐心。蚂蚁试图用系统性建设和持续创新，重新定义自己在 AI 时代的位置，并为“下一个支付宝”预留足够长的生长时间。

3.8. B 端合作生态：行业大客户+开发生态共同提升平台粘性

阿里 2B 的 AI 路线已经从“卖模型/卖算力”的单点竞争，升级为一套更系统、更可复制的商业化工程：用行业标杆牵引打开关键行业深水区，用平台生态粘性抬高迁移成本与交付效率，并以“云钉一体”的企业入口把 AI 能力沉到组织关系与业务流程里，最终形成“基础设施—平台—应用/交付”的闭环。

商业化总逻辑：标杆牵引 × 生态粘性 × 入口闭环

在关键行业，阿里云强调的不再是“把 API 卖给客户就结束”，而是以“底座+平台”的全栈方式进入客户核心链路：飞天企业版在 AI 时代被描述为覆盖 IaaS/PaaS/MaaS 的全栈 AI 平台，并通过“一云多芯/一云多算”来消化异构硬件与算力复杂性、提升资源利用率。飞天企业版与阿里云全栈 AI 能力深度融合，同时百炼专属版可直接部署于专有云，让政企客户在安全环境中开发大模型。这类“深交付”模式的意义在于：一旦在某行业形成复用的工程范式（算力/网络/存储/安全/平台/运维），后续复制的边际成本会快速下降，标杆就能反哺更多行业扩张。

平台侧，阿里云把竞争维度从“模型能力/价格”拉到“开发效率与生态规模”。百炼平台上已有超过 20 万开发者，创建了 70 多万个 Agent。当开发者、组件、Agent、部署与运营工具都沉淀在同一平台上，客户的“上手速度”与“迁移成本”会被同时重塑——这就是生态粘性的核心来源。

而入口闭环，主要由钉钉承担。吴泳铭在电话会上把钉钉明确为“阿里面向企业端最重要的 AI 应用资产”，并将其重新定位为“自然语言交互的企业智能中枢”，钉钉承载的规模：7 亿用户、2600 万企业组织。这意味着阿里的 B 端 AI 不是先做一个“独立 AI App”再找场景，而是直接从企业日常高频入口切入，把 AI 渗透进组织运行的毛细血管。

B 端场景全景：阿里 2BAI 优先落点

强监管/高价值行业：政企、能源电力、央国企与关键行业

这类行业的共同特征是：合规要求高、系统复杂、容错率低，天然更适合“专有云/混合云+MaaS 平台+行业智能体”的深交付。用飞天企业版承载算力与云平台能力，再用百炼专属版把模型开发、调优与治理能力下沉到客户可控环境中。

企业通用场景：协同办公、流程审批、知识管理、会议生产力

钉钉的 AI 化，本质上是在企业最常用的工作流里，把“对话”改造成“办事”：

- 交互层：用钉钉 ONE 替代复杂菜单，一句话下达任务即可。
- 架构层：通过 AgentOS 把钉钉升级成“能指挥 AI 干活的操作系统/调度中枢”，自动调用审批、日程、文档等功能完成任务。
- 生态层：用 DEAP·企业 AI 平台提供从模型管理到应用落地的全链路

服务，把应用商店进化为“智能体人才市场”。

此外，钉钉也在把 AI 能力产品化为具体工具形态（听记、表格、搜问、硬件等），用来提高“可感知的 ROI”。AI 听记与阿里云团队联合训练后，普通话/方言识别准确率提升至 90%（特定场景 97%），并在 2000 多万企业组织中快速渗透。

表 7：阿里 B 端合作情况

场景/行业	代表客户/伙伴	主要落地形态	业务价值/指标	对应阿里产品栈
金融：银行/保险（整体渗透）	九成国家级及大型国有银行、全部 12 家股份制银行、前十财险公司	以通义为底座叠加百炼能力，推进行业智能体/应用落地 基于通义千问做深度训练与行业微调，打造	百炼调用量 12 个月增长 15 倍；20 万开发者、80 万 Agent	通义大模型 + 百炼（在线推理 /Batch）
金融支付/清算/反欺诈（垂直大模型共建）	中国银联 × 阿里云	金融支付垂域大模型，覆盖支付清算、风控反欺诈、客户运营等关键环节	标杆/范式输出（未披露量化 ROI）	通义千问（行业微调）+ 阿里云 AI 与云基础设施
金融：银行（审核/风控作业智能化）	中国工商银行（ICBC）	基于通义千问多模态做“商户智能审核助手”，替代传统 OCR 式流程	未披露	通义千问多模态能力（MaaS/行业应用）
金融：保险（产品要件编写/校验）	中华联合财险	用通义大模型做保险产品要件智能编写与校验	未披露	
政企/关键能体与通义千问）：煤矿/矿山行业大模型	中国煤	行业大模型接入通义千问，并共建煤炭行业 AI 基础平台	未披露	西门子 × 阿里云 trial Copilot: 自主完成订单调度、生产、仓储物流等任务 化指标（强调“可行动”智能体）ent 形态应用
汽车制造（全链路 AI 与企业专属大模型）		全栈 AI 战略合作：覆盖研发、生库问答、通义万相用于营销内容生成等	未披露	阿里云云基础设施 + 通义系列大模型（含万相等）
出行服务（客服/判责/导购交易机器人）	哈啰集团 × 阿里云百炼	基于百炼+通义模型组合构建交易机器人：意图识别、多轮对话、判责处置、智能问答；引入 RAG/COT/TOOL 构建 Agent 贯穿售前售中售后	客服运营成本降低 30%+；租车 GMV 提升 5%；判责准确率 87%+	百炼（MaaS/Agent）+ 通义千问模型族 + RAG/工具调用
人力资源：招聘全流程智能体	智联招聘	覆盖职位发布到面试的全流程 AI 智能体 计划于 2026 年在飞猪万豪旗舰店启用 AI 智能体应用，提供个性化行程建议并提升预订效率（试点/规划）	HR 发起沟通率、人岗匹配率均提升超过 70%	通义千问 +（企业侧 Agent 开发/平台能力）
酒店文旅（AI Agent 试点）	万豪国际 × 阿里巴巴	在 Qwen 模型家族与 Model Studio 上构建/微调/部署模型应用；探索营销内容与消费者洞察	未披露	飞猪旗舰店场景 + AI 智能体能力（技术底座未细化）
消费品/美妆（内容生成+洞察）	欧莱雅中国 × 阿里云		未披露	Qwen/通义模型家族 + Model Studio（百炼/开发平台）+ AI coding assistant

终端生态 (AI PC 助手)	HP × 阿里云	等方向; 并采用阿里云 AI coding assistant 提升研发效率 (AlibabaCloud) 推出 Qwen-powered smart assistant 以推动 AI PC 在中国增长 (生态合作) (AlibabaCloud) ONE (自然语言入口) + AgentOS (企业智能中	未披露	Qwen/通义模型能力 + 终端生态合作
协同办公入口: AI 钉钉 (平台级重构)	钉钉 (企业工作入口)	枢) + DEAP (企业 AI 平台) 贯通“模型管理→应用落地”, 从应用商店走向“智能体人才市场”本地化部署形态 (模型/数据/应用在企业内网) 满足金融政务等合规刚需 箱即用/合规) (服装品牌) 表、数据标注与任务分发, 解决数据分散与协同问题 AI 听记与阿里云团队联	强调证明 ROI、形成组织与流程粘性	钉钉 (ONE/AgentOS/DEAP) + 通义 (“脑力”) + 阿里云底座
协同办公: 安全合规/本地化运行环境	钉钉 (面向高安全行业)	合训练; AI 把能力封装为录音笔, 打通线上到线下会议室 员工自发搭建 800+ AI Agent 用于 IT 运维/安全巡检/生产数据查询; 三周完成 10 万员工账号迁徙	未披露	钉钉 AI 表格
协同办公: 会议记录/听记 (软硬结合)	钉钉 AI 听记 + DingTalk AI	升级为 IaaS/PaaS/MaaS 全栈 AI 平台; “一云多芯”兼容国产芯片, “一云多算”统一调度 CPU/GPU 主权云与当地运营商共建“专有公共云”; 金融云复制国内最佳实践; V2C 将 VM 升级到 AI 原生云	识别准确率: 普通话/方言 90%, 特定场景 97%	通义能力支撑 + 钉钉产品化/硬件化
协同办公: 大客户自建 Agent/组织迁徙	魏桥集团	按效果/吞吐/弹性/延迟/成本做组合优化; 提供在线推理与批处理等形态	体现企业内部智能体规模化生产与入口粘性	钉钉 (Agent 承载/组织体系)
专有云/政企 AI 底座 (合规交付)	飞天企业版 (专有云)	调用量 12 个月+15 倍; 20 万开发者/80 万 Agent	一云多算: 资源利用率提升 100%; 专有云半年多性能提升 9.2 倍	飞天企业版 + (百炼专属版可部署)
国际化: 专有云出海方案	主权云/金融云/V2C (举例含泰国、南非等)	开发者/ISV 生态: 平台化生产 Agent	150+全球安全合规认证; 7×24 多语言应急服务体系等	专有云 + 合规/服务体系 + (云维小智/飞天助理等)
开发者/ISV 生态: 平台化生产 Agent	百炼平台 (面向开发者与企业)	态	调用量 12 个月+15 倍; 20 万开发者/80 万 Agent	百炼 (MaaS/应用开发) + 通义模型族

资料来源: 阿里云开发者社区, 钉钉官网, 新浪财经, 搜狐等, 国泰海通证券研究

“云钉一体”的商业化抓手: 从卖 SaaS 到卖结果/卖产出

在 B 端的开发与交付供给侧, 钉钉与百炼共同指向 “Agent 规模化” 的核心

方向：企业不再只是调用模型能力，而是持续在平台上构建、上线并运营可复用的智能体资产。随着钉钉平台 AI 应用数量已达到 141 万，其价值逐步从“办公协同工具”跃迁为企业智能体的分发与运行环境——组织关系、工作流数据与应用供给三者叠加，形成更强的场景闭环与生态粘性。在商业化层面，“云钉一体”的抓手也随之升级：钉钉 AI 助理市场强调“结果交付”，只有当智能体在真实业务中产生可验证的价值且符合预期，企业才为其付费，体现出从“卖 SaaS 功能订阅”转向“卖效果、卖产出”的路径。其背后契合了 B 端采购的本质逻辑：企业真正买单的不是更会聊天的助手，而是确定性的降本增效、流程可靠性，以及与既有系统深度适配后带来的持续可运营能力。

图 52: AI 钉钉 1.1



资料来源：远川研究

图 53: 钉钉发布 AgentOS



资料来源：远川研究

我们认为，阿里 AI 的竞争重心正在从“模型能力本身”转向“把模型快速、稳定地交付为可执行任务”的平台化与生态化能力：一方面，阿里已完成从单一 API 调用到“模型—平台—应用”全栈链条的产品切换，以通义/Qwen 为底座，用百炼把智能体、工作流与 MCP 等工程化能力封装为开发与分发平台，降低企业级落地门槛。另一方面，开源策略带来供给侧扩张与飞轮效应：Qwen 在开源社区形成了“开发者扩散—生态反哺—商业转化”的闭环，使竞争从单点模型价格战，升级为围绕生态规模与工程效率的系统战——“开源占心智、闭源赚利润、平台锁生态”将成为其关键组合拳。

在应用侧，阿里正尝试把生态服务能力做成“可一句话调用的操作系统”，并在 GEO（生成式搜索/推荐）时代重构营销与流量分发逻辑：千问从问答入口向交易与服务入口演进，通过与淘宝、支付宝、高德、飞猪等生态的系统级打通，形成包含时空信息与交易履约的闭环，使 AI 不再只是“给建议”，而能在实时约束下完成规划与执行。若千问能持续把对话式交互沉淀为高频可交付的“一句话办事”能力，并叠加电商与本地生活的数据和履约体系，将有机会直接改变品牌内容占位、推荐分发与投放 ROI 的衡量范式。

与此同时，云侧竞争也被阿里定义为“为 AI 重做一遍云”的系统工程，而不仅是堆更多 GPU：通过飞天、HPN 8.0、PAI 等在网络互联、调度编排、数据体系与软硬协同上提升训练/推理的效率、稳定性与成本优势，并将这些能力产品化、标准化交付。最终，谁能把端到端训练效率、推理成本、稳定性与安全治理变成可复制的交付能力，谁就更可能在政企与头部行业客户中获得更强粘性与更高的长期现金流确定性。

4. 建议关注与风险提示

推荐标的：税友股份、卫宁健康、恒生电子、安恒信息、七牛智能、千方科技、光云科技、浪潮信息、中科曙光、捷顺科技、数据港。

相关标的：新开普、宏景科技、寒武纪、海光信息、润建股份。

表 8：阿里系持股情况梳理（截至 2026/2/8）

公司名称	阿里系持股主体	持股比例	持股说明
税友股份	上海云鑫创业投资有限公司（蚂蚁集团全资子公司）	3.36%	蚂蚁通过上海云鑫持股，聚焦税务信息化，合作开发税务 AI 助手，适配“灵光”政务场景
卫宁健康	上海云鑫创业投资有限公司（蚂蚁集团全资子公司）	4.23%	2018 年蚂蚁战略入股，聚焦“互联网+医疗健康”，联合开发医疗 AI 应用，对接阿里健康生态
恒生电子	蚂蚁集团（通过杭州恒生电子集团）	约 20.78%	阿里无直接持股，蚂蚁通过恒生集团间接控股，为金融 IT 核心伙伴，深度绑定支付宝等 C 端入口
安恒信息	杭州阿里创业投资有限公司	5.20%	阿里创投为 IPO 前股东，2025-2026 年多次减持，持股比例从约 8% 降至 5.2%，聚焦网络安全领域合作
七牛智能	淘宝中国	16.27%	阿里系为第二大股东，2017 年 E 轮融资进入，既是股东也是重要客户与供应商，协同阿里云布局音视频云服务
千方科技	杭州灝月企业管理有限公司（阿里旗下关联公司）	14.11%	阿里为重要股东，聚焦智慧交通、车路协同，阿里云在智能交通领域的关键合作伙伴，生态资源深度协同
新开普	上海云鑫创业投资有限公司（蚂蚁集团全资子公司）	3.90%	2019 年蚂蚁通过上海云鑫入股，为第二大股东，同时持有子公司完美数联 30% 股份，深耕校园信息化与移动支付场景

资料来源：ifind，搜狐，东方财富，国泰海通证券研究

表 9：与阿里生态合作公司梳理（截至 2026/2/8）

公司名称	核心业务合作内容
光云科技	核心电商 SaaS 入驻淘宝/天猫/1688 服务市场，接入阿里云算力与通义千问 AI，为平台商家提供工具服务
数据港	阿里云核心 IDC 服务商，定制化建设、运营阿里数据中心，承接 AI 智算中心、公有云机房基建与运维
宏景科技	智慧政务、园区、智慧城市项目集成阿里云 IaaS、IoT、AI 视觉能力，标准化采购云服务
捷顺科技	与蚂蚁集团合作停车无感支付、支付宝车主服务、智慧社区通行，接入阿里云 IoT 平台
寒武纪	阿里云采购思元系列 AI 加速卡，双方适配云端大模型推理、智算实例，为阿里公有云提供 AI 芯片
海光信息	阿里云大规模采购海光 CPU/DCU，用于信创云与服务器节点，深度适配阿里云虚拟化与云操作系统
浪潮信息	阿里云全球核心服务器供应商，提供 AI 服务器、液冷整机柜，联合设计智算集群、共建大模型基建
中科曙光	阿里云采购服务器、算力整机、存储设备，参与信创云、国家智算中心项目联合交付
润建股份	为阿里数据中心提供 IDC 机电工程、储能、新能源、算力基地运维外包服务

资料来源：光云科技官网，新浪，东方财富，头条，搜狐，国泰海通证券研究

表 10: 推荐标的的盈利预测估值表 (截至 2026/2/9)

公司	收盘价 (元)	总市值 (亿元)	EPS(元)			PE			评级
			2025E	2026E	2027E	2025E	2026E	2027E	
税友股份	68.73	279.28	0.47	0.84	1.27	145.17	81.89	54.26	增持
卫宁健康	11.20	248.14	0.07	0.16	0.22	166.51	68.86	50.86	增持
恒生电子	30.51	577.90	0.62	0.71	0.83	49.33	42.72	36.86	增持
安恒信息	56.04	57.20	0.33	1.07	1.74	172.17	52.49	32.23	增持
千方科技	12.48	197.21	0.19	0.30	0.42	64.03	40.94	29.87	增持
光云科技	25.60	109.01	0.04	0.16	0.18	681.32	170.33	141.57	增持
捷顺科技	10.61	68.27	0.28	0.38	0.52	37.96	27.90	20.55	增持
浪潮信息	60.49	888.28	1.89	2.49	3.18	32.03	24.26	19.00	增持
中科曙光	91.23	1,334.80	1.68	2.08	2.53	54.15	43.94	36.08	增持
七牛智能	0.52	9.26	-0.03	0.001	0.01	-	463.34	29.89	增持
数据港	39.55	284.12	0.23	0.28	0.34	170.85	138.92	114.55	增持

资料来源: ifind, 国泰海通证券研究

风险提示:

AI 技术发展不及预期, AI 商业落地不及预期, 市场竞争加剧的风险。

本公司是本报告所述海光信息(688041)的做市券商。本报告系本公司分析师根据海光信息(688041)公开信息所做的独立判断。

本公司具有中国证监会核准的证券投资咨询业务资格

分析师声明

作者具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解，本报告清晰准确地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，特此声明。

免责声明

本报告仅供国泰海通证券股份有限公司（以下简称“本公司”）的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告仅在相关法律许可的情况下发放，并仅为提供信息而发放，概不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后的表现依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。

本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权仅为本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用。如征得本公司同意进行引用、刊发的，需在允许的范围内使用，并注明出处为“国泰海通证券研究”，且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

评级说明

	评级	说明
投资建议的比较标准 投资评级分为股票评级和行业评级。 以报告发布后的 12 个月内的市场表现为比较标准，报告发布日后的 12 个月内的公司股价（或行业指数）的涨跌幅相对同期的沪深 300 指数涨跌幅为基准。	增持	相对沪深 300 指数涨幅 15%以上
	谨慎增持	相对沪深 300 指数涨幅介于 5%~15%之间
	中性	相对沪深 300 指数涨幅介于-5%~5%
	减持	相对沪深 300 指数下跌 5%以上
股票投资评级 行业投资评级	增持	明显强于沪深 300 指数
	中性	基本与沪深 300 指数持平
	减持	明显弱于沪深 300 指数

国泰海通证券研究所

地址 上海市黄浦区中山南路 888 号

邮编 200011

电话 (021) 38676666