

量化专题报告

“量价淘金”选股因子系列研究（九）

Memory Map 在因子生产加速上的应用

——以构建羊群效应因子簇为例

前言：本文为国盛金工《“量价淘金”选股因子系列研究》的第九篇报告，也是“因子生产加速”相关研究的首次尝试，从数据存储技术、体系化的因子构建框架这两个角度出发，探索如何系统性、快速、批量挖掘 Alpha 因子。

Memory Map 数据存储技术：相比于传统的 CSV、Parquet 等存储形式，Memory Map 减少了显式的文件 I/O 操作，将数据直接映射到内存中，可大幅提升访问速度。以读取宽表存储形式下、某一交易日所有股票的分钟收盘价数据为例，Memory Map 的读取耗时不到 800 μ s，读取速度约为 Parquet 的 260 倍、CSV 的 330 倍。

体系化的因子构建框架——羊群效应因子簇：我们将事件研究的想法，融入到选股因子的构建中。提炼因子构建流程中的 3 个关键因素，事件识别、因子定义、数据频率，分别展开详细讨论。在 Memory Map 数据存储技术的助力下，基于经济学逻辑，最终构建了约 50 万个羊群效应因子，并通过进一步筛选，保留其中效果最优且相关性较低的 50 个因子，称之为“羊群效应因子簇”。

羊群效应综合因子：在“羊群效应因子簇”中选取信息比率最高的 10 个因子、等权合成，得到羊群效应综合因子。回溯期 2016/01/01-2024/09/30 内，在全体 A 股中，该因子的月度 RankIC 均值为 0.116，年化 RankICIR 为 4.23；10 分组多空对冲的年化收益为 43.21%，信息比率为 3.79，月度胜率为 84.62%，最大回撤为 6.31%。在剔除了市场常用风格和行业的影响后，纯净因子仍然有效，年化 RankICIR 达到 3.67，全市场 10 分组多空对冲的信息比率为 3.81。

指数增强组合的表现：基于羊群效应综合因子，构建月频调仓的指数增强组合：（1）沪深 300 指数增强组合的超额年化收益为 9.06%，跟踪误差为 4.47%，信息比率为 2.03，月度胜率为 73.08%，最大回撤为 4.42%；（2）中证 500 指数增强组合的超额年化收益为 12.20%，跟踪误差为 5.44%，信息比率为 2.24，月度胜率为 72.12%，最大回撤为 4.36%；（3）中证 1000 指数增强组合的超额年化收益为 17.78%，跟踪误差为 6.57%，信息比率为 2.71，月度胜率为 82.69%，最大回撤为 6.24%。

风险提示：以上结论均基于历史数据和统计模型的测算，如果未来市场环境发生明显改变，不排除模型失效的可能性。

作者

分析师 沈芷琦

执业证书编号：S0680521120005

邮箱：shenzhiqi@gszq.com

分析师 刘富兵

执业证书编号：S0680518030007

邮箱：liufubing@gszq.com

研究助理 阮俊烨

执业证书编号：S0680124070019

邮箱：ruanjunye@gszq.com

相关研究

- 1、《“量价淘金”选股因子系列研究（一）：如何将隔夜涨跌变为有效的选股因子？——基于对知情交易者信息优势的刻画》2022-04-26
- 2、《“量价淘金”选股因子系列研究（二）：不同交易者结构下的动量与反转》2022-10-24
- 3、《“量价淘金”选股因子系列研究（三）：如何基于 RSI 技术指标构建有效的选股因子》2023-03-06
- 4、《“量价淘金”选股因子系列研究（四）：高/低位放量：从事件驱动到选股因子》2023-12-18
- 5、《“量价淘金”选股因子系列研究（五）：基于趋势资金日内交易行为的选股因子》2024-05-28
- 6、《“量价淘金”选股因子系列研究（六）：创新高股票中的 Alpha》2024-06-26
- 7、《“量价淘金”选股因子系列研究（七）：盲目追随趋势资金的极端交易行为分析——羊群效应的识别与因子构建》2024-08-06
- 8、《“量价淘金”选股因子系列研究（八）：逐笔买卖差异中的选股信息——条件成交不平衡因子》2024-10-09
- 9、《量化分析报告：择时雷达六面图：本期打分无变化》2024-11-16
- 10、《量化周报：市场短期有可能进入震荡整固期》2024-11-17

内容目录

一、前言 4

二、Memory Map 数据存储技术..... 5

2.1 概念简介 5

2.2 数据存储实例 5

2.3 数据读取与因子计算速度对比 7

三、羊群效应因子簇的构建 8

3.1 因子构建的体系化思路 8

3.2 事件识别：趋势资金是否行动 9

3.2.1 各种不同维度的成交量 9

3.2.2 价格涨跌幅 11

3.2.3 价格波动率 11

3.2.4 量价相关性 11

3.2.5 小结 12

3.3 因子定义：羊群效应如何衡量 13

3.3.1 各种不同维度的成交量 13

3.3.2 价格涨跌幅 14

3.3.3 价格波动率 14

3.3.4 量价相关性 14

3.3.5 小结 15

3.4 数据频率：不同数据集的构建 15

3.5 因子的生产、筛选与表现 16

3.5.1 因子的批量生产与筛选：羊群效应因子簇 16

3.5.2 羊群效应综合因子示例 17

3.5.3 指数增强组合的表现 19

四、国盛金工量价因子库简介 22

五、总结 23

图表目录

图表 1: 因子生产过程中的重要环节与因素 4

图表 2: 宽表存储示例：以某日个股分钟收盘价为例 5

图表 3: 窄表存储示例：以某日个股分钟行情数据为例 5

图表 4: Memory Map 数据存储结构：以某日个股分钟收盘价为例 6

图表 5: Memory Map 数据存储代码：以某日个股分钟收盘价为例 6

图表 6: Memory Map、Parquet 和 CSV 存储文件系统的数据读取速度对比 7

图表 7: 因子构建的体系化思路：以羊群效应因子为例 8

图表 8: wind 基于固定金额对大小单进行划分的标准 9

图表 9: 平安银行（000001.SZ）20240830 逐笔成交数据片段 10

图表 10: 基于各种不同维度的成交量对趋势资金进行识别 10

图表 11: 基于量价相关性的变化对趋势资金进行识别 12

图表 12: 基于各种不同维度的成交量构建羊群效应因子 14

图表 13: 基于量价相关性构建羊群效应因子 15

图表 14: 羊群效应因子簇回测绩效示例 16

图表 15: 羊群效应综合因子 10 分组及多空对冲净值 17

图表 16: 羊群效应综合因子分年度表现 18

图表 17: 羊群效应综合因子与 Barra 风格因子相关系数 18

图表 18: 纯净羊群效应综合因子 10 分组及多空对冲净值 19

图表 19: 纯净羊群效应综合因子分年度表现 19

图表 20: 沪深 300 指数增强组合净值 20

图表 21: 中证 500 指数增强组合净值 20


图表 22:	中证 1000 指数增强组合净值	21
图表 23:	国盛金工量价因子库示例	22

一、前言

传统量化策略在当前市场环境下正面临一系列挑战，其中最显著的问题是边际效益递减。随着市场的发展与竞争的加剧，信息快速传播且投资者行为趋同，基于公开信息的策略越来越难以获得显著的 Alpha，现有模型和因子的有效性在逐渐衰减；另一方面，靠人力挖掘 Alpha 新因子的难度也越来越大，提取增量信息的效率快速下降，需要持续投入大量资源对现有模型进行不断的升级和迭代，以维持未来获取超额收益的能力。

因此，如何系统性、快速、批量挖掘 Alpha 新因子，对传统模型进行迭代，就成为一项至关重要的技术。在此背景下，国盛金工推出“因子生产加速”相关研究，尝试在数据存储、因子计算、因子构建框架等各个层面做出努力，提升因子的生产效率。

图表1：因子生产过程中的重要环节与因素



资料来源：国盛证券研究所整理

本文为国盛金工《“量价淘金”选股因子系列研究》的第九篇报告，也是我们“因子生产加速”系列研究的首次尝试，先聚焦数据存储端，重点介绍 Memory Map 这一数据存储技术将如何提升整个因子生产过程的效率，并具体以羊群效应因子的构建为例，详细介绍如何相对体系化地批量构建因子，最终提出“因子簇”的概念，得到羊群效应话题相关的一簇有效因子。

二、Memory Map 数据存储技术

2.1 概念简介

Memory Map（内存映射）技术是一种将文件或设备的内容直接映射到进程虚拟地址空间中的方法。通过这种方式，进程可以像访问内存一样访问文件或设备，而不需要显式地进行读写操作。

Memory Map 相比于传统的 CSV、Parquet 等存储形式，减少了显式的文件 I/O 操作，由于数据直接映射到内存中，因此提高了访问速度。该格式适用于需要频繁访问大文件的场景，如读取所有 A 股的高频量价数据。

2.2 数据存储实例

股票行情数据的存储通常可分为宽表存储和窄表存储这两种形式，以分钟行情数据为例：

（1）宽表存储，即将每个特征设置为二维矩阵、并保存为单独的文件，比如对于 2024/09/30 这一交易日的分钟收盘价数据，存为一个数据大小为 $242 \times N$ （242 为每日分钟数据的总行数，N 为当日股票数量）的矩阵文件；

图表2: 宽表存储示例: 以某日个股分钟收盘价为例

	股票1	股票2	股票3	股票4	股票5	股票6		股票N
分钟1								
分钟2								
分钟3	每个格子里，存放的都是对应股票对应分钟的收盘价数据							
分钟4								
分钟5								
.....								
分钟242								

资料来源: Wind, 国盛证券研究所

（2）而对于窄表存储，我们会将当日的分钟开盘价、最高价、最低价、收盘价、成交量都存放在一个文件中作为列索引，行索引设置为股票代码和时间戳的双重索引，数据文件大小即为 $(242 \times N) \times 5$ 。

图表3: 窄表存储示例: 以某日个股分钟行情数据为例

		开盘价	最高价	最低价	收盘价	成交量
股票1	分钟1					
股票1	分钟2					
股票1						
股票1	分钟242					
股票2	分钟1	每个格子里，存放的都是对应股票对应分钟的 开盘价/最高价/最低价/收盘价/成交量数据				
股票2	分钟2					
股票2						
股票2	分钟242					
.....						
股票N	分钟1					
股票N	分钟2					
股票N						
股票N	分钟242					

资料来源: Wind, 国盛证券研究所

由于股票因子为截面数据，宽表更适合高效地进行向量化计算，因此我们选择宽表形式


存储高频量价数据，避免了窄表数据中需要通过 for 循环来遍历股票代码的操作。

接下来，我们具体展示一个利用 Memory Map 格式进行数据存储的案例。比如 2024/09/30 这一交易日分钟收盘价的宽表文件 20240930_close_1m.mmap，由行索引（分钟时间戳），列索引（股票代码）和数据值三部分构成。我们需要向系统申请一块连续的内存空间来存储这三部分数据，由于行索引和列索引为字符串格式，而数据值为浮点型，所以申请的内存空间数据格式也存在差异：

- （1）对于列索引（股票代码），我们认为每个股票代码的最长长度为 9 个字节（比如“000001.SZ”），因此需要 $9*N$ （ N 为股票数量）的空间来存储列索引；
- （2）对于行索引（分钟时间戳），我们认为最长长度为 17 个字节（比如“20240930 09:30:00”），因此需要 $17*242$ 的空间来存储行索引；
- （3）对于数据值，需要 $242*N$ 的字节空间来存储。

至目前为止，我们一共需要 $9*N+17*242+242*N$ 的空间来存储整个宽表文件。但在读取数据时，我们并不知道这块连续的空间中哪一部分是索引或者数据值，因此还需要在一开始留出额外的 4 个字节来存放基础信息：行索引个数、行索引最大长度、列索引个数、列索引最大长度。最终，我们总共需要 $4+9*N+17*242+242*N$ 的空间来存储宽表文件 20240930_close_1m.mmap，具体的存储结构如图表 4 所示。

图表4: Memory Map 数据存储结构：以某日个股分钟收盘价为例



资料来源：Wind，国盛证券研究所

图表 5 展示了具体的存储代码。对于 Data Frame 文件，我们首先计算出行和列索引的最大元素长度和元素数量（代码的第 4-7 行），然后定义内存空间的数据类型及写入的数据（代码的第 10、11 行），最后调用 Numpy 的 memmap 方法申请一块内存空间（代码的第 14 行）并写入数据（代码的第 15 行）。

图表5: Memory Map 数据存储代码：以某日个股分钟收盘价为例

```

1 # df.shape (242,5082) DataFrame格式
2 index = df.index.map(str)
3 columns = df.columns.astype(str)
4 idxlen = index.map(lambda x: len(x)).max() # 行索引最大长度
5 clmlen = columns.map(lambda x: len(x)).max() # 列索引最大长度
6 idxnum = len(index) # 行索引元素个数 (比如每日分钟数据行数242)
7 clmnum = len(columns) # 列索引元素个数 (即个股数量)
8 dtype = []
9 data = []
10 dtype += ['<i4i', '%dS%d'%(idxnum, idxlen), '%dS%d'%(clmnum, clmlen), '%dS'%(idxnum*clmnum, 'float64')] # 定义数据类型
11 data += [[idxnum, clmnum, idxlen, clmlen], index, columns] # 定义写入数据
12 data += [df.values.flatten()]
13 dtype = ','.join(dtype)
14 fb = np.memmap('close_20241031.mmap', dtype=dtype, mode='w+', shape=(1)) # 申请内存空间
15 fb[0] = tuple(data) # 数据写入

```

资料来源：Wind，国盛证券研究所

2.3 数据读取与因子计算速度对比

本节内容测试对比不同存储文件系统的性能差异以及因子的计算耗时。本文的测试系统环境为 Ubuntu 22.04 LTS，硬件配置为：CPU，AMD 7T83（64 核，主频 2.5GHz）；显卡，NVIDIA RTX4090；存储，三星 PM9A3 15.36T NVME 固态硬盘 raid0 阵列（软 raid）。

我们通过 Python 的 timeit 方法测试了 Memory Map、Parquet 和 CSV 存储文件系统的数据读取速度，读取的数据即为前文所述的宽表存储形式下、某一交易日所有股票的分钟收盘价数据。对比发现，Memory Map 的读取性能显著优于另外两种存储文件系统。如图表 6 所示，Memory Map 的读取耗时不到 800 μ s，而 Parquet、CSV 的读取耗时分别为大约 206ms、264ms，约为 Memory Map 的 260 倍、330 倍。

图表6: Memory Map、Parquet 和 CSV 存储文件系统的数据读取速度对比

```
# mmap
%timeit df = mpd.from_mmap('/ssd1/x_alpha_data/market/features/1m/close/20231229.mmap')
✓ 6.4s
792  $\mu$ s  $\pm$  1.83  $\mu$ s per loop (mean  $\pm$  std. dev. of 7 runs, 1,000 loops each)

# parquet
%timeit df = pd.read_parquet('/ssd1/test/20231229_close.parquet')
✓ 1.7s
206 ms  $\pm$  9.35 ms per loop (mean  $\pm$  std. dev. of 7 runs, 1 loop each)

# csv
%timeit df = pd.read_csv('/ssd1/test/20231229_close.csv')
✓ 2.1s
264 ms  $\pm$  1.96 ms per loop (mean  $\pm$  std. dev. of 7 runs, 1 loop each)
```

资料来源: Wind, 国盛证券研究所

在因子计算上，我们也通过一个具体的案例进行对比说明。测试案例为：在 CPU 多进程并行下，读取某只股票某日的一分钟收益率数据，计算分钟收益率的标准差，得到该股当日的高频波动率；计算全体 A 股 2021/01/01-2024/09/30 的上述日度指标。计算结果显示，若原始数据的存储格式为 CSV，该过程大约需要 36s；若为 Parquet，大约需要 22s；若为 Memory Map，只需 8s 左右。

三、羊群效应因子簇的构建

3.1 因子构建的体系化思路

我们将事件研究的想法，融入到选股因子的构建中。比如在《“量价淘金”选股因子系列研究（七）：盲目追随趋势资金的极端交易行为分析——羊群效应的识别与因子构建》这篇报告中，我们曾构建“羊群效应”概念相关的因子，目标是关注市场中的理性资金（即报告中定义的“趋势资金”）行动之后、其追随者（大概率是一些跟风的非理性投资者）的极端交易行为。


基于上述目标，结合事件研究的框架，我们可以从这个角度入手：首先识别市场中的趋势资金，将“趋势资金有所行动”定义为一个事件；随后，关注这个事件发生之后的量价数据，从中提取有效信息、构建因子，衡量羊群效应的强弱程度。那么在因子的构建过程中，主要涉及以下 3 个关键因素：

（1）事件识别：如何识别趋势资金的行动。此处提到的“趋势资金”只是一个笼统的称谓，是想寻找当下对股价可能产生重要影响的交易群体，或许是机构投资者、也或许是个人投资者，可以很直观、也可以非常模糊，我们并不在乎其是否能明确落实到某一类特定的投资者身上。趋势资金可以存在多种代理变量，比如根据价格走势、成交量变化、成交量内部结构的变化，都可以对趋势资金是否行动进行判断。

（2）因子定义：如何刻画羊群效应的强弱。这一因素中，我们主要考察趋势资金行动的时间点后，紧跟着的一些量价特征，比如价格、成交量、量价相关性、大小单资金流、主买单、主卖单等等，这些指标既可以是其本身的数值，也可以是与趋势资金对应时间点相比的变化，也可以是与趋势资金这个事件发生之前相比的变化。如此一来，我们又可以赋予羊群效应因子多种不同的定义。

（3）数据频率：在何种数据频率上识别事件、定义因子。可用的数据集包括日频数据、分钟数据、逐笔数据、用逐笔数据合成的其他不同频率的数据集等等，不同频率提取到的信息可能存在较大差异，我们可以在不同数据维度上识别趋势资金的行动、考察跟随者的交易行为。

图表7：因子构建的体系化思路：以羊群效应因子为例



资料来源：国盛证券研究所整理

后文将逐一对上述 3 个关键因素进行详细描述，展示完整的因子构建流程。

3.2 事件识别：趋势资金是否行动

关于“趋势资金是否行动”，我们通过“量价数据是否发生异常”来进行判断。其中，“量价数据”可以是各种不同维度的成交量、价格涨跌幅、价格波动率、量价相关性；“发生异常”可以是成交量、价格波动率极端放大，价格涨跌幅、量价相关性极端放大或缩小。

接下来，我们根据不同的“量价数据”，详细展示如何识别趋势资金的行动。


3.2.1 各种不同维度的成交量

此概念中涉及的关键因素，可用一句话进行概括，即“何人、何方向的量突然放大了”，涉及的关键因素有 4 个：何人、何方向、量、放大。

首先，关于“量”，我们考察 4 个指标：成交量、成交金额、成交笔数、单笔成交金额（即成交金额除以成交笔数）。

其次，关于“何人的量”，我们通过“大小单”进行细分，既可以是不区分大小单的整体的量，也可以是大单、中单、小单的量。关于大单、中单、小单的定义，可以直接采用 wind 数据库基于固定金额进行划分的方式（如下图表 8，其中超大单由于数据覆盖度较低，我们暂不考虑），也可以采用浮动金额进行划分，比如基于逐笔委托数据，对于每只股票，将当日的逐笔委托数据与过去 20 日的所有逐笔委托数据进行对比，处于过去 20 日数据 90%-99%分位数的定义为当日的大单，处于 70%-90%分位数的定义为中单，处于 70%分位数以下的定义为小单。

图表8: wind 基于固定金额对大小单进行划分的标准



资料来源: Wind, 国盛证券研究所

接着，关于“何方向的量”，我们通过逐笔成交数据中的“主买”、“主卖”信息进行区分。“主买”、“主卖”方向是逐笔成交数据中的一项重要细节，如图表 9 展示了平安银行（000001.SZ）在 2024 年 8 月 30 日的逐笔成交数据片段，其中有一列“方向”数据，列明了每一笔成交的买卖方向，标签为“B”代表这一笔成交为主动买入单，即对应着在这一笔成交中，买单是主动吃单方，卖单是挂单方、等待成交；标签为“S”则代表该笔成交为主动卖出单，即买单是挂单方、等待成交，而卖单是主动吃单方。这一“主买”或“主卖”的方向差异，在一定程度上反应了交易双方的激进程度以及对市场未来走势的预期差异。

在讨论“何方向的量”时，我们既可以计算不区分主买、主卖方向的整体量，也可以只计算主买或者主卖方向的量。


图表9: 平安银行 (000001.SZ) 20240830 逐笔成交数据片段

时间戳	成交价格	成交量	成交状态	方向	买单ID	卖单ID	成交ID
10:08:00:560	10.16	100	1	B	12145278	12143550	12145290
10:08:00:560	10.16	200	1	B	12145278	12143611	12145291
10:08:00:560	10.16	100	1	B	12145278	12143843	12145292
10:08:00:630	10.17	600	1	B	12145353	11513896	12145354
10:08:00:860	10.16	1700	1	S	12145278	12145819	12145820
10:08:02:050	10.16	200	1	S	12145278	12149488	12149489
10:08:02:050	10.16	100	1	S	12145278	12149504	12149505
10:08:02:050	10.16	400	1	S	12145278	12149506	12149507
10:08:02:050	10.16	200	1	S	12145278	12149508	12149509
10:08:02:090	10.16	300	1	S	12145549	12149510	12149511
10:08:03:130	10.15	1100	1	S	4581621	12153063	12153064
10:08:03:530	10.16	100	1	B	12154146	12149510	12154147
10:08:04:020	10.16	100	1	B	12155727	12149510	12155728
10:08:04:020	10.16	300	1	B	12155727	12149514	12155729
10:08:04:020	10.16	200	1	B	12155727	12149527	12155730
10:08:05:010	10.16	200	1	B	12158627	12149527	12158628

资料来源: Wind, 通联数据, 国盛证券研究所

最后, 关于“量的放大”, 也可以有不同的定义方式。以 1 分钟数据为例, 比如我们可以采取以下两种方式: (1) 日内固定对比, 每个交易日选取超过当日日内“均值+1.5 标准差”的分钟数据, 定义为放大; (2) 日间滚动对比, 以过去 5 个交易日的所有分钟数据为标准, 将当日超过过去 5 日 90% 分位数的分钟数据定义为放大。

图表10: 基于各种不同维度的成交量对趋势资金进行识别



资料来源: 国盛证券研究所整理

如图表 10 所示, 4 个因素中, “何人的量” 有 7 种不同定义, “何方向的量” 有 3 种区分方法, “量” 可以考察 4 个指标, “量的放大” 存在 2 种判断标准, 它们互相搭配, 一共可以产生 168 种识别趋势资金是否行动的方式。

另外, 关于上文中涉及的参数, 我们在此重点申明: 所有参数都不会进行遍历测试与样本内优化, 我们会先验地测试参数的敏感性, 若某一参数非常敏感、则舍弃对应的定义方式, 我们只在参数不敏感的前提下、选取一个较为合理的取值, 进入上述框架中。即

对于两种不同的定义方式，我们要求它们的区别必须来源于底层逻辑上稍有差异，而不是简单修改了同一逻辑下的参数取值。

3.2.2 价格涨跌幅

在“价格涨跌幅”维度下，我们主要考察收益率的极端变化情况，可以分为极端放大、极端缩小。

关于“极端”的定义，我们也可以采取日内固定对比、日间滚动对比两种方式，比如以 1 分钟数据为例：（1）日内固定对比，每个交易日选取大于当日日内“均值+1.5 标准差”的分钟收益率数据、定义为收益极端放大，选取小于当日日内“均值-1.5 标准差”的分钟收益率数据、定义为收益极端缩小；（2）日间滚动对比，以过去 5 个交易日的所有分钟收益率为标准，将当日大于过去 5 日 90%分位数的分钟数据定义为收益极端放大，将当日小于过去 5 日 10%分位数的分钟数据定义为收益极端缩小。

因此在“价格涨跌幅”维度下，我们一共可以得到 4 种不同的识别方式。

3.2.3 价格波动率

关于波动率，我们主要考察波动率极端放大的情况。

可以构造两个关于波动率的代理变量，以 1 分钟数据为例：（1）计算每分钟的振幅；（2）滚动计算过去 5 分钟收益率的标准差。

关于“极端放大”，类似于前文，我们也可以采取两种判断方法：（1）日内固定对比，每个交易日选取超过当日日内“均值+1.5 标准差”的数据，定义为波动增大；（2）日间滚动对比，以过去 5 个交易日的所有数据为标准，将当日超过过去 5 日 90%分位数的数据定义为波动增大。

如此一来，在“价格波动率”维度下，我们也可以得到 4 种不同的识别方式。

3.2.4 量价相关性

该维度考察量价相关性极端放大或极端缩小的情况，由于涉及到“量”与“价”的交互，识别方式种类繁多。

我们先讨论比较简单的“价格”数据，它既可以是原始的价格，也可以是价格的变化、即收益率。


再来关注“成交量”，这一部分与前文类似，可根据“何人、何方向的量”进行详细定义。

“量”可以采用成交量、成交金额、成交笔数、单笔成交金额这 4 个指标；“何人的量”，既可以是不区分大小单的整体量，也可以是基于固定金额或者浮动金额划分的大单、中单、小单的量；“何方向的量”，既可以计算不区分主买、主卖方向的整体量，也可以只计算主买或者主卖方向的量。

接下来，在计算“量”与“价”的相关性时，根据两个序列的时间戳是否错位，又可以分为量价对齐、量先价行（即将量序列往前移动一单位时间）、价先量行（即将价格序列往前移动一单位时间）这 3 种情况。

最后，在判断量价相关性极端放大或极端缩小时，也可以采取两种判断方法：（1）日内固定对比，每个交易日选取大于当日日内“均值+1.5 标准差”的数据、定义为极端放大，选取小于当日日内“均值-1.5 标准差”的数据、定义为极端缩小；（2）日间滚动对比，以过去 5 个交易日的所有数据为标准，将当日大于过去 5 日 90%分位数的数据定义为极端放大，将当日小于过去 5 日 10%分位数的数据定义为极端缩小。

图表11: 基于量价相关性的变化对趋势资金进行识别



资料来源: 国盛证券研究所整理

如图表 11 所示, 在“量价相关性”维度下, 我们一共可以得到超过 2000 种识别趋势资金是否行动的方式。同样地, 我们再次申明: 这些定义方式的差异来源, 是底层逻辑上的细微差异, 而不是简单地修改参数; 我们只在参数不敏感的先验前提下, 选取一个较为合理的取值, 进行事件的识别。

3.2.5 小结

至此, 关于“趋势资金是否行动”这一事件的识别, 已经讨论完毕。我们通过观测各种不同维度的成交量、价格涨跌幅、价格波动率、量价相关性是否发生异常, 得到了上千种不同的识别方式。

实际上, 我们能想到的方法还有更多, 比如在“量价相关性”维度, 还可以考虑成交量序列、价格序列的自相关性, 但由于算力有限、且考虑到最终因子的相关性可能较高, 本文不再做更多讨论。本节内容的主要目的, 在于展示上述体系化的思维与框架, 各位读者可根据实际情况, 在框架中修改、删减或增加具体的识别方式。

3.3 因子定义：羊群效应如何衡量

关于“羊群效应的强弱程度”，我们借助“趋势资金行动之后的量价特征”来进行衡量。与上节内容类似，用到的“量价数据”包括各种不同维度的成交量、价格涨跌幅、价格波动率、量价相关性；“量价特征”的构建，可以是上述量价数据本身的数值，也可以是与趋势资金对应时间点量价数据的相互关系，也可以是与趋势资金这个事件发生之前量价数据的相互关系。

后文根据不同的“量价数据”，详细展示如何定义羊群效应因子。

3.3.1 各种不同维度的成交量

关于量的数据，与前文完全一致，根据“何人、何方向的量”进行详细定义，共可得到 84 种代理变量：“量”可以采用成交量、成交金额、成交笔数、单笔成交金额；“何人的量”，既可以是不区分大小单的整体量，也可以是基于固定金额或者浮动金额划分的大单、中单、小单的量；“何方向的量”，既可以计算不区分主买、主卖方向的整体量，也可以只计算主买或者主卖方向的量。

接下来，关于如何构建具体的量价特征，我们以“在 1 分钟数据集上、衡量趋势资金行动之后未来 5 分钟的羊群效应”为例，提供几种思路。特别地，量的数据以最简单的“成交量”为例。

第一步，我们需要先定义每日的“极端跟随成交量”：比如每个交易日，对于判定为趋势资金行动的每一分钟，都取随后 5 分钟里成交量最大的这一分钟，将其视为跟随趋势资金的极端行为，记录这一分钟的成交量，得到本次的极端跟随成交量。


第二步，我们用极端跟随成交量的大小，作为羊群效应强弱的代理变量，构建因子。这一步可以涉及多种构建逻辑，比如：

- (1) 本身数值：每个交易日，求日内所有极端跟随成交量的平均值，得到当日因子值；
- (2) 与趋势资金的相关性：每个交易日，将趋势资金的成交量与对应的极端跟随成交量对齐，求这两个序列的相关系数，得到当日因子值；
- (3) 与趋势资金的相对比值：将每一次的极端跟随成交量，除以对应趋势资金的成交量，得到该次跟随行为的比值；每个交易日，对当日所有比值求均值，得到当日因子值；
- (4) 与趋势资金事件发生之前的相关性：每个交易日，将趋势资金前 5 分钟成交量之和与对应的极端跟随成交量对齐，求这两个序列的相关系数，得到当日因子值；
- (5) 与趋势资金事件发生之前的相对比值：将每一次的极端跟随成交量，除以对应趋势资金的前 5 分钟成交量之和，得到该次跟随行为的比值；每个交易日，对当日所有比值求均值，得到当日因子值。

当然，上述关于“极端跟随成交量”的定义方式、每日因子的计算方法，在细节上还存在许多拓展空间，我们不再详细展开，读者可根据类似思路进行拓展。

在上述案例中，关于量的数据、我们找到 84 种代理变量，关于因子的构建逻辑、我们提供了 5 种思路，因此共可得到 420 种不同的因子定义方式。

图表12: 基于各种不同维度的成交量构建羊群效应因子



资料来源: 国盛证券研究所整理

3.3.2 价格涨跌幅

该维度主要关注收益率的情况, 比如取趋势资金行动后 5 分钟里的最大分钟收益率, 定义为极端跟随收益率, 考察其本身数值、与趋势资金行动时点收益率的相关性或者相对比值、与趋势资金行动之前收益率的相关性或者相对比值, 共可得到 5 种不同的因子定义方式。

3.3.3 价格波动率

若我们用振幅或者收益率的标准差衡量波动率, 同样也考察其本身数值、与趋势资金的相关性或相对比值、与趋势资金之前的相关性或相对比值, 则可以得到 10 种不同的因子定义方式。


3.3.4 量价相关性

该维度下因子的定义方式种类较多。与前文类似, 因子定义方式的多样性来源于以下四个方面:

- (1) “价格”数据有 2 种情况, 既可以是原始的价格, 也可以是价格的变化、即收益率;
- (2) “成交量”数据, 仍然根据“何人、何方向的量”进行详细定义, 共有 84 种变量;
- (3) 计算“量”与“价”相关性, 根据两个序列是否错位, 可分为量价对齐、量先价行、价先量行这 3 种情况;
- (4) 最终构建因子时, 可考虑量价相关性指标的本身数值、与趋势资金对应指标的相关性或相对比值、与趋势资金行动之前对应指标的相关性或相对比值, 共有 5 种计算方法。

因此如图表 13 所示，在“量价相关性”维度下，我们一共可以得到超过 2500 种对羊群效应因子进行定义的方法。同样地，在同一种定义方式下，我们不做任何参数的遍历与优化，只选取一个较为合理的参数取值。

图表13: 基于量价相关性构建羊群效应因子



资料来源：国盛证券研究所整理

3.3.5 小结

至此，关于“羊群效应因子”的定义方法，已经讨论完毕。在“趋势资金有所行动”这一事件发生之后，我们通过计算成交量、价格涨跌幅、价格波动率、量价相关性这些量价数据的本身数值、与趋势资金对应时点量价数据的相互关系、与趋势资金这个事件发生之前量价数据的相互关系，得到了上千种不同的因子构造方式。

实际上，上述框架还存在很大的拓展空间，比如在“波动率”维度，除了价格的波动率，我们还可以考虑各种成交量指标的波动率，又可衍生出至少几百种不同的定义方式。本文不再做过多讨论，各位读者可自行在上述框架中修改、删减或增加具体的构建方法。

3.4 数据频率：不同数据集的构建

本小节内容较为简单，主要涉及我们究竟在何种数据频率上识别事件、定义因子。可用的数据集包括日频数据、分钟数据、逐笔数据、用逐笔数据合成的其他不同频率的数据集等等，各位读者可以根据实际需求，构建不同的数据集，然后在不同数据维度上识别趋势资金的行动、考察跟随者的交易行为。

本文构建的因子，以“1 分钟数据集（包括用逐笔数据合成的 1 分钟量价特征）”为主。

3.5 因子的生产、筛选与表现

3.5.1 因子的批量生产与筛选：羊群效应因子簇

考虑到算力与时间因素，我们对前文提到的事件识别方法、因子定义方法做了精简，各选取了几百种方法，目前一共构建了约 50 万个羊群效应因子。通过进一步分时段筛选，留下有效因子，得到“羊群效应因子簇”：

（1）在时间段 2016/01/01-2020/12/31 内，综合考虑因子的 IC、ICIR、10 分组多头超额收益、10 分组多头超额收益的信息比率以及因子互相之间的相关性，挑选效果最优且相关性较低的因子，大约有 200 个；

（2）对于挑选出的约 200 个因子，再考虑它们从 2021 年开始至今的 IC、ICIR、10 分组多头超额收益、10 分组多头超额收益的信息比率以及因子互相之间的相关性，进一步挑选其中效果最优且相关性较低的因子，最终剩下 50 个，称之为羊群效应概念所对应的因子簇。

回测结果显示，在 2016/01/01-2024/09/30 期间，全体 A 股中，50 个因子的年化 ICIR 绝对值都能达到 2 以上。图表 14 罗列了其中 20 个因子的回测绩效，为了方便展示，因子名称以序号的方式做了简化。特别地，这些因子都是未经行业、市值中性化操作的原始因子，大部分因子中性化后的效果可进一步提升。

图表14: 羊群效应因子簇回测绩效示例

因子名称	IC 信息				10 分组多空对冲绩效指标				
	月度 IC 均值	年化 ICIR	月度 RankIC 均值	年化 RankICIR	年化收益率	年化波动率	信息比率	月度胜率	最大回撤率
因子 1	-0.060	-2.63	-0.092	-3.44	29.13%	10.62%	2.74	79.81%	9.05%
因子 2	-0.058	-3.17	-0.084	-3.75	26.80%	8.64%	3.10	81.73%	6.80%
因子 3	-0.056	-2.77	-0.083	-3.53	27.21%	9.41%	2.89	82.69%	9.64%
因子 4	-0.053	-2.91	-0.080	-3.82	25.76%	8.85%	2.91	78.85%	5.45%
因子 5	-0.053	-2.54	-0.074	-3.30	25.89%	9.53%	2.72	77.88%	6.19%
因子 6	-0.052	-2.85	-0.076	-3.74	23.67%	8.31%	2.85	77.88%	5.51%
因子 7	-0.045	-2.52	-0.054	-2.89	21.10%	8.02%	2.63	76.92%	6.30%
因子 8	-0.039	-2.80	-0.059	-3.69	17.42%	6.25%	2.79	78.85%	3.35%
因子 9	-0.036	-2.51	-0.064	-3.70	20.90%	7.69%	2.72	80.77%	5.84%
因子 10	-0.035	-2.35	-0.045	-3.05	16.91%	6.35%	2.66	75.00%	3.33%
因子 11	-0.029	-2.41	-0.059	-3.52	15.52%	5.78%	2.68	78.85%	4.51%
因子 12	0.039	2.90	0.059	3.94	19.58%	6.15%	3.19	86.54%	3.21%
因子 13	0.039	2.76	0.056	3.67	18.86%	6.73%	2.80	83.65%	4.12%
因子 14	0.042	2.59	0.060	3.54	21.42%	7.99%	2.68	79.81%	7.10%
因子 15	0.051	2.62	0.065	3.21	23.68%	8.76%	2.70	75.00%	6.50%
因子 16	0.054	2.56	0.071	3.04	24.32%	9.28%	2.62	75.96%	4.89%
因子 17	0.054	2.65	0.072	3.29	25.38%	9.49%	2.67	83.65%	6.83%
因子 18	0.056	2.63	0.064	3.57	22.99%	8.60%	2.67	79.81%	4.90%
因子 19	0.068	3.03	0.087	3.50	31.64%	11.05%	2.86	82.69%	7.00%
因子 20	0.069	3.59	0.090	3.69	33.91%	10.26%	3.31	88.46%	8.97%

资料来源：Wind，通联数据，国盛证券研究所

以图表 14 中的最后一个因子为例，我们详细介绍该因子是如何构建的：

- (1) 根据逐笔成交数据，计算股票每分钟的主动买入成交单数，将“主买单数大于当日均值+1.5 倍标准差”的分钟，视为趋势资金有所行动的分钟；
- (2) 对于趋势资金的每一分钟，计算未来 5 分钟的“(主买成交单数-主卖成交单数)/(主买成交单数+主卖成交单数)”，得到此次跟随行为的强度；
- (3) 每个交易日，以对应的趋势资金主买单数为权重，对当日所有跟随行为强度求加权平均值，得到当日的跟随行为强弱程度；
- (4) 滚动回看过去 20 个交易日，求 20 日跟随行为强弱程度的算术平均值，即为羊群效应因子。


以上述因子为例，对比不同原始数据存储格式下的因子计算速度。回测期 2016/01/01-2024/09/30 内，在 CPU 单进程下，从读取个股分钟数据开始至计算得到所有 A 股的日度因子值，若原始数据的存储格式为 CSV，该过程大约需要 45min；若为 Parquet，大约需要 25min；若为 Memory Map，只需要 10min 左右（服务器配置为：CPU，AMD 7T83（64 核，主频 2.5GHz）；显卡，NVIDIA RTX4090；存储，三星 PM9A3 15.36T NVME 固态硬盘 raid0 阵列（软 raid））。可见 Memory Map 技术确实大幅提升了因子的计算速度。

3.5.2 羊群效应综合因子示例

以选取图表 14 中信息比率最高的 10 个因子等权合成为例，展示羊群效应综合因子的表现。回测时间段 2016/01/01-2024/09/30 内，以全体 A 股为研究样本，羊群效应综合因子的月度 IC 均值为 0.088，年化 ICIR 为 3.45，月度 RankIC 均值为 0.116，年化 RankICIR 为 4.23；10 分组多空对冲的年化收益为 43.21%，年化波动为 11.41%，信息比率为 3.79，月度胜率为 84.62%，最大回撤为 6.31%。

图表 15 展示了羊群效应综合因子的 10 分组及多空对冲净值走势，图表 16 则汇报了其各年度表现情况。

图表15: 羊群效应综合因子 10 分组及多空对冲净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表16: 羊群效应综合因子分年度表现

年份	年化收益率			分组 10 对冲分组 1 绩效指标			
	分组 1	分组 10	分组 10 对冲分组 1	年化波动率	信息比率	月度胜率	最大回撤率
2016	-1.03%	56.11%	56.26%	9.84%	5.72	90.91%	0.64%
2017	-38.64%	-11.80%	40.87%	6.95%	5.88	91.67%	0.14%
2018	-48.12%	-23.58%	43.88%	6.47%	6.79	91.67%	0.16%
2019	-4.71%	35.20%	36.31%	14.29%	2.54	66.67%	5.98%
2020	-2.25%	40.15%	42.34%	13.61%	3.11	83.33%	4.86%
2021	-8.76%	34.33%	44.14%	12.52%	3.53	83.33%	5.78%
2022	-36.28%	5.99%	60.98%	8.76%	6.96	100.00%	0.00%
2023	-15.73%	21.42%	43.07%	8.33%	5.17	91.67%	0.31%
2024 (截至 9 月)	-27.24%	-8.87%	19.61%	15.60%	1.26	55.56%	6.31%

资料来源: Wind, 通联数据, 国盛证券研究所

得到了选股效果不错的综合因子后, 我们考察其与市场常用风格因子的相关性。图表 17 展示了羊群效应综合因子与 10 个 Barra 风格因子的相关系数, 可以看到, 综合因子与波动率、流动性因子的相关性相对较高, 相关系数绝对值在 0.40 左右, 与其他因子的相关性较低。

图表17: 羊群效应综合因子与 Barra 风格因子相关系数


羊群效应综合因子		羊群效应综合因子	
Beta	-0.056	NonLinearSize	0.005
BooktoPrice	0.197	Size	0.000
EarningsYield	0.100	Momentum	-0.039
Growth	0.060	Liquidity	-0.372
Leverage	0.029	ResidualVolatility	-0.395

资料来源: Wind, 通联数据, 国盛证券研究所

为了剔除市场常用风格和行业的干扰, 我们每月月底将羊群效应综合因子对 Barra 风格因子和中信一级行业虚拟变量进行回归, 取残差作为纯净因子, 检验其选股效果。图表 18 展示了纯净因子在全体 A 股中的 10 分组及多空对冲净值走势, 图表 19 则汇报了其分年度的表现情况。

剔除常用风格与行业的影响后, 因子仍然有效。纯净羊群效应综合因子的月度 IC 均值为 0.051, 年化 ICIR 为 3.74, 月度 RankIC 均值为 0.054, 年化 RankICIR 为 3.67; 10 分组多空对冲的年化收益为 24.76%, 年化波动为 6.50%, 信息比率为 3.81, 月度胜率为 83.65%, 最大回撤为 2.07%。

图表18: 纯净羊群效应综合因子 10 分组及多空对冲净值



资料来源: Wind, 通联数据, 国盛证券研究所

图表19: 纯净羊群效应综合因子分年度表现

年份	年化收益率			分组 10 对冲分组 1 绩效指标			
	分组 1	分组 10	分组 10 对冲分组 1	年化波动率	信息比率	月度胜率	最大回撤率
2016	13.45%	44.26%	28.03%	6.80%	4.12	72.73%	0.19%
2017	-28.88%	-13.37%	21.30%	7.40%	2.88	83.33%	1.86%
2018	-42.66%	-24.21%	30.33%	5.42%	5.59	83.33%	0.87%
2019	8.22%	37.99%	27.50%	4.90%	5.61	100.00%	0.00%
2020	6.56%	32.16%	24.83%	9.09%	2.73	75.00%	1.72%
2021	3.02%	37.44%	32.93%	8.41%	3.91	83.33%	2.03%
2022	-24.14%	-7.92%	20.57%	4.54%	4.53	75.00%	0.48%
2023	-5.64%	14.95%	21.73%	4.90%	4.44	83.33%	0.95%
2024 (截至 9 月)	-21.47%	-9.43%	15.83%	3.70%	4.28	88.89%	0.59%

资料来源: Wind, 通联数据, 国盛证券研究所


3.5.3 指数增强组合的表现

本小节内容基于羊群效应综合因子, 以最大化预期收益为优化目标, 构建沪深 300、中证 500、中证 1000 指数增强组合, 组合的调仓频率为月度。

沪深 300 指数增强组合的约束条件为: (1) 指数成分股权重不低于 85%; (2) 中信一级行业权重偏离不超过 2%; (3) 个股权重偏离不超过 0.3%。

2016/01/01-2024/09/30, 沪深 300 指数增强组合的年化收益为 12.74%, 相对沪深 300 指数的超额年化收益为 9.06%, 跟踪误差为 4.47%, 信息比率为 2.03, 月度胜率为 73.08%, 最大回撤为 4.42%。

图表20: 沪深 300 指数增强组合净值




资料来源: Wind, 通联数据, 国盛证券研究所

中证 500 指数增强组合的约束条件为: (1) 指数成分股权重不低于 85%; (2) 中信一级行业权重偏离不超过 1%; (3) 个股权重偏离不超过 0.5%。

2016/01/01-2024/09/30, 中证 500 指数增强组合的年化收益为 12.61%, 相对中证 500 指数的超额年化收益为 12.20%, 跟踪误差为 5.44%, 信息比率为 2.24, 月度胜率为 72.12%, 最大回撤为 4.36%。

图表21: 中证 500 指数增强组合净值




资料来源: Wind, 通联数据, 国盛证券研究所

中证 1000 指数增强组合的约束条件为: (1) 指数成分股权重不低于 85%; (2) 中信一级行业权重偏离不超过 1%; (3) 个股权重偏离不超过 0.5%。

2016/01/01-2024/09/30, 中证 1000 指数增强组合的年化收益为 14.82%, 相对中证 1000 指数的超额年化收益为 17.78%, 跟踪误差为 6.57%, 信息比率为 2.71, 月度胜率为 82.69%, 最大回撤为 6.24%。

图表22: 中证 1000 指数增强组合净值



资料来源: Wind, 通联数据, 国盛证券研究所

四、国盛金工量价因子库简介

我们将构建的量价因子入库、定期维护。数据库中目前的量价因子，都是基于一定的经济学逻辑进行构建的，根据因子所属大类，分为动量/反转、波动率、流动性、量价相关性、技术分析指标等类别，每个因子都有对应的历史外发报告。本文构建的羊群效应因子簇，已在因子库中定期更新，本系列研究后续报告中的因子，也将陆续纳入因子库中，敬请读者关注。

图表23: 国盛金工量价因子库示例

symbol # text	date # text	高低位放量因子值 # float8	RSI因子值 # float8	MIF因子值 # float8	重组涨跌幅因子值 # float8
000001.SZ	20240918	0.3474977003780657	-1.1957326177496128	0.2298992253556377	0.0011058783295183
000002.SZ	20240918	0.9310370957229276	1.9534330335455508	0.7590843794050569	-0.0021010463057952
000004.SZ	20240918	1.0732280242374848	0.1741173192472445	0.4339250419041851	0.0604317126379871
000006.SZ	20240918	1.6347185614365074	0.8253468749261188	0.5336730865179611	0.0410011121782405
000007.SZ	20240918	(Null)	0.5280563534828389	0.36264725351005	0.0102116060302665
000008.SZ	20240918	-0.2819793702313336	-1.27578919120527	0.3908173883945225	-0.0134323909804432
000009.SZ	20240918	0.575938031619775	0.0323641703839925	-0.1885224502760658	-0.005251240295299
000010.SZ	20240918	-0.4925481641070248	-1.6085883600899749	0.0566640728807671	0.0090864864358415
000011.SZ	20240918	0.5024849433238495	1.9344055849698591	0.3300014876816119	0.0101883752886224
000012.SZ	20240918	-0.1833416605991665	-0.5119121288740587	-0.2867483221312011	0.0001080244450484
000014.SZ	20240918	2.566095992597219	3.171478712770288	0.1163839156126371	0.0207531006630271
000016.SZ	20240918	3.422866540700886	1.629876317667133	0.6192400834962782	0.0264904821314503
000017.SZ	20240918	0.0417962309281161	0.7385245197370978	-0.0503052300791644	0.0287634216270077
000019.SZ	20240918	0.2557423910739086	0.0708062646937222	-0.4105511592320245	0.0036237431341714
000020.SZ	20240918	2.375346353171181	3.913756987256512	0.1182040311415072	0.0906713684850118
000021.SZ	20240918	1.4585702276806904	0.6155610477345164	0.3877788398565488	0.0109217964116936
000025.SZ	20240918	-1.0167769737487056	2.157699321292135	0.1060392678513669	-0.0084292239367209

资料来源: Wind, 通联数据, 国盛证券研究所

五、总结

本文为国盛金工《“量价淘金”选股因子系列研究》的第九篇报告，也是我们“因子生产加速”相关研究的首次尝试，聚焦数据存储技术、体系化的因子构建框架，详细讨论如何系统性、快速、批量挖掘 Alpha 因子。

在数据存储端，本文重点介绍了 Memory Map 这一数据存储技术，其相比于传统的 CSV、Parquet 等存储形式，减少了显式的文件 I/O 操作，将数据直接映射到内存中，可大幅提升访问速度。在展示了具体的 Memory Map 数据存储案例、以及对应的存储代码后，我们也测试对比了不同存储文件系统的数据读取速度。以读取宽表存储形式下、某一交易日所有股票的分钟收盘价数据为例，Memory Map 的读取速度约为 Parquet 的 260 倍、CSV 的 330 倍。

在因子构建框架层面，我们将事件研究的想法，融入到选股因子的构建中，并以羊群效应因子为例，展示了一套相对体系化的因子构建思路。具体地，我们提炼因子构建流程中的 3 个关键因素，分别展开了详细讨论：

（1）事件识别：如何识别趋势资金的行动。我们通过观测成交量、价格涨跌幅、价格波动率、量价相关性是否发生异常，得到了上千种不同的识别方式。

（2）因子定义：如何刻画羊群效应的强弱。在“趋势资金有所行动”这一事件发生之后，我们通过计算成交量、价格涨跌幅、价格波动率、量价相关性这些量价数据的本身数值、与趋势资金对应时点量价数据的相互关系、与趋势资金事件发生之前量价数据的相互关系，得到了上千种不同的因子构造方式。

（3）数据频率：在何种数据频率上识别事件、定义因子。可用的数据集包括日频数据、分钟数据、逐笔数据、用逐笔数据合成的其他不同频率的数据集等等，我们可以在不同数据维度上识别趋势资金的行动、考察跟随者的交易行为。

考虑到实际因素，我们对事件识别、因子定义方法做了精简，在 Memory Map 数据存储技术的助力下，利用 1 分钟数据集构建了约 50 万个羊群效应因子，并通过进一步筛选，保留其中效果最优且相关性较低的 50 个因子，称之为“羊群效应因子簇”。回测结果显示，50 个羊群效应因子的年化 ICIR 绝对值都能达到 2 以上。

为了展示综合因子的表现，我们在“羊群效应因子簇”中选取信息比率最高的 10 个因子、等权合成，得到羊群效应综合因子。回测期 2016/01/01-2024/09/30 内，在全体 A 股中，羊群效应综合因子的月度 IC 均值为 0.088，年化 ICIR 为 3.45，月度 RankIC 均值为 0.116，年化 RankICIR 为 4.23；10 分组多空对冲的年化收益为 43.21%，年化波动为 11.41%，信息比率为 3.79，月度胜率为 84.62%，最大回撤为 6.31%。在剔除了市场常用风格和行业的影响后，纯净因子仍然有效，年化 ICIR 达到 3.74，全市场 10 分组多空对冲的信息比率为 3.81。

更进一步，我们基于羊群效应综合因子，构建月频调仓的指数增强组合：

（1）沪深 300 指数增强组合的超额年化收益为 9.06%，跟踪误差为 4.47%，信息比率为 2.03，月度胜率为 73.08%，最大回撤为 4.42%；

（2）中证 500 指数增强组合的超额年化收益为 12.20%，跟踪误差为 5.44%，信息比率为 2.24，月度胜率为 72.12%，最大回撤为 4.36%；

(3) 中证 1000 指数增强组合的超额年化收益为 17.78%，跟踪误差为 6.57%，信息比率为 2.71，月度胜率为 82.69%，最大回撤为 6.24%。

风险提示

以上结论均基于历史数据和统计模型的测算，如果未来市场环境发生明显改变，不排除模型失效的可能性。

免责声明

国盛证券有限责任公司（以下简称“本公司”）具有中国证监会许可的证券投资咨询业务资格。本报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为客户。在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。

本报告的信息均来源于本公司认为可信的公开资料，但本公司及其研究人员对该等信息的准确性及完整性不作任何保证。本报告中的资料、意见及预测仅反映本公司于发布本报告当日的判断，可能会随时调整。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息及资料保持在最新状态，对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

本公司力求报告内容客观、公正，但本报告所载的资料、工具、意见、信息及推测只提供给客户作参考之用，不构成任何投资、法律、会计或税务的最终操作建议，本公司不就报告中的内容对最终操作建议做出任何担保。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。投资者应当充分考虑自身特定状况，并完整理解和使用本报告内容，不应视本报告为做出投资决策的唯一因素。

投资者应注意，在法律许可的情况下，本公司及其本公司的关联机构可能会持有本报告中涉及的公司所发行的证券并进行交易，也可能为这些公司正在提供或争取提供投资银行、财务顾问和金融产品等各种金融服务。

本报告版权归“国盛证券有限责任公司”所有。未经事先本公司书面授权，任何机构或个人不得对本报告进行任何形式的发布、复制。任何机构或个人如引用、刊发本报告，需注明出处为“国盛证券研究所”，且不得对本报告进行有悖原意的删节或修改。

分析师声明

本报告署名分析师在此声明：我们具有中国证券业协会授予的证券投资咨询执业资格或相当的专业胜任能力，本报告所表述的任何观点均精准地反映了我们对标的证券和发行人的个人看法，结论不受任何第三方的授意或影响。我们所得报酬的任何部分无论是在过去、现在及将来均不会与本报告中的具体投资建议或观点有直接或间接联系。

投资评级说明

投资建议的评级标准		评级	说明
评级标准为报告发布日后的 6 个月内公司股价（或行业指数）相对同期基准指数的相对市场表现。其中 A 股市场以沪深 300 指数为基准；新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为基准；香港市场以摩根士丹利中国指数为基准，美股市场以标普 500 指数或纳斯达克综合指数为基准。	股票评级	买入	相对同期基准指数涨幅在 15%以上
		增持	相对同期基准指数涨幅在 5%~15%之间
		持有	相对同期基准指数涨幅在 -5%~+5%之间
		减持	相对同期基准指数跌幅在 5%以上
	行业评级	增持	相对同期基准指数涨幅在 10%以上
		中性	相对同期基准指数涨幅在 -10%~+10%之间
		减持	相对同期基准指数跌幅在 10%以上

国盛证券研究所

北京 地址：北京市东城区永定门西滨河路 8 号院 7 楼中海地产广场东塔 7 层 邮编：100077 邮箱：gsresearch@gszq.com	上海 地址：上海市浦东新区南洋泾路 555 号陆家嘴金融街区 22 栋 邮编：200120 电话：021-38124100 邮箱：gsresearch@gszq.com
南昌 地址：南昌市红谷滩新区凤凰中大道 1115 号北京银行大厦 邮编：330038 传真：0791-86281485 邮箱：gsresearch@gszq.com	深圳 地址：深圳市福田区福华三路 100 号鼎和大厦 24 楼 邮编：518033 邮箱：gsresearch@gszq.com